
بنام خداوند جان و خرد

دانشگاه شهید بهشتی

دانشکده فیزیک

پایان‌نامه کارشناسی ارشد فیزیک
گرایش فیزیک آماری و سامانه‌های پیچیده

نقش رفتار مقیاسی در بهبود تحلیل و پیش‌بینی پذیری سری‌های زمانی

نگارنده

علی خبازیان زاده هندوآبادی

استاد راهنما

دکتر سید علی حسینی اسفیدواجانی

تابستان ۱۴۰۵

چکیده

سری‌های زمانی مالی، نوعی از سیستم‌های پیچیده، غیرخطی و غیرایستا هستند که پویایی آنها اغلب مقیاس‌بندی، وابستگی‌های بلندمدت، تک‌فرکتالی و چندفرکتالی و درجات مختلفی از پیش‌بینی‌پذیری را نشان می‌دهند. این پایان‌نامه به بررسی نقش رفتار مقیاس‌بندی و پیچیدگی نظری اطلاعات در تحلیل و پیش‌بینی پذیری سری‌های زمانی، با تاکید ویژه بر بازارهای مالی، می‌پردازد. ابتدا، ویژگی‌های اساسی سیستم‌های پیچیده و حقایق اصلی داده‌های مالی با استفاده از قوانین مقیاس‌بندی، روش‌های فرکتالی و چندفرکتالی و معیارهای آماری بررسی می‌شوند. سپس رویکردهای اقتصادسنجی کلاسیک، از جمله $ARMA$، $ARIMA$، $ARCH$ و $GARCH$، در کنار تکنیک‌های مدرن مدل‌سازی توالی مانند TCN، RNN، $LSTM$، GRU، مبدل‌های علی، مبدل‌های باقیمانده و $PatchTST$ بررسی می‌شوند. تحقیقات تجربی از فرآیندهای تصادفی تصنعی کنترل‌شده با شدت نویز و ساختارهای وابستگی مختلف استفاده می‌کند. آنتروپی شنون و آنتروپی بلوک برای تعیین کمیت عدم قطعیت و اطلاعات زمانی موجود در این فرآیندها به کار گرفته می‌شوند. قابلیت‌های پیش‌بینی $ARIMA$، $XGBoost$، شبکه‌های عصبی عمیق و معماری‌های مبتنی بر $Transformer$ از طریق وظایف رگرسیون و طبقه‌بندی ارزیابی می‌شوند. یافته‌ها نشان می‌دهد که افزایش نویز و آنتروپی به تدریج اطلاعات موجود برای پیش‌بینی را کاهش می‌دهد و منجر به خطاهای پیش‌بینی بالاتر و دقت جهت‌دار نزدیک به سطح شانس می‌شود. در مقابل همچنین مشاهده شد که وابستگی‌های زمانی ساختاریافته، اطلاعات قابل بهره‌برداری را ارائه می‌دهند که مدل‌های توالی پیشرفته، به ویژه معماری‌های مبتنی بر مکانیزم توجه، می‌توانند به طور موثر آنها را ثبت کنند. به طور کل می‌توان ادعا کرد که نتایج نشان می‌دهد که معیارهای مقیاس‌بندی و آنتروپی، چارچوب مفیدی برای شناسایی تغییرات در پیچیدگی سری‌های زمانی و تعیین شرایطی که تحت آن پیش‌بینی قابل اعتماد امکان‌پذیر است، ارائه می‌دهند.

واژگان کلیدی: فیزیک، سامانه‌های پیچیده، سری‌های زمانی مالی، آنتروپی اطلاعات، مدل‌سازی توالی‌ها، تک‌فرکتالی، چندفرکتالی، مکانیزم توجه، یادگیری عمیق، فیزیک آماری

فهرست مطالب

چکیده ۱

۱ پیچیدگی چیست؟ ۱

۱.۱ جایگاه علم پیچیدگی در میان رشته‌های دانشگاهی ۲

۲.۱ دامنه‌ی پیچیدگی ۳

۳.۱ معرفت شناسی پیچیدگی ۵

۴.۱ پیچیدگی و نوپدیدی ۶

۲ حقایق سبک‌مند در بازارهای مالی ۸

۱.۲ حقایق تجربی سبک‌مند ۹

۱.۱.۲ توزیع دم کلفت ۱۰

۲.۱.۲ گوسی بودن تجمعی ۱۳

۳.۱.۲ عدم وجود خودهمبستگی‌ها ۱۵

۱.۳.۱.۲ فرضیه بازار کارا ۱۶

۲.۳.۱.۲ مداخله‌ی سرمایه‌گذاران در بازار و بررسی حباب‌ها در بازارهای مالی ۱۷

۴.۱.۲ خوشه بندی نوسانات ۱۸

۵.۱.۲ سایر ویژگی‌های تجربی مهم ۲۴

۲.۲ بررسی وجود حقایق سبک‌مند در بازار نوظهور رمزارزها ۲۵

۱.۲.۲ بازده لگاریتمی ۲۵

۲.۲.۲ توزیع دم کلفت . . . ۲۶
۳.۲.۲ گوسی بودن تجمعی . . . ۲۷
۴.۲.۲ عدم وجود خودهمبستگی‌ها . . . ۲۸
۵.۲.۲ خوشه بندی نوسانات . . . ۳۰

۳ خواص مقیاسی ۳۲
۱.۳ مقدمه‌ای بر تاریخچه‌ی بررسی خواص مقیاسی در تحلیل بازارهای مالی . . . ۳۳
۲.۳ خودهمانندی، فرکتال‌ها و ناوردایی مقیاس . . . ۳۳
۱.۲.۳ فرکتال‌های هندسی و ناوردایی مقیاسی . . . ۳۳
۲.۲.۳ فرکتال‌های تصادفی و ناوردایی مقیاس آماری . . . ۳۵
۳.۲.۳ مقیاس‌بندی یک گام تصادفی ساده . . . ۳۷
۳.۳ فرآیندهای خودوابسته و نمای هرست . . . ۳۸
۱.۳.۳ فرآیندهای خودهمبسته . . . ۳۸
۲.۳.۳ نمای هرست . . . ۳۹
۳.۳.۳ تحلیل آماری بازمقیاس‌شده‌ی محدوده . . . ۴۰
۴.۳ چندفرکتالی و چندمقیاسی . . . ۴۱
۵.۳ فرآیندهای چندفرکتالی . . . ۴۳
۶.۳ مدل‌های چندفرکتالی در امور مالی . . . ۴۴
۱.۶.۳ مدل چندفرکتالی بازده دارایی‌ها . . . ۴۴
۲.۶.۳ مدلسازی سری‌های زمانی مالی با استفاده از ولگشت‌های تصادفی چندفرکتالی . . . ۴۵
۷.۳ روش‌های اندازه‌گیری ویژگی‌های مقیاسی در سری‌های زمانی . . . ۴۶
۱.۷.۳ روش نمای هرست تعمیم‌یافته . . . ۴۶
۱.۱.۷.۳ انتخاب q . . . ۴۸
۲.۱.۷.۳ انتخاب τ . . . ۴۸
۲.۷.۳ نمای هرست تعمیم یافته به عنوان یک معیار اقتصاد کلان . . . ۴۸

۸.۳ بررسی رفتار مقیاسی در بازار نوظهور رمزارزها ۵۱

۴ مدل‌های خطی در تحلیل بازارهای مالی ۵۵

۱.۴ فرآیندهای خودرگرسیو ۵۶

۱.۱.۴ فرآیندهای خودرگرسیونی ۵۶

۲.۱.۴ شرایط ایستایی ۵۶

۳.۱.۴ گشتاورها و ساختار وابستگی ۵۷

۴.۱.۴ روش‌های تخمین ۵۷

۱.۴.۱.۴ حداقل مربعات معمولی ۵۷

۲.۴.۱.۴ تخمین حداکثر درستنمایی ۵۸

۵.۱.۴ انتخاب مدل و تشخیص ۵۸

۱.۵.۱.۴ معیار اطلاعات آکائیک ۵۸

۲.۵.۱.۴ معیار اطلاعات بیزی ۵۹

۶.۱.۴ کاربردها و محدودیت ها ۵۹

۲.۴ خانواده‌ی مدل‌های ARIMA ۶۰

۱.۲.۴ دامنه‌ی انواع مدل‌ها ۶۰

۲.۲.۴ مدل‌های ARMA ۶۰

۳.۲.۴ مدل‌های ARIMA ۶۰

۴.۲.۴ بسط‌های فصلی از خانواده‌ی مدل‌های ARIMA ۶۱

۵.۲.۴ مدل‌های فصلی و اطلاعات برون‌زا ۶۱

۶.۲.۴ کاربردها و محدودیت‌های استفاده در امور مالی ۶۱

۳.۴ خانواده‌ی مدل‌های ARCH ۶۲

۱.۳.۴ مدل‌های ARCH ۶۲

۲.۳.۴ مدل‌های GARCH ۶۳

۳.۳.۴ مدل‌های اثر نامتقارن و اهرمی ۶۳

۱.۳.۳.۴ مدل‌های نمایی GARCH . . . ۶۳
۲.۳.۳.۴ مدل‌های GJR-GARCH/TGARCH . . . ۶۴
۳.۳.۳.۴ مدل‌های نوسان با حافظه بلندمدت (FIGARCH) . . . ۶۴
۴.۳.۴ تخمین و استنتاج . . . ۶۵
۵.۳.۴ مقایسه مدل و تشخیص . . . ۶۵
۴.۴ تحلیل ریسک به کمک مدل‌های رایج در تحلیل بازارهای مالی . . . ۶۶
۱.۴.۴ توزیع مقادیر حدی تعمیم‌یافته . . . ۶۷
۲.۴.۴ نظریه مقدار حدی . . . ۶۷
۳.۴.۴ پیک‌های عبوری از آستانه . . . ۶۸
۴.۴.۴ توزیع تعمیم‌یافته‌ی پارتو . . . ۶۹
۵.۴.۴ تخمین پارامترها . . . ۷۰
۶.۴.۴ ارتباط توزیع تعمیم یافته‌ی پارتو با ارزش در معرض خطر . . . ۷۱
۵.۴ بررسی بازارهای طلا و بیت کوین به کمک مدل‌های خطی . . . ۷۱

۵ مدل‌های یادگیری عمیق در تحلیل بازارهای مالی ۸۰
۱.۵ مدل‌سازی توالی‌ها . . . ۸۱
۱.۱.۵ مدل‌های مارکوف . . . ۸۲
۲.۱.۵ مدل‌های حالت پنهان . . . ۸۲
۳.۱.۵ مدل‌های حالت نهفته توالی . . . ۸۴
۱.۳.۱.۵ مدل‌های فضای حالت . . . ۸۵
۲.۳.۱.۵ مدل‌های پنهان مارکوف . . . ۸۵
۳.۳.۱.۵ مدل‌های حالت نهفته عصبی . . . ۸۶
۲.۵ مدل‌های شبکه عصبی بازگشتی . . . ۸۷
۱.۲.۵ شبکه‌های عصبی بازگشتی: معماری و فرمول‌بندی ریاضی . . . ۸۷
۲.۲.۵ مسئله گرادیان ناپدید شونده و منفجر شونده . . . ۸۸

۳.۵ مدل‌های حافظه کوتاه‌مدت بلندمدت ۸۹
۱.۳.۵ واحد بازگشتی دروازه‌ای ۹۰
۲.۳.۵ کاربردهای مدل‌های مبتنی بر شبکه‌های عصبی بازگشتی در امور مالی ۹۲
۳.۳.۵ مزایا و محدودیت‌های مدل‌های مبتنی بر شبکه‌های عصبی بازگشتی در تحلیل بازارهای مالی ۹۲
۴.۵ مروری بر تاریخچه‌ی پردازش زبان طبیعی قبل از ترنسفورمرها ۹۲
۱.۴.۵ مدل CBOW ۹۴
۲.۴.۵ مدل Skip-gram ۹۴
۵.۵ مدل‌های ترنسفورمر ۹۵
۱.۵.۵ معماری ترنسفورمرها ۹۵
۲.۵.۵ فرمولاسیون ریاضی ۹۶
۳.۵.۵ رمزگذاری موقعیتی ۹۷
۴.۵.۵ لایه‌ی رمزگذار ۹۸
۵.۵.۵ لایه‌ی رمزگشا ۹۹
۶.۵.۵ تطبیق مدل با سری‌های زمانی مالی ۹۹
۷.۵.۵ کاربرد ترنسفورمرها در تحلیل بازارهای مالی ۱۰۰
۸.۵.۵ ملاحظات آموزش و بهینه‌سازی ۱۰۰
۹.۵.۵ مزایا و محدودیت‌ها ۱۰۰
۱۰.۵.۵ مهندسی ویژگی ۱۰۱
۶.۵ مدل TCN ۱۰۱
۱.۶.۵ فرمول بندی ریاضی ۱۰۲
۲.۶.۵ causal convolution ۱۰۲
۳.۶.۵ dilated convolution ۱۰۲
۴.۶.۵ میدان پذیرا ۱۰۳
۵.۶.۵ بلوک باقیمانده ۱۰۳

۶ شبیه‌سازی‌ها و نتایج ۱۰۴
۱.۶ انتخاب مدل‌ها ۱۰۵
۱.۱.۶ مدل Causal Encoder Transformer ۱۰۵
۲.۱.۶ مدل Residual Causal Transformer ۱۰۶
۳.۱.۶ مدل PatchTST ۱۰۶
۲.۶ انتخاب روش‌ها و معیارها ۱۰۷
۱.۲.۶ آنتروپی اطلاعات شنون ۱۰۷
۲.۲.۶ آنتروپی جایگشت ۱۰۸
۳.۲.۶ آنتروپی بلوک ۱۰۸
۳.۶ آزمایش اول ۱۱۱
۴.۶ آزمایش دوم ۱۱۵
۱.۴.۶ مشخصه‌ی آنتروپیک داده‌ی سری زمانی تولید شده با ساختار الفبایی ۱۱۸
۲.۴.۶ بخش اول، مطالعه‌ی رگرسیونی ۱۲۰
۳.۴.۶ بخش دوم، مطالعه‌ی طبقه‌بندی ۱۲۵
۵.۶ آزمایش سوم ۱۳۰
۱.۵.۶ شاخص قدرت نسبی مبتنی بر شمارش ۱۳۱
۲.۵.۶ شاخص‌های تعریفی برای هر بلوک ۱۳۳

۷ نکاتی برای مطالعات بیشتر ۱۳۸
۱.۷ بازتولید حقایق سبکمند بازارهای مالی به کمک مدل‌های توسعه‌یافته در فیزیک ۱۳۸
۲.۷ بررسی همبستگی متقابل در بازارهای مالی به کمک مدل‌های مقیاسی ۱۳۹
۳.۷ مدل‌های هیبرید: ترکیب مدل‌های سنتی تحلیل بازارهای مالی با مدل‌های ماشینی ۱۴۰
۴.۷ مدل‌های زبانی بزرگ در تحلیل بازارهای مالی ۱۴۱
۱. پیوست الف: آزمون‌های آماری رایج در تحلیل بازارهای مالی ۱۴۲

پیوست‌ها ۱۴۲

فهرست تصاویر

۱.۱ مقایسه‌ی قلمروی چهار علم فیزیک، پیچیدگی، زیست شناسی سامانه‌ها و زبان شناسی زیستی و انسان شناسی [۱] . ۳

۲.۱ دامنه‌ی علم پیچیدگی در مقایسه با بخش‌هایی از قلمروی فیزیک [۱] ۴

۳.۱ توصیفی هندسی از جایگاه واقعیت، بخشی از واقعیت و دنیای ویگنر بر حسب پارامترهای تعریف کننده‌ی مربوطه [۱] . ۶

۴.۱ شرایط لازم برای نوپدیدی در حل مسئله‌ی فرما [۱] ۷

۱.۲ عملکرد بازده‌ی سهام دو شرکت اپل و تسلا در یک سال گذشته‌ی میلادی ۱۰

۲.۲ توزیع داده‌های سهام دو شرکت تسلا و اپل در سال گذشته‌ی میلادی و مقایسه با توزیع نرمال برای چک کردن چاقی دم تابع توزیع ۱۱

۳.۲ توزیع تجمعی بازده سهام شرکت اپل در ۵ سال گذشته ۱۴

۴.۲ خودهمبستگی برای بازده روزانه سهام تسلا در یک سال گذشته ۱۶

۵.۲ بازده روزانه مربعی سری زمانی شرکت اپل در بازه زمانی پنج سال گذشته ۱۹

۶.۲ خودهمبستگی برای توابع مختلف بازده روزانه سهام شرکت اپل در بیست سال گذشته ۲۰

۷.۲ برازش قانون توانی برای خودهمبستگی بازده مطلق روزانه‌ی ۳۰ سال گذشته‌ی سهام شرکت اپل ۲۱

۸.۲ خوشه بندی نوسانات و بتای قانون توانی سه سهام گوگل، اپل و فیس‌بوک ۲۲

۹.۲ نمودار رتبه‌بندی خودهمبستگی با بازده مطلق اپل، مایکروسافت و گوگل ۲۴

۱۰.۲ قیمت و بازده لگاریتمی سولانا و لایت کوین در یک سال گذشته ۲۶

۱۱.۲ تست‌های آماری روی بازده لگاریتمی دو رمزارز سولانا و لایت کوین ۲۶

۱۲.۲ بررسی دم تابع توزیع دو رمزارز سولانا و اتریوم ۲۷

۱۳.۲ بررسی گوسی بودن تجمعی توزیع بیت کوین در طول پنج سال گذشته ۲۸

۱۴.۲ بررسی عدم وجود خودهمبستگی‌ها در رمزارز باینس کوین در طول سال گذشته ۲۹
۱۵.۲ بررسی خوشه بندی نوسانات در رمزارز بیت کوین برای پنج سال گذشته ۳۱

۱.۳ نمای هرست تعمیم یافته (مرور ادبیات (بالا) و مستخرج شده) روی شاخص سهام دو کشور در حال توسعه و توسعه یافته‌ی تایلند و ژاپن بین سال‌های ۱۹۹۰ و ۲۰۰۱ . . . . . ۴۹
۲.۳ بررسی $qH(q)$ (مرور ادبیات (بالا) و مستخرج شده) روی شاخص سهام دو کشور در حال توسعه و توسعه یافته‌ی تایلند و ژاپن بین سال‌های ۱۹۹۷ و ۲۰۰۱ . . . . . ۵۰
۳.۳ بررسی تحلیل طیفی نمای هرست (مرور ادبیات (چپ) و مستخرج شده) روی شاخص سهام دو کشور در حال توسعه و توسعه یافته‌ی تایلند و ژاپن بین سال‌های ۱۹۹۷ و ۲۰۰۱ . . . . . ۵۱
۴.۳ نمای هرست تعمیم یافته در بازار رمزارزها بین بیت کوین و لایت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۵ . . . . . ۵۲
۵.۳ بررسی $qH(q)$ در بازار رمزارزها بین بیت کوین و لایت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۵ . . . . . ۵۳
۶.۳ بررسی تحلیل طیفی نمای هرست برای دو رمزارز بیت کوین و لایت کوین ۵۴

۱.۴ بررسی قیمت، بازده و تابع توزیع بازده طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ . . . . . ۷۲
۲.۴ بررسی تابع خودهمبستگی طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ برای ۴۰ تاخیر اول ۷۳
۳.۴ بررسی تابع خودهمبستگی جزئی طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ برای ۴۰ تاخیر اول ۷۴
۴.۴ بررسی پیش‌بینی‌های نوسانات و شبیه‌سازی مونت کارلو روی طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ برای ۳۰ روز آینده ۷۵
۵.۴ پیش‌بینی مدل‌ها خطی و نتایج تاریخی برای بازه‌ی زمانی ماه اول سال ۲۰۲۶ روی طلا و بیت کوین ۷۶
۶.۴ تحلیل توزیع ریسک و ارزش در معرض ریسک برای طلا و بیت کوین ۷۸
۷.۴ تحلیل ریسک به کمک توزیع نظریه ارزش حدی و برازش پارتو تعمیم یافته برای طلا و بیت کوین ۷۹

۱.۵ مکانیزم کارکرد مدل حالت پنهان مارکوف ۸۴
۲.۵ مکانیزم مدل‌های شبکه عصبی بازگشتی ۸۸
۳.۵ مکانیزم مدل‌های حافظه کوتاه‌مدت بلندمدت ۹۰
۴.۵ مکانیزم مدل‌های واحد بازگشتی دروازه‌ای ۹۱
۵.۵ مکانیزم مدل اصلی ترنسفورمر ۹۷

۶.۵ مکانیزم کارکرد مدل پیچشی زمانی ۱۰۳

۱.۶ نمونه‌هایی از سری‌های زمانی تولید شده به کمک معادله‌ی اویلر ۱۱۱

۲.۶ بررسی نسبت نویز به روند به کمک آنتروپی اطلاعات (شنون) در سری‌های زمانی تولید شده ۱۱۲

۳.۶ کاهش پیش‌بینی پذیری مدل‌ها با افزایش نویز در سری‌های زمانی تولید شده ۱۱۳

۴.۶ بررسی معیارهای پیش‌بینی پذیری مدل‌ها با افزایش نویز در سری‌های زمانی تولید شده ۱۱۴

۵.۶ بررسی افزایش آنتروپی اطلاعات و پیش‌بینی پذیری جهت بازار بهنجار شده با افزایش نویز در سری‌های زمانی تولید شده ۱۱۴

۶.۶ نمونه‌ی تولید شده از ده بلوک اول سری زمانی تولید شده ۱۱۶

۷.۶ سری زمانی تولید شده به کمک ساختار الفبایی مدنظر ۱۱۸

۸.۶ آنتروپی بلوک و آنتروپی شرطی برای طول کلمات ۸ و ۱۶ و ۳۰ . . . . . ۱۱۹

۹.۶ آنتروپی بلوک بایاس شده به علت طول کلمات بزرگ ۱۲۰

۱۰.۶ پیش بینی رگرسیونی مدل‌های مورد مطالعه از جهت بازار برای بازده سهام نسبی ۱۲۱

۱۱.۶ سری‌های زمانی بازیابی شده و نتایج پیش بینی‌های بازیابی شده مدل‌های ماشینی ۱۲۲

۱۲.۶ مقایسه‌ی مدل‌های ماشینی با کمک معیارهای DA و $RMSE$ ۱۲۳

۱۳.۶ ماتریس درهم‌ریختگی مدل‌های ماشینی ۱۲۴

۱۴.۶ مقایسه‌ی عملکرد مدل‌ها در پیش بینی بازده نسبی سهام یک روز بعد به کمک مسئله‌ی طبقه بندی ۱۲۵

۱۵.۶ مقایسه‌ی عملکرد مدل‌ها در پیش بینی بازیابی شده‌ی سری زمانی به کمک مسئله‌ی طبقه بندی ۱۲۶

۱۶.۶ ماتریس درهم‌ریختگی نتایج مدل‌های ماشینی در مسئله‌ی طبقه بندی ۱۲۷

۱۷.۶ نتایج معیارهای بررسی فرآیند یادگیری مدل‌های ماشینی در مسئله‌ی طبقه بندی ۱۲۸

۱۸.۶ نتایج مقایسه‌ی میزان اعتمادپذیری نتایج مدل‌های ماشینی در مسئله‌ی طبقه بندی ۱۲۹

۱۹.۶ داده‌ی تصنعی تولیدی جدید برای پارامتر دمای ۲ . . . . . ۱۳۲

۲۰.۶ داده‌ی تصنعی پارامتر دمای ۲ برای ۱۰ بلوک اول ۱۳۲

۲۱.۶ فرکانس انتخاب بلوک‌ها برای داده‌های دماهای مختلف ۱۳۵

۲۲.۶ تخمین گرهای آنتروپی برای داده‌های با دماهای مختلف ۱۳۶

۲۳.۶ نتایج بازیابی شده از فرآیند آموزش مدل‌های ماشینی روی بازده سهام داده‌های تصنعی جدید برای دماهای مختلف . . ۱۳۶

۲۴.۶ نتایج دقت مدل‌ها برای همه‌ی آزمایش‌ها ۱۳۷

۱ آزمون‌های آماری رایج در تحلیل بازارهای مالی ۱۴۳

پیشگفتار

در این رساله سعی داریم بازارهای مالی را از طریق دیدگاه‌های میان‌رشته‌ای علم پیچیدگی، مدل‌سازی آماری، نظریه اطلاعات و یادگیری ماشین بررسی کنیم. در اینجا صحبت با معرفی پیچیدگی و حوزه‌های اصلی آن آغاز می‌شود و پس از آن به بررسی حقایق سبک‌مند که در داده‌های مالی مشاهده می‌شوند، با توجه ویژه به قوانین مقیاس‌بندی، وابستگی بلندمدت و چندفرکتالی پرداخته می‌شود. سپس بحث از مدل‌های سری زمانی خطی کلاسیک، از جمله $ARMA$ و $ARIMA$، به مدل‌های نوسان شرطی مانند $ARCH$ و $GARCH$ می‌رسد. در ادامه، طیف وسیع‌تری از رویکردهای مدل‌سازی توالی، از جمله فرآیندهای مارکوف، مدل‌های پنهان مارکوف، مدل‌های فضای حالت، شبکه‌های کانولوشن زمانی، شبکه‌های عصبی بازگشتی، $LSTM$ و GRU، بررسی می‌شود. مروری مختصر بر پردازش زبان طبیعی و توسعه معماری $Transformer$، پایه مفهومی روش‌های پیش‌بینی مبتنی بر مکانیزم توجه را بیشتر ایجاد می‌کند. با تکیه بر این پیشینه نظری، بخش اصلی تجربی این پایان‌نامه، خانواده متنوعی از مدل‌های پیش‌بینی - از جمله $ARIMA$، $XGBoost$، مدل‌های یادگیری عمیق بازگشتی و کانولوشنی، و معماری‌های مبتنی بر $Transformer$ مانند رمزگذارهای علی، علی باقیمانده و $PatchTST$ - را با استفاده از فرآیندهای تصادفی مصنوعی با طراحی دقیق ارزیابی می‌کند. ساختار و عدم قطعیت این فرآیندها از طریق معیارهای نظریه اطلاعات، به ویژه آنتروپی شانون، آنتروپی بلوک و مقادیر مرتبط با نرخ آنتروپی بررسی می‌شود، در حالی که عملکرد مدل از طریق وظایف رگرسیون و طبقه‌بندی ارزیابی می‌شود. به طور کلی می‌توان گفت این رساله به دنبال ارتباط پیچیدگی آماری و محتوای اطلاعاتی یک سری زمانی با توانایی معماری‌های مختلف یادگیری ماشین برای یادگیری دینامیک اساسی آن است و از این طریق بررسی می‌کند که چگونه افزایش نویز، عدم قطعیت و پیچیدگی ساختاری بر مدل‌سازی توالی مالی و عملکرد پیش‌بینی تأثیر می‌گذارد. با ایجاد روابط مقیاس بالا، آنتروپی اطلاعات کاهش یافته و پیش بینی پذیری افزایش می یابد.

فصل ۱

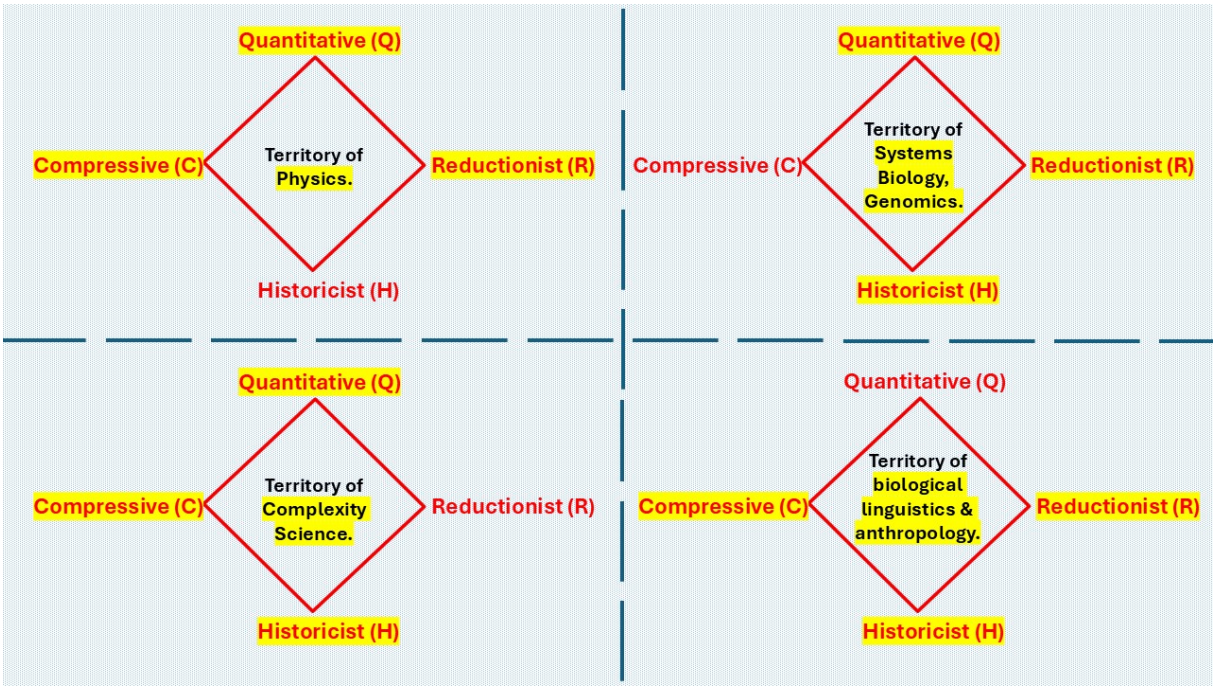
پیچیدگی چیست؟

در این بخش قصد داریم به مسئله‌ی پیچیدگی، از زوایای مختلف نگاه کنیم و سعی کنیم وزن درستی برای جایگاه نظریه‌ی پیچیدگی در میان دیگر نظریات در علم، تخمین بزنیم. شاید در ابتدا توضیح اینکه پیچیدگی چیست ساده نباشد. از لحاظ تاریخی، می‌توان ادعا کرد که سنگ‌بنای این علم توسط مقاله‌ی معروف آقای اندرسون گذاشته شد. جایی که وی برای اولین بار مطرح کرد که دیدگاه‌های تقلیل‌گرایانه در فیزیک برای توصیف فیزیک به تنهایی کافی نیستند و لازم است که هر مسئله، در جایگاه خود و با در نظر گرفتن مقیاس‌های مربوطه، مورد مطالعه قرار گیرد و اینکه شاید لزومی نداشته باشد که برای درک عملیات نهفته در یک مسئله، به اصلاح "پایین‌تر" برویم. دیدگاه رایج تا آن زمان، در ادامه‌ی دیدگاه‌های جریان اصلی در فیزیک قرن بیستمی بود که ادعا می‌کردند برای توصیف هر مسئله در جهان هستی لازم است به دنیایی زیرین‌تر برویم تا درک درستی از مسئله داشته باشیم، که صحبت مذکور در مقاله‌ی "بیشتر متفاوت است" در خلاف جهت جریان اصلی مطرح شد. نویسنده در این مقاله سعی کرده است که با آوردن مثال‌هایی از گوشه و کنار علم، نشان دهد که دیدگاه تقلیل‌گرایانه کار می‌کند اما حدودی دارد. برای مثال فیزیکدانان انرژی‌های بالا و ذرات بنیادی، به این باورند که فیزیک این را نشان داده است که ماده از بلوک‌های سازنده‌ی ساده‌تر تشکیل شده است و به کمک تقلیل‌گرایی می‌توان خیلی از مسائل جهان هستی را توصیف کرد. اما چیزی که اندرسون ادعا می‌کند که آن دیدگاه‌ها گرچه می‌توانند فیزیک را توصیف کنند اما نمی‌توانند ادعایی برای توصیف تمام فیزیک داشته باشند. به عبارت دیگر تمام فیزیک را نمی‌توان به هر روش مفیدی به آن قوانین تقلیل داد. مورد دیگر این است که نوپدیدی مسئله‌ای واقعی در علم است. یعنی در مراحل بالاتری از پیچیدگی، قوانین جدیدی ظاهر می‌شوند که دیگر به کمک آن معادلات بنیادین قابل توصیف یا پیش بینی نیستند. برای مثال، ابررسانایی یا مغناطش فقط در سیستم‌هایی متشکل از ذرات برهمکنش‌کننده‌ی زیاد پدید می‌آیند و این پدیده‌ها به نظریه‌های خاص

خود نیاز دارند. چنین شد که فیزیکدان‌ها تصمیم گرفتند به سراغ قلمروی سامانه‌های پیچیده وارد شوند و به دنبال راهگشایی از مسائل این قلمرو گردند. در نهایت می‌توان اشاره کرد که این زمینه‌ای است که در کنار فیزیک آماری در حال رشد است؛ از الگوریتم‌های محاسباتی برای حل مسائل پیچیده استفاده می‌کند و با نظریه شبکه‌های عصبی همپوشانی دارد. این پیشرفت مهمی است که به ما نوید می‌دهد که این امکان وجود دارد که با دقت فیزیکی لازم بتوانیم به مسائل پیچیده‌ی واقعی در دنیا برخورد داشته باشیم و حتی تئوری‌های جدیدی در نظریه‌ی پیچیدگی مطرح کنیم. [۲، ۳]

۱.۱ جایگاه علم پیچیدگی در میان رشته‌های دانشگاهی

برای اینکه تخمین درستی از جایگاه علم پیچیدگی در میان دیگر علوم داشته باشیم، لازم است که چهارچوبی برای علوم تعریف کنیم و با پاسخ به پرسش‌های مربوطه، سعی در پیدا کردن مکان مناسب آن علم کنیم. از این دست پرسش‌های می‌توان به ۴ پرسش اشاره کرد. می‌توان پرسید که علم مذکور، تا چه حد کمی است. یا به عبارتی دیگر تمایل به محاسبه در آن مانند علوم طبیعی به چه صورت است؟ سوال دیگر این است که علم یاد شده، تا چه حد رابطه‌ی خوبی با فشرده‌سازی دارد. به دیگر سخن نوشتن یک معادله‌ی کوتاه ریاضی که ذات یک پدیده را توصیف کند، چقدر با این علم همخوانی دارد؟ دو پرسش دیگر اما، کیفی‌ترند. جای سوال است که آیای قلمروی علم یاد شده، تاریخ محور است؟ اگر تاریخ محور است، این تمایل تا چه میزان است؟ و در آخر مورد پرسشگری است که آیا تقلیل‌گرا نیز است؟ دیدگاه تقلیل‌گرایی میزان ارتباط اجزای سیستم را با هم می‌سنجد. گویی ما از خود می‌پرسیم که چقدر باید پایین برویم و جزئی‌تر شویم تا به توصیف قبول واقع از سطح مورد نظر برسیم. ممکن است فیزیکدانی ادعا کند که برای فهم گرانش لازم است که گرویتون‌ها را بشناسیم که این بدان معناست که تقلیل‌گرایی از ارکان علم فیزیک است که علم فیزیک بر آن استوار شده است؛ اما این جای سوال است که آیا این تنها رکن سازنده‌ی فیزیک است؟ پاسخ این سوال خیر است. فیزیک غالبا علمی کمی است که در آن دیدگاه‌های تقلیل‌گرایانه حاکم است و با فشرده سازی برخی معادلات ریاضی می‌توان توصیف خوب و قابل قبولی با در نظر گرفتن تخمین‌های مناسبی برای توصیف آنچه که در طبیعت می‌بینیم ارائه کرد. در مقابل اما علم زیست شناسی شاخه‌ی تبارزایی شناسی دارد که این نشان می‌دهد که زیست شناسی علمی تاریخ محور است. بر خلاف فیزیک که این رکن را دارا نبود. شاید بتوان ادعا کرد که نوعی دیگر از تقلیل، تقلیل به معادلات کوتاه فشرده است. اما باید به این نکته‌ی ظریف دقت کرد که علم زیست شناسی تقلیل‌گرا است اما لزوما نمی‌توان با نوشتن یک معادله‌ی کوتاه ریاضی ذات یک پدیده را در آن حیطه توصیف کرد. علم پیچیدگی نیز در مقام مقایسه با علم فیزیک، بر خلاف فیزیک و آنچه از مقالات اندرسون یاد شد، تقلیل‌گرا نیست اما وابسته به تاریخ است. در شکل زیر قلمروی چهار رشته‌ی مهم دانشگاهی با هم به قیاس گذاشته شده است. [۱]

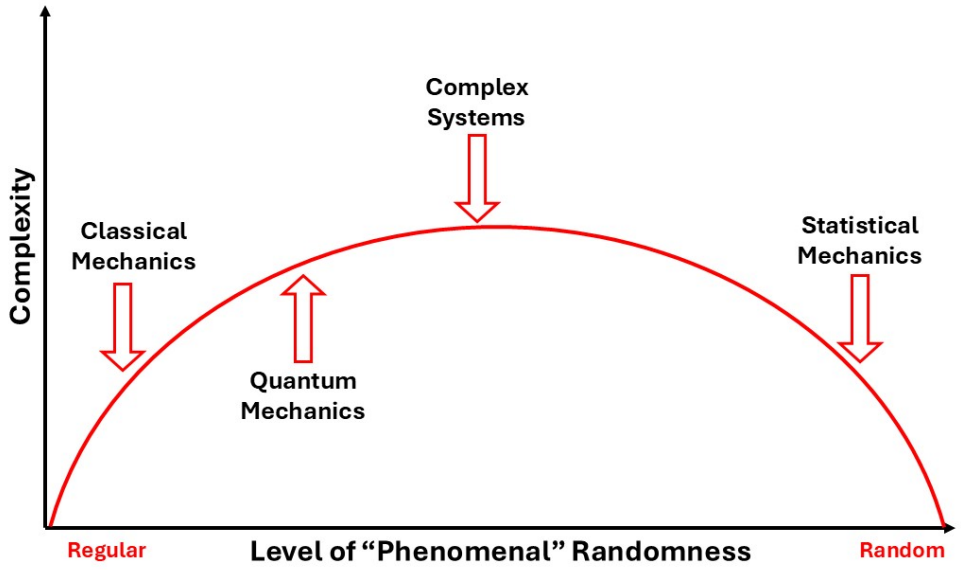


شکل ۱.۱: مقایسه‌ی قلمروی چهار علم فیزیک، پیچیدگی، زیست شناسی سامانه‌ها و زبان شناسی زیستی و انسان شناسی [۱]

۲.۱ دامنه‌ی پیچیدگی

حال که با چهارچوب‌های اصلی سازنده‌ی علم پیچیدگی آشنا شدیم، سوالی که پیش می‌آید این است که دامنه این علم چگونه است و حد و مرزهای این علم تا کجا پیش‌روی می‌کند؟ تا اینجا متوجه شدیم که علم پیچیدگی برای توضیح مسائل به پایین نگاه نمی‌کند؛ به عبارتی در این چهارچوب جدید، پاسخ‌های مسئله در همان مقیاس مورد مطالعه قرار می‌گیرند. ما دیگر تقلیل‌گرا نیستیم و این از مهم‌ترین ویژگی‌های این چهارچوب است مخصوصا وقتی که صحبت از نوپدیدی به میان آید. در این قلمرو، ما با عوامل تطبیقی سر و کار داریم و حتی لازم است که ریاضیات جدیدی را برای ارضای مسائل در این زمینه تولید کنیم که در دامنه‌ی علم پیچیدگی تعریف شوند. با توجه به اینکه چهارچوب‌های این علم، نزدیکی زیادی به حوزه‌ی فیزیک دارند، می‌توان جایگاه خوبی را برای مسائل مربوطه به حوزه نیز تخمین زد. شاید بتوان گفت که مسائل در عالم واقع را می‌شود روی یک خط از منظم به تصادفی گسترده کرده. برای مثال آنچه که ما در مکانیک کلاسیک در فیزیک مورد مطالعه قرار می‌دهیم از پیچیدگی کمی برخوردار است و سیستم‌های تا حد خوبی منظم را می‌توان به آن وسیله مورد مطالعه قرار داد. با در نظر گرفتن این دو پارامتر، نظم و پیچیدگی، شاید بتوان ادعا کرد مسائلی که با کمک ابزارهای توسعه یافته در ادبیات مکانیک کوانتوم مورد مطالعه قرار می‌گیرند نسبت به مکانیک کلاسیک کمی بغرنج‌تر هستند و میزانی از رفتار تصادفی نیز وارد کار می‌شود که به همان قدر از رفتار منظم می‌کاهد. این البته در بالاتر معیار پیچیدگی مسائل نیز موثر است. در آن طرف طیف اما ما می‌توانیم مکانیک آماری و نظریه ترمودینامیک را

قرار دهیم که مسائلی از آن دست قاعده‌ی نظم کمتری دارند و تصادفی بودن یک اصل مهم را در این حیطه تعریف می‌کند. از آن طرف اما با اینکه مسائل عمدتا ریشه‌ی تصادفی دارند، پیچیدگی این مسائل به حد خوبی پایین است و حل کردن مسائل آن حیطه آنچنان بغرنج نیست. حال آنکه نظریه‌ی پیچیدگی درست در وسط این طیف قرار می‌گیرند. جایی که کار کردن با عوامل وفقی این نیاز را مطرح می‌کنند که ما برای حل این مسائل به مکانیک وفقی[1] روی بیاوریم و حتی لازم است که ریاضیاتی جدید برای حل این مسائل تولید شود. شکل زیر تخمین خوبی از صحبت بالا را به نمایش می‌گذارد. [۱]



شکل ۲.۱: دامنه‌ی علم پیچیدگی در مقایسه با بخش‌هایی از قلمروی فیزیک [۱]

اگر بخواهیم بین دانش‌های جدید قرن بیست و یکمی، بین نظریه‌ی پیچیدگی و هوش مصنوعی قیاسی به کار ببریم می‌توان از این نقطه آغاز کرد که رویکرد علم پیچیدگی، رویکردی نزدیک به علم فیزیک است و تلاش دارد که کاری مانند آنچه ما در فیزیک انجام می‌دهیم، انجام دهد. به عبارتی سعی بر این است که با کمک تعداد کمی از معادلات ریاضی، بتوانیم فرآیندهای ضروری را توصیف کنیم که این فرآیندها بتوانند تا حد خوبی نظم‌ها را توصیف کنند اما مشکل اساسی این است که این رویکردها پیش بینی نمی‌کنند. به خلاصه می‌توان گفت مکانیزم‌ها، چه در علم فیزیک و چه در علم پیچیدگی، به درستی هر چه بهتر درک می‌شوند اما پیش بینی به عمل نمی‌آید. این در حالی است که در حوزه هوش مصنوعی، درک آنچه در میان است، در حاله‌ای از ابهام است که آن را فعلا به عنوان یک جعبه سیاه[2] می‌شناسند اما با مجموعه داده‌های بزرگ و به کمک تنظیم کردن میلیاردها پارامتر، سعی می‌شود که پاسخ‌های بسیار پیش بینی کننده‌ای تولید شود و این دو مورد ذکر شده، یعنی درک

[1] Adaptive mechanics
[2] Black Box

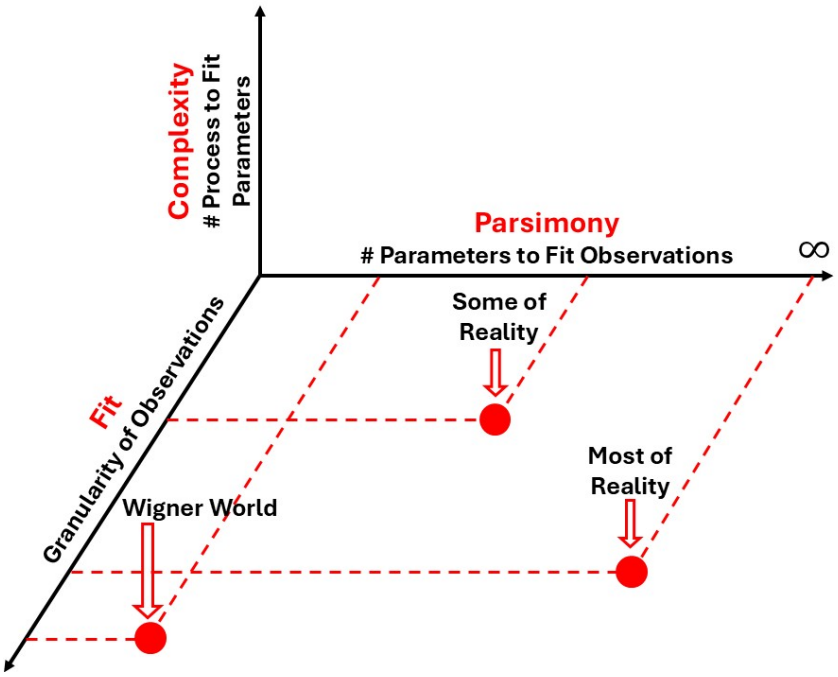
و پیش بینی پذیری، تفاوت اساسی دو حوزه‌ی پیچیدگی و هوش مصنوعی هستند. لازم به ذکر است که یکی از سوالات باز در حد فاصل این دو قلمرو این است که چگونه این دو مسیر را آشتی دهیم؟ آنچه که مسلم است این است که ایده‌ی اصلی پشت تمام یادگیری ماشینی، ایده‌ی یادگیری تقویتی[۱] است که این ایده راجع به مدل خاصی نیست که در نهایت نمونه سازی شود بلکه راجع به نحوه‌ی تنظیم پارامترهاست. این درحالی است که علم پیچیدگی، یک علم فرانظری[۲] است.

۳.۱ معرفت شناسی پیچیدگی

برای صحبت از معرفت شناسی علم پیچیدگی[۳] لازم است که در ابتدا اشاره کنیم که در سال ۱۹۶۰، مقاله‌ی معروفی توسط فیزیکدان بزرگ، آقای ویگنر به نام "کارایی غیر منطقی ریاضیات در علوم طبیعی"[۴] مطرح شد که در آنجا ویگنر اشاره کرد که تخیلات ریاضی می‌توانند الگوهای منظم در طبیعت را پیش بینی کنند. در اصل چیزی که ویگنر را به شدت تحت تاثیر قرار داده بود این مسئله بود که مدل سازی با پارامترهای بسیارکم و فشرده سازی شده، می‌توانند پدیده‌ها را بسیار دقیق پیش بینی کنند. [۴] دنیایی که ویگنر می‌دید، با دو مشخصه‌ی جزئیات لازم برای مشاهده و پارامترهای لازم برای برازش مشاهدات، توصیف می‌شد اما سوال این است که دنیای واقع نسبت به این مشخصه‌ها در کجا قرار می‌گیرد. می‌توان ادعا کرد اکثر آن چیزی که در طبیعت مشاهده می‌کنیم، بر خلاف تصوری که ویگنر داشت نیاز به پارامترهای زیادی برای توصیف دارند. به عبارتی دنیای فیزیکی مورد مشاهده‌ی ما، ترکیبی از نظم و بی‌نظمی است و هستی شناسی[۵] متفاوتی از آنچه ویگنر مطرح می‌کرد دارد. یعنی در برخورد با دامنه‌های پیچیدگی در دنیای واقع، این کارایی غیرمنطقی ریاضیات نیست که کار می‌کند بلکه عدم کارایی غیرمنطقی ریاضیات است که حاکم است. نکته‌ی اصلی درشت دانه بندی[۶] این است که شما اثربخشی پیش بینی را با از دست دادن پارامترها و درجات آزادی، از دست ندهید. بنابرین می‌توان ادعا کرد که حوزه‌های خاصی در قلمروی پیچیدگی وجود دارند که در آنها میانگین گیری عملا مجاز است که یک مثال بسیار خوب از این حوزه مقیاس بندی[۷] است. برای مثال شما در نظریه مقیاس بندی، معادلاتی بدست می‌آورید که به شدت شبیه معادلات مستخرج از فیزیک هستند. در ادامه در فصل‌های پیش رو، بیشتر از این حوزه سخن به میان خواهیم آورد. حال برای آنکه بتوانید بخشی از واقعیت را توصیف کنید، باید در نظر داشته باشید که نیازمند این هستید که درجات موثری از درشت دانه

[1] Reinforcement Learning
[2] Transtheoretical
[3] Epistemology of Complex Science
[4] "The unreasonable effectiveness of mathematics in the natural sciences" - 1960 essay by Eugene Wigner
[5] Ontology
[6] Coarse graining
[7] Scalling

بندی را کشف کنید و محافظات مزوسکوپیک[۱] درستی را تعریف کنید. در شکل زیر توصیف هندسی‌ای از صحبت بالا به نمایش گذاشته شده است. [۱]



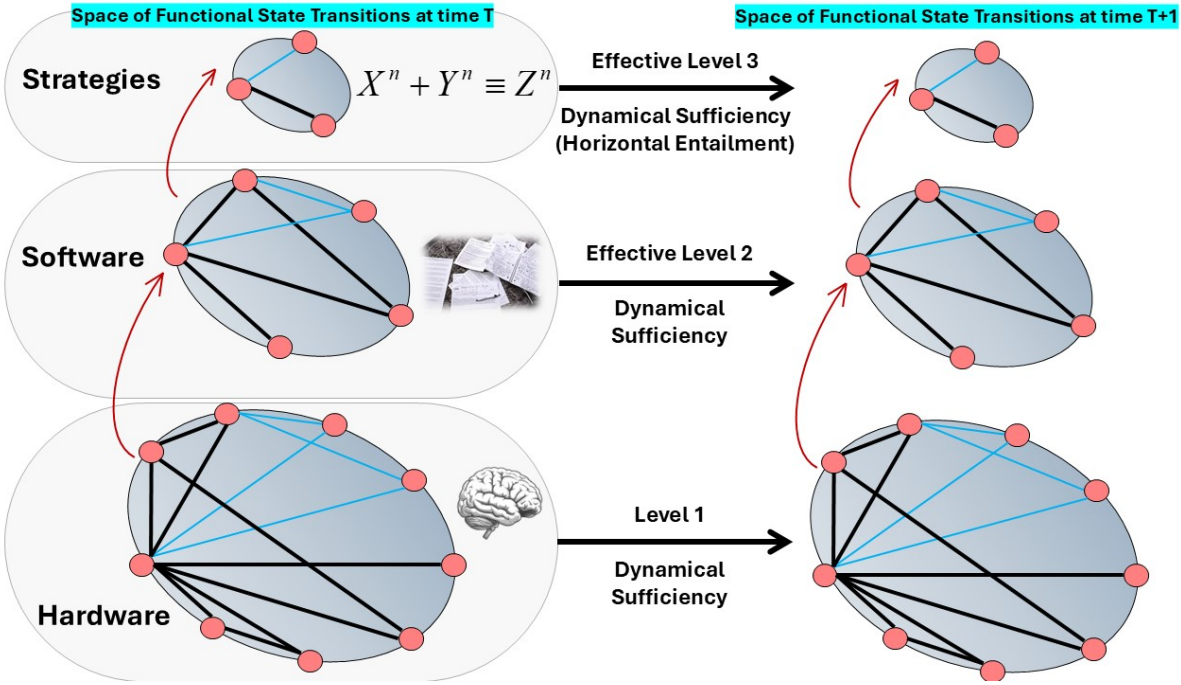
شکل ۳.۱: توصیفی هندسی از جایگاه واقعیت، بخشی از واقعیت و دنیای ویگنر بر حسب پارامترهای تعریف کننده‌ی مربوطه [۱]

۴.۱ پیچیدگی و نوپدیدی

حتما برای شما پیش آمده است که در میانه‌ی راه، ماشینتان خراب شود. اولین فکری که در این هنگام به ذهن شما می‌رسد این است که کاپوت ماشین را بالا دهید و زیر آن را چک کنید. ذهن شما سعی دارد با این انتخاب، شما را به سمت سریع‌ترین راه‌حل مشکل رهنمون سازد. برای اشاره به مثالی دیگر برای باز کردن بحث نوپدیدی[۲]، تقریبا همه‌ی ما با "حدس آخر فرما"[۳] آشنایی داریم. این حدس در سال ۱۶۳۷ برای اولین بار توسط فرما، مطرح شد و این ریاضیدان بزرگ در آنجا ادعا کرده بود که "پانویس کتاب من برای اثبات این حدس، جای کافی ندارد". این حدس تا سال ۱۹۹۵ هنوز اثبات نشده بود تا آنکه اندرو ویلز، بعد از ۳۸۵ سال این حدس را اثبات کرد و قضیه‌ی مدولاریتی[۴] شکل گرفت. بیایید به روند کلی اثبات شدن این حدس به طور کلی بنگریم. در ابتدا ایده‌ی کلی حل این مسئله در ذهن آقای ویلز مطرح شده و سعی در اثبات آن داشته است. سپس آنچه که می‌اندیشیده را به روی کاغذ آورده و روابط شکل گرفته در ذهن خود را به کمک زبان ریاضی بیان

[1] Mesoscopic protection
[2] Emergence
[3] Fermat's Last Theorem
[4] Modularity theorem

کرده است. در اینجا سخت افزار، ذهن اندرو، نرم افزار آنچه که روی کاغذ آورده شده و استراتژی نوع به هم مرتبط کردن مفاهیم ریاضی لازم و کافی برای اثبات مسئله است. ما نیز میدانیم آنچه که با منطق آدمی و منطق ریاضی درست باشد و از لحاظ ریاضی بی ایراد نوشته شده باشد را می‌توان در چارچوب علم ریاضی تعریف کرد. هر مرحله از اثبات مسئله‌ی فرما، لازم و کافی است که "آینده‌ی خود" را پیش‌بینی کند. برای مثال تصور کنید در هر مرحله از این اثبات، اعم از سخت افزار، نرم افزار و استراتژی، ایرادی به کار آقای اندرو وارد باشد. برای رفع آن ایراد، در هر مرحله به دنبال پاسخ سوال میگردیم و دیگر نیازی به نگاه کردن به زیر کاپوت ماشین برای حل مسئله نیست. در اینجا مسئله‌ی نوپدیدی [۱] مطرح است. وقتی که یک پدیده بشدت ظهور می‌کند، دیگر نیازی نیست که زیر کاپوت را نگاه کنید و هر مسئله در همان سطح قابل حل است. اگر نوپدیدی مطرح نبود، همیشه لازم میشد که تا پایین ترین مرحله پیش برویم تا شاید ارزش افزوده ای بیابیم که به کمک آن مسئله را حل کنیم. [۲] نوپدیدی در شرایط خاصی پدید می‌آید که شامل بسته شدن کارکردی [۳]، نظریه‌های موثر [۴] و کفایت دینامیکی [۵] است. در شکل زیر به نوپدیدی در مسئله‌ی اثبات قضیه‌ی فرما آورده شده است.



شکل ۴.۱: شرایط لازم برای نوپدیدی در حل مسئله‌ی فرما [۱]

[1] Emergence 101 - "When there is no need to look under the hood"

[2] There is no additional value in terms of unfolding the game.

[3] Functional Closure

[4] Effective Theories

[5] Dynamical Sufficiency

فصل ۲

حقایق سبک‌مند در بازارهای مالی

مطالعات زیادی در مورد ویژگی‌های آماری سری‌های زمانی مالی انجام شده است که مجموعه‌ای از ویژگی‌های مشترک را در بین ابزارها، بازارها و دوره‌های مختلف زمانی آشکار می‌کند که به عنوان حقایق سبکی یا سبکمند [1] شناخته می‌شوند. این حقایق آماری نهفته در دیتاهای سیستم‌های مالی، معمولاً معیاری برای سنجش اثربخشی مدل‌های مالی هستند که به وضوح نیاز به بازتولید ویژگی‌های داده‌های واقعی دارند تا به طور بالقوه مؤثر واقع شوند. [۱۱] در پاسخ به این سوال که حقایق سبک‌مند در بازارهای مالی چه هستند می‌توان به سخن آقای کاتلر و همکاران اشاره کرد: "همانطور که با بررسی اجمالی اکثر روزنامه‌ها و مجلات مالی آشکار می‌شود، دیدگاه بسیاری از تحلیلگران بازار، رویکردی مبتنی بر رویداد بوده و هست که در آن تلاش می‌شود تا یک حرکت مشخص بازار با ربط دادن آن به یک رویداد یا اطلاعیه اقتصادی یا سیاسی «توضیح» یا توجیه شود". [۲۶]

بنابراین مطالعه این نوع سیستم‌های پیچیده‌ی اقتصادی و مالی می‌تواند چالش برانگیز باشد اما می‌تواند فرصتی برای فهمیدن چگونگی برخی از ویژگی‌های خاص در زمینه سیستم‌های پیچیده باشد و ابزارهای مؤثری برای کمی‌سازی این ویژگی‌ها باشند. [۵، ۶] به دنبال این مسیر، در حدود سال ۱۹۹۰، برخی از فیزیکدانان به بررسی پیچیدگی سیستم‌های مالی علاقه‌مند شدند و یکی از اولین آثار متعلق به این

[1] Stylized Facts

جریان، "پیاده‌روی‌های لوی و انتشار افزایش‌یافته در بورس میلان"[۱] مقاله‌ی آقای روزاریو منتگنا بود که این مقاله‌ی نوآورانه، به هدف نشان دادن نقض قضیه حد مرکزی[۲] در بازار سهام منتشر کرد. [۵، ۷] از این نقطه به بعد، جامعه فیزیک شروع به درک اهمیت فرآیندهای غیر گاوسی[۳] در بازارهای مالی به همراه خواص چندمقیاسی[۴] و بی‌مقیاسی[۵] دیتاهای مالی کرد و بسیاری از محققان بر روی مسائل اقتصادی کار کردند تا انواع رویکردهای این مفهوم جدید، مشتق شده از علوم فیزیکی در حیطه‌ی مذکور را به آزمایش بگذارند. [۵، ۸]

۱.۲ حقایق تجربی سبک‌مند

در این بخش، چهار مورد از مهم‌ترین حقایق تجربی[۶] مشاهده شده در مرور ادبیات [۹، ۱۰]بر روی داده‌ها بازتولید شده است. حال لازم به ذکر است که از آنجا که بیشتر تحلیل‌های زیر بر روی بازده دارایی و کمیت‌های از آن دست انجام می‌شود، تعریف مناسبی از این کمیت‌ها مورد نیاز است. فرض کنید $p(t)$ قیمت، منظور از قیمت در اینجا آخرین قیمت معامله شده روزانه در داده‌های تحلیل شده، یک دارایی مالی در زمان t باشد، بازده (لگاریتمی) در یک دوره زمانی به صورت زیر تعریف می‌شود:

$$r_\tau(t) = \log p(t+\tau) - \log p(t) \tag{۱.۲}$$

این کمیت لگاریتم تغییر نسبی قیمت است و بسته به حرکت $p(t)$ در بازه‌ی زمانی τ می‌تواند مقادیر مثبت یا منفی به خود بگیرد. اگر $\tau = 1$ روز باشد، کمیت $r_1(t)$ به عنوان بازده روزانه شناخته می‌شود.

[1]"Lévy walks and enhanced diffusion in Milan stock exchange"

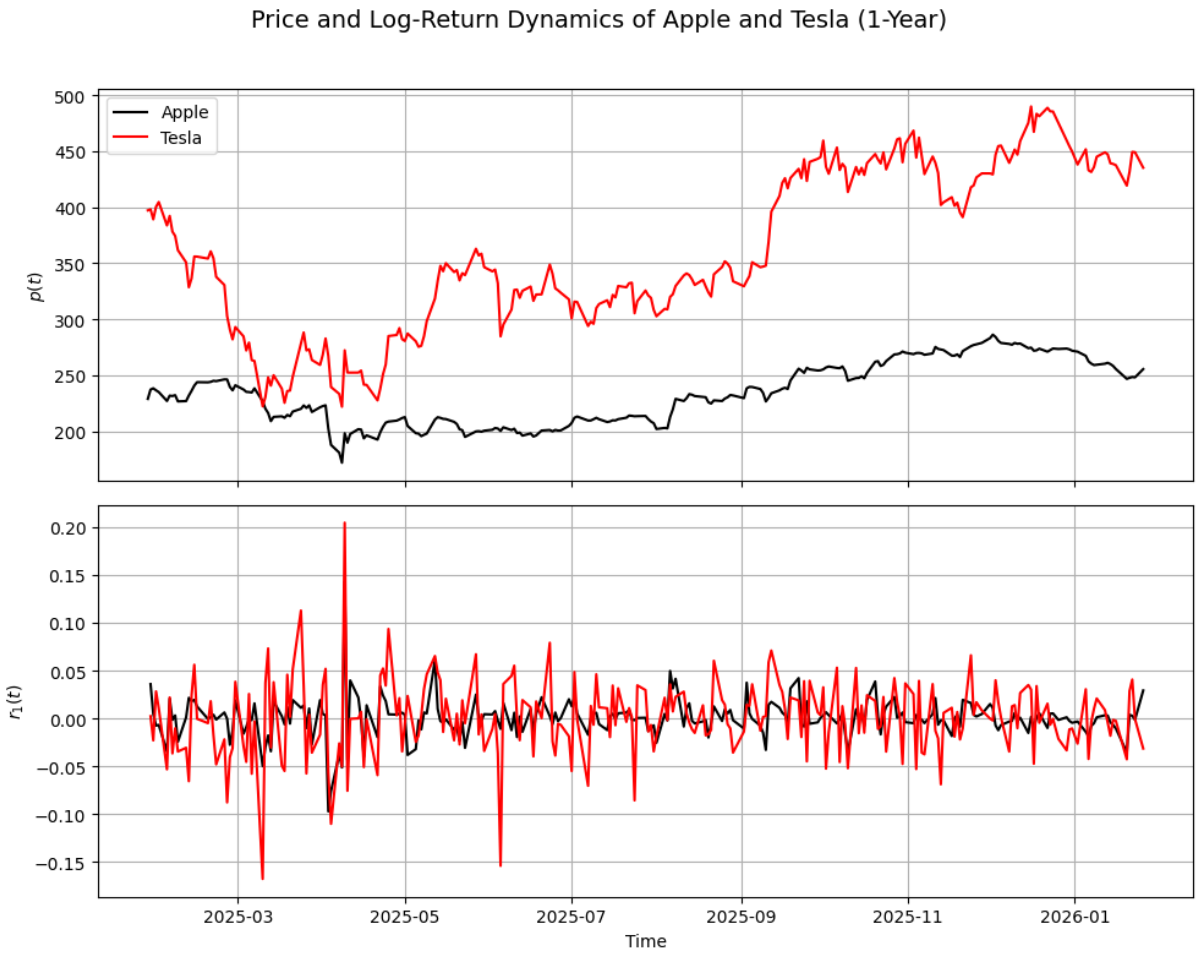
[2]Central limit Theorem

[3]Non-Gaussian processes

[4]Multiscale properties

[5]Scale-free properties

[6]Emperical Stylized Facts



شکل ۱.۲: عملکرد بازده‌ی سهام دو شرکت اپل و تسلا در یک سال گذشته‌ی میلادی

۱.۱.۲ توزیع دم کلفت

از زمان اولین مطالعات روی توزیع تجربی بازده دارایی‌ها، [۱۲] می‌توان گفت که توزیع نرمال برای مدل‌سازی و توصیف داده‌های بازارهای مالی معتبر نیست. نوسانات غیر نرمال[1] در سیستم‌های مالی و دیگر کمیت‌های مرتبط با اقتصاد بشدت رایج هستند و پیاده‌سازی روش‌هایی که می‌توانند به تخمین رفتار توزیع‌ها در ناحیه‌ی تغییرات بزرگ و اتفاقات نادر، که به عنوان "دنباله یا دم" تابع توزیع احتمال شناخته می‌شوند، کمک کنند، بسیار مهم است. [۹، ۱۰، ۱۳] به عنوان مثال، در زمینه مدیریت ریسک، مطالعه این دنباله‌ها می‌تواند درک درست‌تری از بزرگی و احتمال وقوع زیان‌های شدید ارائه دهد و امکان ارزیابی دقیق‌تری از ریسک ارائه داده و منجر به افزایش استحکام و دقت مدل‌ها شود. یکی از این راه‌های اندازه‌گیری انحراف توزیع داده از یک توزیع گاوسی، محاسبه‌ی به اصطلاح کشیدگی[2] بیش از حد است که به کمک فرمول زیر

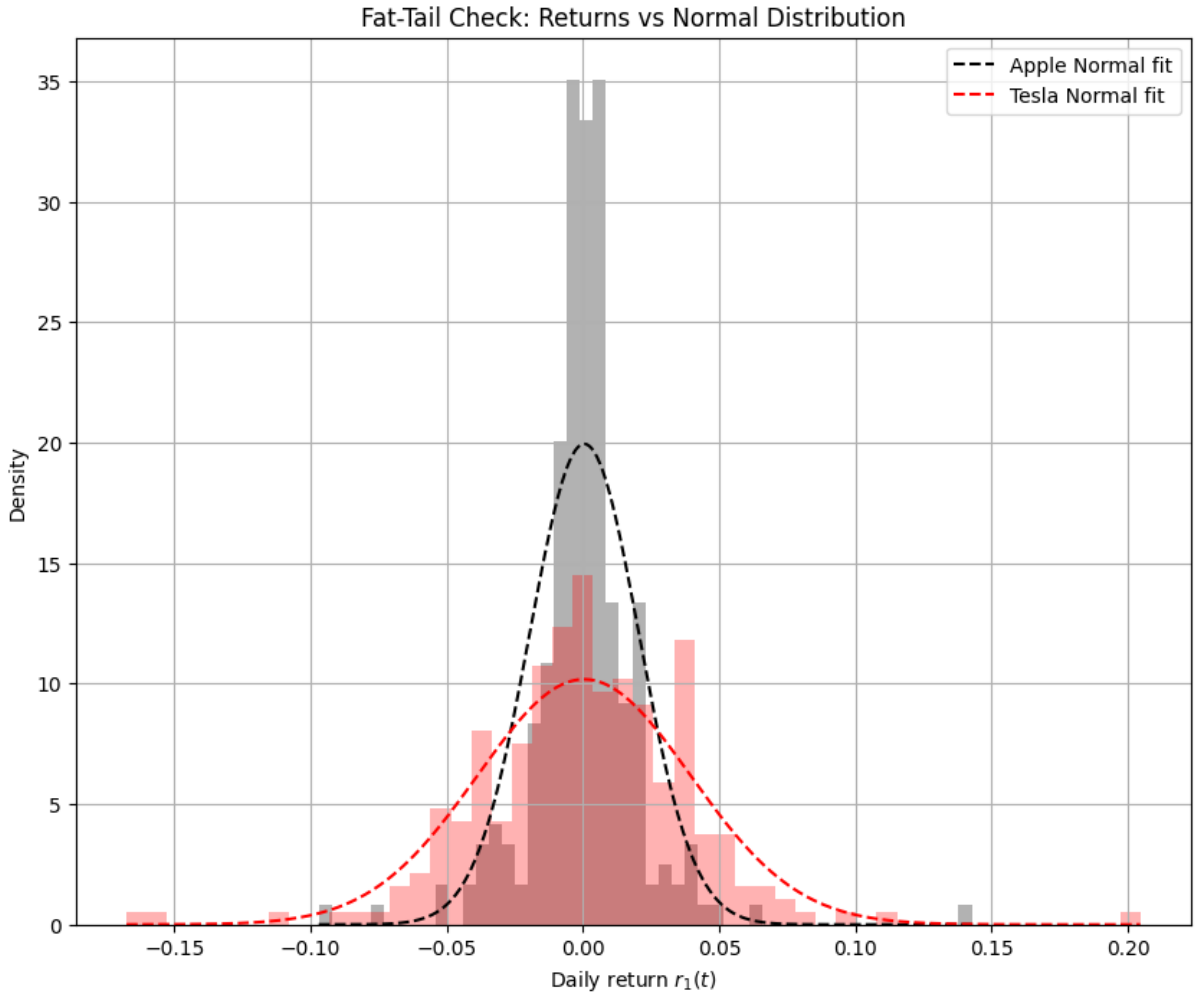
[1] Non-normal fluctuations

[2] excess kurtosis

انجام می‌شود:

$$\gamma = \frac{\left\langle (r_\tau(t) - \langle r_\tau(t) \rangle)^4 \right\rangle}{\sigma_\tau^4} - 3 \tag{۲.۲}$$

برای تابع توزیع نرمال، کشیدگی بیش از حد برابر با صفر داریم. کشیدگی بیش از حد مثبت، دنباله‌های سنگین، دم کلفت یا به اصطلاح "دم چاق"(بازده‌های شدیدتر از حالت عادی) و برای کشیدگی بیش از حد منفی، دنباله‌های سبک(بازده‌های حالت شدید، کمتر از حالت عادی) را خواهیم داشت. برای مثال در شکل زیر، سهام اپل با کشیدگی بیش از حد برابر با 12.286، از سهام تسلا با کشیدگی بیش از حد 4.111 دم چاق‌تر است و هر دو دم‌های چاق، کشیدگی بیشتر از حد مثبت دارند. در بررسی داده‌های مالی، طبق آنچه که از داده‌ها به طور آماری و در طول سالیان استنتاج شده است، عمدتا توزیع دم کلفت داریم.



شکل ۲.۲: توزیع داده‌های سهام دو شرکت تسلا و اپل در سال گذشته‌ی میلادی و مقایسه با توزیع نرمال برای چک کردن چاقی دم تابع توزیع

می‌توان نشان داد که تقریباً هر سری زمانی در مجموعه داده‌ها با کشیدگی به نسبت بزرگی به نسبت به توزیع گاوسی مشخص می‌شود. توزیع‌هایی با این ویژگی، توزیع‌های کشیده نام دارند و در سیستم‌های مالی، احتمال بیشتری برای داشتن بازده‌های شدید، چه مثبت و چه منفی، وجود دارد. لازم به ذکر است که نقض قضیه‌ی حد مرکزی(CLT)، یکی از دلایلی است در این سیستم‌ها توزیع‌های تجربی از توزیع گاوسی منحرف می‌شوند است. [۷، ۱۴]

این نوع فرآیندها در سیستم‌های پیچیده‌ی مالی، فرضیات CLT را برآورده نمی‌کنند: دلیل اول این مهم این است که نمی‌توان فرض کرد که داده‌ها، مجموع ساده‌ای از متغیرها هستند چرا که فرآیندهای ما، فرآیندهای صرفا افزایشی نیستند. در ادامه به عنوان دلیل دوم می‌توان اشاره کرد که متغیرها در سیستم‌های پیچیده عمدتا با هم همبستگی دارند و این امر مستقل در نظر گرفتن متغیرها را که از شروط قضیه حد مرکزی است، غیرممکن می‌سازد. همچنین تضمینی نیست که واریانس فرآیندها محدود باشد و به عنوان مورد آخر باید اشاره کرد متغیرها اغلب به طور یکسانی توزیع نشده‌اند. [۹-۱۱، ۱۴، ۱۵].

به جهت دستیابی به دیدگاهی کمی‌تر درباره‌ی دنباله‌های این توزیع‌ها، توزیع تجمعی مکمل[1] که به صورت زیر تعریف می‌شود، مورد مطالعه قرار می‌گیرد:

$$P_{>}(s;\tau) = \int_{s}^{+\infty} p\left(r_\tau\right) dr_\tau \tag{۳.۲}$$

که در مرور ادبیات، در منابع مختلف [۱۰، ۱۶، ۱۷] نشان داده شده است که می‌توان فرض کرد کمیت یاد شده به طور مجانبی از قانون توانی[2] پیروی می‌کند:

$$P\left(r_\tau > x\right) = P_{>}(x;\tau) \sim x^{-\alpha} \tag{۴.۲}$$

این بدان معناست که با کمی کردن پارامتر α می‌توان به دید مهمی در ارتباط با آمار مقادیر حدی دست یافت. به عنوان مثال مبتوان گفت که اگر تابع توزیع تجمعی یک فرآیند معادله بالا را برآورده کند، نتیجه می‌شود که فقط برای $n < \alpha$ گشتاورهای اول محدود هستند. همچنین تأکید بر این نکته مهم است که توزیع بازده‌ها به مقیاس زمانی τ بستگی دارد و در توضیحات بخش بعد، جزئیات بیشتری در این مورد ارائه خواهد شد.

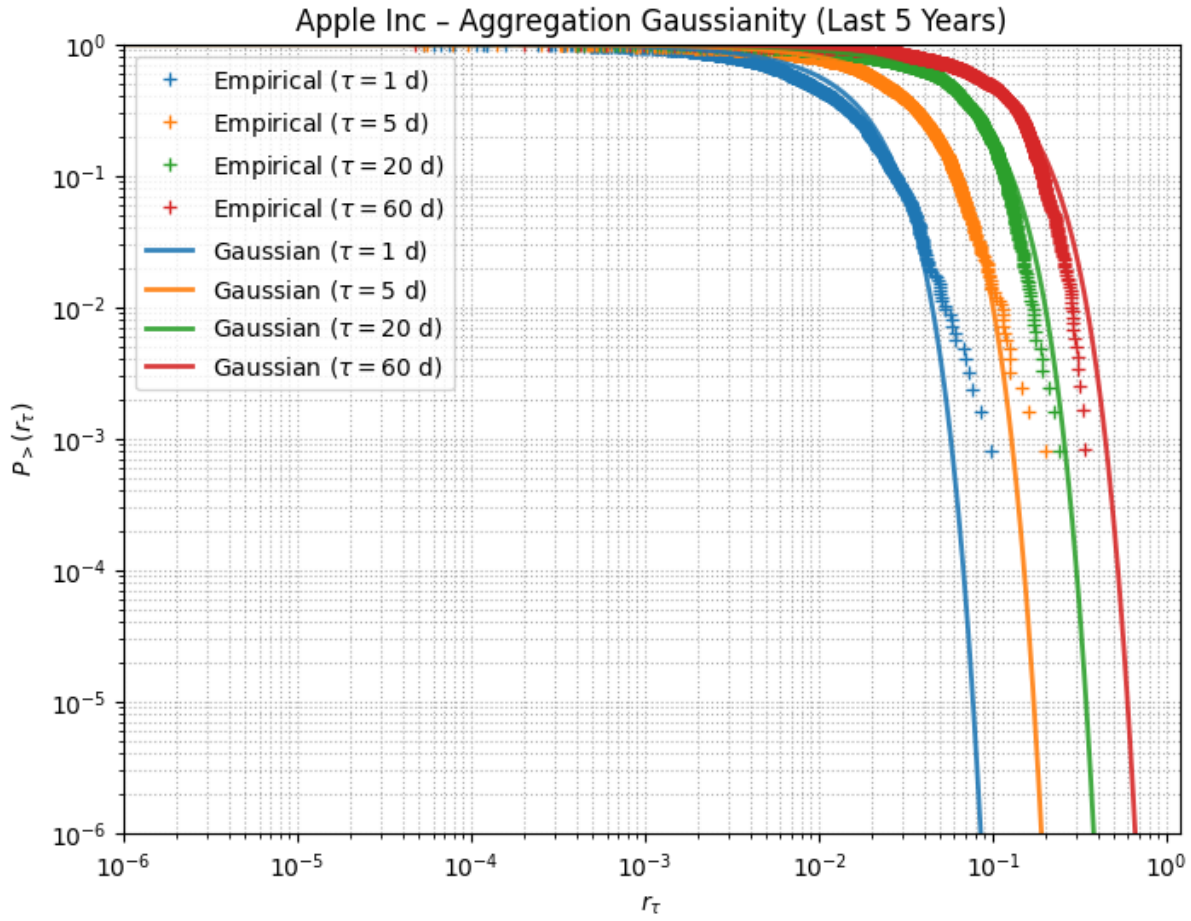
[1] Complementary Cumulative Distribution Function (CCDF)

[2] Power Law

۲.۱.۲ گوسی بودن تجمعی

مطالعه توزیع بازده سهام‌های شرکت‌های مالی می‌تواند دید مهمی برای در نظر گرفتن اتفاقات حدی به روشی مؤثر ارائه دهد. از دیرباز و عمدتا در مرور ادبیات، تمرکز اصلی بر بازده‌های روزانه بوده است، اما به طور گسترده شناخته شده است که مقیاس زمانی τکه بازده‌ها در آن محاسبه می‌شوند، بر خواص توزیع داده‌های آنها تأثیر می‌گذارد. مشاهده شده است که وقتی τ افزایش می‌یابد، خاصیت دم سنگین توزیع ضعیف می‌شود و به شکل گاوسی نزدیک می‌شود. در واقع این حقیقت آماری داده‌های مالی که به صورت سبکمند مشخص شده است، گاوسی بودن تجمعی[1] نامیده می‌شود و به نوعی منجر به بازیابی اعتبار قضیه حد مرکزی برای مقیاس‌های زمانی بزرگ می‌شود. علاوه بر این، وابستگی قابل توجه معادله‌ی (۳.۲) به τ به این معنی است که فرآیند زیربنایی قیمت‌ها برای مقیاس‌های زمانی کوچک بی‌اهمیت نیست، زیرا اثرات خاصی مانند دم‌های پهن وجود دارد که با افزایش τ کمتر مشهود می‌شوند. در شکل زیر می‌توان نمونه‌ی روشنی از این گرایش را مشاهده کرد. بنا به آنچه که اشاره شد، بدیهی است که با افزایش مقیاس زمانی τ که بازده‌ها در آن محاسبه می‌شوند، توزیع‌ها به یک توزیع گاوسی با میانگین و واریانس محاسبه شده بر اساس بازده‌های تجربی نزدیک‌تر خواهند شد. [۵، ۹، ۱۰، ۱۴، ۱۸، ۱۹].

[1] Aggregational Gaussianity (AG)



شکل ۳.۲: توزیع تجمعی بازده سهام شرکت اپل در ۵ سال گذشته

این نمودار، پدیده‌ی شناخته‌شده‌ی گاوسی بودن تجمعی در بازارهای مالی را نشان می‌دهد. همانطور که مشاهده می‌شود، برای کوتاه‌ترین افق تجمعی، ($\tau = 1$) بازده‌های روزانه، تابع توزیع تجمعی مکمل تجربی به شدت از معیار گاوسی منحرف می‌شود. در این رژیم، توزیع، دنباله‌های دم کلفت قابل توجهی را از خود نشان می‌دهد، با کاهشی که به طور قابل توجهی از گاوسی کندتر شده است و اغلب با رفتاری شبیه به قانون توانی در مناطق حدی سازگاری دارد. با افزایش افق تجمعی τ، منحنی‌های تجربی به تدریج به سمت راست تغییر می‌کنند که این نشانگر واریانس بزرگتر بازده‌های تجمعی است و دنباله‌های آنها به طور فزاینده‌ای تندتر می‌شوند. این تغییر در انحنا نشان دهنده از دست دادن تدریجی رویدادهای حدی نسبت به مرکز توزیع است. در نتیجه، توزیع‌های تجربی به معیار گاوسی نزدیک‌تر می‌شوند و این همگرایی به سمت نرمال بودن است که دقیقا توسط قضیه حد مرکزی پیش‌بینی شده است. خود خط مرجع گاوسی به طور سیستماتیک احتمال رویدادهای شدید را در مقادیر کوچک τ کمتر از مقدار واقعی تخمین می‌زند، اما دقت آن با افزایش τ بهبود می‌یابد و در نهایت تقریب معقولی از توزیع بازده تجمعی در مقیاس‌های زمانی طولانی‌تر ارائه می‌دهد. همچنین لازم به ذکر است که در مرور ادبیات کارهای خانم دکتر دی‌متئو مشاهده شد که بهترین انتخاب τ برای داشتن چهارچوب گوسی مناسب روی دیتاهای روزانه، چهارچوب نوزده روزه‌ی بازده‌های روزانه

است که همانطور که از شکل بالا پیداست، نزدیک‌ترین تخمین گوسی نیز با آنچه در مرور ادبیات مشاهده شد، تطابق دارد.

۳.۱.۲ عدم وجود خودهمبستگی‌ها

در مطالعه داده‌های بازارهای مالی، بررسی وجود همبستگی بین یک سری زمانی مشخص و یک نمونه از کپی تأخیری آن، امری اساسی است. به این ترتیب می‌توان تشخیص داد که آیا سیستم حافظه دارد یا خیر و اینکه آیا روابط سیستماتیکی، مانند روندها، بین مشاهدات ما از گذشته‌ی سهم و آینده‌ی آن وجود دارد یا خیر. معمولاً معیاری که برای کمّی‌سازی این ویژگی استفاده می‌شود، ضریب همبستگی پیرسون[۱] است که به این صورت تعریف می‌شود:

$$\begin{aligned} C_\tau(\Delta t) &= \operatorname{corr}\left(r_\tau(t+\Delta t), r_\tau(t)\right) = \\ &= \rho\left(r_\tau(t+\Delta t), r_\tau(t)\right) = \\ &= \frac{\operatorname{cov}\left(r_\tau(t+\Delta t), r_\tau(t)\right)}{\sigma_{r_\tau(t+\Delta t)}\sigma_{r_\tau(t)}} \end{aligned} \tag{۵.۲}$$

که روی داده‌های دنیای واقعی به ضریب همبستگی نمونه تبدیل می‌شود:

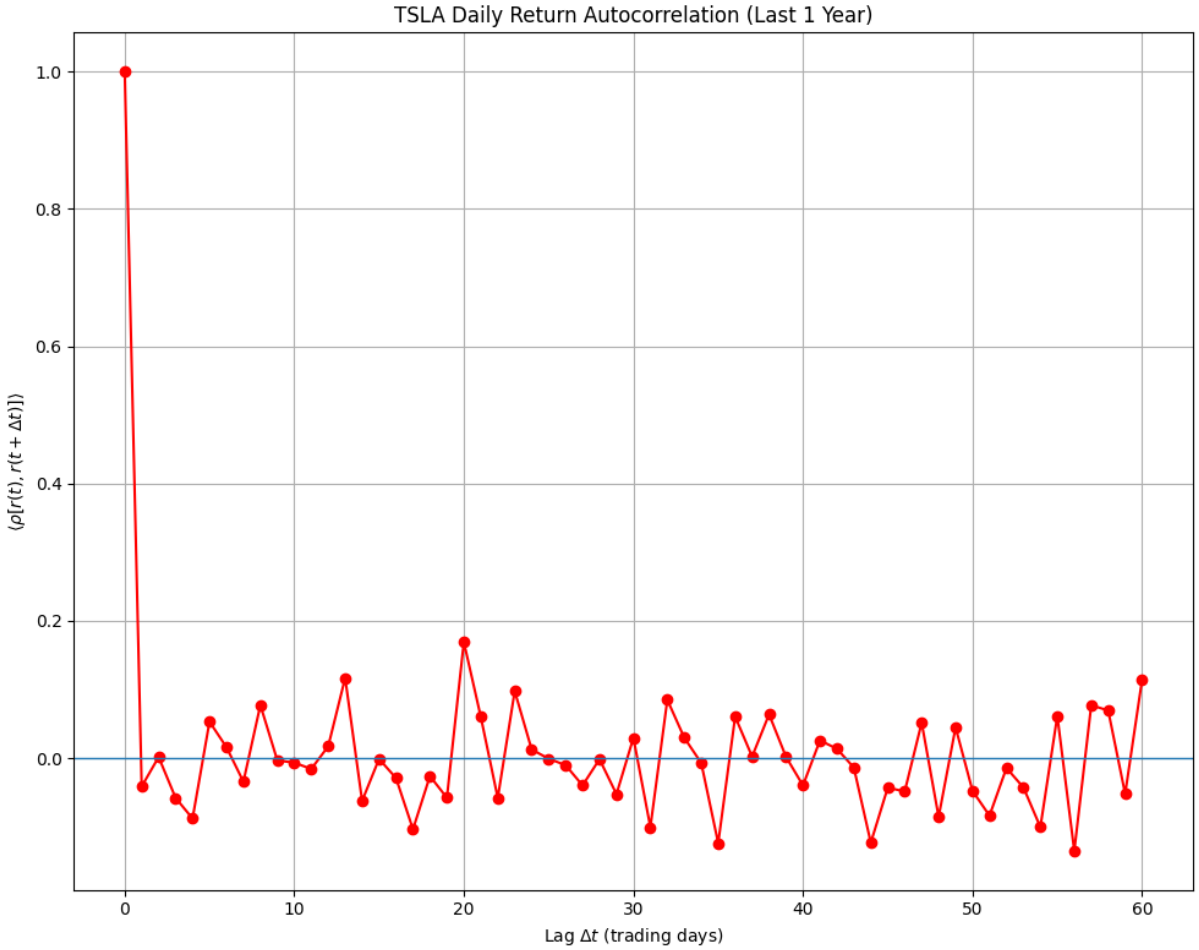
$$\begin{aligned} &\rho\left(r_\tau(t+\Delta t), r_\tau(t)\right) = \\ &= \frac{1}{N-1}\sum_{i=1}^{T-\Delta t}\left(\frac{r_\tau(t+\Delta t) - \langle r_\tau(t+\Delta t)\rangle}{\sigma_{r_\tau(t+\Delta t)}}\right)\left(\frac{r_\tau(t) - \langle r_\tau(t)\rangle}{\sigma_{r_\tau(t)}}\right) \end{aligned} \tag{۶.۲}$$

که در آن میانگین و انحراف معیار نیز بر روی داده‌ها محاسبه می‌شوند. این کمیت، همبستگی خطی بین دو متغیر را اندازه‌گیری می‌کند که در این مورد $r_\tau(t+\Delta t)$ و $r_\tau(t)$ هستند و کوواریانس نرمال شده آنها را نشان میدهد. خروجی این فرمول مقادیری را در بازه [۱،۱-] در نظر میگیرد که در آن ۰ به معنای عدم وجود همبستگی، ۱+ به معنای همبستگی خطی مثبت و ۱- به معنای همبستگی خطی منفی است [۲۰، ۲۱]. در مورد داده‌های مالی، میدانیم که بازده‌ها هیچ همبستگی معناداری ندارند. [۹، ۱۰، ۲۲] دلیل این مهم، این است که اگر همبستگی‌های خطی بین تغییرات قیمت‌ها وجود داشته باشد، می‌توان از آنها به سادگی برای تدوین استراتژی‌های آربیتراژ[۲] استفاده کرد که بلافاصله آن همبستگی‌ها را کاهش می‌دهد [۱۰]. بنابراین، سومین واقعیت آماری مطرح شده، عدم وجود خودهمبستگی بازده‌ها است و

[1] The Pearson correlation coefficient

[2] Arbitrage Strategies

همچنین به عنوان گواهی بر اعتبار فرضیه بازار کارآمد[1] شناخته می‌شود [۱۰، ۲۳]. در واقع، این فرضیه بیان می‌کند که تقریباً غیرممکن است که به طور مداوم از بازار بهتر عمل کرد، زیرا تمام اطلاعات یا بخشی از اطلاعات مربوط به یک اوراق بهادار به سرعت در قیمت معامله شده‌ی آن منعکس می‌شود [۲۴].



شکل ۴.۲: خودهمبستگی برای بازده روزانه سهام تسلا در یک سال گذشته

از نمودار بالا مشخص است که خودهمبستگی در بازده روزانه‌ی سهام شرکت تسلا، بلافاصله به صفر می‌رسد و برای هر تأخیر زمانی Δt که برای محاسبات به کار گرفته شده است، حول این مقدار نوسان می‌کند.

۱.۳.۱.۲ فرضیه بازار کارا

فرضیه‌ی بازار کارا برای اولین بار توسط پدر علم مالی مدرن یعنی آقای پروفسور یوجین فاما مطرح شد. این فرضیه ادعا می‌کند که بازارهای مالی به طور پیوسته بروز کردن اطلاعات هستند. این فرضیه منجر به این ادعا می‌شود که بازده‌های آینده‌ی سهام در بازه‌های کوتاه مدت قابل

[1] Efficient Market Hypothesis (EMH)

پیش بینی نیستند و اگر چنین نباشد، فرصت آربیتراژی پیش می‌آید که در پی استفاده از آن فرصت‌ها، اطلاعات جدید همچنان به بازار تزریق شده و بازار قیمت خود را بروز می‌کند و به سبب استفاده از این ظرفیت آربیتراژ، برای قیمت بروز شده، همچنان این فرضیه را کارا می‌کند. همچنین این فرضیه ادعا دارد که حباب‌های قیمتی از بین میروند. دیدگاه‌های دیگری در تکمیل این فرضیه مانند دیدگاه‌های روان‌شناختی بازار توسط محققین بنامی مانند پروفسور شیلر مطرح شده است که نشان می‌دهند تمایل‌های روانشناختی انسان‌ها در تصمیم‌گیری‌ها باعث می‌شوند که در نهایت بازارها به طور موثری کارا نباشند و لزوما قیمت‌گذاری‌ها منطقی نباشند. دیدگاه‌هایی از این دست فرصت‌هایی را برآمده از داده‌های مرتبط به احساسات سرمایه‌گذاران و رفتار غیرمنطقی آنها را در برخورد با بازار سهام نشان میدهند. این نظریات ذیل نظریه مالی رفتاری مورد مطالعه قرار می‌گیرند. این دو محقق بزرگ بازارهای مالی به همراه یکی دیگر از همکارانشان به خاطر بررسی فرضیه بازار کارا در سال ۲۰۱۳ میلادی موفق به کسب جایزه‌ی نوبل در اقتصاد شدند.

۲.۳.۱.۲ مداخله‌ی سرمایه‌گذاران در بازار و بررسی حباب‌ها در بازارهای مالی

در این بخش از مرور تاریخچه‌ی ادبیات در حوزه‌ی فیزیک اقتصاد، به بررسی دیدگاه‌های موجود در اثر حضور مداخله‌گران، سرمایه گذاران در بازارهای مالی و نحوه‌ی اثر عملکردهای آنان در این زمینه اشاراتی داریم. [۵۷، ۵۸] طبق آنچه در بالاتر یاد شد، دو دیدگاه رایج در بررسی بازار کارا، در اثر مداخله‌گران در بازارمالی نیز مفید فایده هستند. ایده‌ی اصلی پشت فرضیه‌ی بازارکارا در اینجا این است که از آنجا که بازارها همواره در حال منعکس کردن اطلاعات موجود در قیمت‌ها هستند، پس مداخله‌گران و سرمایه‌گذاران در می‌توانند در شکل‌گیری این حباب‌ها و بعدتر در سقوط‌های بازار موثر باشند. دیدگاه دیگر که دیدگاه مالی رفتاری بود تاکید دارد که رفتار غیرمنطقی سرمایه‌گذاران می‌توانند باعث شکل‌گیری حباب شوند. همچینن خود سقوط‌ها در این نظریه بسته به نحوه‌ی رفتار جمعی سرمایه‌گذاران بررسی می‌شوند. بدین طریق که اگر هر ریزشی را نوعی از سقوط میشناسند و معتقدند اگر انسان‌ها به این خرده شکست‌ها بیش از حد واکنش نشان دهند، به سقوط بازار منجر می‌شوند و اگر این خرده شکست‌ها کمتر از حد لازم توجه بگیرند و با واکنشی نرم‌تر توسط سرمایه‌گذاران مواجه شوند، پس یک شکست موقتی نرم اتفاق میوفتد و بازار بعد یک دوره‌ی حرکت محدود، دوباره به قیمت تعادلی خود که می‌تواند بالاتر از قیمت شکست یا پایین‌تر باشد برگردد. همچنین تئورسین‌هایی مانند آقای دکتر بلنچارد نظریاتی دارند که اتفاقا حباب‌ها می‌توانند منطقی باشند و سرمایه‌گذاران "دانسته و آگاهانه" در شکل‌گیری این حباب‌ها تاثیر بگذارند. در نهایت دیدگاه‌های تئورسین‌های سیستم پیچیده مانند پروسفور سورنت، توماس لاکس و پروفسور فارمر مطرح می‌شود که اذعان دارند که این حباب‌ها حاصل پدیداریافتگی اندرکنش‌های عوامل متفاوت سازنده‌ی این بازارها هستند. بطور کلی نیز حباب‌های بازار مالی را می‌توان در دو دسته جای داد: دسته‌ی اول از نوع حباب‌های انتظارات عقلایی که خود شامل دو دسته است. دسته‌ی اول که در آن اطلاعات متقارن توزیع شده و دسته‌ی دوم که اطلاعات نامتقارنند. در دسته‌ی اول حباب با انتظارات عقلایی سازگار است؛

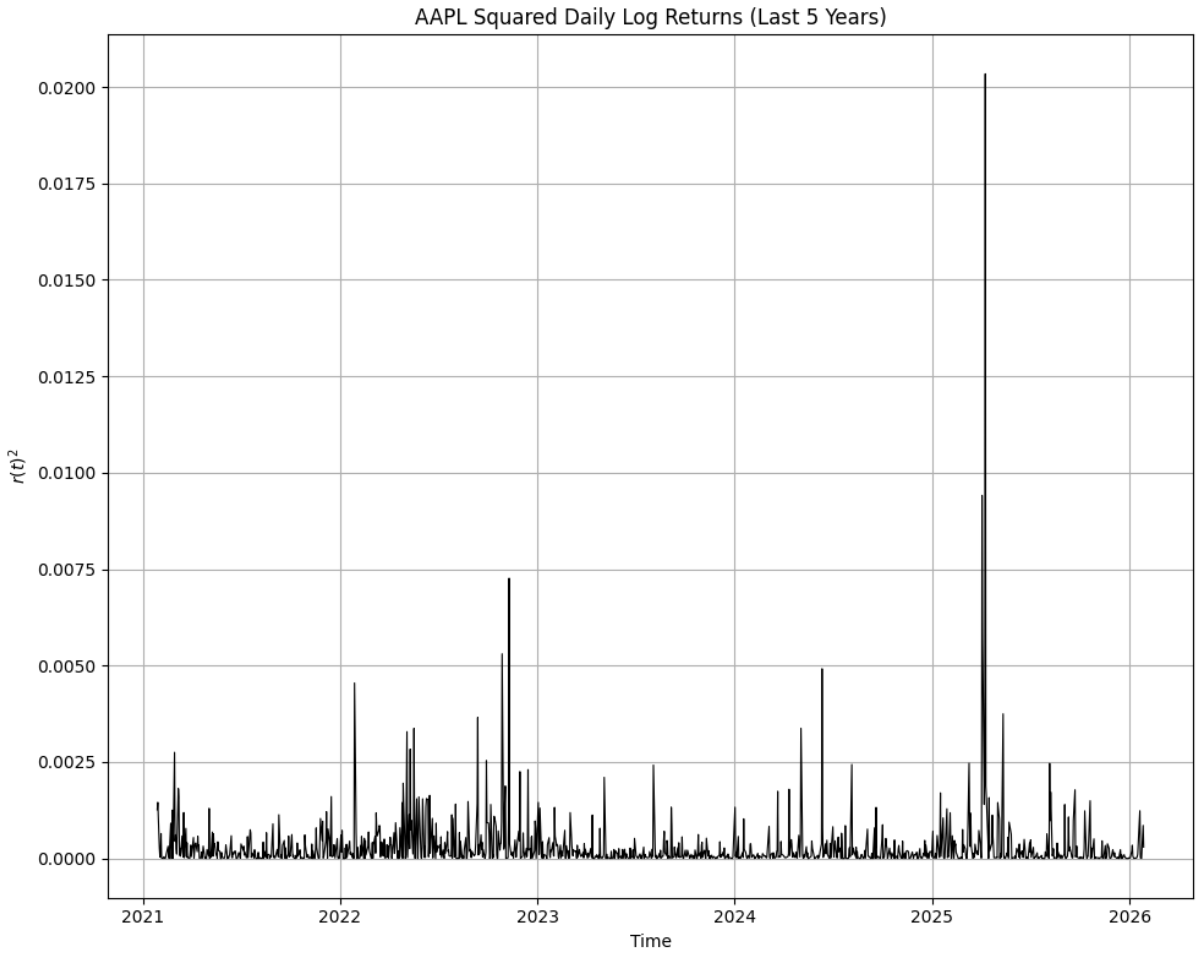
سرمایه‌گذاران آگاهانه بر آن سوار می‌شوند زیرا انتظار سودهای آینده را دارند و دسته‌ی دوم که ادعا می‌کنند سرمایه‌گذاران اطلاعات متفاوتی دارند؛ عدم قطعیت مرتبه بالاتر باعث می‌شود حباب‌ها ادامه پیدا کنند. در نوع دوم اما حباب‌ها از نوع بازار ناکارآمدند. سه دسته دیدگاه در اینجا مطرح است: دسته‌ی اول که دیدگاه‌های متفاوت نام دارد ادعا می‌کند که سرمایه‌گذاران در مورد ارزش بنیادی اختلاف نظر دارند؛ اختلاف نظر و محدودیت‌های فروش استقراضی، قیمت‌ها را افزایش می‌دهد. دسته‌ی مالی رفتاری که محدودیت‌های آربیتراژ و سوگیری‌های روانشناختی مانع از اصلاح قیمت‌ها به سمت بازار کارا می‌شوند و باعث می‌شوند که حباب‌ها پدید آیند و دسته‌ی آخر که در ذیل سیستم‌های پیچیده مطرح می‌شود و میگویند که بازخورد مثبت، تقلید و رفتار گروهی در میان عواملِ در تعامل، حباب‌های درون‌زا را ایجاد می‌کنند.

۴.۱.۲ خوشه بندی نوسانات

با مشاهده عدم وجود خودهمبستگی برای بازده‌ها، می‌توان استدلال کرد که توابع غیرخطی این بازده‌ها نیز از همین ویژگی پیروی می‌کنند و بنابراین افزایش قیمت‌ها کاملا مستقل است [۱۰]. با این حال، اگر مقدار مطلق یا مربع بازده‌ها را محاسبه کنیم، آنها یک خودهمبستگی بلندمدت مثبت بالاتر از صفر را نشان می‌دهند که به آرامی به صفر میل می‌کند [۹، ۱۰]. این ویژگی آماری به طور کلی به عنوان خوشه‌بندی نوسانات شناخته می‌شود و ابتدا به عنوان تمایل بازارهای مالی به تجربه دوره‌های نوسانات بالا و به دنبال آن دوره‌های طولانی نوسانات پایین توصیف شد [۱۰]. این نشان می‌دهد که حرکات بزرگ قیمت‌ها به جای اینکه به طور تصادفی در طول زمان توزیع شوند، تمایل به رخ دادن در خوشه‌ها دارند و همراه با دنباله‌های سنگین، که در بخش "توزیع دم کلفت" در همین فصل توضیح داده شد، شواهد بیشتری وجود دارد که قیمت‌ها را نمی‌توان به سادگی به عنوان گام‌های تصادفی[1] مدل‌سازی کرد [۱۲]. به عنوان مثال، مربع بازده روزانه شرکت اپل رسم شده است و بدیهی است که بازده‌های بزرگ اغلب بخشی از یک خوشه با مشخصه‌ی نوسانات بالا هستند در حالی که مناطق تقریبا مسطح متعلق به گروه‌هایی با تغییرات قیمت پایین‌تر هستند. همچنین می‌توان اشاره کرد یکی از دلایل به وجود آمدن مدل‌های خطی که درون خود، وابستگی نوسانی بازده‌ی قیمت‌ها را، مانند خانواده‌ی مدل‌های ARCH/GARCH[2]، کد می‌کنند همین حقیقت آماری سبکمند خوشه بندی نوسانات است

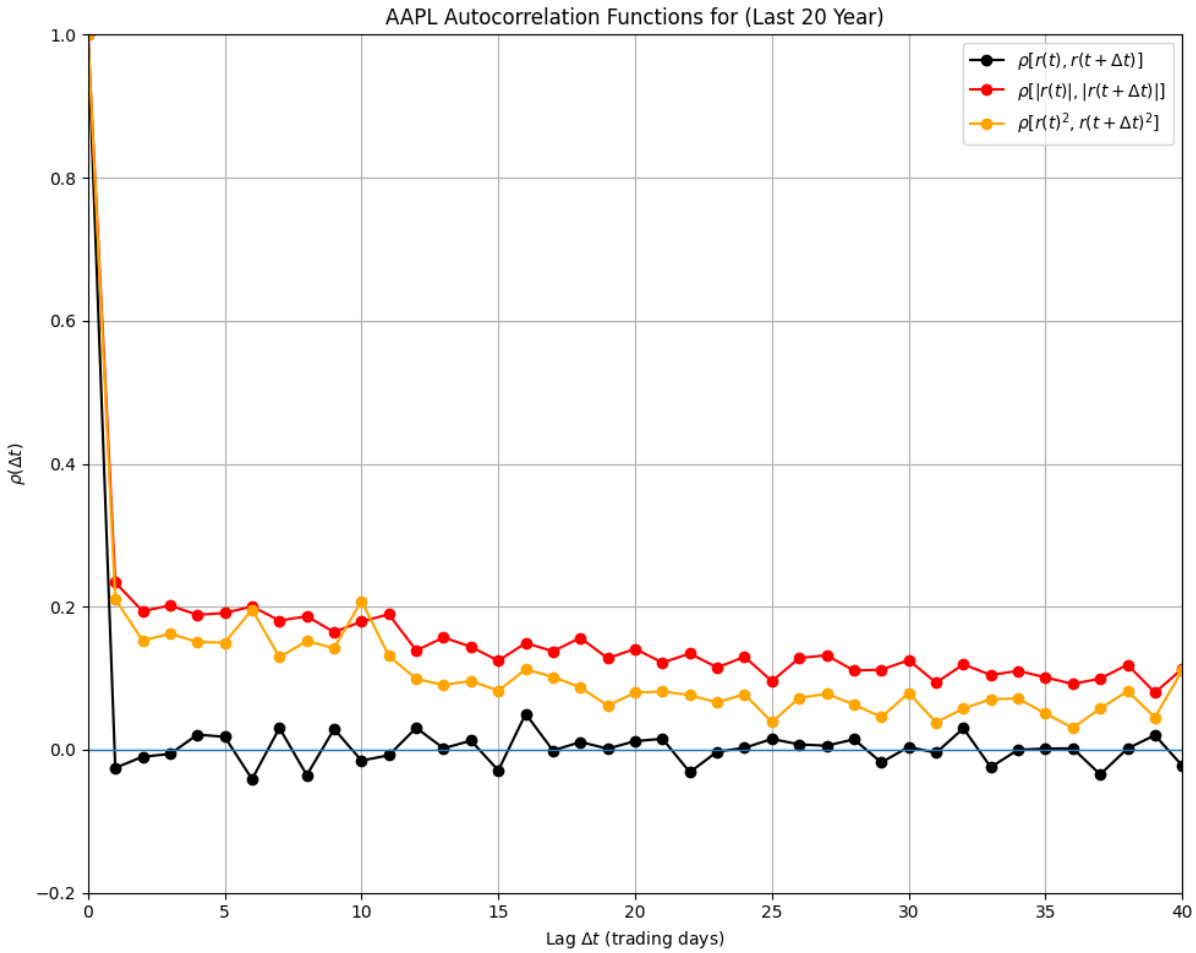
[1] Random Walk

[2] Autoregressive Conditional Heteroscedasticity (ARCH) models and Generalized Autoregressive Conditional Heteroscedasticity (GARCH) models



شکل ۵.۲: بازده روزانه مربعی سری زمانی شرکت اپل در بازه زمانی پنج سال گذشته

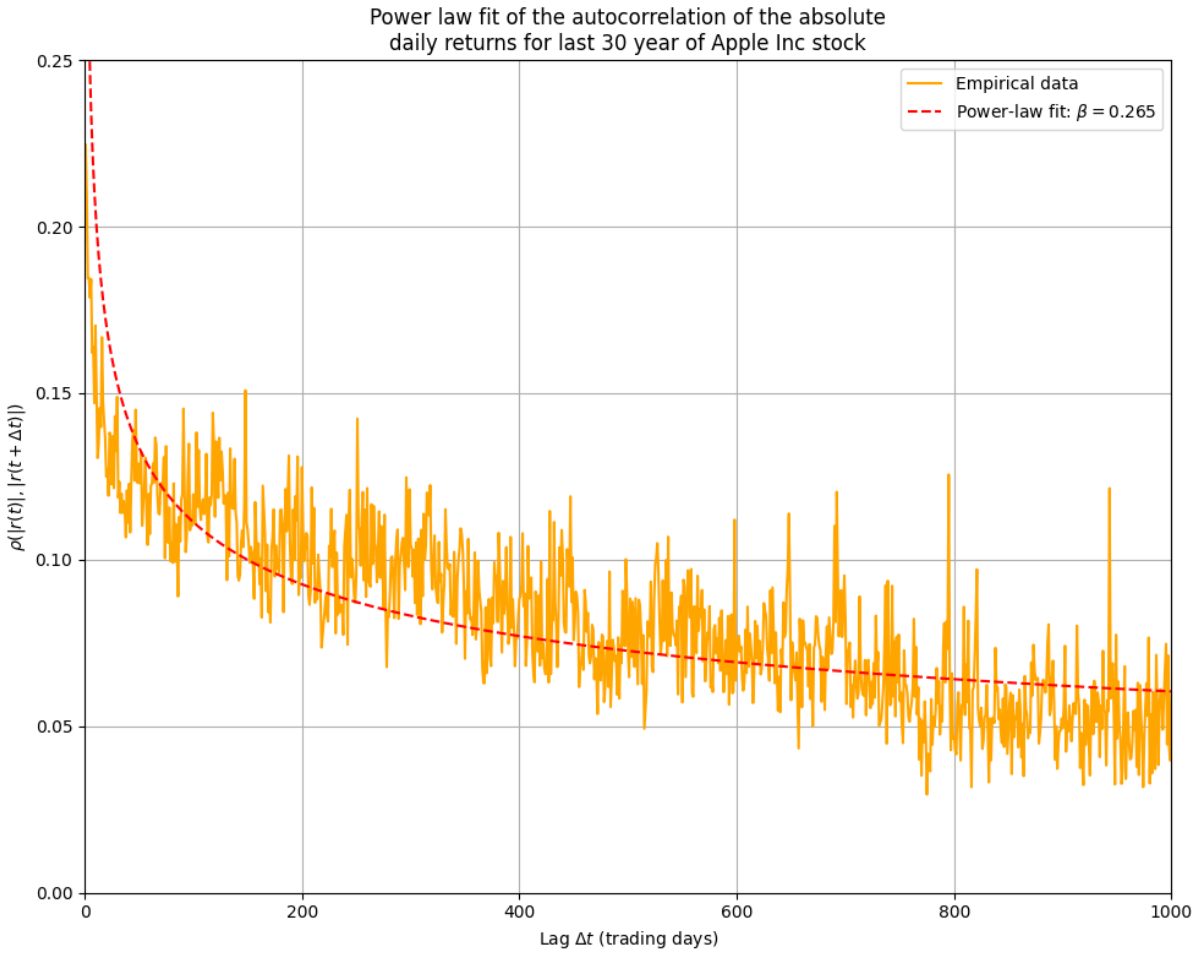
خوشه‌های زیادی از نوسانات بالا یا پایین را می‌توان در طول دوره‌ی پنج ساله‌ی سهام اپل در شکل بالا مشاهده کرد. در شکل زیر نیز خودهمبستگی برای بازده‌های مطلق و مربع روزانه‌ی سهام اپل در بیست سال گذشته علاوه بر خود بازده سهام آورده شده است.



شکل ۶.۲: خودهمبستگی برای توابع مختلف بازده روزانه سهام شرکت اپل در بیست سال گذشته

در بسیاری از کارهای گذشته ثابت شده که خودهمبستگی توان‌های مختلف v از بازده‌های مطلق با β تقریباً در بازه $[0.1, 0.4]$ برای بازده مطلق و مربع به صورت یک قانون توانی کاهش می‌یابد: [۹، ۱۰، ۲۵]

$$\rho\left(|r_1(t)|^v, |r_1(t+\Delta t)|^v\right) \sim (\Delta t)^{-\beta} \tag{۷.۲}$$

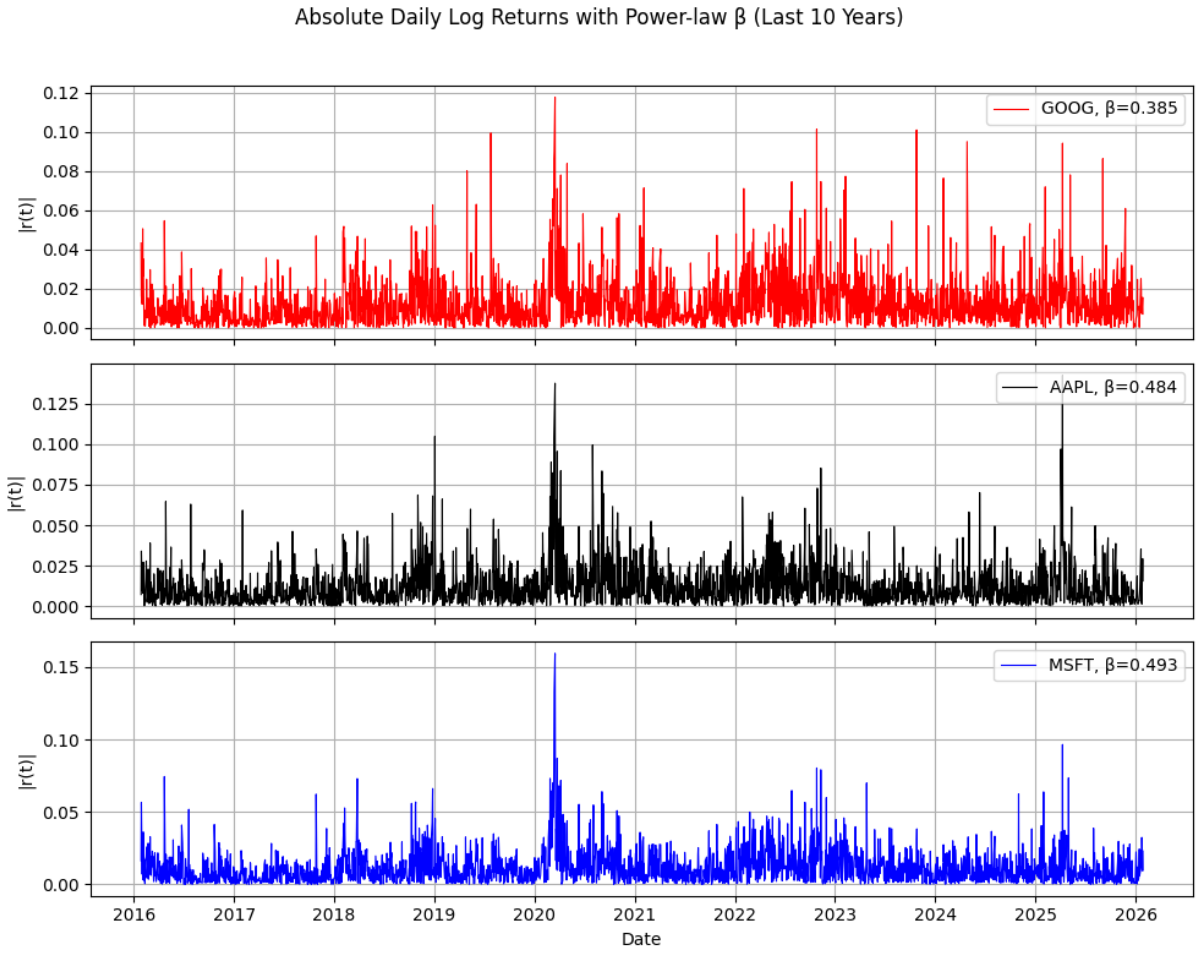


شکل ۷.۲: برازش قانون توانی برای خودهمبستگی بازده مطلق روزانه‌ی ۳۰ سال گذشته‌ی سهام شرکت اپل

به طور کلی و برای جمع بندی باید اشاره کرد که خوشه‌بندی نوسانات یک واقعیت مستند و سبک‌شده از سری‌های زمانی مالی است که با تداوم بازده‌های مطلق بزرگ و به دنبال آن بازده‌های مطلق بزرگ، و سپس برای بازده‌های کوچک و به دنبال آن بازده‌های کوچک، مشخص می‌شود. این پدیده به وضوح با کاهش آهسته تابع خودهمبستگی بازده‌های مطلق مشهود است. برای بازده‌های روزانه شرکت اپل در طول ۳۰ سال گذشته، متوجه شدیم که خودهمبستگی بازده‌های لگاریتمی مطلق به صورت یک قانون توانی، همانطور که از معادله‌ی بالا برمی‌آید، با توان تخمینی $\beta = 0.265$ کاهش می‌یابد. چنین کاهش آهسته و غیر نمایی نشان‌دهنده وابستگی بلندمدت در نوسانات است، به این معنی که شوک‌های وارده به تغییرپذیری بازار در طیف وسیعی از مقیاس‌های زمانی ادامه دارند. این رفتار با مدل‌های حافظه کوتاه‌مدت ناسازگار است و نمی‌توان آن را به طور کامل توسط فرآیندهای استاندارد از نوع $GARCH$ که همبستگی‌های کاهشی نمایی را در نوسانات اعمال می‌کنند، ثبت کرد. در عوض، واپاشی قانون توانی مشاهده‌شده با مدل‌های نوسان چندفرکتالی [1] و بلندمدت سازگار است که در آن‌ها پویایی

[1] Multi-fractal models

بازار توسط عوامل ناهمگن، مکانیسم‌های بازخورد و ساختارهای مقیاس‌ناپذیر اداره می‌شود. از دیدگاه سری زمانی، وجود واپاشی قانون توانی با $\beta < 1$ نشان می‌دهد که نوسان، همبستگی‌های پایداری دارد که به طور قابل توجهی بر تخمین ریسک پذیری سهام، پیش‌بینی قیمت سهم و مشخصات مدل تأثیر می‌گذارد و نیاز به چارچوب‌هایی فراتر از مدل‌های خطی کلاسیک و تصادفی تک‌مقیاس دارد. طبق آنچه که در ادبیات مرور شده، سهامی که با مقادیر پایین توان β مشخص می‌شوند، خوشه‌های طولانی‌تر و آشکارتری از نوسانات بزرگ یا کوچک را نشان می‌دهند. از این رو، وقتی که فرآیند نوسانات را مدل‌سازی می‌کنیم، این وابستگی را نمی‌توان نادیده گرفت و این ویژگی‌های تجربی مشاهده شده لزوماً باید در نظر گرفته شوند [۱۰].

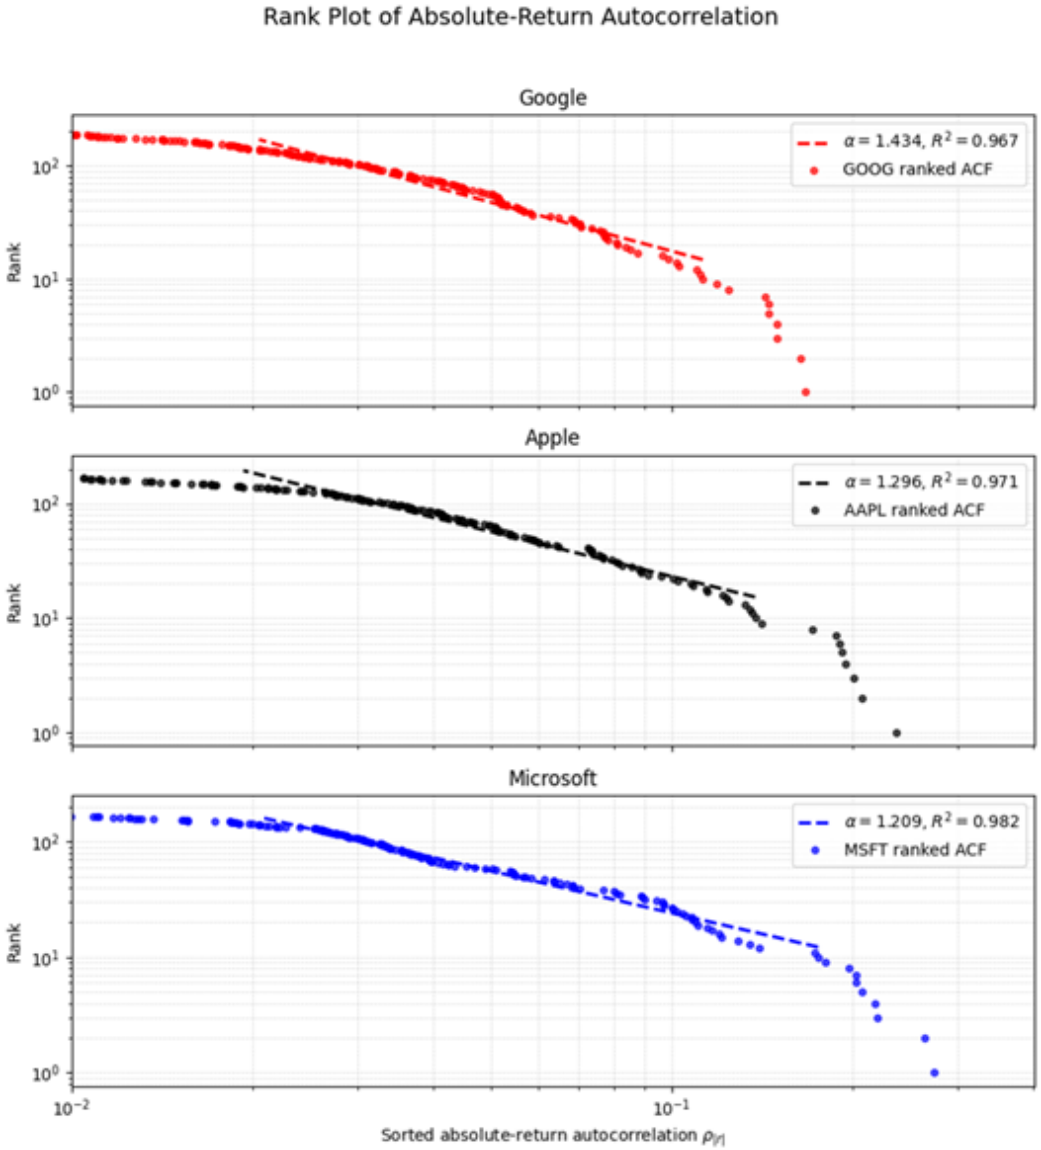


شکل ۸.۲: خوشه بندی نوسانات و بتای قانون توانی سه سهام گوگل، اپل و فیس‌بوک

واضح است که وقتی β کوچکتر باشد، خوشه‌های نوسان در مقایسه با مواردی که β بزرگتر است، مشهودتر بنظر میرسند. بر اساس بررسی ادبیات، می‌توان مشاهده کرد که سهام با $\beta \sim 0.1 - 0.2$ خوشه‌های زیادی را در طول دوره مورد تحلیل نشان می‌دهند پس می‌توان آنها را به دلیل نوسانات بیشتر قیمتی، ریسک‌پذیرتر از باقی سهام‌ها، در نظر گرفت. از سوی دیگر، سری‌های زمانی که مقدار $\beta \sim 0.4 - 0.5$ را نشان می‌دهند، بازده مطلق کوچکتری دارند و شامل خوشه‌هایی هستند که برای دوره‌های کوتاه‌تری باقی می‌مانند. بنابراین، این نوع آخر

سهام با تغییرات قیمت محدودتری نمایش داده می‌شوند و از این نظر دارایی‌های امن‌تر به نسبت سایرین در نظر گرفته می‌شوند.

همچنین شکل زیر وابستگی بلندمدت نوسان‌ها را به کمک دو پنل بررسی می‌کند. پنل زیر، خودهمبستگی‌های بازده مطلق مرتب‌شده بر اساس رتبه را نشان می‌دهد که تقریبا رفتاری خطی روی محورهای لگاریتمی از خود نشان می‌دهند و نشان می‌دهند که دامنه‌های خودهمبستگی از توزیع زیپف مانند قانون توانی پیروی می‌کنند. [۶۷-۶۹] توان‌های مقیاس‌بندی تخمینی $\alpha = 1.434$ برای گوگل، $\alpha = 1.296$ برای اپل و $\alpha = 1.209$ برای مایکروسافت هستند که همگی دارای نیکویی برازش عالی $R^2 > 0.96$ هستند و رفتار مقیاس‌بندی قوی را در طیف وسیعی از مقادیر خودهمبستگی نشان می‌دهند. از آنجایی که β با توان زیپف $\beta \propto \alpha^{-1}$ رابطه معکوس دارد، دارایی‌هایی با α بزرگتر، پایداری قوی‌تری در همبستگی‌های نوسانات نشان می‌دهند. بنابراین، این توان‌های مقیاس‌بندی باید به عنوان معیارهای پایداری پویایی نوسانات تفسیر شوند تا شاخص‌های مستقیم ریسک سرمایه‌گذاری. رتبه‌بندی زیپف و کاهش قانون توانی، در کنار هم، شواهد مکملی ارائه می‌دهند که نوسانات در بازارهای مالی دارای ویژگی‌های حافظه بلندمدت و تغییرناپذیر با مقیاس هستند که با یکی از حقایق اساسی سری‌های زمانی مالی سازگار است.



شکل ۹.۲: نمودار رتبه‌بندی خودهمبستگی با بازده مطلق اپل، مایکروسافت و گوگل

۵.۱.۲ سایر ویژگی‌های تجربی مهم

در کنار مطالب گفته شده از حقایق تجربی در این فصل، ویژگی‌های دیگری نیز وجود دارند که در داده‌های مالی مشترک هستند و در فصل بعدی بر روی برخی از آنها تمرکز خواهیم کرد. عمدتاً دو جنبه‌ی تجربی ویژگی‌های مقیاس‌بندی و همبستگی‌ها، از سری‌های زمانی مالی مورد تحلیل قرار خواهند گرفت. ویژگی‌های مقیاس‌بندی[1] در فیزیک، آمار و ریاضیات به خوبی شناخته شده‌اند و به چگونگی رفتار یک سیستم یا یک فرآیند هنگام تغییر مقیاس یا اندازه مشخصه‌ی آن اشاره دارند. در مورد سری‌های زمانی مالی، به دنبال الگوهایی هستیم که در مقیاس‌های

[1] Scaling Properties

زمانی مختلف تکرار می‌شوند و خواهیم دید که چگونه می‌توان آنها را کمی کرد و نتیجه‌ی آنها بر درک هر چه بهتر بازارهای مالی چیست. تمرکز بر مفهوم چندمقیاسی خواهد بود. علاوه بر این، مطالعه همبستگی بازده دارایی‌ها ابزاری معتبر برای مطالعه ساختار سلسله مراتبی[۱] بازارهای مالی در بررسی سهام شرکت‌هایی با ویژگی‌های مشابه بوده است. [۹، ۱۰، ۲۷-۳۰]

۲.۲ بررسی وجود حقایق سبک‌مند در بازار نوظهور رمزارزها

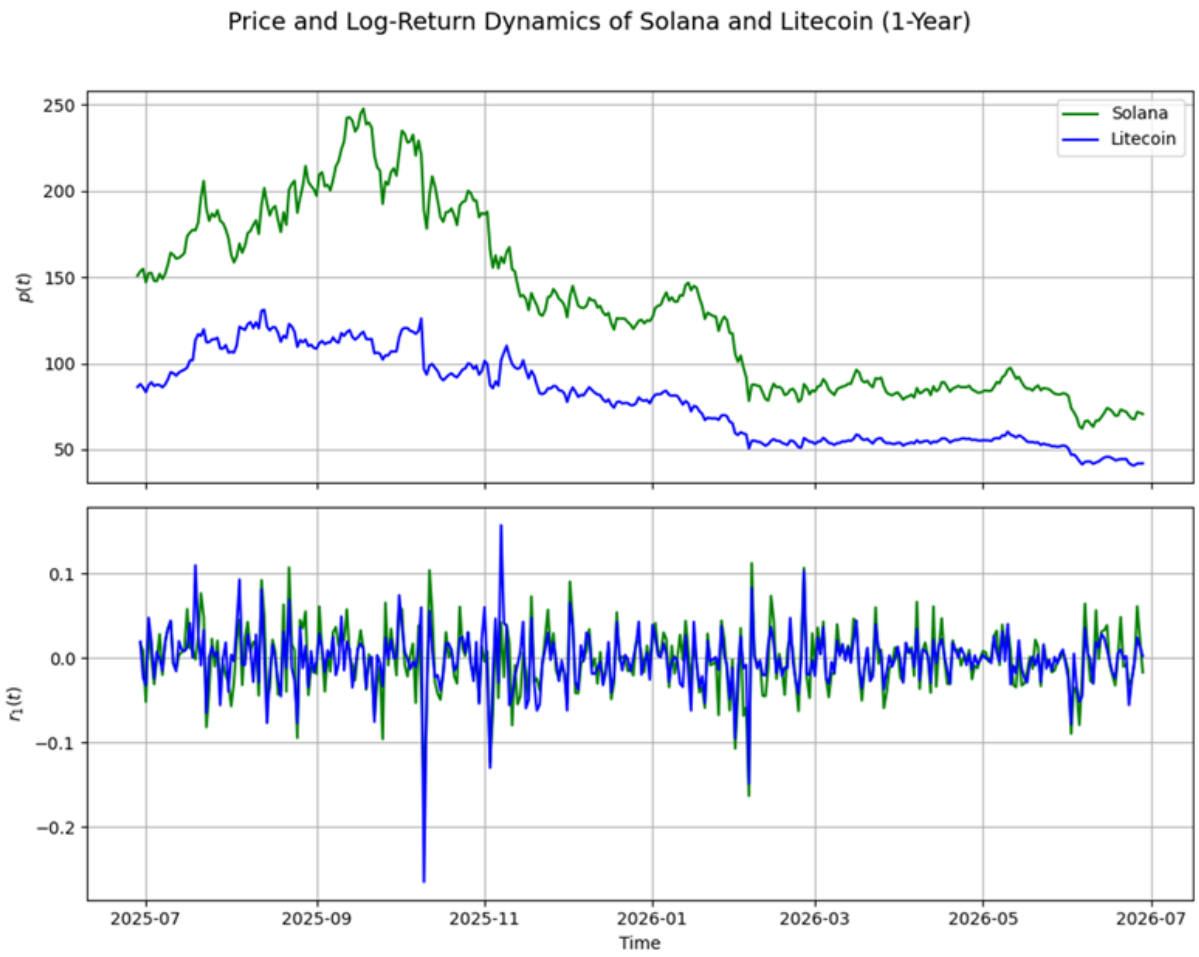
۱.۲.۲ بازده لگاریتمی

برای بررسی پویایی قیمت و بازده لگاریتمی، دو رمزارز سولانا و لایت کوین برای بازه‌ی زمانی یک سال گذشته انتخاب شدند. با بررسی آمار توصیفی و جدول تشخیصی[۲] آنها می‌توان گفت که هر دو رمزارز، با وجود روندهای مشخص در مسیر قیمت خود، سری‌های بازده بسیار ناپایداری را نشان می‌دهند که در حدود صفر نوسان می‌کنند که نشان می‌دهد بازده لگاریتمی به طور قابل توجهی بسیار پایدارتر از قیمت‌های خام آنها است. سولانا نوسان بازده کمی بزرگتری با انحراف معیاری حدود 0.03757 نسبت به لایت‌کوین (با مقدار 0.03405) نشان می‌دهد، در حالی که هر دو دارایی میانگین بازده روزانه نزدیک به صفر دارند. توزیع بازده از حالت نرمال منحرف می‌شود، همانطور که توسط آزمون جارک-برا[۳] برای هر دو دارایی تأیید شده است. با این حال، لایت‌کوین دنباله‌های به مراتب سنگین‌تری با کشیدگی اضافی 11.74 و چولگی منفی قوی‌تری -1.14 نسبت به سولانا با کشیدگی اضافی 1.78 و چولگی -0.24 نشان می‌دهد که احتمال حرکات نزولی شدید را بیشتر مشخص می‌کند. آزمون کولموگروف-اسمیرنوف نشان می‌دهد که توزیع بازده سولانا نسبتاً به گاوسی نزدیک‌تر است، در حالی که لایت‌کوین به طور قابل توجهی از نرمال بودن فاصله می‌گیرد. آزمون دیکی-فولر افزوده شده، وجود ریشه واحد را برای هر دو سری بازده به شدت رد می‌کند و ایستایی را تأیید می‌کند. در نهایت، آزمون‌های $Ljung-Box$ و $ARCH-LM$ تفاوت‌هایی را در وابستگی زمانی و ناهمسانی واریانس شرطی بین این دو دارایی نشان می‌دهند، به طوری که لایت‌کوین همبستگی سریالی معنی‌داری را نشان می‌دهد، در حالی که سولانا اثرات $ARCH$ از نظر آماری معنی‌دار نشان می‌دهد، که با خوشه‌بندی نوسانات که معمولاً در بازارهای ارزهای دیجیتال مشاهده می‌شود، سازگار است. در شکل زیر می‌توانید اطلاعات آماری مربوطه را بررسی کنید:

[1] Hierarchical structure

[2] for more informmation, refer to the appendix.

[3] Jarque–Bera test



شکل ۱۰.۲: قیمت و بازده لگاریتمی سولانا و لایت کوین در یک سال گذشته

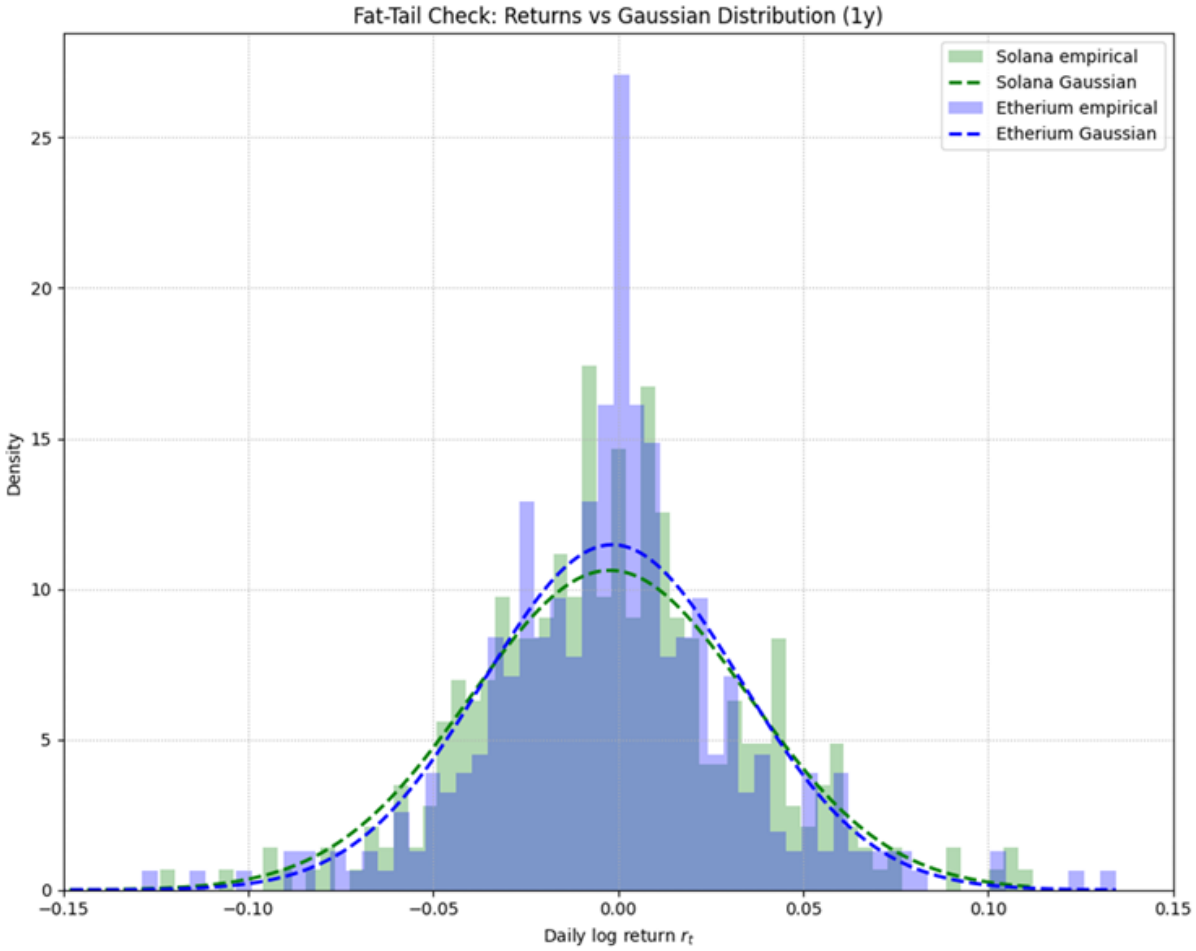
Asset	Mean	Std	Skewness	Excess Kurtosis	Jarque-Bera p	KS p	ADF p	Ljung-Box(20) p	ARCH-LM p
Solana	-0.00225	0.03757	-0.23697	1.77826	0.00000	0.25288	0.00000	0.09878	0.01200
Litecoin	-0.00212	0.03405	-1.13566	11.74373	0.00000	0.00671	0.00000	0.00723	0.99050

شکل ۱۱.۲: تست‌های آماری روی بازده لگاریتمی دو رمزارز سولانا و لایت کوین

۲.۲.۲ توزیع دم کلفت

طبق آزمون‌های آماری برای بررسی دنباله پهن و برای تشخیص میزان فاصله‌ی دم تابع توزیع از تابع توزیع نرمال برازش شده، برای بازده روزانه سولانا و اتریوم مشاهده می‌شود که هر دو رمزارز، کشیدگی اضافی مثبت را نشان می‌دهند که نشان‌دهنده توزیع بازده لپتوکورتیک با دنباله‌های سنگین‌تر نسبت به توزیع گاوسی است. اتریوم کشیدگی اضافی بزرگتری معادل 2.702 نسبت به سولانا با 1.778 نشان می‌دهد

که نشان‌دهنده فراوانی بیشتر نوسانات شدید قیمت است. آزمون جارک-برا فرضیه صفر نرمال بودن را برای هر دو دارایی که $p < 0.001$ را نشان می‌دهد، قویاً رد می‌کند و تأیید می‌کند که بازده آنها به طور قابل توجهی از توزیع نرمال منحرف است. آزمون کولموگروف-اسمیرنوف همچنین نشان می‌دهد که بازده سولانا نسبتاً به گاوسی نزدیک‌تر است، در حالی که اتریوم از نظر آماری انحراف قابل توجهی از نرمال بودن دارد. به طور کلی، این یافته‌ها نشان می‌دهند که هر دو سری بازده ارز دیجیتال غیر گاوسی هستند، و اتریوم رفتار دنباله سنگین برجسته‌تری نسبت به سولانا نشان می‌دهد، که با وجود حرکات شدید بازار که معمولاً در بازارهای ارز دیجیتال مشاهده می‌شود، سازگار است.

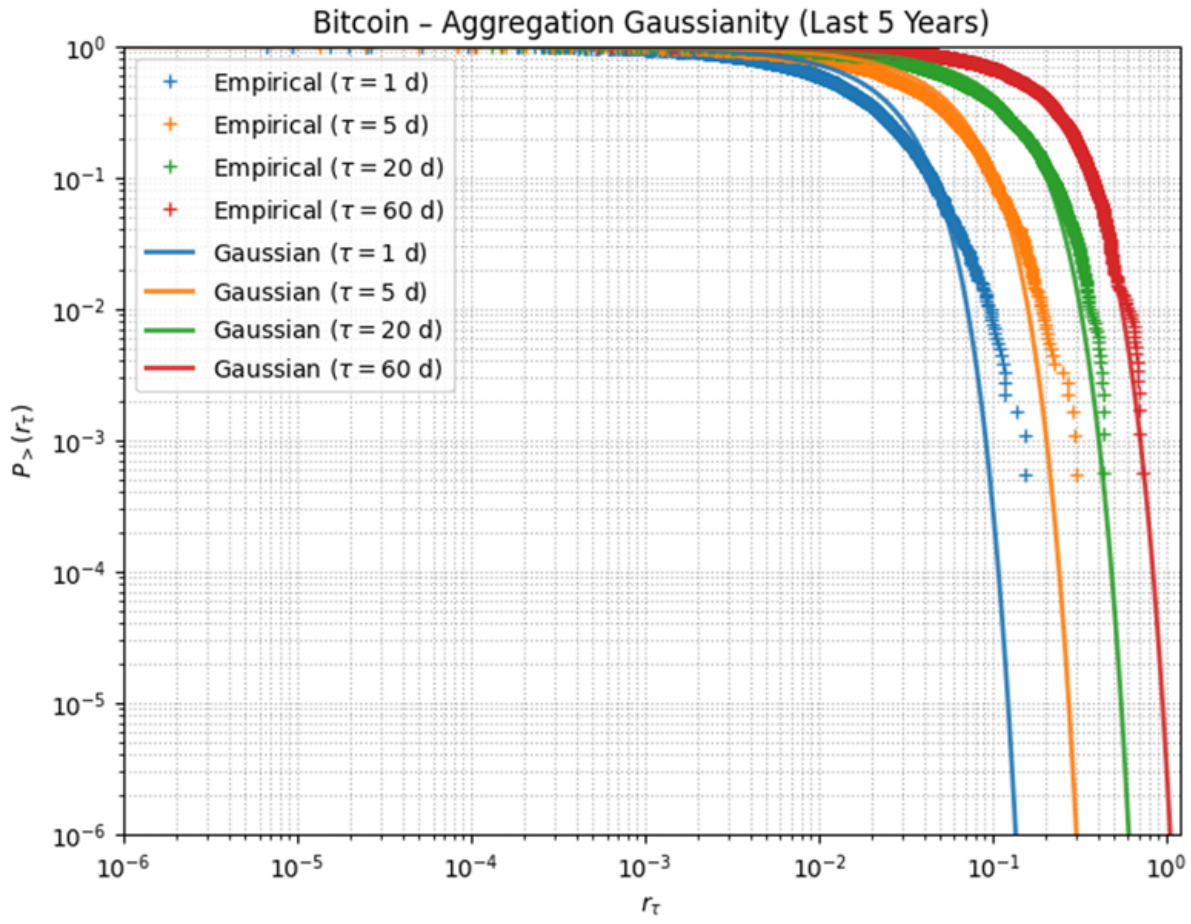


شکل ۱۲.۲: بررسی دم تابع توزیع دو رمزارز سولانا و اتریوم

۳.۲.۲ گوسی بودن تجمعی

شکل زیر توزیع‌های بازده تجربی بیت‌کوین را در افق‌های تجمعی از ۱ تا ۶۰ روز معاملاتی در طول پنج سال گذشته نشان می‌دهد. با افزایش فاصله‌ی این تجمیع‌ها، توزیع‌ها به تدریج متقارن‌تر و زنگوله‌ای شکل می‌شوند و از نظر بصری به توزیع گاوسی نزدیک می‌شوند. این همگرایی از نظر کمی با کاهش مداوم فاصله کولموگروف-اسمیرنوف از مقدار 0.72 در $\tau = 1$ به مقدار 0.042 در $\tau = 60$ می‌رسد که نشان

دهنده کاهش اختلاف بین توزیع‌های تجربی و نرمال است. افزایش به طور مقاوم مقدار $KSp - value$ نشان می‌دهد در حالی که نرمال بودن برای بازده‌های روزانه به شدت رد می‌شود، دیگر نمی‌توان آن را در افق تجمیع ۶۰ روزه رد کرد. کشیدگی اضافی[1] نیز به صورت یکنواخت کاهش می‌یابد، که نشان می‌دهد ماهیت دنباله‌دار بازده‌های روزانه به تدریج با افزایش تجمیع از بین می‌رود. در مجموع، این شکل شواهد تجربی روشنی از واقعیت سبک‌مند ارائه شده در بازارهای مالی ارائه می‌دهد، که به موجب آن توزیع بازده در مقیاس‌های زمانی طولانی‌تر به سمت نرمال بودن همگرا می‌شود، که با قضیه حد مرکزی و یافته‌های تجربی قبلی در بازارهای مالی سازگار است.



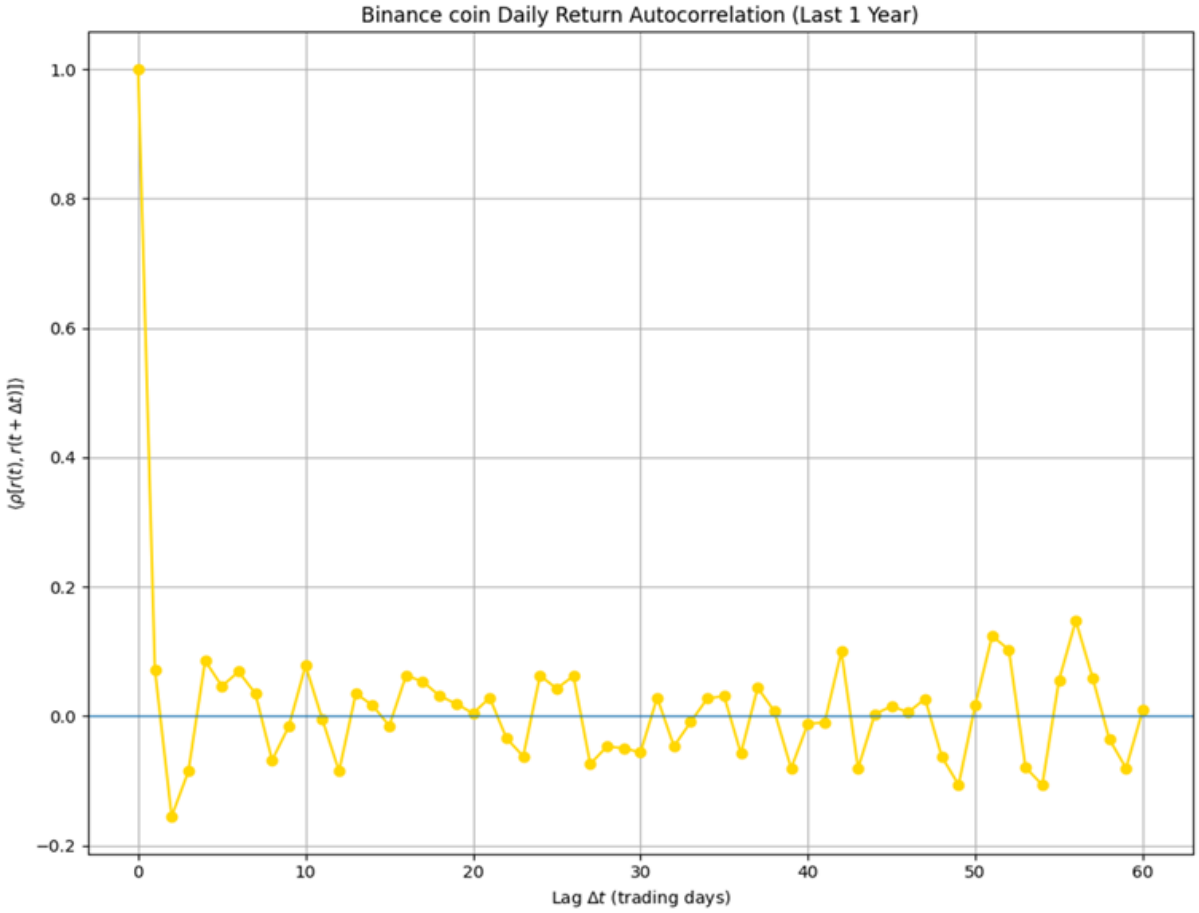
شکل ۱۳.۲: بررسی گوسی بودن تجمعی توزیع بیت کوین در طول پنج سال گذشته

۴.۲.۲ عدم وجود خودهمبستگی‌ها

در شکل زیر، تابع خودهمبستگی بازده روزانه گزارش‌شده رمزارز بایننس کوین در طول سال گذشته آورده شده است. بجز خودهمبستگی در صفر نمودار، ضرایب خودهمبستگی به طور تصادفی در اطراف صفر نوسان می‌کنند و در تمام تأخیرهای بررسی شده از نظر بزرگی، در

[1] Excess kurtosis

مرتبه صفر کوچک باقی می‌مانند. هیچ همبستگی مثبت یا منفی ثابتی مشاهده نمی‌شود، که نشان می‌دهد بازده‌های گذشته اطلاعات پیش‌بینی‌کننده کمی در مورد بازده‌های آینده ارائه می‌دهند. اگرچه چند تأخیر مجزا مقادیر خودهمبستگی کمی بالاتری را نشان می‌دهند، اما این مقادیر کوتاه‌مدت هستند و الگوی سیستماتیکی را تشکیل نمی‌دهند. به طور کلی، عدم وجود خودهمبستگی ثابت نشان می‌دهد که بازده‌های ارز دیجیتال تقریباً به صورت سریالی غیر همبسته هستند، که با عدم همبستگی خطی که به طور گسترده در بازارهای مالی مستند شده است، سازگار است. این رفتار از فرضیه بازار کارا[1] ضعیف پشتیبانی می‌کند، که بیان می‌کند اطلاعات قیمت تاریخی موجود در دسترس عموم به سرعت در قیمت‌های بازار گنجانده می‌شود و تغییرات قیمت آینده را تا حد زیادی از بازده‌های گذشته غیرقابل پیش‌بینی می‌کند.



شکل ۱۴.۲: بررسی عدم وجود خودهمبستگی‌ها در رمزارز بایننس کوین در طول سال گذشته

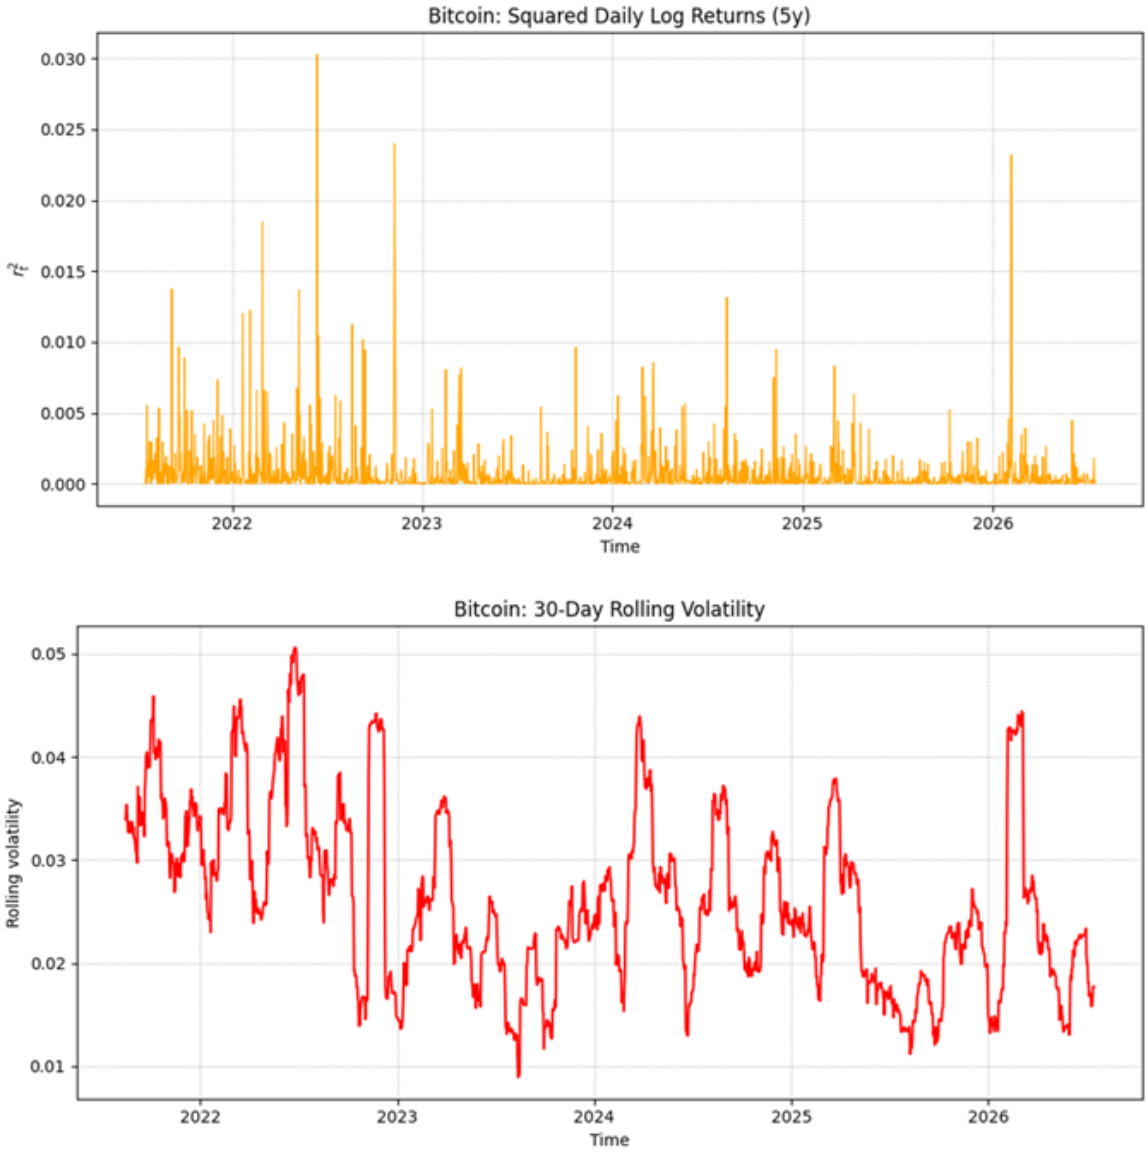
[1] Efficient Market Hypothesis (EMH)

۵.۲.۲ خوشه بندی نوسانات

در شکل زیر پویایی نوسانات بیت کوین در پنج سال گذشته با استفاده از بازده لگاریتمی روزانه و معیار نوسان غلتان ۳۰ روزه [۱] آورده شده است. سری بازده غلتان، انفجارهای قابل توجهی از نوسانات بزرگ را نشان می‌دهد که با دوره‌های نسبتاً آرام از هم جدا شده‌اند، که نشان می‌دهد دوره‌های نوسان بالا تمایل به خوشه‌بندی در طول زمان دارند تا اینکه به طور مستقل رخ دهند. این رفتار بیشتر توسط نوسان غلتان ۳۰ روزه تأیید می‌شود که دوره‌های مداوم نوسان بالا و پایین را به جای نوسان تصادفی در اطراف یک سطح ثابت نشان می‌دهد. چنین تداومی، مشخصه واقعیت خوشه‌بندی نوسان است و نشان می‌دهد که تغییرات بزرگ قیمت، صرف نظر از جهت، احتمالاً با تغییرات بزرگ قیمت دنبال می‌شوند.

در مقایسه با بازارهای مالی سنتی، بازارهای ارزهای دیجیتال عموماً خوشه‌بندی نوسانات برجسته‌تری را نشان می‌دهند که نشان‌دهنده حساسیت بالاتر آنها به معاملات سوداگرانه، شوک‌های نقدینگی و انتشار سریع اطلاعات است. این مشاهدات از استفاده از مدل‌های ناهمسانی واریانس شرطی، مانند خانواده $GARCH$، برای مدل‌سازی نوسان بازده ارزهای دیجیتال پشتیبانی می‌کند.

[1] 30-Day Rolling Volatility



شکل ۱۵.۲: بررسی خوشه بندی نوسانات در رمزارز بیت کوین برای پنج سال گذشته

فصل ۳

خواص مقیاسی

خواص مقیاسی به نحوه‌ی رفتار یک سیستم یا پدیده هنگام تغییر مقیاس یا اندازه مشخصه آن اشاره دارد.

این خواص را در فیزیک آماری و پدیده‌های بحرانی میشناسیم. چرا که از آنها به طور گسترده‌ای برای مطالعه رفتار سیستم در نزدیکی نقاط بحرانی استفاده می‌شوند. همچنین، ترکیب آنها با مفهوم جهان‌شمولی[۱] و گروه بازبهنجارش، منجر به راهکاری قدرتمند برای مطالعه سیستم‌های دینامیکی شده است و محققان را قادر می‌سازد تا خواصی را که قبلتر ناشناخته بودند، بررسی کنند. به طور کلی این قوانین بینش‌هایی در مورد خواص اصلی سیستم و پویایی فرآیند مورد بررسی ارائه می‌دهند که در پیش‌بینی رفتار سیستم در مقیاس‌های مختلف، کاربرد دارند. [۳۱، ۳۲] در بررسی رفتار مقیاسی به طور کل و نه فقط در تحلیل بازارهای مالی، روش‌های مختلفی مطرح شده است. از مهم‌ترین مدل‌ها می‌توان به مدل ماکزیمم‌های مدول تبدیل موجک[۲]، تحلیل نوسان چندفرکتالیِ بدون‌روند[۳]، روش‌های هرست و روش‌های تعمیم یافته‌ی هرست اشاره کرد. [۵۹-۶۲]

برای مطالعه‌ی این خواص و روش‌ها، با تمرکز روی کارهای خانم دکتر دی‌متئو، با مروری بر تاریخچه و مروری در مفاهیم خودهمانندی و

---

[1] Universality

[2] Wavelet Transform Modulus Maxima (WTMM)

[3] Multifractal Detrended Fluctuation Analysis (MF-DFA)

تغییرناپذیری مقیاس[1]، سخن را آغاز می‌کنیم.

۱.۳ مقدمه‌ای بر تاریخچه‌ی بررسی خواص مقیاسی در تحلیل بازارهای مالی

در سال ۲۰۰۱ بحثی میان دانشمندان بزرگ حوزه‌ی فیزیک اقتصاد در باب بررسی خواص مقیاسی و اهمیت وجودی این خواص جریان داشت. به طور بخصوص بحثی میان لبارون از یک سو، و مندلبرات و استنلی و پلرو از سوی دیگر، و توماس لاکس جایی در میانه، در گرفته است تا مشخص شود که آیا فرآیندهایی که داده‌های مالی را توصیف می‌کنند واقعاً مقیاس‌پذیر هستند یا اینکه شباهت مشاهده شده در مقیاس‌های مختلف صرفاً یک مصنوع از داده‌ها[2] است. جلوتر اما از ابتدای سل ۲۰۰۳ و به خصوص در کارهای دی‌متئو نشان داده شد که نه تنها این خواص مصنوعی نیستند که به عنوان یکی از مهم‌ترین خواص و حقایق سبک‌مند در بازارهای مالی شناخته می‌شوند. امروزه ما می‌دانیم که چندمقیاسی‌سازی از یک یا چند پدیده مرتبط با پویایی معاملات[3] سرچشمه می‌گیرد. به طور خاص، می‌توان آن را به دنباله‌های پهن، خودهمبستگی مقدار مطلق بازده لگاریتمی، پویایی نقدینگی[4] یا همبستگی (غیرخطی) بین بازده‌های بالا و پایین ایجاد شده توسط فرکانس‌های زمانی مختلف که معامله‌گران در آن فعالیت می‌کنند و حجم‌های معامله شده نسبت داد.

۲.۳ خودهمانندی، فرکتال‌ها و ناوردایی مقیاس

در این بخش اساس ریاضی مربوط به خواص خودمتشابهی، فرکتال‌ها و ناوردایی مقیاسی را بررسی می‌کنیم.

۱.۲.۳ فرکتال‌های هندسی و ناوردایی مقیاسی

تعریف۱: تشابه S تبدیلی خطی است که به صورت ترکیبی از انتقال، چرخش و مقیاس‌بندی یکنواخت که می‌تواند بزرگنمایی یا کوچکنمایی باشد، به دست می‌آید. بنابراین می‌توان گفت که دو جسم هندسی A و B در صورتی مشابه هستند که دو تبدیل تشابه S, S' وجود داشته باشد به طوری که $S(A) \cong B$ و $A \cong S'(B)$.

تعریف ۲: یک تبدیل تشابه تعمیم‌یافته $\hat{S}$ اجتماع n تبدیل متشابه است.

تعریف ۳: جسم هندسی O خودمتشابه است اگر حداقل یک تبدیل تشابه تعمیم‌یافته $\hat{S}$ وجود داشته باشد به طوری که $\hat{S}(O) \cong O$.

[1] Scale Invariance
[2] Artifact of the data
[3] Trading Dynamics
[4] Liquidity Dynamics

یک نمونه خاص از اشیاء هندسی خودمتشابه، فراکتال‌هایی هستند که برای اولین بار توسط بنوا مندلبروت تعریف شدند. [۳۳] این اشیاء با این ویژگی مشخص می‌شوند که اجزای آنها، هنگامی که با ضریب مقیاس مناسبی بزرگنمایی می‌شوند، شبیه به کل به نظر می‌رسند و یک فراکتال را می‌توان به صورت بازگشتی با اعمال یک تبدیل تشابه تعمیم‌یافته به دفعات نامحدود بر روی یک ساختار هندسی ساخت. یک مثال معمول، مجموعه کانتور است که می‌تواند با اعمال تبدیل تشابه تعمیم‌یافته زیر به صورت بازگشتی ساخته شود:

$$\hat{S} = S_1 \cup S_2, \;\; With \;\; S_1 = \frac{1}{3}x \;\; and \;\; S_2 = \frac{1}{3}x + \frac{2}{3} \tag{۱.۳}$$

با بازه یک بعدی واحد $I = [0, 1]$. بنابراین، شیء فراکتال به صورت $\hat{S}^{\infty}(I)$ تعریف می‌شود.

تعریف ۴: بُعد فرکتال (یا هاسدورف) d_f یک شیء O که در $\mathscr{R}^d$ قرار دارد، به صورت زیر تعریف می‌شود:

$$d_f = -\lim_{r \to \infty} \frac{\log N(r)}{\log r} \tag{۲.۳}$$

که در آن $N(r)$ حداقل تعداد گوی‌های d بعدی لازم با شعاع r برای پوشاندن جسم O (با توجه به موقعیت مراکز گوی‌ها در r ثابت) است.

$$B_{x_0}(r) = \{x \in \mathscr{R}^d : ||x - x_0|| \leq r\} \tag{۳.۳}$$

تعریف ۵: یک فراکتال زیرمجموعه‌ای از یک فضای اقلیدسی است به طوری که

$$d_T \leq d_F \leq d \tag{۴.۳}$$

که در آن d بُعد تعبیه آن (یعنی بُعد فضایی که جسم d در آن زندگی می‌کند) و بُعد توپولوژیکی آن d_T (یعنی بُعد محلی هر نقطه از جسم) است.

برای مثال، مجموعه کانتور از اشیاء نقطه‌مانند $(d_T = 0)$ تشکیل شده و روی خط حقیقی $(d = 1)$قرار گرفته است. بُعد فرکتالی آن را می‌توان به سادگی با تعریف تحلیلی کمیت $N(r)$ موجود در تعریف ۴ محاسبه کرد. در هر مرحله از ساخت مجموعه کانتور، جسم هندسی

توسط 2^n گوی با قطری برابر با $2r = 3^{-n}$ پوشانده شده است. از این رو خواهیم داشت:

$$\begin{aligned} d_F &= -\lim_{r\to\infty} \frac{\log N(r)}{\log r} = \\ &= -\lim_{r\to\infty} \frac{\log(2^n)}{\log(3^{-n}2^{n-1})} = \\ &= -\lim_{r\to\infty} \frac{n\log(2)}{-n\log 3 - \log 2} = \\ &= \frac{\log 2}{\log 3} \simeq 0.63 \end{aligned} \tag{۵.۳}$$

جالب است که بدانیم یک قانون مقیاسی طبیعی در اینجا مطرح می‌شود:

$$N(r) = 2^{-1}N(r/3) = 3^{-d_F}N(r/3) \tag{۶.۳}$$

زیرا در هر تکرار عملیات بالا، تعداد توپ‌هایی که باید جسم را بپوشانند با کاهش اندازه، افزایش خواهند یافت.

تعریف ۶: یک تابع مشتق‌پذیر را در صورتی ناوردای مقیاس می‌نامیم که برای هر انتخاب λ و برای برخی انتخاب‌های α داشته باشیم:

$$f(x) = \lambda^{-\alpha} f(x/\lambda) \tag{۷.۳}$$

در مورد فرکتال‌ها، خودهمانندی جسم در رابطه‌ای از این نوع مطرح می‌شود که البته فقط برای مجموعه‌ای محدود از عوامل مقیاس λ که به بُعدهای فرکتال s آن مربوط است، معتبر است. با این حال، باید تأکید کرد که خودهمانندی منجر به قوانین توانی از نوع معادله بالا می‌شود، اما عکس آن تضمین شده نیست. به عبارتی دیگر، عبارت بالا میگوید که خودهمانندی شرط لازم برای برقراری قوانین توانی است اما کافی نیست و عکس قضیه برقرار نیست. با این وجود، از قبل مشخص است که مطالعه ویژگی‌های مقیاس‌بندی یک سیستم می‌تواند بینش‌های مهمی در مورد ماهیت عمیق آن ارائه دهد . [۳۲]

۲.۲.۳ فرکتال‌های تصادفی و ناوردایی مقیاس آماری

در اینجا توصیف فرکتال‌های تصادفی مهم است، چرا که اشیاء هندسی با خواص تقریباً فرکتال (یعنی خودتشابهی) هستند که می‌توانند به عنوان تحقق فرآیندهای تصادفی با ویژگی‌های خاص به دست آیند. در واقع، قوانین احتمالی حاکم بر این فرآیندها خودمتشابه هستند و این

فرآیندها با چیزی که به نام ناوردایی مقیاس آماری[1] شناخته می‌شود، مشخص می‌شوند.

به عنوان مثال، حرکت براونی در $\mathscr{R}^d$ یک فرکتال تصادفی است که می‌توان آن را با یک گام تصادفی گسسته با یک گام به طول r_0 و جهت‌هایی که به طور تصادفی از یک توزیع چرخشی نامتغیر با میانگین صفر گرفته شده‌اند، تقریب زد. فرض کنید $p(\vec{x})$ توزیع جابجایی به تنهایی $\vec{x}$ باشد، جابجایی خالص گام پس از m گام $\vec{X}_m = \sum_{i=1}^{m} \vec{x}_i$ است. با داشتن $i.i.d$. با استفاده از گام‌ها و با بهره‌گیری از خطی بودن انتظار، گشتاور اول و دوم جابجایی خالص به سادگی عبارتند از:

$$\begin{aligned} &\left\langle \vec{X}_m \right\rangle_m = 0 \\ &and \\ &\left\langle |\vec{X}_m|^2 \right\rangle_m = \left\langle \sum_{i=1}^{m} \sum_{j=1}^{m} \vec{x}_i.\vec{x}_j \right\rangle_m = \\ &= \sum_{i=1}^{m} \left\langle |\vec{X}_i|^2 \right\rangle = m r_0^2 \end{aligned} \tag{۸.۳}$$

که در آن، زیروند m نشان دهنده میانگین محاسبه شده با توجه به توزیع جابجایی m ام گام است. اگر بخواهیم بُعد فرکتالی d_f این فرآیند را محاسبه کنیم، لازم است حداقل تعداد $N(r)$ از تک گوی‌هایی به طول r که برای پوشش این مسیرها لازم است را محاسبه کنیم. با انتخاب $r = r_0$ خواهیم داشت:

$$N(r_0) = nN(\sqrt{n}r_0) \tag{۹.۳}$$

همانطور که میدانیم گشتاور اول و دوم جابجایی خالص پس از m گام، هم برای یک پیمایش تصادفی m گام به طول r_0، و هم برای یک پیمایش تصادفی m/n گام به طول $\sqrt{n}r_0$ دقیقاً یکسان است. با فرض $N(r_0) \sim {r_0}^{-d_F}$، $d_F = 2$ بدست می‌آید و با دانستن اینکه بُعد توپولوژیکی یک مسیر پیمایش تصادفی تعبیه شده در $\mathscr{R}^d$، $d_T = 1$ است، نتیجه این می‌شود که تحقق‌های این فرآیند برای $d \geq 2$، فرکتال‌های تصادفی هستند. این بدان معناست که خود فرآیند تولید، خودمتشابه است و این همچنین به معنای تغییرناپذیری مقیاس آماری قوانین آماری زیربنایی است. به عنوان مثال، فرض کنید $p(\vec{x})$ یک توزیع گاوسی باشد:

$$p(\vec{x}) = \frac{1}{(2\pi\sigma^2)^{d/2}} e^{-\frac{|\vec{x}|^2}{2\sigma^2}} \tag{۱۰.۳}$$

[1] Statistical scale invariance

توزیع احتمال جابجایی $\vec{X}_n = \sum_{i=1}^{n} \vec{x}_i$ پس از n مرحله به صورت زیر است:

$$p_n(\vec{X}_n) = \int \prod_{i=1}^{n} d\vec{x}_i p(\vec{x}_i) \delta^{(d)}(\vec{X}_n - \sum_{i=1}^{n} \vec{x}_i) = \\ \dots \\ = \frac{1}{(2\pi n\sigma^2)^{d/2}} e^{-\frac{|\vec{X}_n|^2}{2n\sigma^2}} \tag{۱۱.۳}$$

که دوباره یک تابع گاوسی با انحراف معیار $\sqrt{n}$ برابر بزرگتر از انحراف معیار جابجایی تک مرحله‌ای است. با انجام تغییر مقیاس $\vec{X}_n$ به مقدار $\sqrt{n}$، برای بازیابی مقیاس تک مرحله‌ای اصلی، به دست می‌آید $\vec{x}' = \vec{X}_n/(n)^{d/2}$ که به دلیل پایستگی احتمال تحت تغییر متغیرها، به این معنی است که:

$$p(\vec{x}')d\vec{x}' = p_n(\vec{X}_n)d\vec{X}_n \quad \rightarrow \quad p(\vec{x}') = p(\vec{x}) \tag{۱۲.۳}$$

این بدان معناست که توزیع متغیر تصادفی جدید مقیاس‌بندی‌شده $\vec{x}'$ که از n مرحله جابجایی $\vec{X}_n$ به دست آمده است، مشابه توزیع آن در مرحله اول است. از این رو، فرآیند از نظر آماری نسبت به مقیاس ثابت است. در نتیجه، اگر یک قانون مقیاسی برای جذر میانگین مربعات جابجایی فرآیند پس از n مرحله فرض کنیم:

$$\bar{R}(n,\sigma) = \left(\left\langle |\vec{X}_n|^2 \right\rangle\right)^{1/2} \sim n^{\nu} \tag{۱۳.۳}$$

یک قانون توان با توان $\nu = 1/2$ بدست می‌آید.

۳.۲.۳ مقیاس‌بندی یک گام تصادفی ساده

اگر یک گام تصادفی ساده را با فرض $f(t) \sim N(0,\sigma^2)$ در نظر بگیریم که با معادله تفاضلی بیان می‌شود:

$$x(t+1) = x(t) + f(t) \tag{۱۴.۳}$$

استخراج ویژگی‌های مقیاس‌بندی فرآیند از گشتاورهای توزیع افزایش‌ها ساده است. با تعریف $y_\tau(t) = x(t+\tau) - x(t)$، به دلیل استقلال متغیرهای $f(t)$، توزیع آن به صورت زیر است:

$$y_\tau(t) \sim N(0, \tau\sigma^2) \tag{۱۵.۳}$$

که بدیهی است به t بستگی ندارد. از این رو نتیجه می‌شود:

$$\mathbb{E}(|y_\tau(t)|^q) = \frac{(\sigma^2\tau)^{\frac{1+q}{2}}}{2^{\frac{q}{2}}\sqrt{\pi\sigma^2\tau}}\Gamma(\frac{1+q}{2}) \sim \tau^{q/2} \tag{۱۶.۳}$$

که نشان می‌دهد چگونه فرآیند افزایش‌ها برای یک پیمایش تصادفی ساده با τمقیاس‌بندی می‌شود. در بخش‌های بعدی اهمیت این رابطه مقیاس‌بندی نشان داده خواهد شد.

۳.۳ فرآیندهای خودوابسته و نمای هرست

برای تعمیم مفاهیم ذکر شده، تعریف فرآیندهای خودهمبسته که دسته وسیع‌تری از فرآیندها هستند و شامل فرآیندهای خودمتشابه نیز می‌شوند، مهم است. همچنین یکی از شناخته‌شده‌ترین معیارهای حافظه بلندمدت در تحلیل سری‌های زمانی، توان هرست، معرفی خواهد شد.

۱.۳.۳ فرآیندهای خودهمبسته

نعریف ۷: با فرض $X(0) = 0$، یک فرآیند تصادفی $X(t)$ وجود دارد که شرایط زیر را برآورده می‌کند:

$$\{X(ct_1), ..., X(ct_k)\} \overset{d}{=} \{c^H X(t_1), ..., c^H X(t_k)\} \tag{۱۷.۳}$$

برای برخی $H > 0$ و همه $c > 0$، خودهمبسته نامیده می‌شود. H شاخص خودهمبستگی یا توان مقیاس‌بندی $X(t)$ نامیده می‌شود. برای روشن‌تر شدن موضوع، می‌توان گفت که خودهمبستگی امکان مقیاس‌بندی‌های مختلف در امتداد جهت‌های یک پایه متعامد را فراهم می‌کند، در حالی که خودهمانندی نیاز به مقیاس‌بندی‌های یکسان در امتداد هر جهت دارد. از این رو، اشیاء خودهمانند تحت هر دو انبساط و

چرخش ثابت هستند. نمونه‌های معمول فرآیندهای خودهمبسته مورد استفاده در امور مالی، فرآیندهای پایدار-L و حرکت‌های براونی کسری، $B_H(t)$ هستند. در حالی که مورد اول با افزایش‌های پایدار و مستقل مشخص می‌شود، افزایش‌های وابسته با خودهمبستگی منفی برای $0 < H < 1/2$ و خودهمبستگی مثبت برای $1/2 < H < 1$ دارد. وقتی $H = 1/2$ باشد، این حرکت‌های براوونی کسری به یک حرکت براونی ساده تبدیل می‌شوند. [۱۵، ۲۷]

۲.۳.۳ نمای هرست

توان هرست یک معیار آماری از حافظه بلندمدت سری‌های زمانی است و می‌توان آن را از رفتار مجانبی تابع خودهمبستگی بدست آورد. [۲۷، ۳۴]

برای مثال، اگر یک تابع گاوسی استاندارد ایستای $X(t)$ با $\mathbb{E}[X(t)] = 0$ و $\mathbb{E}[X^2(t)] = 1$ در نظر بگیریم، تابع خودهمبستگی:

$$C(\Delta t) = \mathbb{E}\{X(t)X(t + \Delta t)] \tag{۱۸.۳}$$

می‌تواند برای اندازه‌گیری زبری پروفیل $X(t)$ در صفحه اقلیدسی مفید باشد. در واقع، اگر تابع همبستگی به صورت زیر رفتار کند

$$C(\Delta t) \sim 1 - |\Delta t|^{\alpha}, \quad for \quad \Delta t \to 0 \tag{۱۹.۳}$$

برای $\alpha \in (0, 2]$ می‌توان بُعد فرکتال مسیر تصادفی $X(t)$ را با رابطه زیر استخراج کرد:

$$d_F = 2 - \frac{\alpha}{2} \tag{۲۰.۳}$$

از سوی دیگر، با تحلیل رفتار مجانبی در تأخیرهای زمانی بزرگ $C(t)$، می‌توان وابستگی بلندمدت فرآیند را کمّی کرد:

$$C(\Delta t) \sim |\Delta t|^{-\beta}, \quad for \quad \Delta t \to +\infty \tag{۲۱.۳}$$

برای $\beta \in (0,1)$. توان هرست از این کمیت با معادله زیر تعریف می‌شود:

$$H = 1 - \frac{\beta}{2} \tag{۲۲.۳}$$

و اطلاعاتی در مورد وابستگی به حافظه بلندمدت فرآیند ارائه می‌دهد. بر این نکته تأکید داریم که بُعد فرکتال یک ویژگی محلی[۱] است در حالی که وابستگی به حافظه بلندمدت یک ویژگی سراسری[۲] است. برای فرآیندهای خودمتشابه (در یک فضای n بعدی)، ویژگی‌های محلی در مقیاس‌های بزرگتر نیز حفظ می‌شوند و بنابراین خواهیم داشت:

$$d_F = n + 1 - H \tag{۲۳.۳}$$

به طور کلی، فرآیندهایی که با $H \in (0.5, 1)$ مشخص می‌شوند، با وابستگی به حافظه بلندمدت یا پایداری مشخص می‌شوند، در حالی که وقتی $H \in (0, 0.5)$ باشد، گفته می‌شود که فرآیند ضدپایدار است. به طور کلی، همانطور که نشان داده خواهد شد، توان هرست را می‌توان صرف نظر از خواص آماری فرآیند زیربنایی تولیدکننده آنها، روی سری‌های زمانی اندازه‌گیری کرد، با این وجود باید همیشه بررسی شود که روابط مقیاس‌بندی فرض شده از نظر تجربی معتبر باشند.

۳.۳.۳ تحلیل آماری بازمقیاس‌شده‌ی محدوده

بین دهه پنجاه و شصت میلادی، آقای هرست و همکارانش یک تکنیک برای تحلیل آماری توصیف وابستگی بلندمدت سطح آب در انواع مختلف کانال‌ها و مخازن معرفی کردند. [۳۵، ۳۶] این روش، تحلیل آماری بازمقیاس‌شده[۳] نامیده می‌شود و ابزاری کاربردی برای بدست آوردن توان هرست یک سری زمانی معین است. با توجه به یک سری زمانی $X(t)$ که برای $t = n, 2n, 3n, \ldots$ تعریف شده است، میانگین و انحراف معیار در یک پنجره زمانی عبارتند از:

$$\begin{aligned} \langle X \rangle_T &= \tfrac{n}{T} \sum_{K=1}^{T/n} X(kn) \\ S(T) &= (\tfrac{n}{T} \sum_{K=1}^{T/n} [X(kn) - \langle X \rangle_T]^2)^{1/2} \end{aligned} \tag{۲۴.۳}$$

[1] Local property

[2] Global property

[3] Re-scaled Statistical Analysis

دامنه R از سری زمانی به صورت اختلاف بین حداکثر و حداقل مقادیر $X(t)$ در بازه $[n, T]$ تعریف می‌شود:

$$R(T) = \max_{n \le t \le T}[X(t)] - \min_{n \le t \le T}[X(t)] \tag{۲۵.۳}$$

توان هرست را می‌توان از رابطه مقیاس‌بندی کمیت زیر تعریف کرد:

$$\frac{R(T)}{S(T)} \sim \left(\frac{T}{n}\right)^H \tag{۲۶.۳}$$

بنابراین، این یک روش تقریب می‌تواند به عنوان یک معیار برای وابستگی بلندمدت یک سیگنال استفاده شود و با توجه به این واقعیت که برای یک فرآیند تصادفی مستقل $H = 0.5$ (همچنین به معادله (۱۶.۳) از منظر طیف چندمقیاسی فرآیندهای خودهمبسته به عنوان $H(q)$ و H مرتبط مراجعه کنید)، هنگامی که $H \neq 0.5$باشد، فرآیند اساسی خواص همبستگی غیربدیهی را نشان می‌دهد. بدیهی است که این فقط ساده‌ترین نسخه از این تکنیک است و چندین افزونه‌ی ارتقایافته از آن، در سال‌های اخیر پیشنهاد شده است. [۲۷، ۳۷]

۴.۳ چندفرکتالی و چندمقیاسی

چندفرکتالی بودن[1] در ابتدا در زمینه آشفتگی در مکانیک سیالات مطرح شد و سپس به صورت نظری برای فرآیندهای تصادفی تعریف شد. به طور کلی، سیستم‌هایی که چندفرکتالی بودن را نشان می‌دهند، با قوانین مقیاس‌بندی تعریف شده توسط طیفی از توان‌ها و نه با یک بعد فرکتالی واحد مشخص می‌شوند. [۱۵، ۳۸-۴۰]

یک معیار تصادفی μ که روی بازه $X \in \mathscr{R}$ تعریف می‌شود، نگاشتی است که روی یک فضای احتمال تعریف شده و در کلاس همه معیارها روی X مقداردهی می‌شود. این یک هسته انتقال است که متغیر تصادفی را به هر زیرمجموعه از X اختصاص می‌دهد.

تعریف ۸: یک معیار تصادفی μ که این ویژگی‌ها را برآورده می‌کند: برای هر تبدیل آفین S روی خط حقیقی، برای هر بازه $I_1 \subseteq I_2$

$$\frac{\mu(SI_1)}{\mu(SI_2)} \; and \; \frac{\mu(I_1)}{\mu(I_2)} \tag{۲۷.۳}$$

هرگاه $I_1, I_2, SI_1, SI_2 \subseteq X$ به صورت یکسان توزیع شوند برای همه دنباله‌های غیر نزولی از بازه‌های فشرده $I_1 \subseteq ... \subseteq I_n$ موجود

[1] Multi-Fractality

در X، متغیرهای تصادفی زیر

$$\frac{\mu(I_1)}{\mu(I_2)}, ..., \frac{\mu(I_{n-1})}{\mu(I_n)} \tag{۲۸.۳}$$

که از نظر آماری مستقل هستند؛ خودمتشابه است . [۱۵] اگر بازه X به شکل $[0, T]$ باشد، $0 < T \leq \infty$، ویژگی اول دلالت بر وجود یک فرآیند تصادفی مثبت $M(c)$ مستقل از μ دارد به طوری که :

$$\mu[0, ct] \stackrel{d}{=} M(c)\mu[0, t] \ for \ 0 < t \leq T, \ 0 < c \leq 1 \tag{۲۹.۳}$$

با توجه به دو ثابت $a, b \leq 1$، به لطف ویژگی دوم می‌توان نوشت:

$$\frac{\mu[0, abt]}{\mu[0, t]} = \frac{\mu[0, abt]}{\mu[0, at]} \frac{\mu[0, at]}{\mu[0, t]} \tag{۳۰.۳}$$

که نشان‌دهنده‌ی ویژگی زیر برای فرآیند M است:

$$M(ab) \stackrel{d}{=} M_1(a)M_2(b) \tag{۳۱.۳}$$

که در آن M_1 و M_2 دو کپی مستقل از M هستند. برای تکمیل این بحث، با این فرض که بدون از دست دادن کلیت، $X = [0, 1]$ باشد، و با در نظر گرفتن $\mu(a) \equiv \mu[0, a]$، رابطه فوق حاکی از:

$$\mathbb{E}[M(a)^q] = a^{\tau(q)+1} \tag{۳۲.۳}$$

است و بنابراین خواهیم داشت:

$$\mathbb{E}[\mu(a)^q] = \mathbb{E}[\mu(1)^q]a^{\tau(q)+1} \tag{۳۳.۳}$$

که رابطه مقیاس‌بندی است که چندفراکتال‌ها را مشخص می‌کند.پس می‌توان نتیجه گرفت که چندفراکتال بودن نتیجه مستقیم خودهمانندی آماری معیار تصادفی μ است. تابع $\tau(q)$ تابع مقیاس‌بندی است و ویژگی‌های زیر را برآورده می‌کند:

$\tau(0) = -1$، $\tau(1) = 0$، (تقعر به دلیل نابرابری هولدر). [۱۵]

۵.۳ فرآیندهای چندفرکتالی

از معیارهای تصادفی، چندفرکتالی را می‌توان به سادگی به فرآیندهای تصادفی تعمیم داد.

تعریف ۹: یک فرآیند تصادفی $X(t)$ اگر ایستا باشد و شرایط زیر را داشته باشد، چندفراکتال خواهد بود:

$$\mathbb{E}(|X(t)|^q) = c(q)t^{\tau(q)+1}, \ for\ all\ t \in \tau,\ q \in Q \tag{۳۴.۳}$$

که در آن τ و Q بازه‌هایی روی خط حقیقی با طول مثبت هستند به طوری که $0 \in \tau$ ، $[0,1] \in Q$ و $\tau(q)$ و $c(q)$ توابعی با دامنه Q هستند. تابع $\tau(q)$ همان تابع مقیاس‌بندی است که قبلاً در بخش قبلی تعریف شد. تقعر نشان می‌دهد که رابطه مقیاس‌بندی چندفرکتالی فقط می‌تواند برای فواصل زمانی محدود برقرار باشد و بنابراین فرآیندهای چندفرکتالی باید شامل یک تقاطع باشند. می‌توان نشان داد که فرآیندهای خودآفین، چندفرکتالی هستند. برای یک فرآیند خودآفین $\{X(t), t \geq 0\}$، با شاخص خودآفینی H، از تعریف ۷ مشخص است که $X(t) \stackrel{d}{=} t^H X(1)$ است و بنابراین:

$$\mathbb{E}[|X(t)|^q] = t^H E[|X(1)|^q] \tag{۳۵.۳}$$

مقیاس‌بندی تعریف‌شده در رابطه (۳۴.۳) به طور خاص موارد زیر را برقرار می‌کند:

$$\tau(q) = Hq - 1 \quad and \quad c(q) = \mathbb{E}[|X(1)|^q] \tag{۳۶.۳}$$

در این حالت، تابع مقیاس‌بندی در q خطی است و رفتار مقیاسی فقط به H برای توصیف نیاز دارد. از این مشاهده، نتیجه‌ی زیر حاصل می‌شود:

- اگر $\tau(q)$ تابعی خطی از q باشد، فرآیند تک‌مقیاس (تک‌فرکتالی) است.

- اگر $\tau(q)$ تابعی غیرخطی از q باشد، فرآیند چندمقیاس (چندفرکتالی) است.

معمولاً وقتی ویژگی مقیاس‌بندی (۳۴.۳) را به صورت تجربی بازیابی می‌کنیم، ادعا می‌شود که داده‌ها چندمقیاس هستند. [۱۵، ۲۷، ۴۱]

۶.۳ مدل‌های چندفرکتالی در امور مالی

هنگام مطالعه خولص مقیاسی با زمان فرآیندی که تغییرات قیمت یک دارایی مالی را توصیف می‌کند، ویژگی‌های چندمقیاسی به طور گسترده‌ای در بازارهای مختلف مشاهده می‌شوند. بنابراین بسیاری از محققان تصمیم گرفتند مدل‌هایی را ابداع کنند که بتوانند این ویژگی‌ها را با کمک نظریه فرآیندهای چندفرکتالی توضیح دهند. در ادامه دو مدل اصلی در این چارچوب ارائه شده است: مدل چندفرکتالی بازده دارایی‌ها توسط مندلبرات و همکاران و گام تصادفی چندفرکتالی توسط باکری و همکاران. به‌طور خاص، مدل دوم معمولاً به‌عنوان معیاری برای آزمایش اثربخشی روش‌های تخمین چندمقیاسی استفاده می‌شود، زیرا تحلیلی از طیف چندمقیاسی را ارائه می‌دهد. [۱۱، ۱۵، ۲۷، ۴۱-۴۴]

۱.۶.۳ مدل چندفرکتالی بازده دارایی‌ها

در مدل چندفرکتالی بازده دارایی‌ها، قیمت دارایی به عنوان فرآیندی چندمقیاسی با دنباله‌های سنگین و حافظه بلندمدت در نظر گرفته می‌شود و نوسانات با توصیف زمان معاملاتی که توسط تابع چگالی تجمعی یک معیار چندفرکتالی تصادفی ایجاد می‌شود، معرفی می‌شوند. با توجه به قیمت یک دارایی مالی $\{P(t); 0 \leq t \leq T\}$، فرآیند $X(t)$ به صورت زیر تعریف می‌شود:

$$X(t) = \ln P(t) - \ln P(0) \tag{۳۷.۳}$$

با فرض خواص زیر:

- $X(t)$ به عنوان یک فرآیند مرکب تعریف می‌شود:

$$X(t) \equiv B_H[\theta(t)] \tag{۳۸.۳}$$

با حرکت براونی کسری $B_H(t)$ با شاخص خود-همبستگی H، زمان معاملاتی تصادفی $\theta(t)$ (تابع صعودی t).

- زمان معاملاتی (t)، تابع توزیع تجمعی یک معیار چندفرکتالی است که روی $[0, T]$ تعریف شده است، بنابراین یک فرآیند چندفرکتالی

با مسیرهای پیوسته غیرکاهشی و گام‌های ایستا است.

- $B_H(t)$ و $\theta(t)$ و مستقل از یکدیگر هستند.

با این فرضیات، فرآیند $X(t)$، با افزایش‌های ثابت و تابع مقیاس‌بندی $\tau_x(q) \equiv \tau_\theta(Hq)$ چندفرکتالی است.

ماهیت چندفرکتالی این فرآیند، یک رابطه چندمقیاسی (۳۴.۳) را تحمیل می‌کند و بسته به معیار μ که زمان معاملات را مشخص می‌کند و شاخص H حرکت براونی کسری، فرآیند می‌تواند ویژگی‌های متفاوتی را به خود بگیرد.

به عنوان مثال، وقتی $H \geq 0.5$ و $\mathbb{E}(\theta^{Hq})$ متناهی باشد، فرآیند قیمت در مقدار افزایش‌های خود حافظه طولانی دارد و می‌توان دنباله‌های طولانی در توزیع افزایش‌ها، خوشه‌بندی نوسانات یعنی وابستگی طولانی در مقدار مطلق افزایش‌های قیمت و عدم همبستگی در افزایش‌های قیمت را به دست آورد. [۱۵]

۲.۶.۳ مدلسازی سری‌های زمانی مالی با استفاده از ولگشت‌های تصادفی چندفرکتالی

یک فرآیند گام تصادفی چندفرکتالی $X(t)$ فرآیند حدی $\Delta t \to 0$ از یک گام تصادفی استاندارد $X_{\Delta t}(t)$ با واریانس تصادفی است:

$$X(t) = \lim_{\Delta t \to 0} X_{\Delta t}(t) = \lim_{\Delta t \to 0} \sum_{k=1}^{t/\Delta t} \varepsilon_{\Delta t}[k] e^{\omega_{\Delta t}[k]} \tag{۳۹.۳}$$

که در آن $e^{\omega_{\Delta t}[k]}$ نوسان تصادفی است و $\varepsilon_{\Delta t}$ یک نویز سفید گاوسی از واریانس $\sigma^2 \Delta t$ مستقل از $\omega \Delta t$ است. برای به دست آوردن یک طیف چندمقیاسی دقیق برای مقیاس‌های زمانی کوچکتر از مقیاس انتگرالی L، فرآیند $\omega_{\Delta t}$ باید یک فرآیند گاوسی ایستا باشد به طوری که:

$$\begin{aligned} &\mathbb{E}(\omega_{\Delta t}[k]) = -Var(\omega_{\Delta t}[k]); \\ &Cov(\omega_{\Delta t}[k], \omega_{\Delta t}[l]) = \lambda^2 \ln \rho_{\Delta t}[|k-l|] \; where \\ &\rho_{\Delta t}[k] = \left\{ \begin{array}{ll} \frac{L}{(|k|+1)\Delta t} & for |k| \leq L/\Delta t - 1 \\ 1 & otherwise \end{array} \right\} \end{aligned} \tag{۴۰.۳}$$

از رابطه بالا چنین نتیجه می‌شود که نوسانات تا یک تأخیر زمانی L همبستگی دارند. از این ویژگی‌ها، طیف چندمقیاسی زیر حاصل می‌شود:

$$\begin{aligned} &E(|X(t+l) - X(t)|^q) = K_q l^{\varsigma_q} \\ &\varsigma_q = (q - q(q-2)\lambda^2)/2 \end{aligned} \tag{۴۱.۳}$$

پارامتر λ^2 ضریب تناوب نامیده می‌شود و غیرخطی بودن ς_q را کنترل می‌کند، وقتی $\lambda^2 = 0$ فرآیند $X(t)$ یک حرکت براونی با تابع مقیاس‌بندی خطی است. [۱۱، ۴۴] بنابراین می‌توان از این فرآیند برای توصیف نوسانات بازده سری‌های زمانی مالی استفاده کرد: قیمت یک دارایی $P(t)$ توسط $e^{X(t)}$ مدل‌سازی می‌شود که در آن $X(t)$ یک گام تصادفی چندفرکتالی است. از داده‌ها می‌توان پارامترهای مدل را به روش زیر استخراج کرد:

- واریانس σ^2 را می‌توان با استفاده از رابطه $Var(X(t)) = \sigma^2 t$ استخراج کرد.
- L و λ را می‌توان از فرم تقریبی همبستگی بزرگی فرآیند بدست آورد:

$$C_\omega(\tau, l_1, l_2) = Cov(\omega(t, l_1), \omega(t+\tau, l_2)) \simeq -\lambda^2 \ln\left(\frac{\tau}{L}\right), \quad L > \tau \gg \max(l_1, l_2) \qquad (۴۲.۳)$$

آنچه این مدل را بسیار جالب می‌کند این مطلب است که حقایق تجربی مشاهده‌شده شامل عدم همبستگی بین تغییرات قیمت، همبستگی‌های نوسان بلندمدت و همبستگی خطی و غیرخطی بین دارایی‌ها را بازتولید می‌کند. همچنین، طیف چندمقیاسی دقیقاً مشخص است و فقط سه پارامتر برای کنترل ویژگی‌های سری‌های زمانی تولید شده با این مدل مورد نیاز است: σ^2 که واریانس نوسانات را کنترل می‌کند، λ^2 ویژگی‌های تغییرناپذیری مقیاس و همبستگی نوسان را کنترل می‌کند و L که مقیاس عدم ارتباط نوسان را کنترل می‌کند. [۱۱]

۷.۳ روش‌های اندازه‌گیری ویژگی‌های مقیاسی در سری‌های زمانی

همانطور که در بسیاری از آثار مورد مطالعه در مرور ادبیات نشان داده شده، چندمقیاسی‌سازی یک واقعیت آماری پذیرفته‌شده در سری‌های زمانی مالی است و ابزارهای مختلف زیادی برای اندازه‌گیری این ویژگی‌ها آزمایش و ابداع شده‌اند. در این بخش رساله، تمرکز بر روش نمای هرست تعمیم‌یافته و گونه‌ای از این تکنیک است که از دیدگاه معناداری آماری، پایه و اساس محکم‌تری دارد. [۲۷، ۲۸، ۳۷، ۴۱، ۴۳، ۴۵]

۱.۷.۳ روش نمای هرست تعمیم‌یافته

این روش تعمیمی از روش تحلیلی R/S است که قبلاً برای اندازه‌گیری توان استاندارد هرست نشان داده شده و از گشتاورهای مرتبه q ام توزیع افزایش‌های یک سری زمانی برای استخراج رفتار مقیاسی آن استفاده می‌کند. علاوه بر این، با این ابزار می‌توان رفتار تابعی توان‌های مقیاس‌بندی را مطالعه کرد و تشخیص داد که آیا سری زمانی مشاهده شده خواص چندمقیاسی را نشان می‌دهد یا خیر.

با فرض $X(t)$ یک فرآیند با افزایش‌های ایستا، روش توان هرست تعمیم‌یافته تابع زیر را در نظر می‌گیرد:

$$\Xi(\tau, q) = \mathbb{E}[|X(t+\tau) - X(t)|^q] \sim K_q \tau^{qH_q} \quad (۴۳.۳)$$

که در آن $q = \{q_1, ..., q_{\max}\}$ مجموعه گشتاورهای بررسی شده و $\tau = \{\tau_1, ..., \tau_{\max}\}$ مجموعه مقیاس‌های زمانی است که بازده‌ها روی آنها محاسبه می‌شوند. K_q گشتاور q برای $\tau = 1$ است و H_q به اصطلاح توان هرست تعمیم‌یافته است که به q بستگی دارد. واضح است که این روش فرض می‌کند که فرآیند مورد مطالعه رابطه چندمقیاسی (۳۴.۳) را برآورده می‌کند و بنابراین انتظار می‌رود که qH_q به دلیل نابرابری هولدر یک تابع مقعر باشد. برای یک حرکت براونی استاندارد، که یک فرآیند تک‌مقیاسی است، $H_q = H = 0.5$با صرف نظر از qاست ، در حالی که فرآیندهایی با $H > 0.5$ ($H < 0.5$) پایدار (ضد پایدار) نامیده می‌شوند. به منظور تعریف یک پروکسی چندمقیاسی، غیرخطی بودن تابع qHq مورد مطالعه قرار می‌گیرد، زیرا نشان داده شده است که فقط فرآیندهای تک‌مقیاسی دارای توان‌های مقیاس‌بندی هستند که در q خطی هستند. [۱۵، ۲۷، ۴۱] بنابراین، این ویژگی را می‌توان با انجام یک رگرسیون خطی از معادله (۴۳.۳) در مقیاس لگاریتمی-لگاریتمی تجزیه و تحلیل کرد:

$$\ln(\Xi(\tau, q)) = qH_q \ln(\tau) + \ln(K_q) \quad (۴۴.۳)$$

مطمئناً خطی بودن سمت چپ نسبت به $\ln(\tau)$ باید بررسی شود و اگر این روش برقرار باشد، شیب‌های مختلف خطوط مستقیم را در qهای مختلف محاسبه می‌کند. می‌توان با برازش توان مقیاس‌بندی اندازه‌گیری شده با یک چندجمله‌ای درجه دوم، نماینده چندمقیاسی را ابداع کرد: [۲۸، ۴۱]

$$qH_q = Aq + Bq^2 \quad (۴۵.۳)$$

از این رو اگر مقدار تجربی $\hat{B} = 0$ باشد، فرآیند تک‌مقیاس‌بندی است، در حالی که اگر $\hat{B} \neq 0$ باشد، فرآیند چندمقیاسی‌بندی است. معمولاً هنگام مطالعه سری‌های زمانی مالی،

$$|X(t+\tau) - X(t)| = |\ln P(t+\tau) - \ln P(t)| = |r_\tau(t)| \quad (۴۶.۳)$$

فرآیند بازگشت لگاریتمی است. بدیهی است که انتخاب $\tau_{\max}$ ،$\tau_{\min}$ و $q_{\max}$ ،$q_{\min}$ برای دستیابی به نتایج قابل اعتمادی که بینشی در مورد رفتار مقیاس‌بندی واقعی فرآیند مربوطه ارائه می‌دهند، اساسی است.

۱.۱.۷.۳ انتخاب q

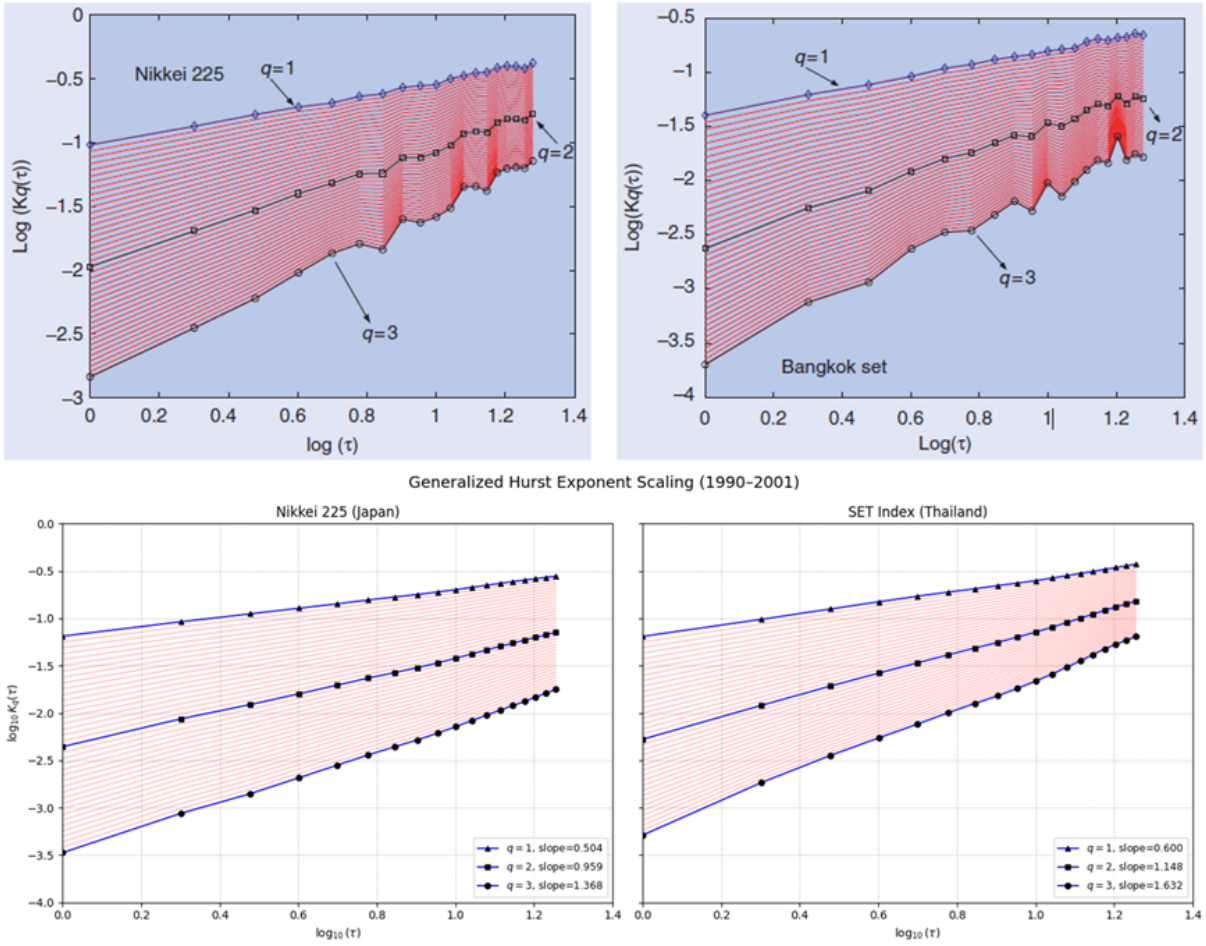
برای انتخاب محدوده صحیح گشتاورها برای انجام تخمین‌های قبلی، می‌توان از دستورالعمل‌های موجود در مرور ادبیات پیروی کرد. برای داشتن یک معیار قوی از چندمقیاسی‌سازی، لازم است که $q < \alpha$ باشد که در آن α توان دم توزیع بازده است، در غیر این صورت رفتاری که با در نظر نگرفتن این واقعیت یافت می‌شود، به شدت دارای سوگیری است. از آنجایی که به طور تجربی نشان داده شده است که سری‌های زمانی مالی دارای دنباله‌های پهن با توان‌های دم از مرتبه‌ی $1.5 \sim$ تا $4 \sim$هستند. [۹، ۱۰، ۴۱]

۲.۱.۷.۳ انتخاب τ

در مورد بازه‌ی تجمیع زمانی، می‌توان در ابتدا یک رویکرد اکتشافی را برای انتخاب داده‌های روزانه $\tau \in [1, 19]$ روز انتخاب کرد، چرا که نزیک‌ترین به حالت گوسی را دارد و چهارچوب به اندازه کافی خوبی را برای برجسته کردن رفتار چندمقیاسی در سری‌های زمانی مالی نشان خواهد داد. با این وجود لازم به ذکر است که این محدوده برخی از سوگیری‌های ناشی از خودهمبستگی‌ها و قوانین توانی را نشان داده است. [۲۷، ۲۸]

۲.۷.۳ نمای هرست تعمیم یافته به عنوان یک معیار اقتصاد کلان

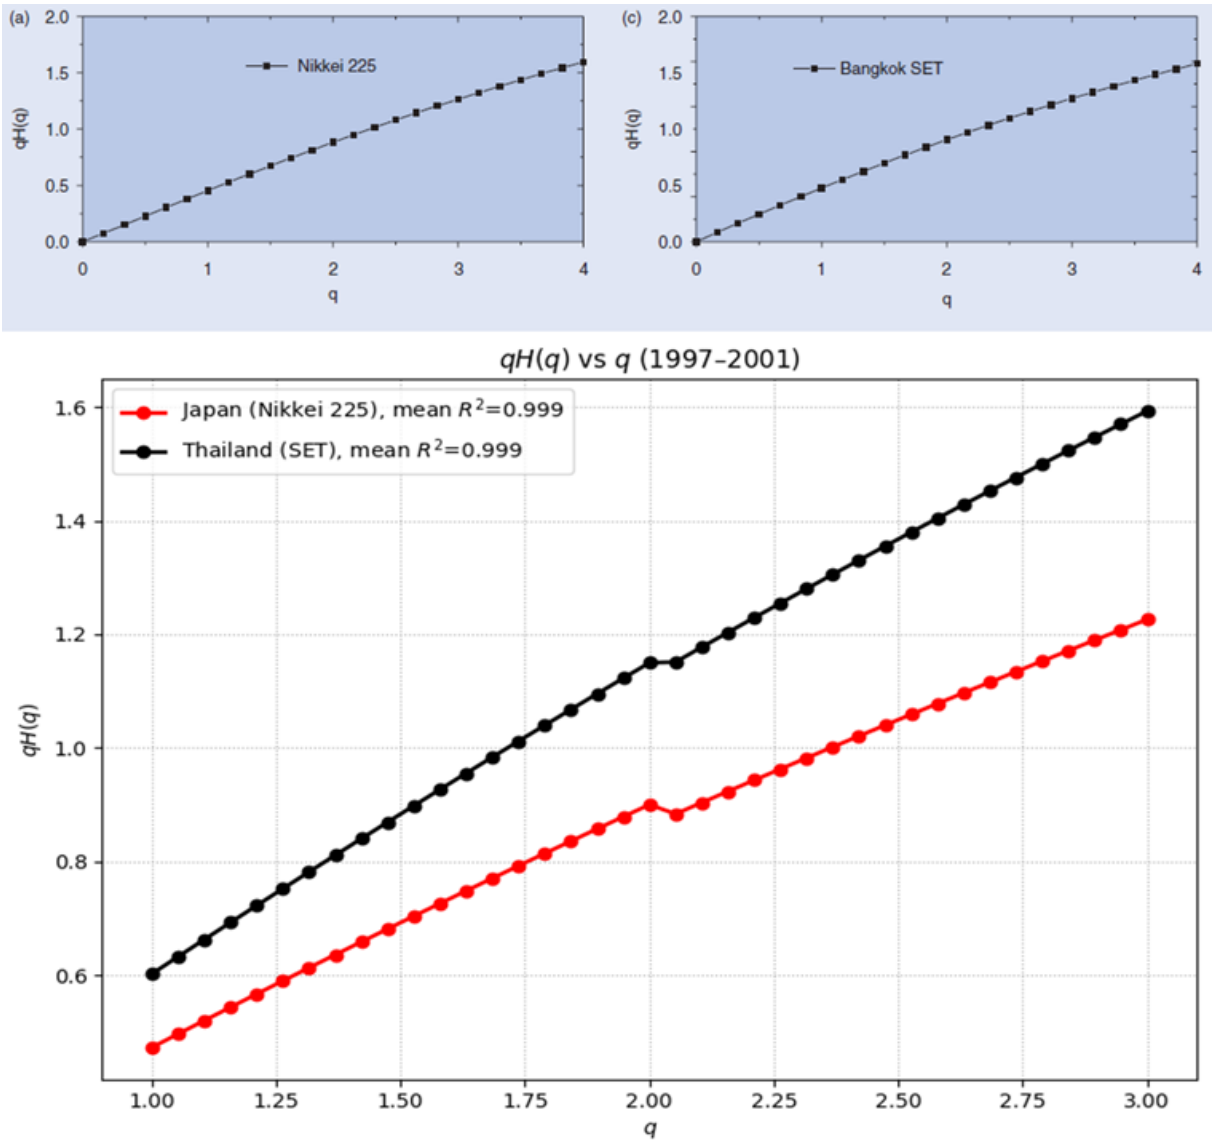
طبق مرور ادبیات، می‌توان ادعا کرد که روش‌های بررسی رفتار مقیاسی با تمرکز بر چندفرکتالی، مانند نمای هرست تعمیم یافته، می‌توانند به عنوان معیاری برای بررسی میزان پیچیدگی اقتصاد کشورها مورد تحقیق قرار گیرند. برای مثال در مقاله‌ی چند مقیاسی در بازارهای مالی [۲۷]، نرخ اوراق خزانه، شاخص پول رایج کشورها نسبت به دلار و شاخص سهام کشورها مورد بررسی قرار گرفت. به عنوان مثال در بررسی نمای هرست تعمیم یافته روی کشورهای درحال توسعه و توسعه یافته می‌توان این را واضحا مشاهده کرد که اقتصادهای توسعه یافته نمودارهای پایدارتری نسبت به اقتصادهای درحال توسعه از خود نشان میدهند و اقتصادهای در حال توسعه با شیب بیشتری نسبت به توسعه یافته حرکت می‌کنند.



شکل ۱.۳: نمای هرست تعمیم یافته (مرور ادبیات (بالا) و مستخرج شده) روی شاخص سهام دو کشور در حال توسعه و توسعه یافته‌ی تایلند و ژاپن بین سال‌های ۱۹۹۰ و ۲۰۰۱

همچنین بررسی شاخص $qH(q)$ نسبت به مرتبه گشتاور آماری به ما نشان میدهد که میزان خمیدگی نمودار کشورهای در حال توسعه

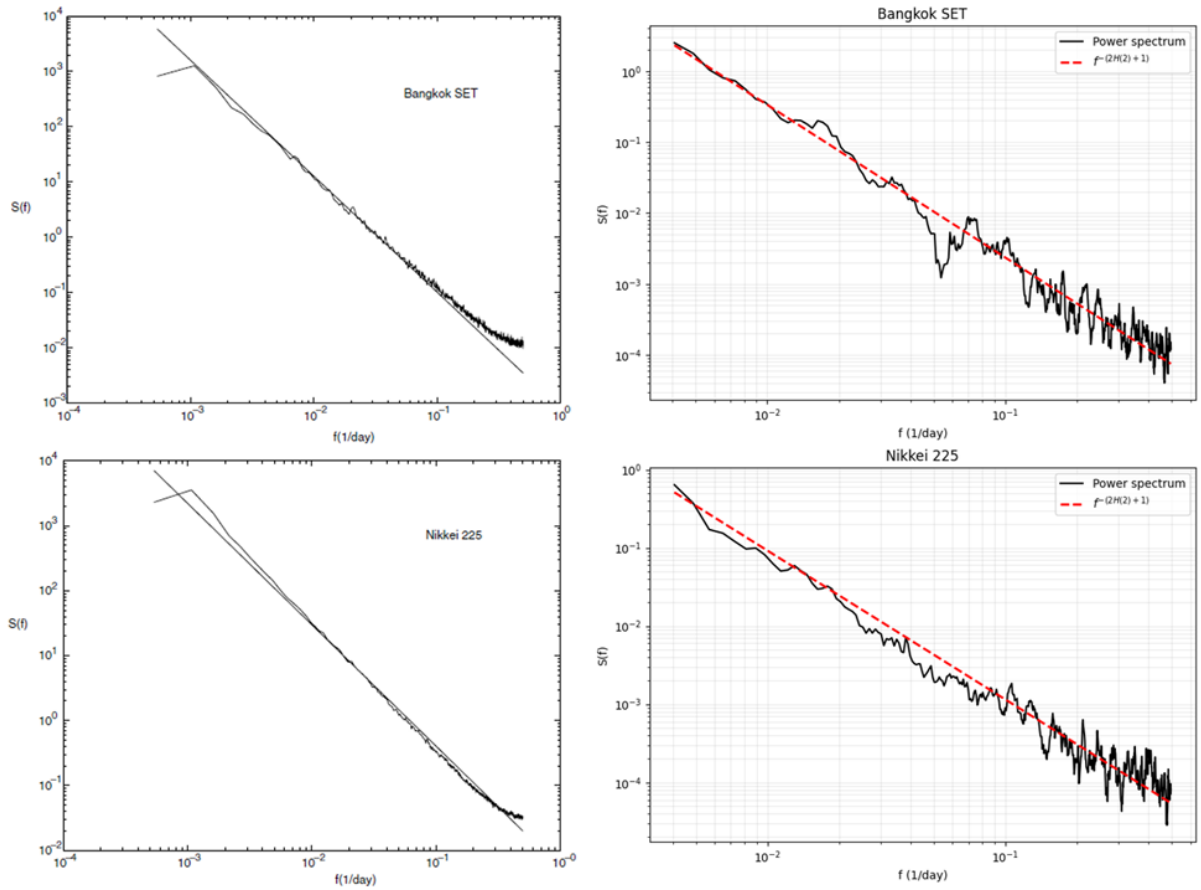
که اقتصاد به نسبت ساده تری نسبت به کشورهای توسعه یافته دارند، متفاوت از این کشورهاست.



شکل ۲.۳: بررسی $qH(q)$ (مرور ادبیات (بالا) و مستخرج شده) روی شاخص سهام دو کشور در حال توسعه و توسعه یافته‌ی تایلند و ژاپن بین سال‌های ۱۹۹۷ و ۲۰۰۱

همچنین با دقت در نمودار بالا می‌توان ادعا کرد که اثر سقوط بازارهای جهان به دلیل حباب دات کام در سال ۲۰۰۰ و در نزدیکی مومنت ۲ به وضوح قابل مشاهده است. برای بررسی بیشتر روش‌های مرتبط به اندازه گیری هرست، این روش‌ها به کمک تحلیل طیفی نیز مورد بررسی قرار گرفته اند. در مقایسه‌ی این روش‌های منوط به تحلیل طیفی $S(f) \propto f^{-2H(2)-1}$ با روش‌های هرست، مشاهده شد که تحلیل‌های طیفی نسبت به روش هرست دارای سوگیری آماری از مرتبه‌ی دو دهم هستند و به دقت روش‌های هرست کار نمی‌کنند. البته با کمک مقایسه‌ی نمودار کشورهای درحال توسعه و توسعه یافته در مرور ادبیات کارهای خانم دکتر دی‌متئو مشاهده شد که کشورهای در حال توسعه همواره $H(2)$ بالاتر از 0.5 داشته و این مقدار برای کشورهای توسعه یافته همواره کمتر از 0.5 بوده است. در شکل زیر نمای هرست برای مومنت دوم گشتاور برای کشور ژاپن در مرور ادبیات کارهای دی‌متئو برابر با 0.43 و برای شاخص سهام کشور تایلند، برابر با 0.55 بدست آمده است.

همپنین در مرور ادبیات، شاخص β برای کشورهای توسعه یافته عددی کمتر از دو و برای کشورهای درحال توسعه، عددی بیشتر از دو است



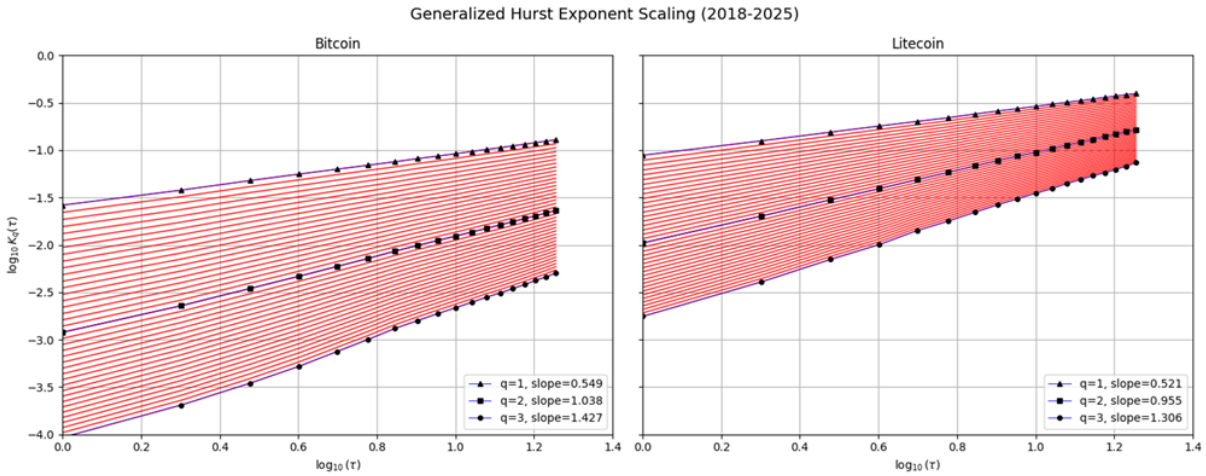
شکل ۳.۳: بررسی تحلیل طیفی نمای هرست (مرور ادبیات (چپ) و مستخرج شده) روی شاخص سهام دو کشور در حال توسعه و توسعه یافته‌ی تایلند و ژاپن بین سال‌های ۱۹۹۷ و ۲۰۰۱

۸.۳ بررسی رفتار مقیاسی در بازار نوظهور رمزارزها

بر اساس مطالعه‌ی مرور ادبیات در حوزه‌ی بازار رمزارزها، این بازارها نه تنها متاثر از قواعد بازار متمرکز خود هستند که همچنان سمت عرضه‌ی آنها تاثیر بسزایی در تعیین قیمت آنها داشته اند. اما امروزه مشاهده می‌شود که عوامل مهم دیگری مانند صندوق‌های قابل معامله در بورس[1] می‌توانند تاثیر بسزایی در این بازارها داشته باشند. عوامل دیگری نیز از این دست عوامل اقتصاد کلان هستند که می‌توانند رفتار این بازارها را تحت الشعاع قرار دهند. رفتار بازار طلا؛ رفتار بازارهای کشورهای توسعه یافته مانند ژاپن و ایالات متحده، شرایط اقتصادی، عدم قطعیت اقتصاد کلان و اتفاقات ژئوپولتیک از این دست هستند. گفته می‌شود که اگرچه رویدادهای هاوینگ بیت کوین همچنان یک مکانیسم مهم در سمت عرضه است، مطالعات اخیر نشان می‌دهد که بیت کوین به طور فزاینده‌ای به عنوان یک دارایی حساس به رفتار اقتصاد کلان

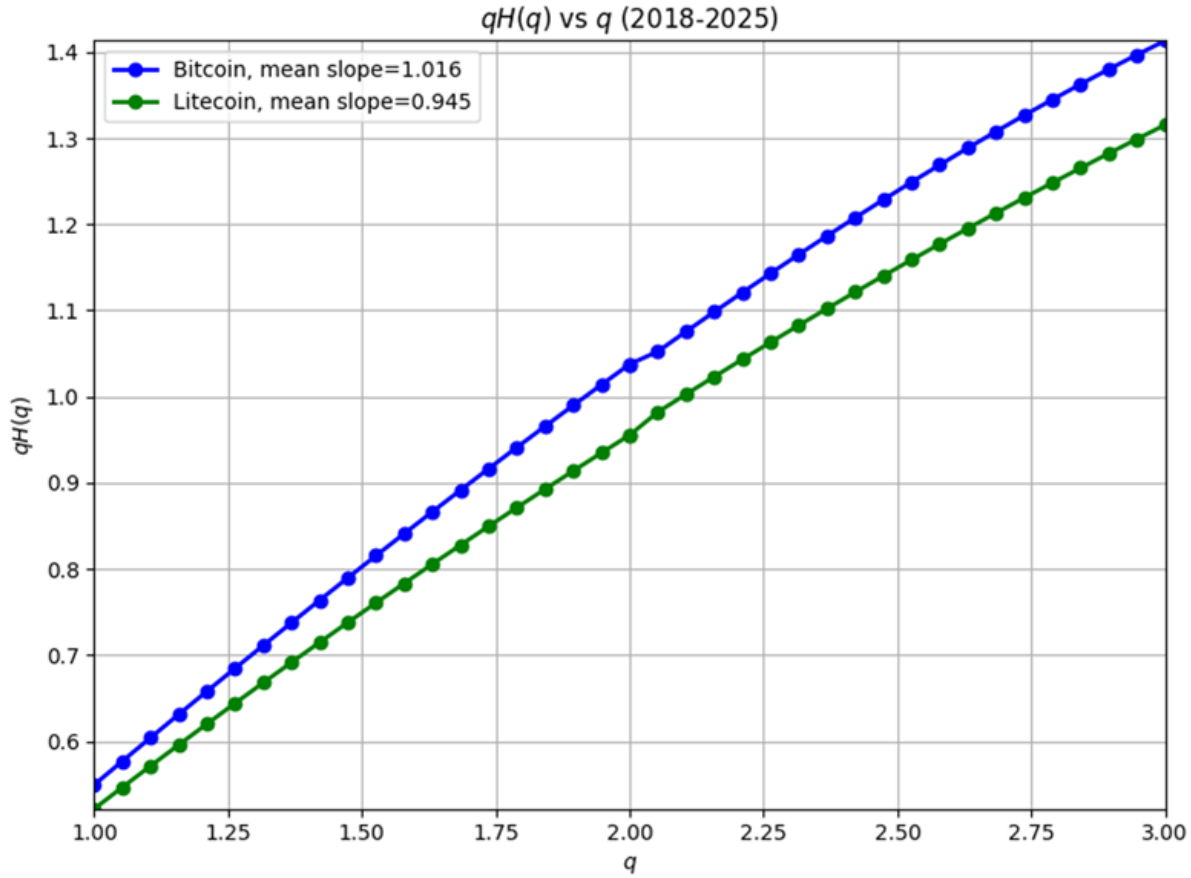
[1] Exchange-traded funds (ETFs)

رفتار کرده است. پذیرش نهادی، نقدینگی جهانی، سیاست پولی و شرایط گسترده‌تر بازار مالی اکنون بخش قابل توجهی از پویایی قیمت بیت کوین را توضیح می‌دهند و تسلط نسبی چرخه سنتی چهار ساله هاوینگ را کاهش می‌دهند. [۶۳-۶۶] در این بخش سعی داریم با بازسازی مرور ادبیات نمای هرست تحلیلی بازارهای رمزارزها داشته باشیم. برای مثال در شکل زیر مقایسه‌ای بین بیت کوین و لایت کوین انجام شده است. همانطور که از مرور ادبیات مشخص است، ادعا می‌شود که از سال ۲۰۱۸ به بعد، شاخص‌های اقتصاد کلان تاثیر بیشتری در بازار بیت کوین داشته اند. در مقایسه‌ی بین نمای هرست تعمیم یافته‌ی بین بیت کوین و لایت کوین می‌توان دید با آنکه بیت کوین پایداری بیشتری نسبت به لایت کوین دارد اما نمودار آن شیب بیشتری نسبت به لایت کوین داشته است.



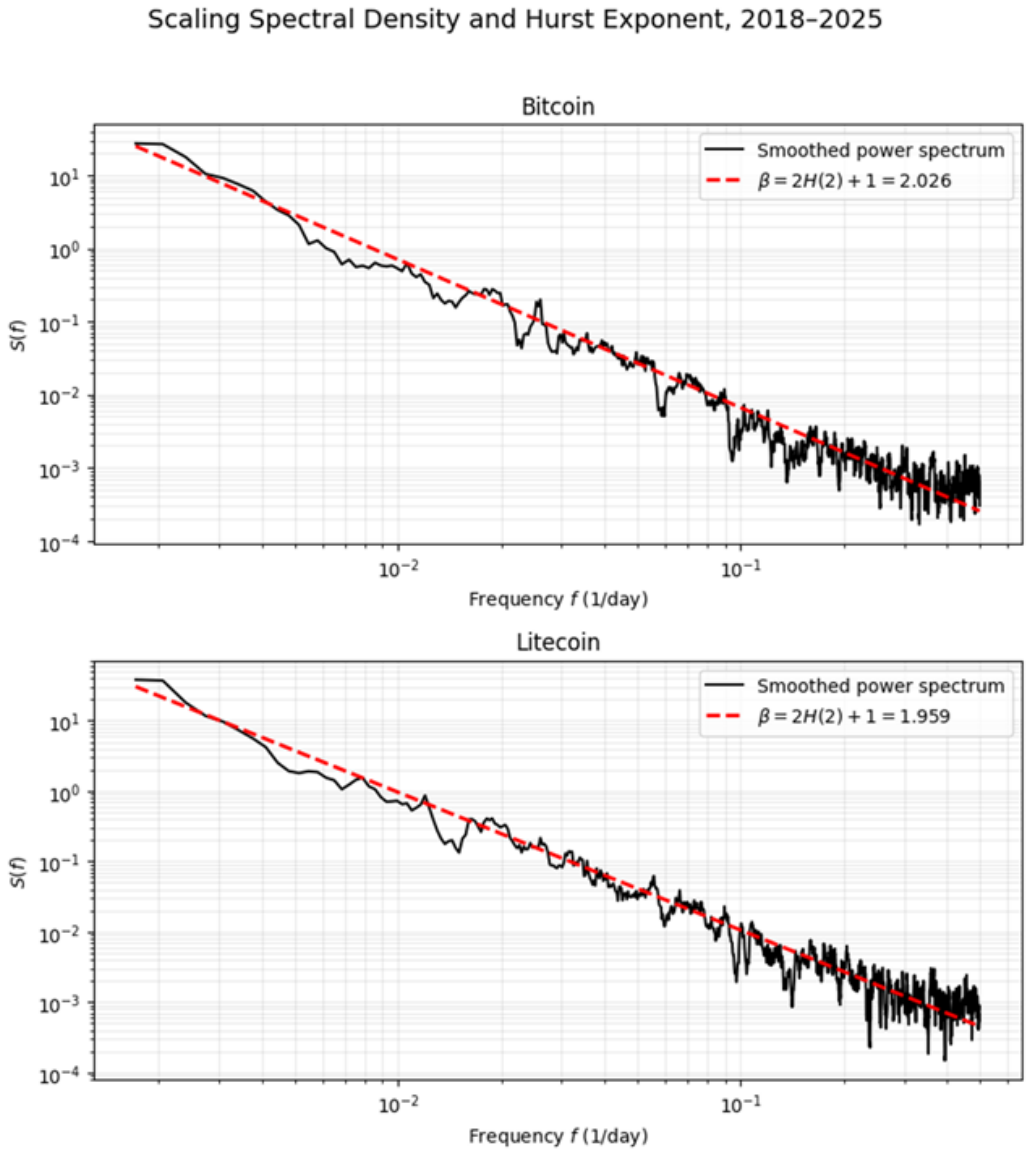
شکل ۴.۳: نمای هرست تعمیم یافته در بازار رمزارزها بین بیت کوین و لایت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۵

همچنین اگر شاخص $qH(q)$ نسبت به گشتاور مومنت مدنظر را برای این دو رمزارز مورد مطالعه قرار دهیم خواهیم دید که لایت کوین رفتار مونوفرکتالی بیشتر از خود نشان داده و شیب بیشتری نسبت به بیت کوین دارد(منحنی‌تر است) در حالی که بیت کوین شیب کمتری دارد و رفتار چندفرکتالی را از خود بیشتر نشان میدهد. همچنان می‌توان مشاهده کرد که تاثیر همه‌گیری ویروس کرونا در نمودار بیت کوین در نزدیکی $q = 2$ منعکس شده است. این درحالی است که نمودار لایت کوین گواهی از این همه‌گیری نداشته و در نمودار میزان پیچیدگی بازارش نمی‌توان اثر این اتفاق را مشاهده کرد.



شکل ۵.۳: بررسی $qH(q)$ در بازار رمزارزها بین بیت کوین و لایت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۵

در آخر برای تحلیل رفتار طیفی این دو رمزارز می‌توان گفت که هم بیت کوین و هم لایت کوین تقریباً مقیاس‌بندی قانون توانی را در حوزه زمان و فرکانس نشان می‌دهند. توان‌های هرست تعمیم‌یافته با افزایش مرتبه گشتاور q کاهش می‌یابند که نشان‌دهنده رفتار چندفرکتالی و دینامیک مقیاس‌بندی متفاوت برای نوسانات کوچک و بزرگ است. بیت کوین با $H(2) \geq 0.5$ پایداری کمی قوی‌تری را نشان می‌دهد، در حالی که لایت کوین با $H(2) \leq 0.5$ ضدپایداری ضعیفی را نشان می‌دهد. توان‌های طیفی، $\beta \approx 2.03$ برای بیت کوین و $\beta \approx 1.96$ برای لایت کوین، با رابطه $\beta = 2H(2) + 1$ سازگار هستند و رفتار مقیاس‌بندی نزدیک به، اما نه دقیقاً برابر با، یک گام تصادفی را نشان می‌دهند. در شکل زیر تحلیل رفتار طیفی نمای هرست این دو رمزارز به مقایسه گذاشته شده است.



شکل ۶.۳: بررسی تحلیل طیفی نمای هرست برای دو رمزارز بیت کوین و لایت کوین

فصل ۴

مدل‌های خطی در تحلیل بازارهای مالی

در زمینه تحلیل بازارهای مالی، از دیرباز به مدل‌های خطی توجه ویژه‌ای شده است. این مدل‌ها طیف وسیعی داشته و غالبا اطلاعات خطی موجود در دیتاها را متوجه می‌شوند. برای مثال خانواده‌ی مدل‌های ARIMA/ARMA[1] مدل‌هایی هستند که کمک تحلیل گذشته‌ی بازار توسط فرآیندهای خودرگرسیو و تحلیل روندهای بازار به کمک پنجره ای ایده‌آل از میانگین متحرک کار می‌کنند. حال اگر واریانس نمونه‌ها در حال افزایش باشند و در گذر زمان مقدار ثابتی نداشته باشند، مدل‌های دیگری در اینجا مورد استفاده قرار می‌گیرند که زیرمجموعه‌ی خانواده‌ی مدل‌های ARCH/GARCH[2] هستند. دلیل این اتفاق این است که این مدل‌ها در کنار کد کردن دیتای گذشته‌ی بازار، افت و خیزهای بازار را نیز متوجه می‌شوند و سعی بر آن دارند که ناهمسانگردی واریانس نمونه‌ها را نیز متوجه شوند. در این فصل سعی بر این داریم که در کنار معرفی این مدل‌ها به کمک شبیه سازی کاربرد آنها را نیز در تحلیل بازارهای مالی متوجه شویم.

[1] Autoregressive integrated moving average (ARIMA)

[2] Generalized AutoRegressive Conditional Heteroskedasticity (GARCH)

۱.۴ فرآیندهای خودرگرسیو

فرآیندهای خودرگرسیو یکی از بلوک‌های اساسی مدل‌های خطی در تحلیل سری‌های زمانی در امور مالی را تشکیل می‌دهند. آن‌ها یک چارچوب برای ثبت وابستگی زمانی در متغیرهای مالی، به ویژه بازده دارایی‌ها، نرخ بهره و شاخص‌های کلان مالی ارائه می‌دهند. مدل‌های خودرگرسیو با مدل‌سازی ارزش فعلی یک سری به عنوان تابعی خطی از تحقق‌های گذشته خود، این امکان را می‌دهند که پایداری، رفتار بازگشت به میانگین و پیش‌بینی‌پذیری این سری‌های زمانی را مطالعه کنند. با وجود سادگی، مشخصات خودرگرسیو اغلب به عنوان مدل‌های معیار و مدل‌های خط پایه[۱] استفاده می‌شوند که مدل‌های غیرخطی[۲] و پیچیده‌تر در برابر آن‌ها ارزیابی می‌شوند. [۸، ۴۶، ۴۷]

۱.۱.۴ فرآیندهای خودرگرسیونی

یک فرآیند خودرگرسیونی از مرتبه p، که با AR(p) نشان داده می‌شود، به صورت زیر تعریف می‌شود:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + ... + \phi_p X_{t-p} + \varepsilon_t, \tag{۱.۴}$$

که در آن ε_t یک نویز سفید با میانگین صفر و واریانس ثابت است و $\phi_1, \phi_2, ..., \phi_p$ ضرایب ثابت هستند. با استفاده از عملگر تأخیر L، مدل را می‌توان به صورت فشرده به صورت $\Phi(L)X_t = \varepsilon_t$ نوشت، که در آن $\Phi(L) = 1 - \phi_1 L - ... - \phi_p L^p$ است. این نمایش، ساختار وابستگی خطی را برجسته‌تر می‌کند و بدین ترتیب تحلیل مدل‌ها آسان‌تر می‌شوند.

۲.۱.۴ شرایط ایستایی

برای اینکه یک فرآیند AR(p) به صورت ضعیف ایستا باشد، ریشه‌های معادله مشخصه $\Phi(z) = 0$ باید خارج از دایره واحد در صفحه مختلط قرار بگیرند. تحت این شرایط می‌توان ادعا کرد که این فرآیند می‌تواند یک میانگین متحرک نامتناهی از داده‌های زمان‌های گذشته را بپذیرد. ایستا بودن تضمین می‌کند که ویژگی‌های آماری مدنظر ما مانند میانگین و واریانس، نسبت به زمان ثابت هستند، که این مهم برای استنتاج مدل، در امور مالی ضروری است. در عمل، بسیاری از سری‌های بازده مالی به صورت ایستا مدل‌سازی می‌شوند، در حالی که سطوح قیمت اغلب این شرط را نقض می‌کنند و نیاز به تفاضل‌گیری دارند.

[1] Baseline models

[2] Non-Linear models

۳.۱.۴ گشتاورها و ساختار وابستگی

وقتی ایستایی برقرار باشد، گشتاورها و ساختار وابستگی یک فرآیند خودرسگرسیو به خوبی تعریف خواهند شد. میانگین غیرشرطی ثابت خواهد بود و معمولاً صفر است، فقط در زمانی که هیچ عرض از مبدایی در نظر گرفته نشود، در حالی که واریانس به ضرایب خودهمبستگی نیز بستگی دارد. توابع خودکوواریانس[۱] و خودهمبستگی، سیستمی از معادلات خطی معروف به معادلات یول-واکر[۲] را برآورده می‌کنند که نحوه کاهش وابستگی‌ها را در طول زمان مشخص می‌کنند. در امور مالی، این ساختار به مدل‌های خودرگرسیو این اجازه را می‌دهد تا رفتار حافظه کوتاه‌مدت را ثبت کنند، دقیقا جایی که این همبستگی‌ها به صورت هندسی کاهش می‌یابند.

۴.۱.۴ روش‌های تخمین

پارامترهای یک مدل خودهمبسته را می‌توان با استفاده از چندین روش شناخته‌شده تخمین زد. رویکرد یول-واکر بر تطبیق خودکوواریانس‌های نظری با نمونه‌های متناظر آنها متکی است که منجر به یک سیستم معادلات خطی می‌شود. تخمین حداقل مربعات معمولی[۳] معمولاً به دلیل سادگی آن تحت فرضیات استاندارد، به ویژه هنگامی که نوآوری‌ها[۴] ناهمبسته هستند، استفاده می‌شود. تخمین حداکثر درست نمایی[۵] چارچوب جایگزینی را ارائه می‌دهد که در خطاهای گاوسی به طور مجانبی کارا است و امکان تحلیل مدل‌ها مبتنی بر احتمال را فراهم می‌کند.

۱.۴.۱.۴ حداقل مربعات معمولی

روش حداقل مربعات معمولی یک روش تخمین پارامتر است که مجموع مربعات باقیمانده‌ها بین مقادیر مشاهده شده و پیش‌بینی‌های مدل را به حداقل می‌رساند. در چارچوب یک مدل AR(p)، این فرآیند به شکل رگرسیون نوشته می‌شود، که در آن متغیر وابسته X_t بر روی مقادیر تأخیری $X_{t-1}, ..., X_{t-p}$ رگرسیون می‌شود. تحت فرض میانگین صفر، نوآوری‌های غیرهمبسته با واریانس ثابت، حداقل مربعات معمولی برآوردگرهای بی‌طرف و سازگار از ضرایب خودرگرسیونی ارائه می‌دهند. به دلیل این سادگی محاسباتی و همچنین هم‌ارزی مجانبی با حداکثر درستنمایی تحت خطاهای گاوسی، این روش را به انتخابی استاندارد در تحلیل بازارهای مالی تبدیل می‌کند.

---

[1] Autocovariance

[2] The Yule Walker Equations

[3] Ordinary least squares (OLS)

[4] innovations (error terms/random shocks)

[5] Maximum Likelihood Estimate (MLE)

۲.۴.۱.۴ تخمین حداکثر درستنمایی

تخمین حداکثر درستنمایی، پارامترهای مدل را با به حداکثر رساندن چگالی احتمال مشترک داده‌های مشاهده‌شده مشروط به مدل تعیین می‌کند. برای یک فرآیند خودرگرسیو با نوآوری‌های گاوسی[۱]، تابع درستنمایی از توزیع نرمال جملات خطا که توسط ضرایب خودرگرسیون و واریانس نوآوری پارامتری شده‌اند، مشتق می‌شود. این روش تخمینی برآوردگرهای مجانبی کارآمدی را تولید می‌کند و استنتاج مبتنی بر درستنمایی، مانند آزمون فرضیه و ساخت فاصله اطمینان را امکان‌پذیر می‌سازد. در عمل نیز، این روش تخمینی هنگام گسترش مدل‌های خودرگرسیو به ساختارهای پیچیده‌تر یا زمانی که فرضیات توزیعی نقش مهمی دارند، مفید واقع می‌شوند.

۵.۱.۴ انتخاب مدل و تشخیص

انتخاب مرتبه مناسب برای پارامتر p گامی بسیار مهم در مدل‌سازی خودرگرسیو است. معیارهای اطلاعاتی مانند معیار اطلاعاتی آکائیک[۲] و معیار اطلاعاتی بیزی[۳] به طور گسترده برای ایجاد تعادل بین کیفیت برازش و صرفه‌جویی در مدل استفاده می‌شوند. بررسی‌های تشخیصی شامل بررسی خودهمبستگی باقیمانده از طریق همبستگی‌نگارها یا آزمون‌های رسمی برای ارزیابی کفایت مدل است. پایداری و ایستایی مدل تخمین زده شده نیز بررسی می‌شود تا اطمینان حاصل شود که فرآیند برازش در طول زمان می‌تواند به خوبی رفتار کند.

۱.۵.۱.۴ معیار اطلاعات آکائیک

معیار اطلاعات آکائیک یک معیار انتخاب مدل است که برای ایجاد تعادل بین خوبی برازش و پیچیدگی مدل طراحی شده است. این معیار به صورت زیر تعریف می‌شود:

$$AIC = -2\log L + 2k, \tag{۲.۴}$$

که در آن L درستنمایی حداکثر شده و k تعداد پارامترهای تخمین زده شده است. معیار آکائیک با افزایش ابعاد مدل، بیش‌برازش را جریمه می‌کند، در همین حال از طریق عبارت درستنمایی، برازش بهتر را پاداش می‌دهد. در مدل‌سازی خودهمبستگی، معیار آکائیک تمایل به مدل‌های انعطاف‌پذیرتر دارد و اغلب در زمانی کاربرد دارد که دقت پیش‌بینی بر صرفه‌جویی اولویت دارد.

[1] Gaussian Innovations

[2] The Akaike information criterion (AIC)

[3] Bayesian information criterion (BIC)

۲.۵.۱.۴ معیار اطلاعات بیزی

معیار اطلاعات بیزی یک چارچوب انتخاب مدل جایگزین با جریمه قوی‌تر برای پیچیدگی ارائه می‌دهد. این معیار به صورت زیر داده می‌شود:

$$BIC = -2\log L + k\log T, \tag{۳.۴}$$

که در آن T نشان دهنده حجم نمونه است. در مقایسه با معیار آکائیک، این معیار بیزی مدل‌های ساده‌تر به ویژه در نمونه‌های بزرگ را ترجیح می‌دهد و در انتخاب ترتیب واقعی مدل تحت فرضیات استاندارد، ثابت قدم است. در اقتصادسنجی مالی[1]، معیار بیزی معمولاً زمانی کارا است که تفسیرپذیری ساختاری و صرفه‌جویی مورد تأکید قرار گیرد.

۶.۱.۴ کاربردها و محدودیت ها

مدل‌های خودرگرسیو اغلب برای مدل‌سازی بازده دارایی‌ها، نرخ بهره و تحلیل سری‌های زمانی مالی که وابستگی سریالی به داده‌های زمان‌های گذشته نشان می‌دهند، به کار می‌روند. آن‌ها به عنوان مدل‌های پایه برای آزمایش پیش‌بینی‌پذیری بازده و کارایی بازار در فرم ضعیف عمل می‌کنند. مشخصات خودرگرسیو همچنین در چارچوب‌های پیچیده‌تری مانند ARMA یا مدل‌های فضای حالت تعبیه شده‌اند تا پویایی‌های بهتری از درک داده‌های مالی را به تصویر بکشند. با وجود قدرت پیش‌بینی محدود به علت عدم درک روابط غیرخطی در مدل‌ها، در بسیاری از محیط‌های تجربی، مدل‌های خودرگرسیو برای الگوبرداری و تفسیر ساختاری همچنان به عنوان مدل خط پایه ارزشمند هستند. حال گرچه مدل‌های خودرگرسیون از نظر تحلیلی کنترل‌پذیر و تخمین آن‌ها آسان است، اما محدودیت‌های قابل توجهی در تحلیل‌های مالی دارند. ساختار خطی آنها توانایی ثبت وابستگی‌های غیرخطی و تغییرات رژیمی را که معمولاً در بازارهای مالی مشاهده می‌شود، محدود می‌کند. علاوه بر این، مدل‌های خودرگرسیو واریانس را ثابت فرض می‌کنند و این امر آنها را برای مدل‌سازی خوشه‌بندی نوسانات و ریسک متغیر با زمان ناکافی می‌کند. این محدودیت‌ها، استفاده از مدل‌های توسعه‌یافته، مانند فرآیندهای نوع GARCH و مدل‌های سری زمانی غیرخطی را که ویژگی‌های تجربی داده‌های مالی را بهتر در خود جای می‌دهند، ترغیب می‌کند.

[1] financial econometrics

۲.۴ خانواده‌ی مدل‌های ARIMA

۱.۲.۴ دامنه‌ی انواع مدل‌ها

سری‌های زمانی مالی اغلب وابستگی زمانی، پایداری و پویایی‌های در حال تکاملی را نشان می‌دهند که نمی‌توان آن‌ها را به طور کافی توسط مدل‌های ایستا به تصویر کشید. خانواده ARMA دسته‌ای انعطاف‌پذیر از فرآیندهای تصادفی خطی را ارائه می‌دهد که قادر به مدل‌سازی وابستگی زمانی از طریق مؤلفه‌های خودرگرسیو و میانگین متحرک هستند. این مدل‌ها به دلیل قابلیت تحلیلی، نظریه آماری مناسب برای پیش‌بینی‌های عمدتا کوتاه‌مدت، به ویژه در امور مالی جذاب هستند. چارچوب ARMA وابستگی خطی و ایستایی ضعیف را فرض می‌کند که به خوبی با بسیاری از متغیرهای رایج در حیطه‌ی بازارهای مالی، مانند بازده لگاریتمی، نرخ رشد و شاخص‌های کلان بدون روند همسو است.

۲.۲.۴ مدل‌های ARMA

یک مدل میانگین متحرک خودرگرسیو دینامیک خودرگرسیو[1] را که مقدار فعلی یک سری را به داده‌های گذشته‌ی خود مرتبط می‌کند، با دینامیک میانگین متحرک که وابستگی به شوک‌های گذشته را ثبت می‌کند، ترکیب می‌کند. به طور رسمی، یک فرآیند $ARMA(p, q)$ به عنوان یک تابع خطی از مقادیر تأخیری خود و تعداد محدودی از نوآوری‌های گذشته تعریف می‌شود. در زمینه‌ی امور مالی، اجزای خودرگرسیو اغلب نشان‌دهنده اثرات تکانه یا بازگشت به میانگین هستند، در حالی که عبارات میانگین متحرک نویز ریزساختار یا شوک‌های کوتاه‌مدت را در نظر می‌گیرند. لازم به ذکر است که شرایط ایستایی برای تضمین گشتاورهای تعریف‌شده و برای استنباط آماری از این مدل‌ها، اساسی هستند.

۳.۲.۴ مدل‌های ARIMA

بسیاری از سری‌های زمانی مالی، به ویژه قیمت‌ها و داده‌های کلان اقتصادی، رفتار غیرایستا[2] نشان می‌دهند که با روندهای تصادفی مشخص می‌شود. مدل‌های میانگین متحرک خودرگرسیو یکپارچه (ARIMA) با معرفی عملگرهای تفاضلی که سری را قبل از اعمال ساختار ARMA ایستا می‌کنند، به این مسئله می‌پردازند. یک مدل $ARIMA(p, d, q)$ به صراحت روندهای تصادفی بلندمدت را از پویایی‌های کوتاه‌مدت جدا می‌کند و محیط را برای مدل‌سازی قیمت دارایی‌ها و متغیرهای اقتصادی یکپارچه مناسب می‌سازد. در امور مالی، تفاضل‌گیری معمولا به عنوان تبدیل قیمت‌ها به بازده تعبیر می‌شود که اغلب فرضیات ایستایی مورد نیاز برای مدل‌سازی خطی را برآورده می‌کند.

[1] Autoregressive moving-average model

[2] non-stationarity

۴.۲.۴ بسط‌های فصلی از خانواده‌ی مدل‌های ARIMA

سری‌های زمانی مالی گاهی الگوهای فصلی ناشی از اثرات نهادی، تقویمی یا رفتاری، مانند چرخه‌های گزارش ماهانه‌ی شرکت‌ها یا فعالیت اقتصادی فصلی را نشان می‌دهند. مدل‌های ARMA فصلی [۱] و ARIMA فصلی [۲] با گنجاندن عبارات خودرگرسیو و میانگین متحرک اضافی در وقفه‌های فصلی، چارچوب استاندارد را گسترش می‌دهند. این مدل‌ها امکان مدل‌سازی همزمان پویایی‌های کوتاه‌مدت و وابستگی فصلی مکرر را فراهم می‌کنند. در امور مالی، امتدادهای فصلی در محاسبات نرخ‌های بهره و حجم معاملات که در فواصل منظم مشاهده می‌شوند، کارا هستند.

۵.۲.۴ مدل‌های فصلی و اطلاعات برون‌زا

در حالی که مدل‌های نوع ARMA وابستگی زمانی داخلی را ثبت می‌کنند، بسیاری از سری‌های زمانی مالی نیز تحت تأثیر عوامل اقتصادی خارجی قرار دارند. مدل‌های میانگین متحرک خودرگرسیو فصلی با متغیرهای "برون‌زا" [۳] با گنجاندن متغیرهای کمکی مشاهده‌شده در کنار اجزای خودرگرسیو و میانگین متحرک، چارچوب خود را گسترش می‌دهند. این متغیرهای برون‌زا ممکن است شامل نرخ بهره یا برای مثال متغیرهای سیاستی یا شاخص‌های بازار باشند. گنجاندن اطلاعات برون‌زا به این مدل‌ها اجازه می‌دهد تا پویایی‌های شرطی ناشی از اصول اقتصادی را ثبت کنند و در عین حال ساختار تصادفی خطی خانواده ARIMA را حفظ کنند.

۶.۲.۴ کاربردها و محدودیت‌های استفاده در امور مالی

مدل‌های خانواده ARMA به دلیل قابلیت تفسیر آسان، به طور گسترده برای پیش‌بینی‌های کوتاه‌مدت تا میان‌مدت در امور مالی استفاده می‌شوند. کاربردها شامل پیش‌بینی بازده دارایی‌ها، نرخ بهره، نرخ ارز و متغیرهای کلان مالی و همچنین به عنوان مدل‌های معیار در مطالعات تجربی است. پیش‌بینی‌های خطی مشتق شده از این مدل‌ها، زمانی که مدل به درستی مشخص شده باشد، تحت بررسی میانگین مربعات خطا بهینه هستند. با وجود سادگی، پیش‌بینی‌های مبتنی بر ARMA اغلب در مقایسه با مدل‌های پیچیده‌تر، به ویژه در محیط‌های بازار پایدار، عملکرد رقابتی دارند. این در حالی است که علیرغم کاربرد گسترده، مدل‌های خانواده ARMA محدودیت‌های مهمی را در هنگام اعمال بر داده‌های مالی نشان می‌دهند. ساختار خطی آنها توانایی ثبت دینامیک‌های غیرخطی، تغییرات رژیم و پاسخ‌های نامتقارن به شوک‌ها را محدود می‌کند. علاوه بر این، فرض واریانس همگن و اغلب نوآوری‌های گاوسی با خوشه‌بندی نوسانات و دنباله‌های سنگین که معمولاً در بازده‌های

[1] Seasonal Autoregressive Moving Average (SARMA)

[2] Seasonal Autoregressive Integrated Moving Average (SARIMA)

[3] Seasonal AutoRegressive Integrated Moving Average with eXogenous variables (SARIMAX)

مالی مشاهده می‌شوند، مغایرت دارد. شکست‌های ساختاری، بحران‌های بازار و محیط‌های نهادی در حال تحول، پایداری پارامترهای تخمینی را بیشتر به چالش می‌کشند و انگیزه‌ای برای گسترش به سمت مدل‌های غیرخطی، فضای حالت مبتنی بر نوسانات ایجاد می‌کنند.

۳.۴ خانواده‌ی مدل‌های ARCH

سری‌های زمانی مالی اغلب واریانس‌های ناهمگن داشته و خوشه‌بندی نوسانات را نشان می‌دهند، که در آن دوره‌های نوسانات بالا معمولاً با نوسانات بالا دنبال می‌شوند و دوره‌های نوسانات پایین پس از نوسانات پایین می‌آیند. این مهم در سال ۱۹۶۳ برای اولین بار توسط دانشمند بزرگ مندلبرات نشان داده شد. مدل‌های خطی سنتی که واریانس ثابت را فرض می‌کنند، مانند مدل‌های کلاسیک ARMA، در به تصویر کشیدن این ویژگی شکست می‌خورند. رابرت انگل در سال ۱۹۸۲ مدل ناهمسانی واریانس شرطی خودرگرسیو[1] را برای مدل‌سازی صریح نوسانات متغیر با زمان معرفی کرد. مدل‌های نوع ARCH با اجازه دادن به وابستگی واریانس شرطی بازده به نوآوری‌های مربع گذشته، نمایش دقیق‌تری از پویایی این بازارهای مالی، به ویژه برای مدیریت ریسک و کاربرد در قیمت‌گذاری اختیار معامله، ارائه می‌دهند. [۴۸]

۱.۳.۴ مدل‌های ARCH

مدل ARCH(q) واریانس شرطی یک سری بازده r_t را به عنوان تابعی خطی از شوک‌های مجذور گذشته آن تعریف می‌کند:

$$\begin{aligned} r_t &= \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim i.i.d.\, N(0,1) \\ {\sigma_t}^2 &= \alpha_0 + \sum_{i=1}^{q} \alpha_i {\varepsilon^2}_{t-i}, \quad \alpha_0 > 0, \alpha_i \geq 0 \end{aligned} \tag{۴.۴}$$

در اینجا، ${\sigma_t}^2$ واریانس شرطی است که به نوآوری‌های مجذور گذشته ${\varepsilon^2}_{t-i}$ بستگی دارد. پارامترهای α_i پایداری شوک‌ها را بر نوسانات فعلی اندازه‌گیری می‌کنند. مدل‌های $ARCH$ به ویژه برای ثبت پویایی نوسانات کوتاه‌مدت مفید هستند، اما اغلب برای مدل‌سازی مناسب سری‌های مالی به q مرتبه بالا نیاز دارند که می‌تواند تخمین را ناکارآمد کند.

[1] autoregressive conditional heteroskedasticity (ARCH)

۲.۳.۴ مدل‌های GARCH

مدل $GARCH(p,q)$[1] با در نظر گرفتن واریانس‌های شرطی گذشته، ARCH را تعمیم می‌دهد، صرفه‌جویی را بهبود می‌بخشد و اثرات نوسانات طولانی‌مدت‌تر را در نظر می‌گیرد.

$$\sigma_t{}^2 = \alpha_0 + \sum_{i=1}^{q} \alpha_i \varepsilon^2{}_{t-i} + \sum_{j=1}^{p} \beta_j \sigma^2{}_{t-j} \tag{۵.۴}$$

مدل GARCH اجازه می‌دهد تا نوسانات در طول زمان از طریق عبارات β_j پایدار بمانند. وقتی $p=1$ و $q=1$، مدل به $GARCH(1,1)$ که به طور گسترده استفاده می‌شود، کاهش می‌یابد، که اغلب برازش بسیار خوبی برای بازده مالی روزانه ارائه می‌دهد. ایستایی نیاز به $\sum \alpha_i + \sum \beta_j < 1$ دارد، که تضمین می‌کند شوک‌های وارده به نوسانات در طول زمان به جای انفجار، کاهش می‌یابند.

۳.۳.۴ مدل‌های اثر نامتقارن و اهرمی

بازارهای مالی اغلب نوسانات نامتقارن را نشان می‌دهند، که در آن شوک‌های منفی، نوسانات آینده را بیشتر از شوک‌های مثبت با همان بزرگی[2] افزایش می‌دهند. مدل‌های استاندارد GARCH نمی‌توانند این پدیده را به تصویر بکشند، که منجر به چندین بسط می‌شود:

۱.۳.۳.۴ مدل‌های نمایی GARCH

EGARCH[3] که توسط نلسون در سال ۱۹۹۱ معرفی شدند، لگاریتم واریانس شرطی را مدل‌سازی می‌کند و به شوک‌های منفی اجازه می‌دهد تا تأثیر متفاوتی نسبت به شوک‌های مثبت داشته باشند: [۴۹]

$$\ln\left(\sigma_t^2\right) = \omega + \sum_{i=1}^{q} \alpha_i \frac{\varepsilon_{t-i}}{\sigma_{t-i}} + \sum_{i=1}^{q} \gamma_i \left(\left|\frac{\varepsilon_{t-i}}{\sigma_{t-i}}\right| - \mathbb{E}\left|\frac{\varepsilon_{t-i}}{\sigma_{t-i}}\right|\right) + \sum_{j=1}^{p} \beta_j \ln\left(\sigma^2{}_{t-j}\right) \tag{۶.۴}$$

در اینجا، پارامترهای α_i اثر علامت را نشان می‌دهند، در حالی که β_j پایداری نوسانات را نشان می‌دهد. مدل‌سازی لگاریتمی، مثبت بودن واریانس را بدون اعمال محدودیت تضمین می‌کند.

[1] Generalized AutoRegressive Conditional Heteroskedasticity (GARCH)

[2] Magnitude

[3] Exponential Generalized AutoRegressive Conditional Heteroskedasticity (EGARCH)

۲.۳.۳.۴ مدل‌های GJR-GARCH/TGARCH

TGARCH / GJR-GARCH - گلستن، جاگاناتان و رانکل (۱۹۹۳) مدل‌هایی را معرفی کردند که به صراحت یک تابع نشانگر را برای ثبت اثر اهرمی اضافه می‌کنند: [۵۰]

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^{q} \alpha_i {\varepsilon^2}_{t-i} + \sum_{i=1}^{q} \gamma_i {\varepsilon^2}_{t-i} I_{\{\varepsilon_{t-i}<0\}} + \sum_{j=1}^{p} \beta_j {\sigma^2}_{t-j} \tag{۷.۴}$$

تابع شاخص $I_{\{\varepsilon_{t-i}<0\}}$ هنگامی که شوک‌ها منفی هستند برابر با یک می‌شود، که به بازده‌های منفی اجازه می‌دهد نوسانات را بیشتر از بازده‌های مثبت افزایش دهند، و اثر اهرمی مشاهده شده در بازارهای سهام را نشان می‌دهد.

۳.۳.۳.۴ مدل‌های نوسان با حافظه بلندمدت (FIGARCH)

برخی از سری‌های مالی، نوسانات با حافظه بلندمدت را نشان می‌دهند، که در آن شوک‌ها به آرامی در طول زمان کاهش می‌یابند. مدل‌های استاندارد GARCH در ثبت این ویژگی ناموفق هستند. مدل‌های FIGARCH[1] که توسط بیلی و همکاران در سال ۱۹۹۶ معرفی شدند، یک پارامتر تفاضل‌گیری کسری d را در نظر می‌گیرند تا نوسانات پایدار اما رو به زوال را امکان‌پذیر سازند: [۵۱]

$$[1-\beta(L)]\varepsilon_t^2 = [1-\phi(L)](1-L)^d u_t, \quad 0<d<1 \tag{۸.۴}$$

در اینجا، L عملگر تأخیر، $(1-L)^d$ نشان دهنده انتگرال کسری و u_t یک عبارت خطای i.i.d[2] است. وقتی $d=0$، FIGARCH به یک GARCH استاندارد کاهش می‌یابد؛ وقتی $d>0$، شوک‌های گذشته بر نوسانات در یک افق بلندمدت تأثیر می‌گذارند و فروپاشی آهسته خودهمبستگی‌های نوسانات مشاهده شده در بسیاری از بازارهای مالی را مدل‌سازی می‌کنند.

[1] Fractionally Integrated Generalized AutoRegressive Conditionally Heteroskedastic (FIGARCH)

[2] Independent and identically distributed random variables (i.i.d)

۴.۳.۴ تخمین و استنتاج

پارامترهای مدل‌های خانواده ARCH معمولاً با استفاده از تخمین حداکثر درستنمایی که پیش‌تر معرفی شد یا تخمین شبه‌حداکثر درستنمایی[1] تخمین زده می‌شوند. با فرض نرمال بودن شرطی، تابع لگاریتم درستنمایی برای یک سری بازده $r_1, ..., r_t$ به صورت زیر است:

$$\ell(\theta) = -\frac{1}{2}\sum_{t=1}^{T}[\ln(2\pi) + \ln(\sigma_t^2) + \frac{\varepsilon_t^2}{\sigma_t^2}] \tag{۹.۴}$$

که در آن $\varepsilon_t = r_t - \mu$ و θ نشان دهنده بردار پارامترهای مدل است. MLE تخمین‌های مجانبی کارآمد را تحت فرضیات توزیع صحیح ارائه می‌دهد. وقتی توزیع واقعی از نرمال بودن منحرف می‌شود، از QMLE استفاده می‌شود. این روش همان تابع درستنمایی را به حداکثر می‌رساند اما با خطاها طوری رفتار می‌کند که گویی گاوسی هستند و حتی تحت تعیین نادرست توزیع نوآوری، تخمین‌های ثابتی از پارامترها تولید می‌کند. محدودیت‌های پارامتر، مانند مثبت بودن ضرایب واریانس و شرایط ایستایی، در طول تخمین اعمال می‌شوند تا پیش‌بینی‌های نوسانات معنادار و پایدار تضمین شوند.

۵.۳.۴ مقایسه مدل و تشخیص

انتخاب مدل مناسب از خانواده ARCH مستلزم ارزیابی برازش درون نمونه‌ای و ارزیابی عملکرد برون نمونه‌ای است. رویکردهای رایج معیارهای اطلاعات در اینجا عبارتند از:

- معیار اطلاعات آکائیک : (AIC)

$$AIC = -2\ell(\hat{\theta}) + 2k \tag{۱۰.۴}$$

که پیچیدگی مدل را به طور متوسط جریمه می‌کند.

- معیار اطلاعات بیزی : (BIC)

$$BIC = -2\ell(\hat{\theta}) + k\ln(T) \tag{۱۱.۴}$$

[1] quasi-maximum likelihood estimate (QMLE)

برای پارامترهای اضافی جریمه بیشتری اعمال می‌کند. در این رویکرد، مدل‌هایی با AIC/BIC پایین‌تر ترجیح داده می‌شوند.

- تشخیص باقیمانده:

باقیمانده‌های استاندارد شده $\hat{\varepsilon}_t/\hat{\sigma}_t$ نباید هیچ خودهمبستگی باقیمانده‌ای را نشان دهند. آزمون‌هایی مانند آزمون $Ljung - Box$ روی باقیمانده‌های مربع، اثرات ARCH باقیمانده را تشخیص می‌دهند.

- عملکرد پیش‌بینی نوسانات:

ارزیابی خارج از نمونه با استفاده از معیارهایی مانند RMSE یا MAPE[1] واریانس شرطی پیش‌بینی‌شده، به تأیید توانایی پیش‌بینی عملی مدل کمک می‌کند.

با ترکیب این تشخیص‌ها، محققان می‌توانند یک مدل صرفه‌جویی‌کننده را شناسایی کنند که به طور مناسب ناهمسانی واریانس شرطی را در نظر می‌گیرد و در عین حال از بیش‌برازش اجتناب می‌کند.

۴.۴ تحلیل ریسک به کمک مدل‌های رایج در تحلیل بازارهای مالی

حرکات شدید بازار اغلب به طور ضعیفی به کمک مدل‌های توزیع‌های آماری مرسوم نمایش داده می‌شوند، زیرا بازده‌های مالی دنباله‌های سنگین، چولگی و کشیدگی بیش از حد را نشان می‌دهند. در نتیجه، مدل‌های مبتنی بر فرضیات گاوسی تمایل دارند احتمال و بزرگی زیان‌های نادر اما شدید را کمتر از حد واقعی تخمین بزنند. نظریه مقدار شدید EVT یک چارچوب آماری ارائه می‌دهد که به طور خاص برای تجزیه و تحلیل رفتار دنباله توزیع‌های احتمال و تخمین احتمال رویدادهای شدید طراحی شده است. EVT شامل دو رویکرد مکمل است: روش حداکثر بلوک، که حداکثر (یا حداقل) مشاهدات را با استفاده از توزیع مقدار شدید تعمیم‌یافته GEV مدل‌سازی می‌کند، و روش قله‌های بیش از آستانه POT، که مشاهدات فراتر از یک آستانه به اندازه کافی بالا را با استفاده از توزیع پارتو تعمیم‌یافته GPD مدل‌سازی می‌کند. اگرچه هر دو رویکرد به طور مجانبی معادل هستند، رویکرد POT به طور کلی تخمین پارامتر کارآمدتری را ارائه می‌دهد زیرا از همه تعدیها به جای فقط حداکثر بلوک استفاده می‌کند. در نتیجه، این مطالعه چارچوب $POT - GPD$ را برای مدل‌سازی رفتار دنباله بازده دارایی‌های شبیه‌سازی شده اتخاذ می‌کند.

[1] The mean absolute percentage error (MAPE)

۱.۴.۴ توزیع مقادیر حدی تعمیم‌یافته

توزیع مقدار حدی تعمیم‌یافته پایه نظری نظریه مقدار حدی را تشکیل می‌دهد و به عنوان توزیع محدودکننده حداکثرهای بلوک نرمال‌شده مطرح می‌شود. GEV به جای مدل‌سازی کل توزیع بازده، منحصراً بر حداکثر (یا حداقل) مشاهده در هر بلوک از داده‌ها، مانند حداکثرهای ماهانه یا سالانه، تمرکز می‌کند. طبق قضیه فیشر-تیپت-گندنکو، توزیع حداکثرهای بلوک صرف نظر از توزیع والد زیربنایی، به خانواده GEV همگرا می‌شود، مشروط بر اینکه شرایط منظم مناسب برآورده شوند. این نتیجه اساس رویکرد حداکثرهای بلوک به EVT را تشکیل می‌دهد و نظریه مجانبی زیربنای مدل‌سازی رویدادهای حدی را ایجاد می‌کند. [۷۵-۷۹] تابع توزیع تجمعی توزیع GEV به صورت زیر است:

$$G(z) = \exp\left\{-\left[1+\xi\left(\frac{z-\mu}{\sigma}\right)\right]^{-1/\xi}\right\}, \quad 1+\xi\frac{z-\mu}{\sigma} > 0 \tag{۱۲.۴}$$

در اینجا μ پارامتر مکان، $\sigma > 0$ پارامتر مقیاس و ξ .پارامتر شکل (شاخص دم) است علامت پارامتر شکل، خانواده محدودکننده را تعیین می‌کند: $\xi = 0$ برای توزیع گامبل یا دنباله سبک، $\xi > 0$ برای توزیع فرچه دنباله سنگین و $\xi < 0$ برای توزیع وایبول دنباله محدود است. اگرچه GEV مبنای نظری EVT را فراهم می‌کند، اما تنها از یک مشاهده از هر بلوک استفاده می‌کند که ممکن است منجر به استفاده ناکارآمد از داده‌های موجود در کاربردهای مالی شود. در نتیجه، بسیاری از مطالعات رویکرد قله‌ها بر آستانه را ترجیح می‌دهند، که تمام مشاهدات حدی را که از یک آستانه از پیش تعریف شده فراتر می‌روند، حفظ می‌کند.

۲.۴.۴ نظریه مقدار حدی

نظریه مقدار حدی[۱] شاخه‌ای از نظریه احتمال است که بر مدل‌سازی رفتار تصادفی مشاهدات نادر و حدی واقع در دنباله‌های یک توزیع احتمال تمرکز دارد. برخلاف مدل‌های آماری مرسوم، که در درجه اول بخش مرکزی توزیع را توصیف می‌کنند، EVT به طور خاص رویدادهای با احتمال کم و تأثیر زیاد مانند سقوط‌های مالی، بحران‌های بازار و زیان‌های شدید را توصیف می‌کند. از آنجا که فرضیات سنتی گاوسی احتمال بازده‌های حدی را دست کم می‌گیرند، EVT به یک چارچوب استاندارد در مدیریت ریسک مالی، بهینه‌سازی سبد سهام و اندازه‌گیری ریسک تبدیل شده است. [۷۰-۷۴] طبق قضیه فیشر-تیپت-گندنکو، توزیع مجانبی حداکثرهای به درستی نرمال شده به توزیع مقدار حدی تعمیم‌یافته[۲] همگرا می‌شود. یک رویکرد جایگزین و اغلب کارآمدتر از نظر داده، روش قله‌های بیش از آستانه[۳] است که مشاهدات فراتر از یک

[1] Extreme Value Theory (EVT)

[2] Generalized Extreme Value (GEV) distribution

[3] Peaks-over-Threshold (POT) method

آستانه به اندازه کافی بالا را با استفاده از توزیع پارتو تعمیم‌یافته[1] مدل‌سازی می‌کند. از آنجایی که POT از تمام مشاهدات دم به جای فقط حداکثرهای بلوک استفاده می‌کند، عموماً تخمین پارامتر کارآمدتری را ارائه می‌دهد و به رویکرد ترجیحی EVT در کاربردهای مالی تبدیل شده است. به فرض اگر داشته باشیم:

$$X_1, X_2, ..., X_n \tag{۱۳.۴}$$

متغیرهای تصادفی مستقل و با توزیع یکسان باشند که نشان دهنده بازده دارایی‌ها باشند. حداکثر مشاهده برابر است با

$$M_n = \max(X_1, ..., X_n). \tag{۱۴.۴}$$

قضیه فیشر-تیپت-گندنکو بیان می‌کند که اگر ثابت‌های نرمال‌سازی مناسب $a_n > 0$ و b_n وجود داشته باشند،

$$\Pr\left(\frac{M_n - b_n}{a_n} \leq z\right) \to G(z) \tag{۱۵.۴}$$

که در آن $G(z)$ به خانواده مقادیر حدی تعمیم‌یافته تعلق دارد. در حالی که روش حداکثر بلوکی تنها بزرگترین مشاهده را در هر بلوک مدل‌سازی می‌کند، سری‌های بازده مالی اغلب شامل حداکثر بلوک نسبتاً کمی هستند که باعث کاهش کارایی تخمین می‌شود. برای غلبه بر این محدودیت، روش حداکثرهای بیش از آستانه POT هر مشاهده‌ای را که از یک آستانه به اندازه کافی بالا عبور می‌کند، در نظر می‌گیرد. این رویکرد اطلاعات دنباله‌دار قابل توجهی بیشتری را حفظ می‌کند و بنابراین به طور کلی تخمین‌های پارامتر دقیق‌تری را برای تجزیه و تحلیل ریسک مالی ارائه می‌دهد.

۳.۴.۴ پیک‌های عبوری از آستانه

روش قله‌های بیش از آستانه POT به جای تحلیل تنها حداکثرهای بلوک، هر مشاهده‌ای را که از یک آستانه بالای از پیش تعریف شده u فراتر رود، در نظر می‌گیرد. این رویکرد اطلاعات بیشتری را که در انتهای توزیع وجود دارد، حفظ می‌کند و منجر به تخمین دقیق‌تر احتمالات رویدادهای حدی می‌شود. POT به روش غالب EVT در امور مالی تبدیل شده است زیرا سری‌های بازده مالی اغلب شامل مشاهدات حدی

[1] Generalized Pareto Distribution (GPD)

کمی هستند و رویکردهای حداکثر بلوک را از نظر آماری ناکارآمد می‌کنند. اگر X یک بازده دارایی و u یک آستانه‌ی به اندازه کافی بالا باشد می‌توان گفت: متغیر تعدی به صورت زیر تعریف می‌شود:

$$Y = X - u, \quad X > u. \tag{۱۶.۴}$$

فقط تعدیهای مثبت مدل‌سازی می‌شوند،

$$Y > 0. \tag{۱۷.۴}$$

طبق قضیه پیکاندز-بالکما-دی هان، داریم:

$$\Pr(X - u \leq y | X > u) \approx G_{\xi,\beta}(y), \tag{۱۸.۴}$$

که در آن $G_{\xi,\beta}$ توزیع تعمیم‌یافته پارتو است. این قضیه، مبنای نظری برای مدل‌سازی زیان‌های دنباله مالی با استفاده از GPD را فراهم می‌کند.

۴.۴.۴ توزیع تعمیم‌یافته‌ی پارتو

توزیع تعمیم‌یافته پارتو توزیع محدودکننده‌ی تعدیها از آستانه‌های به اندازه کافی بالا است. در چارچوب POT، این توزیع، بزرگی مشاهدات حدی را به جای فراوانی وقوع آنها توصیف می‌کند. در نتیجه، GPD امکان تخمین چندک‌های بسیار نادر و معیارهای ریسک دنباله، از جمله ارزش در معرض ریسک[۱] و کسری مورد انتظار[۲] را فراهم می‌کند. تابع توزیع تجمعی مربوط به توزیع پارتوی تعمیم یافته به

[1] Value at Risk (VaR)

[2] Expected Shortfall (ES)

صورت زیر است:

$$F(y) = 1 - \left(1 + \xi \frac{y}{\beta}\right)^{-1/\xi}, \quad \xi \neq 0, \quad y \geq 0, \quad 1 + \xi \frac{y}{\beta} > 0. \tag{۱۹.۴}$$

حال برای شرایطی که $\xi = 0$ تابع توزیع به تابع نمایی ساده می‌شود و خواهیم داشت:

$$F(y) = 1 - \exp\left(-\frac{y}{\beta}\right). \tag{۲۰.۴}$$

و تابع چگالی احتمال مربوطه به صورت زیر است:

$$f(y) = \frac{1}{\beta}(1 + \xi \frac{y}{\beta})^{-1/\xi - 1}, \tag{۲۱.۴}$$

در اینجا $\beta > 0$ پارامتر مقیاس است و ξ پارامتر شکل (شاخص دم) است. مقدار پارامتر شکل، رفتار دم را تعیین می‌کند: اگر $\xi < 0$ باشد، آنگاه کران بالای محدود (توزیع دم کوتاه) و برای $\xi = 0$، دم نمایی داریم، و اگر $\xi > 0$ باشد، آنگاه توزیع دم سنگین با احتمال فزاینده رویدادهای حدی خواهیم داشت. در بازارهای مالی، مقادیر مثبت اغلب مشاهده می‌شوند که منعکس کننده ماهیت دم سنگین بازده دارایی‌ها و احتمال افزایش یافته حرکات بزرگ بازار نسبت به توزیع نرمال است.

۵.۴.۴ تخمین پارامترها

پارامترهای GPD معمولاً با استفاده از تخمین حداکثر درستنمایی MLE تخمین زده می‌شوند. برای مقادیر تعدیهای زیر

$$y_1, y_2, ..., y_n, \tag{۲۲.۴}$$

تابع لگاریتم درستنمایی به صورت زیر است:

$$l(\xi,\beta) = -n\ln\beta - \left(1+\tfrac{1}{\xi}\right)\sum_{i=1}^{n}\ln\left(1+\xi\tfrac{y_i}{\beta}\right), \quad 1+\xi\tfrac{y}{\beta} > 0. \tag{۲۳.۴}$$

تخمین‌ها $(\hat{\xi},\hat{\beta})$ با به حداکثر رساندن تابع درستنمایی لگاریتمی به صورت عددی به دست می‌آیند.

۶.۴.۴ ارتباط توزیع تعمیم یافته‌ی پارتو با ارزش در معرض خطر

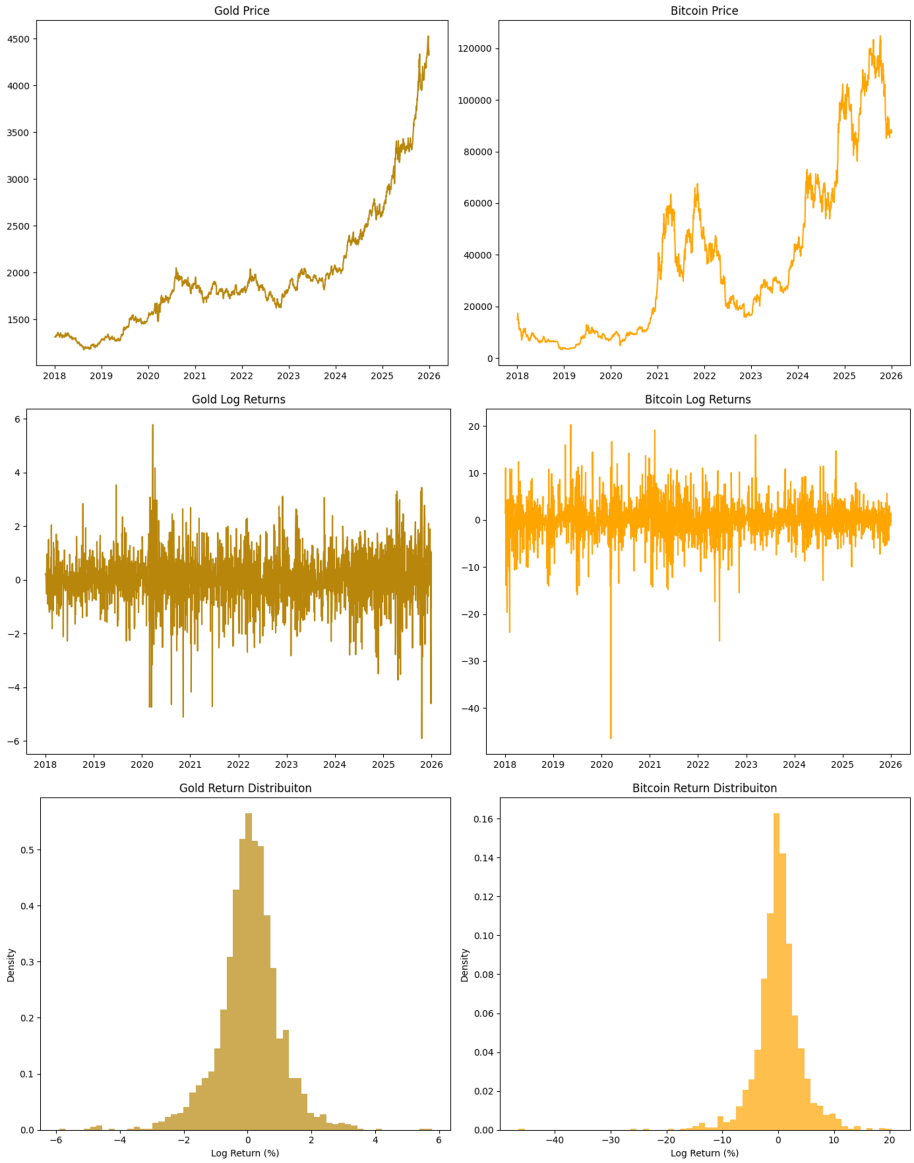
پس از تخمین پارامترهای توزیع تعمیم یافته‌ی پارتو ، تعداد چندک‌های ارزش در معرض خطر فراتر از آستانه u را می توان به صورت تخمین زد

$$VaR_p = u + \frac{\beta}{\xi}\left[\left(\frac{N}{N_u}(1-p)\right)^{-\xi} - 1\right] \tag{۲۴.۴}$$

که در آن N تعداد کل مشاهدات، N_u تعداد تعدیها و u آستانه است. این فرمول‌بندی امکان تخمین قابل اعتماد چندک‌های حدی فراتر از محدوده نمونه مشاهده شده را فراهم می‌کند و به طور گسترده در بانکداری، بیمه و مدیریت ریسک کمی مورد استفاده قرار می‌گیرد.

۵.۴ بررسی بازارهای طلا و بیت کوین به کمک مدل‌های خطی

در ابتدا داده‌ی مورد نظر را از کتابخانه‌ی یاهوفایننس دانلود می‌کنیم. در اینجا برای مقایسه‌ی طلا و بیت کوین، بازه‌ی زمانی ابتدای سال ۲۰۱۸ تا ابتدای سال ۲۰۲۶ مورد بررسی قرار گرفته است. از آنجا که بازارهای مالی در آخرهفته‌های میلادی بسته هستند، برای مقایسه‌ی این بازارها باید دیتا مشابه باشد و دیتاهای روزهای مشترک مورد بررسی قرار گیرد. سپس نمودار قیمت هر دو و نمودار سیگنال بازده مربوط به آنها و نمودار تابع توزیع داده‌های مروبطه را به تصویر می‌کشیم.



شکل ۱.۴: بررسی قیمت، بازده و تابع توزیع بازده طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶

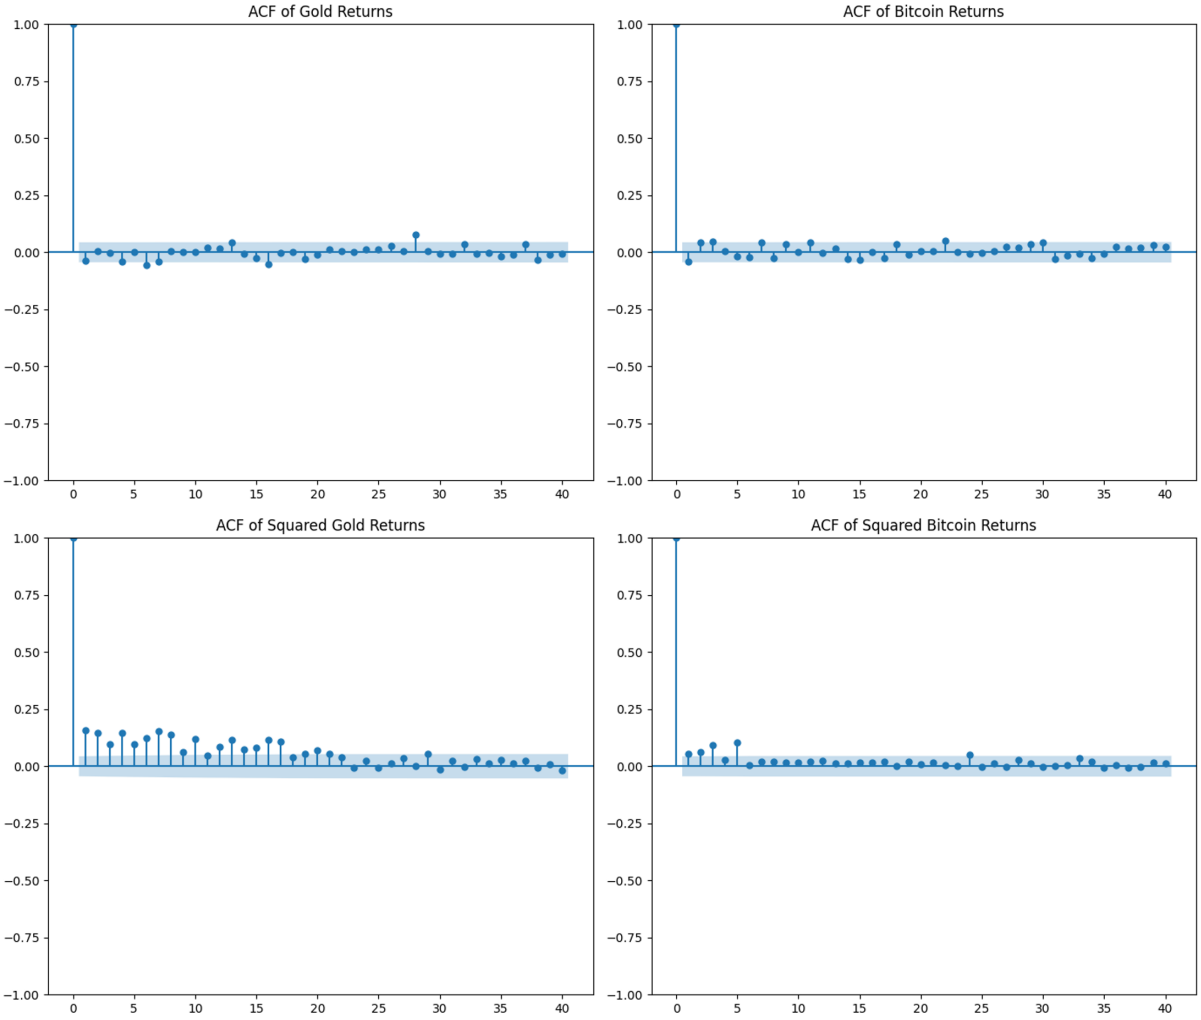
در اینجا باید با استفاده از تست‌های مرتبط به ایستایی دو سهم، رفتار ایستایی آنها مورد مطالعه قرار گیرد. به طور کلی آزمون ادفولر و آزمون $KPSS$ مورد انتخاب است.[۱] بررسی ایستایی به ما این امکان را میدهد که بین خانواده‌ی مدل‌های ARMA یا ARIMA انتخاب کنیم. در صورتی که سهام مورد بررسی، ایستا نباشد، $d = 0$ است و مدل‌هایی از خانواده‌ی ARMA انتخاب می‌شوند. اگر سهام مورد بررسی ایستا باشد، $d = 1$ بوده و خانواده مدل‌های ARIMA مورد بررسی هستند چرا که در این مدل، ابتدا سهام ایستا می‌شود و سپس مدل‌ها برازش می‌یابند. در اینجا پس از بررسی نتایج آزمون تست‌های ایستایی، باید به بررسی ACF[۲] و PACF[۳] هم روی بازده‌ی دارایی‌ها و هم روی مربع

[1] Augmented Dickey Fuller (“ADF”) test and Kwiatkowski-Phillips-Schmidt-Shin (“KPSS”) test

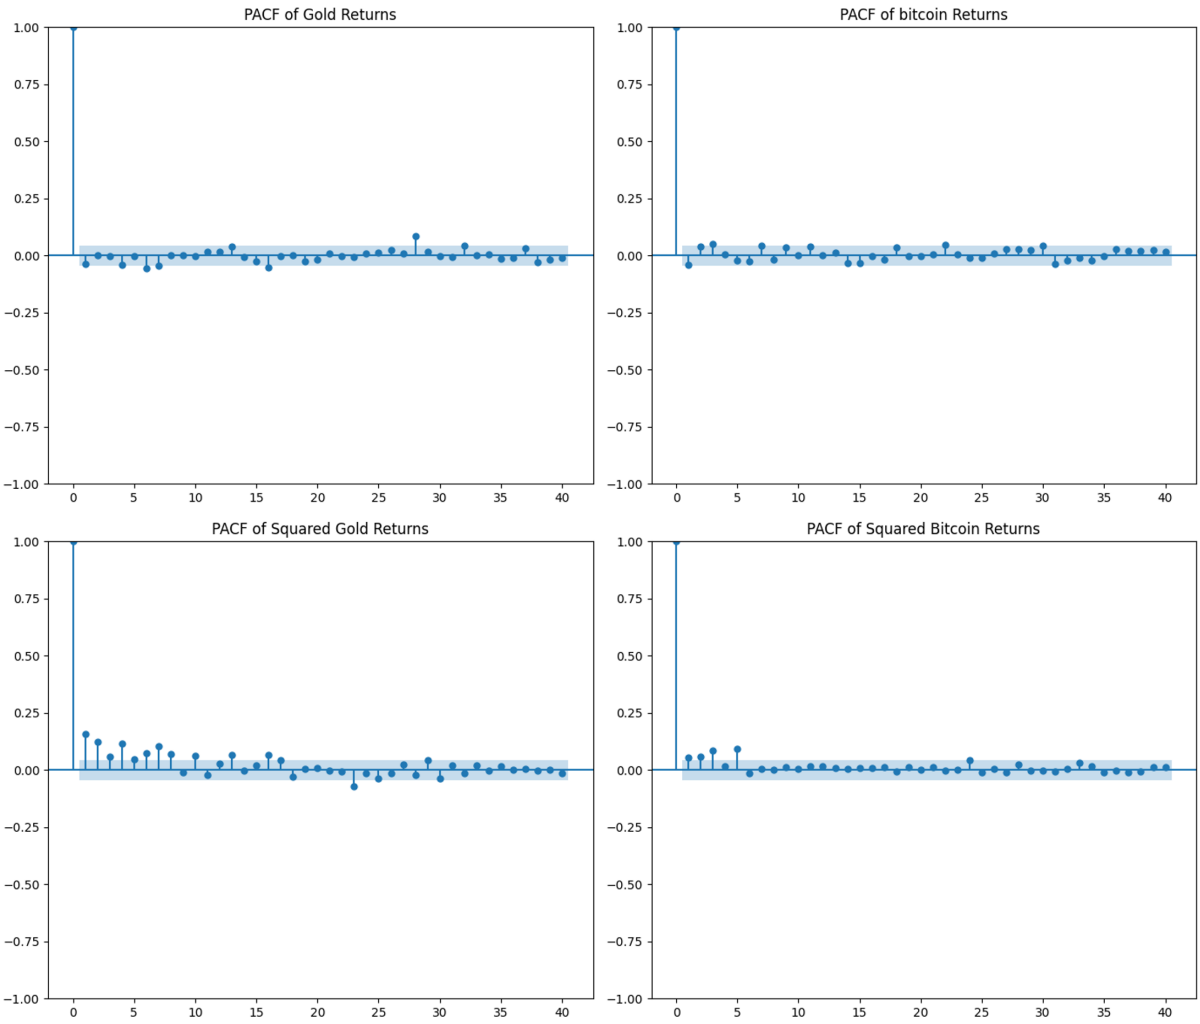
[2] autocorrelation function

[3] partial autocorrelation function

بازده‌ی دارایی‌ها می‌پردازیم. در کنار تست‌های یاد شده، تست‌های Ljung-Box و ARCH-LM و Jarque-Bera نیز بررسی می‌شوند تا به ما در انتخاب بین مدل‌های خانواده‌ی ARMA یا مدل‌های خانواده‌ی ARCH/GARCH کمک کنند. تفاوت در انتخاب بین این دو خانواده در بررسی اطلاعات خطی داخل سهام به کمک مدل‌های میانگین متحرک یا به کمک مدل‌هایی با ناهمسانی نوسان است. از آنجا که به تجربه‌ی پیشبین در مرور ادبیات حقایق تجربی سبک‌مند بازارهای مالی و بازارهای رمزارزها دیدیم، بازارهای رمزارزها بیشتر از بازارهای مالی تابع نوسانات بوده و خوشه بندی نوسانات بیشتری نسبت به بازارهای مالی از خود نشان می‌دهند. پس انتظار می‌رود در عمل برازش داده‌ها، بازار رمزارزها بیشتر با خانواده‌ی مدل‌های ARCH/GARCH برازش شوند و بازارهای مالی دیگر با خانواده‌ی مدل‌های ARIMA/ARMA.



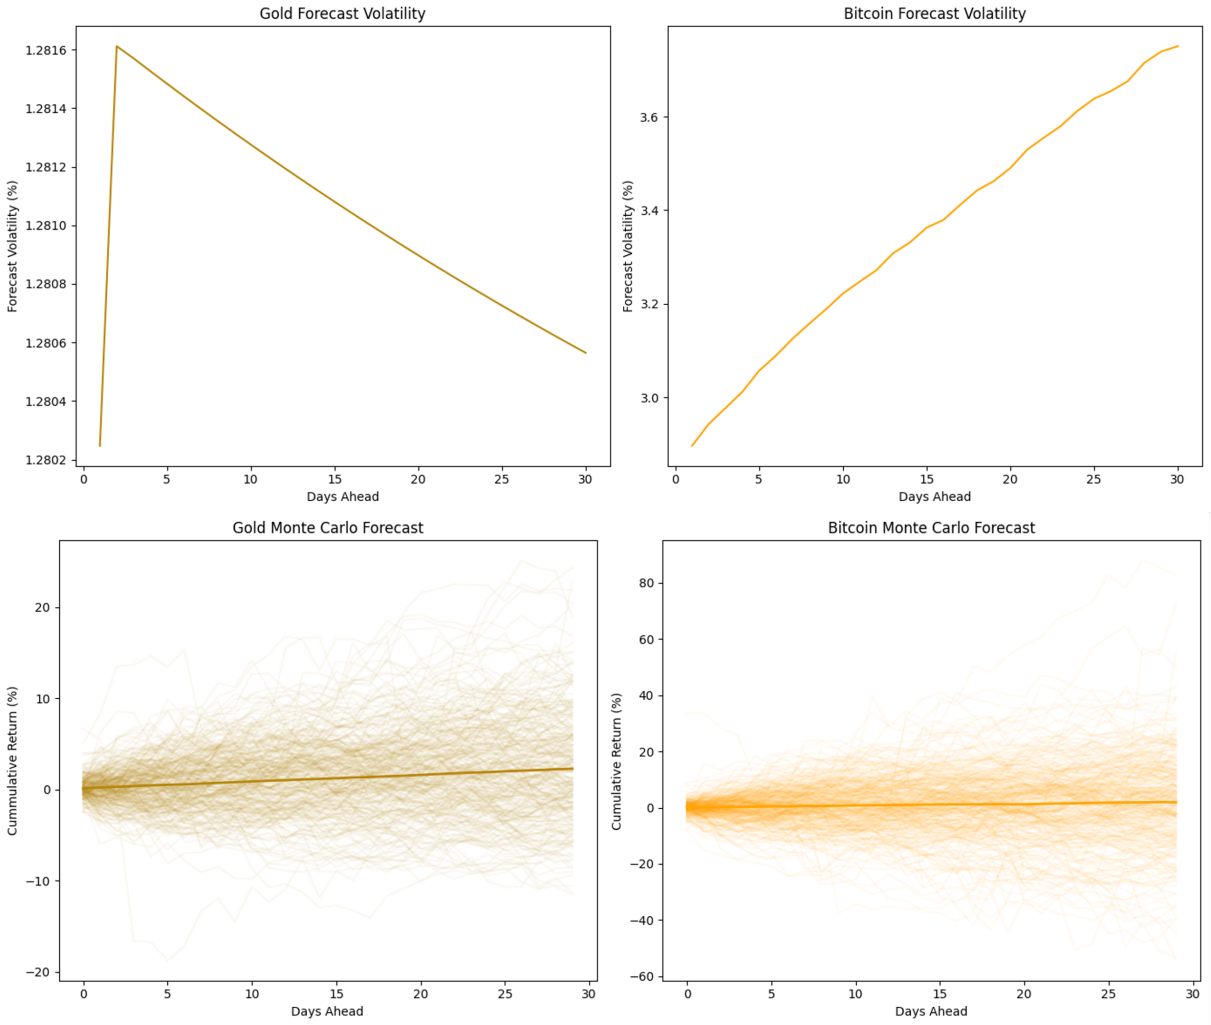
شکل ۲.۴: بررسی تابع خودهمبستگی طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ برای ۴۰ تاخیر اول



شکل ۳.۴: بررسی تابع خودهمبستگی جزئی طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ برای ۴۰ تاخیر اول

بررسی نمودارهای ACF و PACF به ما برای پارامترهای مدل‌هایی نظیر خانواده‌ی مدل‌های ARIMA حق انتخاب می‌دهند. بررسی این نمودارها را به ۳ طریق می‌توان انجام داد. در روش اول از روی نمودار، اولین تاخیری که نمودار در آن قله داشته و فروکش می‌کند مورد انتخاب است. از نمودار ACF می‌توان پارامتر p را برای بخش خودبازگشتی مدل‌های ARIMA انتخاب کرد و از نمودار PACF به کمک همین تحلیل می‌توانیم پارامتر مربوط به میانگین متحرک q را انتخاب کنیم. البته روش دیگر این است که اطلاعات مربوط به تاخیرها را ذخیره کرده و به کمک کد این تاخیر مربوطه را پیدا کنیم. داده‌های بازارهای مالی عمدتا با پارامترهای $p = 1$ و $q = 1$ کار می‌کنند. روش آخر که بهترین و مطمئن‌ترین روش نیز است، بررسی به کمک فضای جست‌وجوی کتابخانه‌ی $Statsmodels$ است. در این روش، می‌توان پارامترهای احتمالی برای مولفه‌های p و q را انتخاب کرد و به کمک بررسی معیارهای آکائیکه و بیزین که در بالاتر اشاره کردیم، بهترین برازش مدل بین خانواده‌های ARIMA و GARCH انتخاب می‌شوند. پیش‌بینی‌های نوسانات با استفاده از مدل نوسانات شرطی برازش‌شده به دست آمدند، که واریانس مورد انتظار بازده دارایی‌ها در آینده را بر اساس پویایی‌های تاریخی بازار تخمین می‌زند. سپس این پیش‌بینی‌های نوسانات در یک

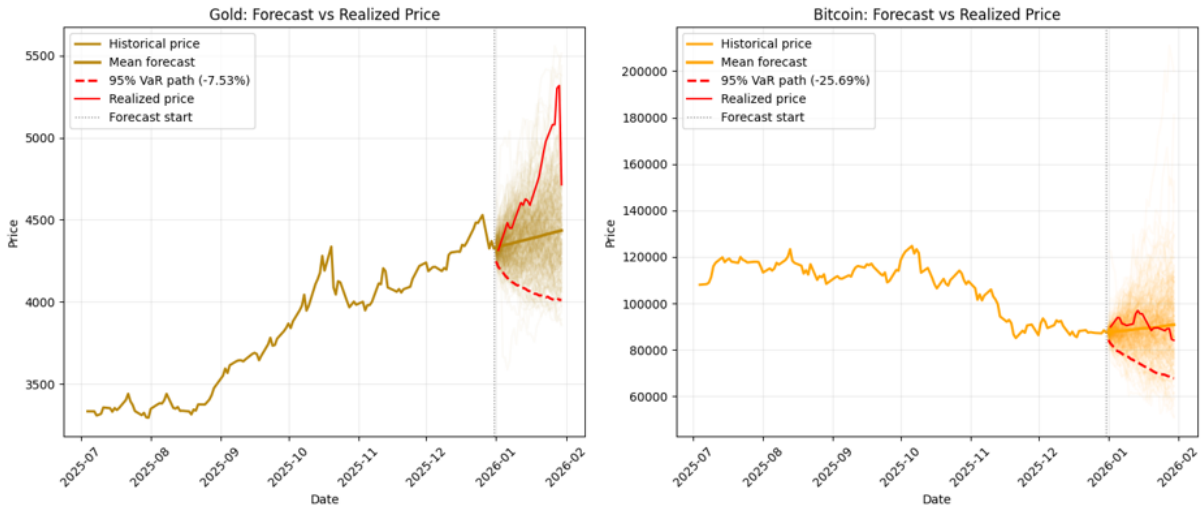
چارچوب شبیه‌سازی مونت کارلو گنجانده شدند، که در آن مسیرهای بازده تصادفی متعددی برای تقریب توزیع احتمال بازده تجمعی آینده ایجاد شد. پراکندگی مسیرهای شبیه‌سازی شده، معیار کمی از عدم قطعیت پیش‌بینی و ریسک سرمایه‌گذاری در طول افق پیش‌بینی را فراهم می‌کند.



شکل ۴.۴: بررسی پیش‌بینی‌های نوسانات و شبیه‌سازی مونت کارلو روی طلا و بیت کوین بین سال‌های ۲۰۱۸ تا ۲۰۲۶ برای ۳۰ روز آینده

در اینجا بهترین برازش برای داده‌های طلا، مدل $\mathrm{AR}(1)-\mathrm{GJR}-\mathrm{GARCH}(1,1)-\mathrm{t}$ و برای داده‌های بیت کوین $\mathrm{AR}(3)-\mathrm{EGARCH}(1,1)-\mathrm{t}$ انتخاب شده است.

همچنین برای مطمئن شدن از برازش مدل‌ها می‌توان روی باقی‌مانده‌ی داده‌ها که توسط مدل مذکور برازش نشده‌اند نیز مطالعه‌ای انجام داد و به کمک بررسی تست‌های آماری مطمئن شد که این توانسته‌ایم بهترین مدل را انتخاب کنیم یا جای بهبود برای پارامترهای مختلف مدل است.



شکل ۵.۴: پیش‌بینی مدل‌ها خطی و نتایج تاریخی برای بازه‌ی زمانی ماه اول سال ۲۰۲۶ روی طلا و بیت کوین

شکل بالا سری قیمت‌های تاریخی، توزیع پیش‌بینی مونت کارلو، میانگین مسیر پیش‌بینی، مسیر ارزش در معرض ریسک $VaR - 95\%$ و قیمت‌های تحقق‌یافته بازار برای طلا و بیت‌کوین در طول دوره پیش‌بینی خارج از نمونه را مقایسه می‌کند. خط چین عمودی نشان‌دهنده آغاز افق پیش‌بینی است که پس از آن قیمت‌های آینده صرفاً با استفاده از اطلاعات موجود تا آن نقطه تخمین زده می‌شوند.[1]

برای طلا، قیمت تحقق‌یافته (خط قرمز) روند صعودی را دنبال می‌کند که به طور قابل توجهی از مسیر پیش‌بینی میانگین فراتر می‌رود. اگرچه پیش‌بینی میانگین تنها افزایش اندکی را نشان می‌دهد، قیمت‌های تحقق‌یافته در ناحیه بالایی مسیرهای شبیه‌سازی‌شده مونت کارلو باقی می‌مانند، که نشان می‌دهد حرکت بازار مشاهده‌شده مطابق با یک سناریوی نسبتاً خوش‌بینانه اما همچنان محتمل تحت مدل تصادفی تخمین زده شده است. مسیر $VaR - 95\%$ به تدریج کاهش می‌یابد و نشان‌دهنده سناریوی نزولی نامطلوب با احتمال تنها پنج درصد تعدی از آن است. شکاف قابل توجه بین قیمت‌های تحقق‌یافته و مرز VaR نشان می‌دهد که بازار طلای تحقق‌یافته شرایط بسیار مطلوب‌تری نسبت به سناریوی ریسک نزولی مدل تجربه کرده است.

در مقابل، بیت کوین عدم قطعیت پیش‌بینی بسیار بیشتری را نشان می‌دهد. شبیه‌سازی‌های مونت کارلو توزیع قابل توجهی وسیع‌تر از مسیرهای قیمت آینده را ایجاد می‌کنند که نشان‌دهنده نوسانات پیش‌بینی بالاتر تخمین زده شده برای بازار ارزهای دیجیتال است. قیمت‌های تحقق یافته بیت کوین در اطراف میانگین پیش‌بینی نوسان می‌کنند و در طول افق پیش‌بینی به خوبی در منطقه اطمینان شبیه‌سازی شده باقی می‌مانند، که نشان می‌دهد مدل پیش‌بینی با وجود نوسانات قابل توجه این دارایی، با موفقیت میزان عدم قطعیت بیت کوین را در بر می‌گیرد. مشابه طلا، قیمت‌های تحقق یافته به طور مداوم بالاتر از مسیر $VaR - 95\%$ باقی می‌مانند، که نشان می‌دهد سناریوی نزولی شدید در

[1] Value at Risk (VaR)

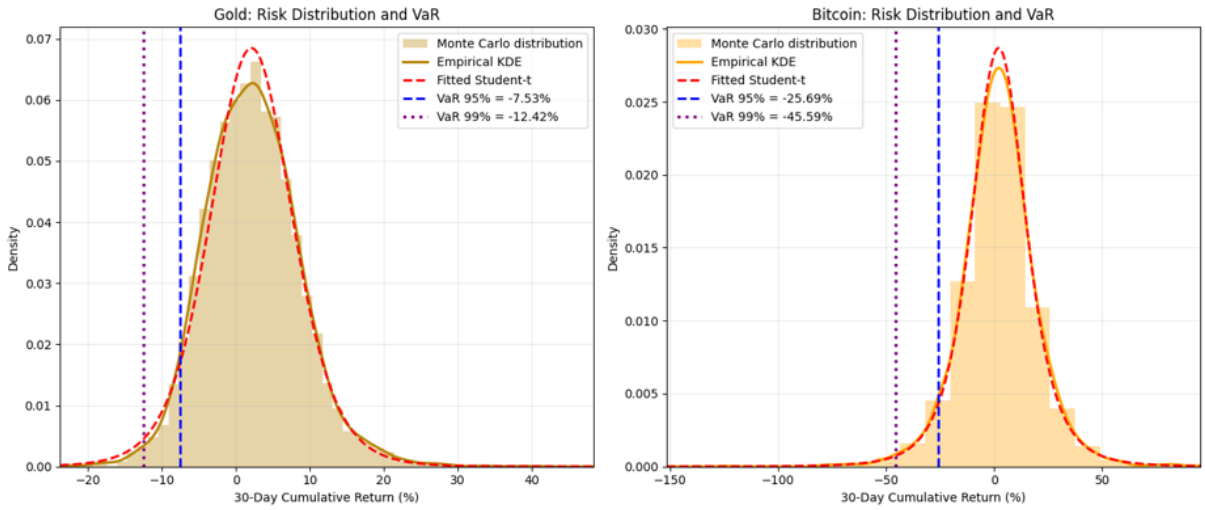
طول دوره ارزیابی تحقق نیافته است.

به طور کلی، این نتایج نشان می‌دهد که چارچوب پیش‌بینی پیشنهادی، پیش‌بینی‌های احتمالی واقع‌بینانه‌ای را ارائه می‌دهد، نه تلاش برای پیش‌بینی مسیر دقیق قیمت آینده. شبیه‌سازی‌های مونت کارلو با موفقیت طیف نتایج احتمالی آینده را مشخص می‌کنند، در حالی که میانگین پیش‌بینی، مسیر مورد انتظار بازار را در بر می‌گیرد و مسیر $VaR - 95\%$، ریسک نزولی را کمی می‌کند. پوشش پیش‌بینی به طور قابل توجهی وسیع‌تر برای بیت کوین در مقایسه با طلا، نشان‌دهنده نوسانات پیش‌بینی به طور قابل توجهی بالاتر و عدم قطعیت بیشتر بازار آن است، در حالی که توزیع باریک‌تر برای طلا با پویایی قیمت نسبتاً پایدار آن سازگار است. این واقعیت که قیمت‌های تحقق‌یافته برای هر دو دارایی در محدوده توزیع پیش‌بینی شبیه‌سازی‌شده باقی می‌مانند، نشان می‌دهد که روش پیش‌بینی به طور کافی عدم قطعیت اساسی را در نظر گرفته و پیش‌بینی‌های احتمالی با کالیبراسیون خوبی تولید می‌کند.

شکل زیر نیز توزیع احتمال تخمینی بازده تجمعی ۳۰ روزه حاصل از شبیه‌سازی‌های مونت کارلو را برای طلا و بیت کوین نشان می‌دهد. هیستوگرام‌ها توزیع‌های بازده شبیه‌سازی شده را نشان می‌دهند، در حالی که تخمین چگالی هسته تجربی [۱] و توزیع استیودنت-t برازش شده [۲] نشان می‌دهند که بازده‌های شبیه‌سازی شده ویژگی‌های دنباله‌دار را که معمولاً در بازارهای مالی مشاهده می‌شود، نشان می‌دهند. خطوط نقطه چین عمودی آستانه‌های ارزش در معرض ریسک $VaR - 95\%$ و $VaR - 99\%$ را نشان می‌دهند که مربوط به حداکثر زیان‌های مورد انتظار در شرایط عادی بازار با سطوح اطمینان 95% و 99% هستند. برای طلا، مقادیر VaR تخمینی 7.53 و 12.42 هستند که نشان دهنده ریسک نزولی نسبتاً محدود در افق ۳۰ روزه است. در مقابل، بیت‌کوین با تخمین‌های VaR معادل -25.69 و -45.59، ریسک نزولی بسیار بزرگتری را نشان می‌دهد که نشان‌دهنده نوسانات بسیار بالاتر و رفتار دنباله‌دار سنگین‌تر آن است. به طور کلی، توزیع گسترده‌تر و تخمین‌های VaR شدیدتر برای بیت‌کوین نشان می‌دهد که در معرض ریسک نزولی بسیار بیشتری نسبت به طلا قرار دارد و نتایج به‌دست‌آمده از پیش‌بینی نوسانات و تحلیل‌های شبیه‌سازی مونت کارلو را تأیید می‌کند.

[1] empirical Kernel Density Estimation (KDE)

[2] fitted Student's t-distribution



شکل ۶.۴: تحلیل توزیع ریسک و ارزش در معرض ریسک برای طلا و بیت کوین

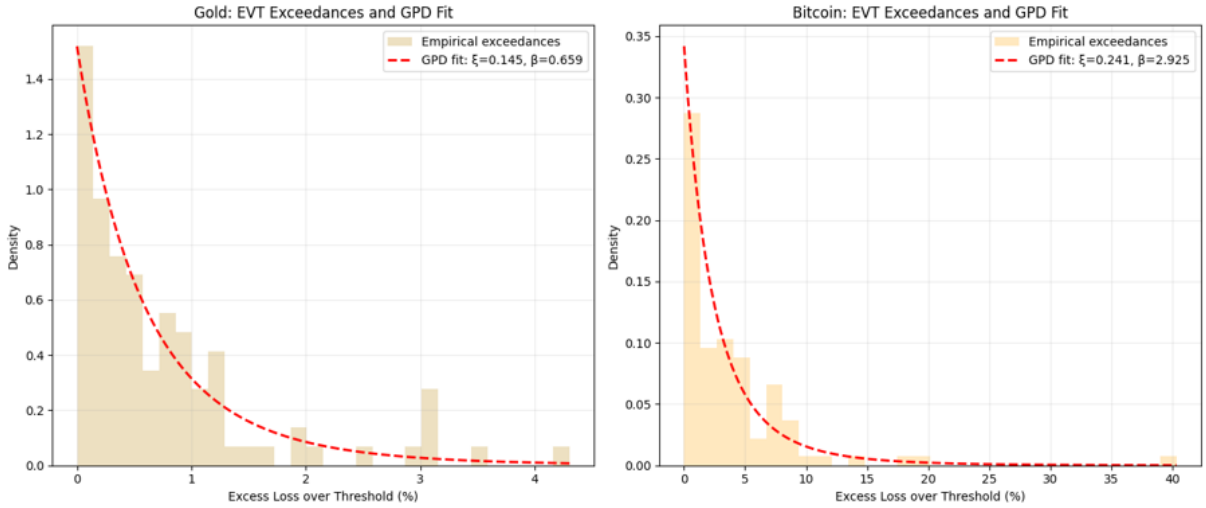
شکل زیر تحلیل نظریه ارزش حدی[۱] از توزیع‌های بازده شبیه‌سازی شده با استفاده از رویکرد قله‌های بیش از آستانه[۲] را ارائه می‌دهد. تنها مشاهداتی که از یک آستانه از پیش تعریف شده فراتر می‌روند، حفظ شده و با استفاده از توزیع پارتو تعمیم‌یافته[۳] مدل‌سازی می‌شوند، که به طور خاص برای توصیف رفتار حرکات شدید بازار طراحی شده است. هیستوگرام‌ها نشان‌دهنده تعدیهای تجربی[۴] هستند، در حالی که منحنی‌های خط چین مدل‌های GPD برازش شده را نشان می‌دهند. برای طلا، این مقادیر نزدیک به آستانه متمرکز شده‌اند و GPD برازش شده از توزیع تجربی پیروی می‌کند که نشان‌دهنده رفتار دم نسبتا سبک و احتمال کمتر ضررهای شدید است. در مقابل، بیت کوین مقادیر به طور قابل توجهی بزرگتر و دم بسیار سنگین‌تری را نشان می‌دهد، با مشاهداتی که بسیار فراتر از آستانه امتداد دارند. اگرچه GPD برازش رضایت‌بخشی با توزیع دم ارائه می‌دهد، اما طیف وسیع‌تر این مقادیر، احتمال بسیار بیشتر حرکات قیمتی نادر اما شدید در بازار ارزهای دیجیتال را برجسته می‌کند. در مجموع، تحلیل EVT با نشان دادن اینکه بیت‌کوین به طور قابل توجهی بیشتر از طلا در معرض ریسک دنباله شدید قرار دارد، نتایج ارزش در معرض ریسک را تکمیل می‌کند و آن را در برابر رویدادهای بازار با احتمال کم و تاثیر زیاد آسیب‌پذیرتر می‌کند.

[1] Extreme Value Theory (EVT)

[2] Peaks-over-Threshold (POT)

[3] Generalized Pareto Distribution (GPD)

[4] empirical exceedance



شکل ۷.۴: تحلیل ریسک به کمک توزیع نظریه ارزش حدی و برازش پارتو تعمیم یافته برای طلا و بیت کوین

فصل ۵

مدل‌های یادگیری عمیق در تحلیل بازارهای مالی

بر اساس آنچه از مرور ادبیات مطالعه شد و ویژگی‌های تجربی‌ای که از بازارهای مالی متوجه شدیم، می‌توان ادعا کرد که روابط غیرخطی، تغییر رژیم‌ها، حقایق سبکمند موجود در این بازارها مانند خوشه بندی نوسانات تاکنون ضعف مدل‌های سنتی در تحلیل و برازش داده‌های مالی به روشنی آشکار شده است. در این فصل سعی داریم که به کمک مدل‌های مدرن‌تر تحلیل بازارهای مالی مانند مدل‌های یادگیری عمیق با تمرکزی بر روی مدل‌های یادگیری بازگشتی و سپس ترنسفورمرها و مدل پیچشی زمانی، بتوانیم اطلاعات بیشتری نسبت به ارتباطات خطی را از داده‌های مالی استخراج کنیم. در این فصل به معرفی، ویژگی‌ها، کاربردها و ضعف‌های این مدل‌ها می‌پردازیم. رویکردهای سنتی مدل‌سازی ریاضی، اغلب برای مدل‌سازی وابستگی‌های زمانی به فرضیات مارکوف یا نمایش‌های حالت نهفته متکی هستند. معماری‌های یادگیری عمیق مدرن این ایده‌ها را با یادگیری نمایش‌های غیرخطی پیچیده از اطلاعات تاریخی از طریق حافظه بازگشتی، عملیات کانولوشن یا مکانیسم‌های توجه گسترش می‌دهند. در نتیجه، مدل‌سازی توالی به عنوان چارچوب اساسی زیربنای مدل‌های پیش‌بینی معاصر مانند شبکه‌های عصبی بازگشتی، شبکه‌های حافظه کوتاه‌مدت طولانی، واحدهای بازگشتی دروازه‌دار، شبکه‌های کانولوشن زمانی و معماری‌های مبتنی بر ترنسفورمرها عمل می‌کند.

۱.۵ مدل‌سازی توالی‌ها

داده های مالی به اصطلاح داده‌های متوالی هستند. قیمت، بازده، نوسانات، حجم معاملات و جریان سفارش در طول زمان تغییر می‌کنند، به این معنی که مشاهدات مستقل از یکدیگر نیستند و وابستگی زمانی را نشان می دهند. در نتیجه، مدل‌های پیش‌بینی موفق باید از اطلاعات موجود در مشاهدات قبلی برای پیش‌بینی آینده استفاده کنند. این مسئله به طور کلی به عنوان مدل سازی توالی شناخته می‌شود، که هدف آن یادگیری رابطه احتمالی در یک دنباله منظم از مشاهدات است. [۸۰-۸۵]

فرض کنید که یک سری زمانی مشاهده شده است

$$y = \{y^{(1)}, y^{(2)}, ..., y^{(T)}\}. \tag{۱.۵}$$

مدل‌های توالی به جای مدل‌سازی هر مشاهده به شکل مستقل، توزیع احتمال مشترک را تخمین می‌زنند.

$$p(y^{(1)}, y^{(2)}, ..., y^{(T)}) = \prod_{t=1}^{T} p(y^{(T)}|y^{(1)}, y^{(2)}, ..., y^{(t-1)}), \tag{۲.۵}$$

که مستقیما از قاعده زنجیره‌ای احتمال پیروی می‌کند. این فرمول‌بندی بیان می‌کند که هر مشاهده به تاریخچه مشاهدات قبلی بستگی دارد و وابستگی زمانی را به مؤلفه اصلی یادگیری توالی تبدیل می‌کند. حال سوالی که پیش می‌آید این است که چرا از مدل‌سازی توالی استفاده کنیم؟ بازارهای مالی چندین ویژگی مانند خوشه‌بندی نوسانات، اثرات حافظه بلندمدت، تغییرات رژیم و پویایی غیرخطی را نشان می‌دهند که مدل‌سازی توالی را ضروری می‌کند:

برخلاف الگوریتم‌های یادگیری ماشین مرسوم که فرض می‌کنند مشاهدات مستقل و با توزیع یکسان $(i.i.d)$ هستند، مدل‌های توالی به صراحت از ساختار زمانی برای بهبود پیش‌بینی‌هایشات استفاده می‌کنند.

هدف کلی یادگیری این است که مدل

$$p(y_t|y_{1:t-1}) \tag{۳.۵}$$

یا معادل آن

$$f(y_{1:t-1}) \rightarrow y_t. \tag{۴.۵}$$

را بررسی کند. در اینجا این دو رویکرد در درجه اول در نحوه نمایش اطلاعات تاریخی $y_{1:t-1}$ با هم تفاوت دارند. می‌توان گفت که دو الگوی اصلی مدل‌سازی یا به عبارتی دیگر دو رویکرد کلاسیک وجود دارد که در ادامه به معرفی آنها خواهیم پرداخت.

۱.۱.۵ مدل‌های مارکوف

مدل‌های مارکوف در سیستم‌های بی‌حافظه و مدل‌سازی این سیستم‌ها کاربردهای زیادی دارند. در اینجا ساده‌ترین فرض این است که فقط جدیدترین مشاهدات برای ما مناسب و ضروری هستند:

$$p(y_t|y_{1:t-1}) \approx p(y_t|y_{t-1}). \tag{۵.۵}$$

این فرض را فرض مارکوف می‌نامند. مثال‌های این فرض شامل زنجیره‌های مارکوف، مدل‌های پنهان مارکوف[1]، مدل‌های فضای حالت و فیلترهای کالمن هستند. مهم‌ترین مزیت این مدل‌ها این است که این مدل‌ها بسیار ساده بوده و قابلیت تفسیرپذیری بالایی دارند. اما در کنار این مزایای جالب این مدل‌ها می‌توان به معابی مانند عدم توانایی این مدل‌ها در ثبت وابستگی‌های بلندمدت و قدرت بیا محدود اطلاعات مستخرج از سری‌های زمانی اشاره کرد.

۲.۱.۵ مدل‌های حالت پنهان

به جای بررسی مستقیم مشاهدات قبلی، این مدل فرض می‌کند که یک حالت نهفته مشاهده نشده x_t تمام اطلاعات تاریخی را خلاصه می‌کند. به جای اینکه

$$p(y_t|y_{1:t-1}) \tag{۶.۵}$$

[1] Hidden Markov Model (HMM)

برای پیش‌بینی بررسی شود، مورد مطالعه‌ی ما تبدیل می‌شود به

$$p(y_t|x_t). \tag{۷.۵}$$

حالت پنهان بر اساس زیر تکامل می‌یابد:

$$x_t = f(x_{t-1}, y_{t-1}), \tag{۸.۵}$$

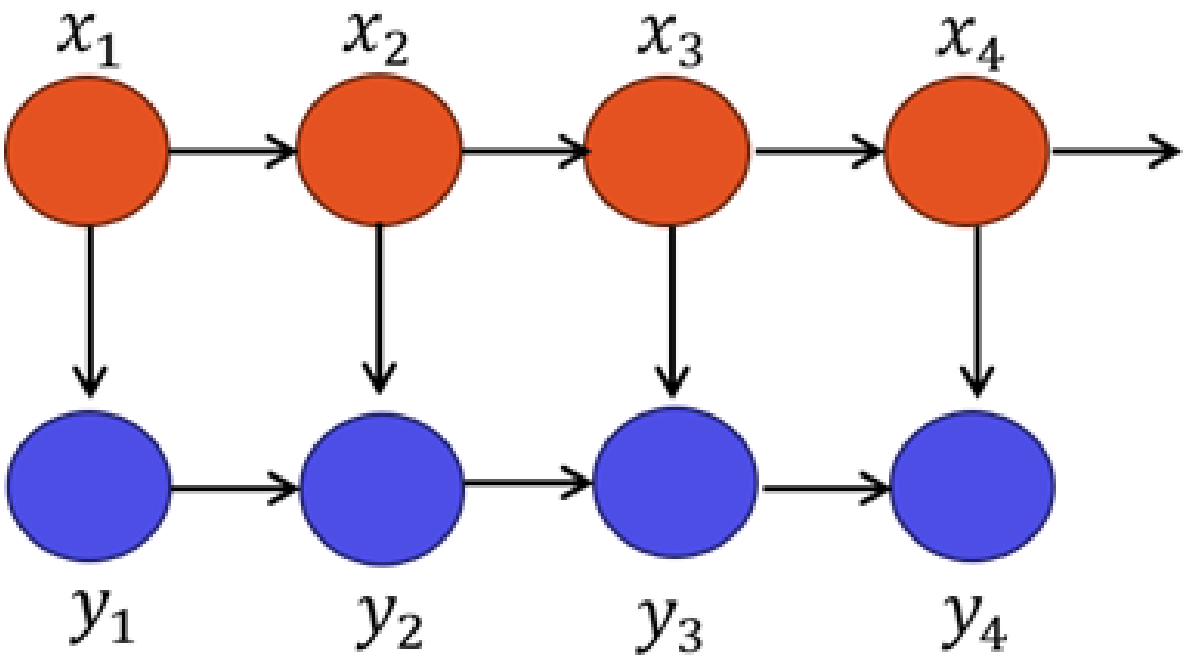
در حالی که مشاهدات به شکل زیر تولید می‌شوند

$$y_t = g(x_t). \tag{۹.۵}$$

این حالت پنهان به شکل حافظه سیستم عمل می‌کند و نویز را فیلتر کرده و در عین حال اطلاعات مفید برای پیش‌بینی را نگه‌داری می‌کند.

مدل‌های یادگیری عمیق مدرن از جمله RNN، $LSTM$، GRU و بسیاری از انواع ترنسفورمرها همگی می‌توانند به عنوان مدل‌های حالت پنهان تفسیر شوند، اگرچه ترنسفورمرها انتشار حالت پنهان مکرر را با مکانیزم‌های مبتنی بر توجه جایگزین می‌کنند.

برای یک شبکه بیزی پویا، گره‌های بالایی $(x_1, ..., x_4)$ نشان دهنده حالت‌های پنهانی هستند که با گذشت زمان تکامل دارند، در حالی که گره‌های پایینی $(y_1, ..., y_4)$ متغیرهای قابل مشاهده را نشان می‌دهند. هر حالت پنهان به حالت قبلی خود وابسته هستند و حافظه‌ی مربوطه به مشاهده را ایجاد می‌کنند. این ساختار، دینامیک سیستم زیربنایی را از مشاهدات حاوی نویزهای بسیار در بازارهای مالی جدا می‌کند و به متغیرهای پنهان اجازه می‌دهد الگوهای زمانی بلندمدتی را که ممکن است به طور مستقیم در داده‌ها قابل مشاهده نباشند، ثبت کنند.



شکل ۱.۵: مکانیزم کارکرد مدل حالت پنهان مارکوف

۳.۱.۵ مدل‌های حالت نهفته توالی

مدل‌های فضای حالت، متغیرهای پنهان را به عنوان حالت‌های دینامیکی پیوسته نشان می‌دهند، در حالی که مدل‌های پنهان مارکوف تعداد محدودی از رژیم‌های گسسته را بررسی می‌کنند. مدل‌های توالی شبکه‌های عصبی هر دو رویکرد را با یادگیری نمایش‌های پنهان غیرخطی به صورت صریح از داده‌ها تعمیم می‌دهند. اگرچه این روش‌ها در پیاده‌سازی متفاوت هستند، اما همگی هدف مشترک تخمین یک حالت پنهان دارند که اطلاعات تاریخی را خلاصه می‌کند و پیش‌بینی را از طریق توزیع شرطی $p(y_t x_t)$ بهبود می‌بخشد.

بسیاری از فرآیندهای متوالی، به ویژه در امور مالی، توسط عواملی هدایت می‌شوند که نمی‌توان به طور صریح مشاهده کرد. نمونه‌هایی از این فرآیندها عبارتند از احساسات دخیل در بازار، رفتار سرمایه‌گذاران، میزان نقدینگی موجود در بازار و رژیم‌های اقتصاد کلان. مدل‌های حالت پنهان به جای مدل‌سازی مشاهدات، فرض می‌کنند که توالی مشاهده شده توسط یک فرآیند پنهان زیربنایی ایجاد می‌شود. بنابراین هدف، به استنباط رسیدن در این حالت پنهان و استفاده از آن برای پیش‌بینی مشاهدات آینده است. [۸۶-۸۹]

از نظر ریاضی، فرض کنید x_t نشان‌دهنده حالت پنهان و y_t نشان‌دهنده متغیر مشاهده شده باشد. یک مدل حالت پنهان از دو جزء تشکیل شده است:

$$x_t = f(x_{t-1}, y_{t-1}) \tag{۱۰.۵}$$

که نحوه‌ی تکامل حالت پنهان را توصیف می‌کند، و

$$p(y_t|x_t), \tag{۱۱.۵}$$

که تولید مشاهدات از حالت پنهان را مدل‌سازی می‌کند. حالت پنهان به عنوان یک نمایش فشرده‌سازی شده از اطلاعات تاریخی عمل می‌کند و به مدل اجازه می‌دهد تا وابستگی‌های زمانی را ثبت کرده و در عین حال نویز مشاهده شده را فیلتر کند.

۱.۳.۱.۵ مدل‌های فضای حالت

مدل‌های فضای حالت[1] فرض می‌کنند که حالت پنهان دارای ارزش پیوسته است و طبق یک سیستم دینامیکی تکامل می‌یابد. هر دو حالت نهفته و مشاهدات با متغیرهای پیوسته نشان داده می‌شوند.

فرمول کلی بدین شرح است:

$$\begin{aligned} x_t &= f(x_{t-1}) + w_t, \\ y_t &= g(x_t) + v_t, \end{aligned} \tag{۱۲.۵}$$

که در آن w_t نویز فرآیند و v_t نویز مشاهده است.

مثال کلاسیک این بخش، فیلتر کالمن است که یک تخمین‌گر بازگشتی بهینه را تحت فرضیات خطی گاوسی ارائه می‌دهد. به طور کل می‌توان به ویژگی‌های این مدل‌ها در کاربرد تحلیلی در امور مالی و از نظر محاسباتی سریع بودن را اشاره کرد. همچنین لازم به ذکر است که این مدل‌ها دینامیک کوتاه‌مدت را ثبت کرده و برای تخمین نوسانات بازارها هم کاربرد دارند.

۲.۳.۱.۵ مدل‌های پنهان مارکوف

مدل‌های پنهان مارکوف[2] فرض می‌کنند که این حالت پنهان متعلق به مجموعه‌ای متناهی از رژیم‌های "گسسته" است. برای مثال در بررسی طبقه‌بندی رفتار بازار اگر فرض بگیریم که سه حالت زیر موجود باشند

$$x_t \in \{Bull, Bear, Sideways\}. \tag{۱۳.۵}$$

[1] State-Space Models (SSM)

[2] Hidden Markov Models (HMM)

حالت‌های پنهان بر اساس موارد زیر تکامل می‌یابند:

$$p(x_t|x_{t-1}), \tag{۱۴.۵}$$

در حالی که مشاهدات به شکل زیر دنبال می‌شوند

$$p(y_t|x_t). \tag{۱۵.۵}$$

برخلاف مدل‌های فضای حالت، مشاهدات ممکن است پیوسته بوده، حتی اگر حالت‌های پنهان گسسته باشند. این مدل‌ها در طبقه‌بندی رفتار بازار به خوبی عمل کرده و در شناسایی چرخه‌های اقتصادی نیز کاربرد خوبی دارند.

۳.۳.۱.۵ مدل‌های حالت نهفته عصبی

یادگیری عمیق مدرن معادلات انتقال سنتی و خطی طراحی شده را با توابع غیرخطی قابل یادگیری جایگزین می‌کند. یعنی به جای مشخص کردن

$$f(.) \tag{۱۶.۵}$$

به طور صریح، مدل یاد می‌گیرد که

$$x_t = f_\theta(x_{t-1}, y_{t-1}), \tag{۱۷.۵}$$

را محاسبه کند که در آن f توسط یک شبکه عصبی نمایش داده می‌شود. معماری‌های معمول از این دست مانند ،شبکه‌های عصبی بازگشتی مدل‌های حافظه کوتاه‌مدت بلندمدت، مدل واحد بازگشتی دروازه‌دار، شبکه‌های عصبی بیزی[۱] و مدل‌های فضای حالت عصبی هستند. برخلاف روش‌های کلاسیک، مدل‌های عصبی می‌توانند دینامیک‌های غیرخطی را به خوبی تقریب بزنند و به‌طور خودکار ویژگی‌های زمانی مرتبط را از داده‌ها یاد بگیرند. همچنین این مدل‌ها حافظه‌ی انعطاف پذیری داشته و مقیاس پذیری بهتری درون آنها رخ میدهد.

[1] Bayesian Neural Networks

۲.۵ مدل‌های شبکه عصبی بازگشتی

سری‌های زمانی مالی وابستگی زمانی قوی، پویایی‌های غیرخطی و ویژگی‌های آماری در حال تکاملی را نشان می‌دهند که مدل‌های خطی سنتی و غیرخطی را به چالش می‌کشند. بازده، نوسانات و حجم معاملات اغلب نه تنها به مشاهدات اخیر، بلکه به الگوهای انباشته شده در زمان نیز بستگی دارند. مدل‌های اقتصادسنجی کلاسیک معمولاً به ساختارهای با تأخیر ثابت و فرضیات ایستایی متکی هستند که ممکن است توانایی آنها را در ثبت وابستگی‌های متوالی محدود کند. شبکه‌های عصبی بازگشتی[1] با مدل‌سازی صریح پویایی از طریق حافظه داخلی، این محدودیت‌ها را برطرف می‌کنند و آنها را برای پیش‌بینی مالی و وظایف تصمیم‌گیری متوالی بسیار مناسب می‌کنند.

۱.۲.۵ شبکه‌های عصبی بازگشتی: معماری و فرمول‌بندی ریاضی

یک شبکه عصبی بازگشتی، دسته‌ای از معماری‌های عصبی است که برای پردازش داده‌های ترتیبی با حفظ یک حالت پنهان که در زمان تکامل می‌یابد، طراحی شده است. با توجه به دنباله ورودی $\{x_t\}_{t=1}^{T}$، حالت پنهان h_t به صورت بازگشتی به صورت زیر به‌روزرسانی می‌شود:

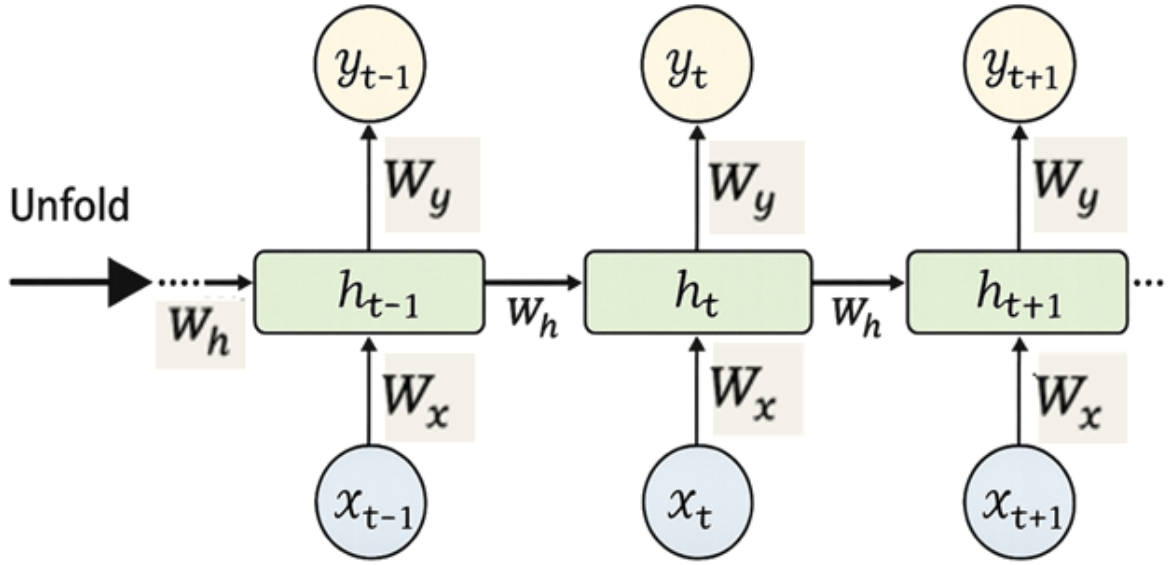
$$h_t = \phi(W_x x_t + W_h h_{t-1} + b), \tag{۱۸.۵}$$

که در آن W_x و W_h ماتریس‌های وزن، b یک عبارت انحراف و ϕ یک تابع فعال‌سازی غیرخطی است. خروجی y_t معمولاً به صورت زیر تعریف می‌شود:

$$y_t = \psi(W_y h_t + c), \tag{۱۹.۵}$$

با $\psi(.)$ که نشان‌دهنده فعال‌سازی خروجی است. آموزش از طریق $BackpropagationThroughTime(BPTT)$ انجام می‌شود، که شبکه را در زمان گسترش می‌دهد و پارامترها را با به حداقل رساندن یک تابع زیان بهینه می‌کند. این ساختار بازگشتی، شبکه‌های عصبی بازگشتی را قادر می‌کند تا وابستگی‌های پویا را که محدود به تأخیرهای ثابت نیستند، ثبت کنند.

[1] recurrent neural network (RNN)



شکل ۲.۵: مکانیزم مدل‌های شبکه عصبی بازگشتی

۲.۲.۵ مسئله گرادیان ناپدید شونده و منفجر شونده

علی‌رغم توانایی نظری آنها در مدل‌سازی وابستگی‌های بلندمدت[1]، شبکه‌های عصبی بازگشتی معمولی در طول آموزش از مشکل ناپدید شدن و انفجار گرادیان رنج می‌برند.[2] از آنجایی که گرادیان‌ها در طول گام‌های زمانی به عقب منتشر می‌شوند، ضرب مکرر توسط ماتریس وزن بازگشتی می‌تواند باعث شود گرادیان‌ها به صورت نمایی کاهش یابند یا به طور غیرقابل کنترلی رشد کنند. در امور مالی که اطلاعات مربوطه ممکن است افق‌های طولانی را در بر بگیرند، ناپدید شدن گرادیان‌ها مانع از شبکه برای یادگیری الگوهای پایدار مانند خوشه‌بندی نوسانات یا تغییر رژیم می‌شود. این محدودیت، توسعه معماری‌های دروازه‌ای مانند شبکه‌های $LSTM$ و GRU را که مکانیسم‌های ساختاری را برای تثبیت جریان گرادیان و حفظ اطلاعات بلندمدت معرفی می‌کنند، انگیزه می‌دهد. [۵۶]

[1] Long range dependencies

[2] The vanishing and exploding gradient problems

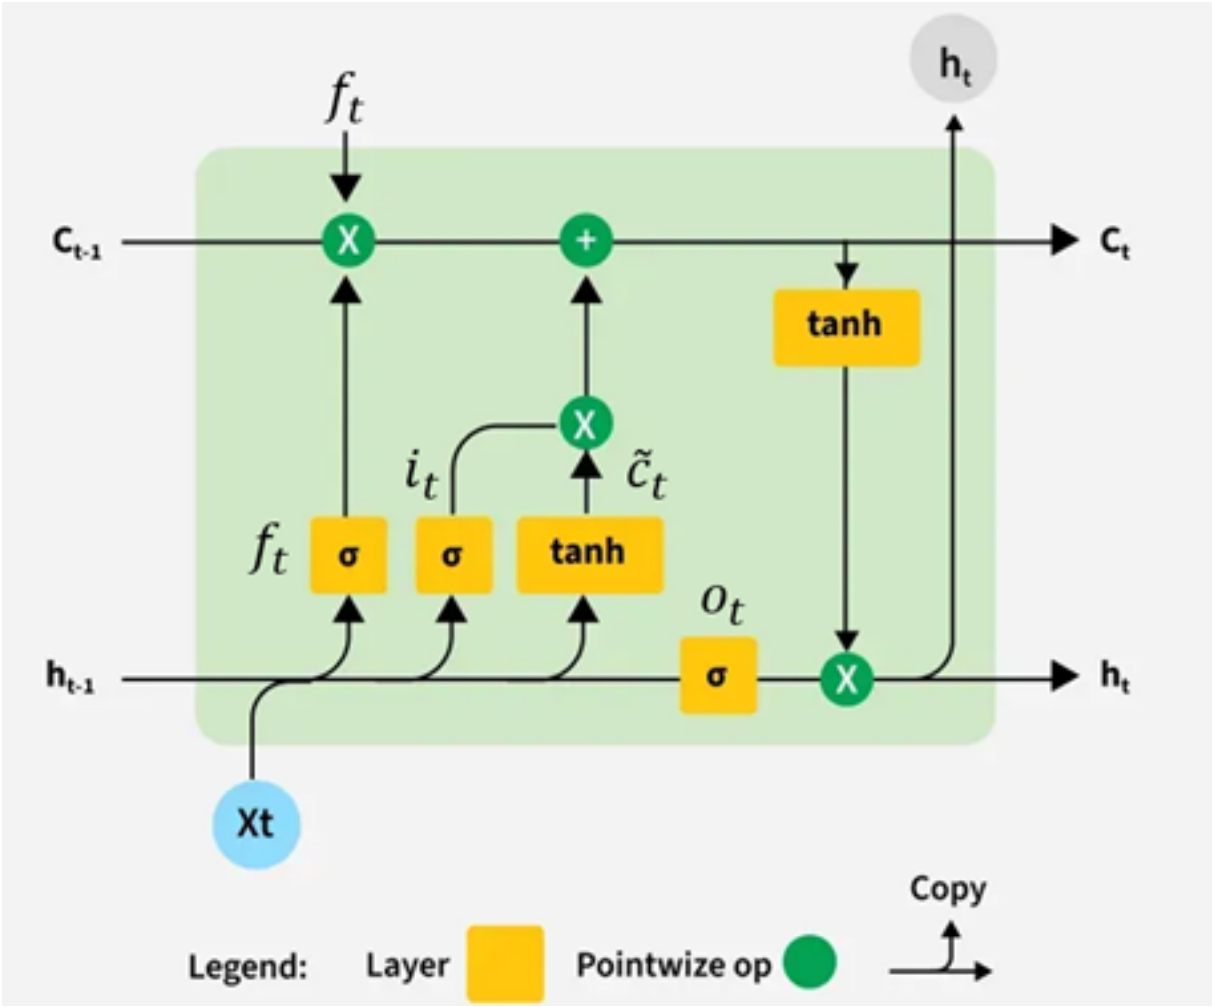
۳.۵ مدل‌های حافظه کوتاه‌مدت بلندمدت

مدل‌های حافظه کوتاه‌مدت بلندمدت[1] برای غلبه بر مشکل محو شدن گرادیان ذاتی در شبکه‌های عصبی بازگشتی استاندارد، با ترکیب سلول‌های حافظه دروازه‌دار، معرفی شدند. یک واحد مدل حافظه کوتاه‌مدت بلندمدت حالت سلول c_tرا حفظ می‌کند که امکان حفظ اطلاعات بلندمدت را از طریق به‌روزرسانی‌های کنترل‌شده فراهم می‌کند. مکانیسم دروازه شامل یک دروازه ورودی، دروازه فراموشی و دروازه خروجی است که به صورت زیر تعریف می‌شوند.

$$
\begin{aligned}
f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), \\
i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), \\
o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o), \\
\tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c), \\
c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \\
h_t &= o_t \odot \tanh(c_t),
\end{aligned}
\tag{۲۰.۵}
$$

که در آن $\sigma(.)$ نشان دهنده تابع سیگموئید لجستیک و $\odot$ ضرب عنصر به عنصر است. این معماری به LSTM ها اجازه می‌دهد تا به صورت انتخابی اطلاعات را حفظ یا حذف کنند که آنها را به ویژه در ثبت وابستگی‌های بلندمدت مانند پایداری نوسانات و پویایی رژیم در سری‌های زمانی مالی مؤثر می‌کند.

[1] long short-term memory (LSTM)



شکل ۳.۵: مکانیزم مدل‌های حافظه کوتاه‌مدت بلندمدت

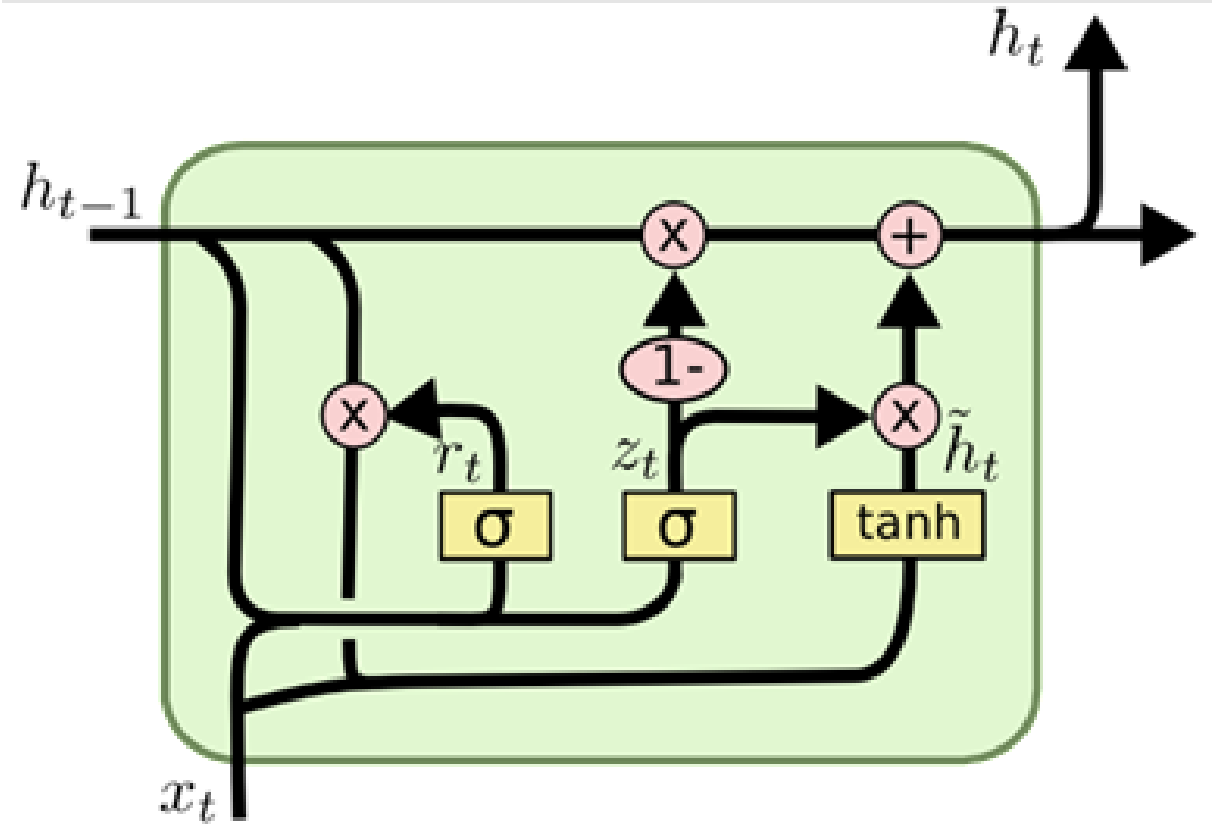
۱.۳.۵ واحد بازگشتی دروازه‌ای

واحد بازگشتی دروازه‌دار[1] یک جایگزین ساده‌شده برای مدل‌های حافظه بلندمدت کوتاه‌مدت است که حافظه و حالت‌های پنهان را در یک نمایش واحد ترکیب می‌کند. این مدل‌ها از دو دروازه استفاده می‌کنند: دروازه به‌روزرسانی و دروازه تنظیم مجدد، که با رابطه زیر داده شده است.

[1] Gated recurrent unit networks (GRU)

$$
\begin{aligned}
z_t &= \sigma(W_z x_t + U_z h_{t-1}),\\
r_t &= \sigma(W_r x_t + U_r h_{t-1}),\\
\tilde{h}_t &= \tanh(W_h x_t + U_h(r_t \odot h_{t-1})),\\
h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t.
\end{aligned}
\tag{۲۱.۵}
$$

با کاهش پیچیدگی معماری و در عین حال حفظ توانایی مدل‌سازی وابستگی‌های بلندمدت، این مدل‌های واحد بازگشتی دروازه‌ای اغلب به عملکردی قابل مقایسه با مدل‌های حافظه بلندمدت کوتاه‌مدت با هزینه محاسباتی کمتر دست می‌یابند. این امر این مدل‌ها می‌کند را در کاربردهای مالی شامل مجموعه داده‌های بزرگ جذاب می‌کند.



شکل ۴.۵: مکانیزم مدل‌های واحد بازگشتی دروازه‌ای

۲.۳.۵ کاربردهای مدل‌های مبتنی بر شبکه‌های عصبی بازگشتی در امور مالی

معماری‌های مبتنی بر شبکه‌های عصبی بازگشتی به ویژه مدل‌های بالا، به طور گسترده در مدل‌سازی مالی شامل وابستگی ترتیبی و زمانی[۱] به کار گرفته شده‌اند. کاربردهای رایج شامل پیش‌بینی بازده، پیش‌بینی نوسانات و مدیریت ریسک است که در آن‌ها پویایی زمانی نقش محوری ایفا می‌کند. آن‌ها همچنین برای طبقه‌بندی بازار، استراتژی‌های معاملات الگوریتمی استفاده می‌شوند. مدل‌های شبکه عصبی بازگشتی با یادگیری الگوهای زمانی غیرخطی از داده‌ها، جایگزینی انعطاف‌پذیر برای رویکردهای اقتصادسنجی سنتی، به ویژه در محیط‌های مالی با فرکانس بالا[۲] ارائه می‌دهند.

۳.۳.۵ مزایا و محدودیت‌های مدل‌های مبتنی بر شبکه‌های عصبی بازگشتی در تحلیل بازارهای مالی

معماری‌های شبکه عصبی بازگشتی مزایای متعددی برای مدل‌سازی سری‌های زمانی مالی ارائه می‌دهند. توانایی آنها در ثبت وابستگی‌های غیرخطی و یادگیری تطبیقی الگوهای پویا و پیچیده، آنها را برای پیش‌بینی وظایفی که در آنها مدل‌های خطی سنتی ممکن است شکست بخورند، بسیار مناسب می‌کند. شبکه‌های یادشده در بالا، به ویژه در مدل‌سازی اثرات حافظه بلندمدت مانند خوشه‌بندی نوسانات و پایداری رژیم بدون نیاز به تعیین صریح ساختارهای تأخیری مؤثر هستند. با این حال، مدل‌های مبتنی بر شبکه عصبی بازگشتی نیز محدودیت‌های قابل توجهی دارند. آنها بیش از اندازه به داده‌ها وابسته هستند و مستعد بیش‌برازش هستند، به خصوص در بازارهای مالی که نسبت سیگنال به نویز[۳] کم است. قابلیت تفسیر مدل در مقایسه با رویکردهای اقتصادسنجی کلاسیک محدود است و استنتاج اقتصادی و شفافیت نظارتی را پیچیده می‌کند. علاوه بر این، آموزش معماری‌های بازگشتی می‌تواند از نظر محاسباتی گران و حساس به انتخاب‌های فراپارامتری باشد. این محدودیت‌ها، تحقیقات مداوم را به سمت مدل‌های توالی قابل تفسیرتر و مقیاس‌پذیرتر، از جمله معماری‌های مبتنی بر توجه و ترنسفورمرها، سوق می‌دهد.

۴.۵ مروری بر تاریخچه‌ی پردازش زبان طبیعی قبل از ترنسفورمرها

پردازش زبان طبیعی[۴] دستخوش چندین تغییر الگوی اساسی شده است و از سیستم‌های زبانی مبتنی بر قانون به رویکردهای یادگیری ماشین آماری و بعدا مدل‌های زبانی تکامل یافته است. سیستم‌های اولیه پردازش زبان طبیعی به شدت به قوانین دستوری دست‌ساز و

[1] Temporal and Sequential dependencies
[2] High Frequency Trading (HFT)
[3] Signal to Noise Ratio (SnR)
[4] Natural Language Processing (NLP)

نمایش‌های نمادین متکی بودند که مقیاس‌بندی و تعمیم آنها به پدیده‌های زبانی متنوع دشوار بود. در طول دهه 1990 و اوایل دهه 2000، روش‌های مبتنی بر مدل‌های احتمالاتی، مانند مدل‌های زبانی $n-gram$ و مدل‌های پنهان مارکوف، غالب شدند و کاربردهای قوی‌تری مانند ترجمه ماشینی، تشخیص گفتار و برچسب‌گذاری اجزای کلام را امکان‌پذیر کردند. با این حال، این رویکردها از کمبود داده‌ها و درک معنایی محدود رنج می‌بردند زیرا کلمات به عنوان نمادهای گسسته بدون ثبت روابط زمینه‌ای آنها در نظر گرفته می‌شدند. با معرفی نمایش‌های توزیع‌شده کلمات از طریق چارچوب $Word2Vec$ توسط میکولوف، پیشرفت بزرگی رخ داد. $Word2Vec$ دو معماری عصبی کارآمد را معرفی کرد: مدل $ContinuousBag-of-Words(CBOW)$ که یک کلمه هدف را از متن اطراف آن پیش‌بینی می‌کند، و مدل $Skip-gram$ که کلمات متن اطراف را از یک کلمه هدف پیش‌بینی می‌کند. این معماری‌ها، جاسازی‌های برداری متراکم و کم‌بعد را یاد گرفتند که در آن‌ها کلمات مشابه از نظر معنایی موقعیت‌های نزدیک به هم را در فضای جاسازی پر می‌کنند و در نتیجه بر بسیاری از محدودیت‌های نمایش‌های پراکنده غلبه کردند. جاسازی‌های کلمه تولید شده توسط مدل‌های قبلی به طور قابل توجهی عملکرد بسیاری از وظایف پردازش زبان طبیعی پایین‌دستی را بهبود بخشیدند و پایه و اساس مدل‌های جاسازی متنی بعدی و در نهایت، معماری‌های مبتنی بر ترنسفورمرها را بنا نهادند. [۹۵، ۹۶، ۹۸، ۱۰۰]

فراتر از بهبود بازنمایی معنایی، این پیشرفت‌ها همچنین نشان‌دهنده‌ی گذار تدریجی از ویژگی‌های زبانی مهندسی‌شده‌ی دستی به یادگیری بازنمایی مبتنی بر داده بودند. روش‌های سنتی مانند TF، $TF-IDF$ و $BM25$ بر معیارهای آماری از پیش تعریف‌شده متکی بودند و کلمات را به عنوان واحدهای مستقل در نظر می‌گرفتند و توانایی آنها را در ثبت شباهت معنایی، چندمعنایی و ساختار نحوی محدود می‌کردند. مدل‌های تعبیه عصبی با یادگیری بازنمایی‌های برداری پیوسته مستقیماً از پیکره‌های متنی بزرگ، بسیاری از این کاستی‌ها را برطرف کردند. به طور خاص، معماری‌های $CBOW$ و $Skip-gram$ از $Word2Vec$ نشان دادند که کلماتی که در زمینه‌های مشابه ظاهر می‌شوند، تمایل به اشتراک‌گذاری معانی مشابه دارند و تعبیه‌هایی ایجاد می‌کنند که هم روابط معنایی و هم نحوی را حفظ می‌کنند. با این وجود، این تعبیه‌ها ایستا باقی ماندند و یک نمایش برداری واحد را به هر کلمه صرف نظر از زمینه آن اختصاص دادند. در نتیجه، کلمات مبهمی مانند "bank" چه به یک موسسه مالی اشاره کنند و چه به کنار رودخانه، تعبیه یکسانی دریافت کردند. این محدودیت، انگیزه‌ی توسعه‌ی مدل‌های زبان متنی، از جمله توکن‌های مربوطه و معماری‌های مبتنی بر ترنسفورمرها را ایجاد کرد که با مدل‌سازی پویای تعاملات بین تمام کلمات در یک جمله، بازنمایی‌های وابسته به زمینه ایجاد می‌کنند. این پیشرفت‌ها به طور قابل توجهی عملکرد را در طیف گسترده‌ای از وظایف پردازش زبان طبیعی، از جمله ترجمه ماشینی، پاسخ به سوالات، تحلیل احساسات و طبقه‌بندی متن، بهبود بخشید. [۹۷، ۹۹، ۱۰۱]

۱.۴.۵ مدل CBOW

با توجه به یک پنجره زمینه با اندازه m، این مدل کلمه مرکزی w_t را از کلمات اطراف آن پیش‌بینی می‌کند:

$$p\left(w_t|w_{t-m},...,w_{t-1},w_{t+1},...,w_{t+m}\right) \tag{۲۲.۵}$$

تعبیه متن به عنوان میانگین بردارهای کلمه اطراف محاسبه می‌شود:

$$h=\frac{1}{2m}\sum_{-m\leq j\leq m,\ j\neq 0} v_{w_{t+j}} \tag{۲۳.۵}$$

احتمال کلمه هدف برابر است با

$$p(w_t|h)=\frac{\exp\left(u_{w_t}^T h\right)}{\sum_{w=1}^{V}\exp(u_w^T h)}, \tag{۲۴.۵}$$

که در آن V اندازه واژگان است، v نشان دهنده جاسازی های ورودی است، u نشان دهنده جاسازی های خروجی است.

۲.۴.۵ مدل Skip-gram

این مدل با پیش‌بینی کلمات متن اطراف از یک کلمه مرکزی، وظیفه معکوس را انجام می‌دهد:

$$P(w_{t+j}|w_t),\quad -m\leq j\leq m,\ j\neq 0 \tag{۲۵.۵}$$

هدف، حداکثر کردن عبارت زیر است:

$$\frac{1}{T}\sum_{t=1}^{T}\sum_{-m\leq \substack{j\\ j\neq 0} \leq m}\log P(w_{t+j}|w_t), \tag{۲۶.۵}$$

که در آن

$$p\left(w_o|w_i\right) = \frac{\exp\left(u_{w_0}^T v_{w_i}\right)}{\sum_{w=1}^{V} \exp(u_w^T v_{w_i})}. \tag{۲۷.۵}$$

در عمل، از نمونه‌برداری منفی برای کاهش پیچیدگی محاسباتی تابع سافت‌مکس روی واژگان بزرگ استفاده می‌شود.

۵.۵ مدل‌های ترنسفورمر

مدل‌های سنتی یادگیری عمیق برای سری‌های زمانی مالی، مانند شبکه‌های عصبی بازگشتی و شبکه‌های حافظه کوتاه‌مدت بلندمدت، برای ثبت وابستگی‌های ترتیبی طراحی شده‌اند اما به دلیل محو شدن گرادیان‌ها و ظرفیت محدود حافظه، با روابط زمانی بلندمدت مشکل دارند. داده‌های مالی وابستگی‌های بلندمدت، تغییرات رژیم و تعاملات پیچیده بین دارایی‌ها را نشان می‌دهند که مدل‌سازی آنها با معماری‌های ترتیبی دشوار است. مدل‌های تبدیل‌کننده [۱]، که در ابتدا در پردازش زبان طبیعی [۲] معرفی شدند، با تکیه کامل بر مکانیسم‌های توجه [۳]، این محدودیت‌ها را برطرف می‌کنند و مدل‌سازی مستقیم وابستگی‌های بلندمدت [۴] را در طول زمان بدون تکرار امکان‌پذیر می‌سازند. این امر تبدیل‌کننده‌ها را به ویژه برای کاربردهای مالی که در آنها اطلاعات گذشته دور ممکن است مرتبط باقی بمانند، جذاب می‌کند.

۱.۵.۵ معماری ترنسفورمرها

معماری ترنسفورمرها در تحلیل بازارهای مالی، حول مفهوم خودتوجهی [۵] ساخته شده و به هر عنصر در یک توالی اجازه می‌دهد تا همزمان به تمام عناصر دیگر توجه کند. یک ترنسفورمر استاندارد از لایه‌های انباشته شده متشکل از ماژول‌های خودتوجهی چند سر [۶] و در پی آن شبکه‌های پیش‌خور مبتنی بر موقعیت [۷] تشکیل شده است. هر زیرلایه با اتصالات باقیمانده و نرمال‌سازی لایه برای تثبیت آموزش پیچیده شده است. برخلاف مدل‌های مبتنی بر شبکه‌های عصبی بازگشتی، ترنسفورمرها توالی‌ها را به صورت موازی پردازش [۸] می‌کنند و به طور قابل توجهی

[1] Encoder models
[2] Natrual Language Processing (NLP)
[3] Attention Mechanism
[4] Long range dependencies
[5] Self-Attention mechanism
[6] Multi-Head Attention Layers
[7] Feed-Forward Neural Netowrks
[8] Parallel computing

کارایی محاسباتی را بهبود می‌بخشند و امکان مقیاس‌پذیری را برای داده‌های مالی با ابعاد بسیار بالا، مانند بازده دارایی‌های چند متغیره، فراهم می‌کنند.

۲.۵.۵ فرمولاسیون ریاضی

در مرکز مکانیزم مبدل، اصل توجه ضرب نقطه‌ای مقیاس‌بندی‌شده قرار دارد. با توجه به ماتریس‌های پرس‌وجو، کلید و مقدار Q، K و V، توجه به صورت زیر محاسبه می‌شود:

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V, \tag{۲۸.۵}$$

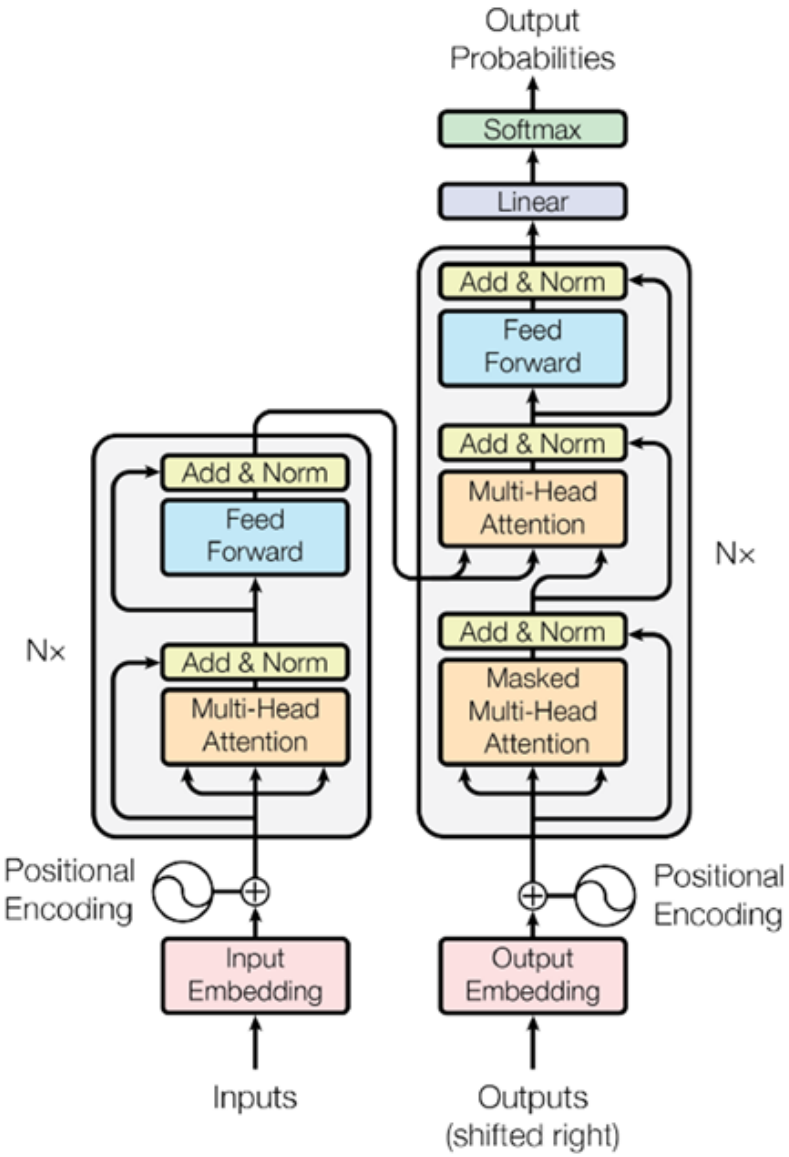
که در آن d_k ضریب نرمالایز کردن حاصل ضرب نقطه‌ای نسبت به مقیاس است. توجه چند سره [۱] این مکانیسم را با تصویر کردن Q، K و V در چندین زیرفضا گسترش می‌دهد و به مدل اجازه می‌دهد ساختارهای وابستگی متنوع را بررسی کند. از آنجایی که ترنسفورمرها فاقد ترتیب توالی ذاتی هستند، کدگذاری موقعیتی [۲] به تعبیه‌های ورودی [۳] اضافه می‌شود تا اطلاعات زمانی را تزریق کند که با استفاده از توابع سینوسی قطعی [۴] یا تعبیه‌های آموخته شده انجام می‌شود. این اجزا با هم، مدل‌سازی انعطاف‌پذیر و گویایی از وابستگی‌های زمانی پیچیده در سری‌های زمانی مالی را امکان‌پذیر می‌کنند.

[1] Multi-Head Attention

[2] Positional Encoding

[3] Inputs

[4] sinusoidal positional encoding



شکل ۵.۵: مکانیزم مدل اصلی ترنسفورمر

۳.۵.۵ رمزگذاری موقعیتی

برخلاف شبکه‌های عصبی بازگشتی، معماری ترنسفورمرها تمام توکن‌های ورودی را به طور همزمان پردازش می‌کند و بنابراین فاقد مکانیسم ذاتی برای ثبت ترتیب متوالی کلمات است. برای گنجاندن اطلاعات موقعیتی، کدگذاری موقعیتی[1] قبل از ورود توکن‌های ورودی به رمزگذار، اضافه می‌شود. کدگذاری‌های موقعیتی به هر توکن اطلاعاتی در مورد موقعیت مطلق آن توکن در توالی ارائه می‌دهند و مکانیسم خودتوجه را قادر می‌سازند تا بین ترتیب‌های مختلف کلمات تمایز قائل شود. ترنسفورمر اصلی از کدگذاری‌های موقعیتی سینوسی ثابت استفاده

[1] Positional Encoding (PE)

می‌کند، که در آن از توابع سینوس و کسینوس با فرکانس‌های مختلف برای تولید بردارهای موقعیت منحصر به فرد برای بسته‌های توکنی استفاده می‌شود. این فرمول‌بندی به مدل اجازه می‌دهد تا به طول‌های توالی که در طول آموزش مشاهده نشده‌اند، تعمیم داده شده و در عین حال روابط موقعیتی نسبی بین توکن‌ها را حفظ کند. [۱۰۲-۱۰۴]

$$\begin{aligned} PE(pos, 2i) &= \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \\ PE(pos, 2i+1) &= \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \end{aligned} \tag{۲۹.۵}$$

pos موقعیت توکن، i شاخص بُعد جاسازی و d_{model} بُعد جاسازی است.

۴.۵.۵ لایه‌ی رمزگذار

رمزگذار[1] مسئول تبدیل توالی ورودی به مجموعه‌ای از نمایش‌های زمینه‌ای است که وابستگی‌های محلی و سراسری بین توکن‌ها را ثبت می‌کند. این سیستم شامل مجموعه‌ای از لایه‌های رمزگذار یکسان است که هر کدام شامل دو زیرلایه اصلی هستند: یک مکانیسم خودتوجهی چند سر و یک شبکه پیش‌خور مبتنی بر موقعیت. اتصالات باقیمانده و نرمال‌سازی برای لایه‌ها پس از هر زیرلایه اعمال شده تا بهینه‌سازی پایدار را تسهیل کرده و جریان گرادیان را بهبود بدهند. از طریق توجه‌های مکرر و تبدیل‌های غیرخطی، هر لایه رمزگذار با ترکیب اطلاعات از تمام توکن‌های دیگر در توالی، به تدریج نمایش هر توکن را اصلاح می‌کند. در نتیجه، رمزگذار جاسازی‌های غنی تولید می‌کند که به عنوان ورودی برای رمزگشا یا وظایف پیش‌بینی پایین‌دست عمل می‌کنند.

$$\begin{aligned} Z^{(l)} &= \text{LayerNorm}(X^{(l)} + MHSA(X^{(l)})) \\ X^{(l+1)} &= \text{LayerNorm}(Z^{(l)} + FFN(Z^{(l)})) \end{aligned} \tag{۳۰.۵}$$

[1] Encoder Stack

۵.۵.۵ لایه‌ی رمزگشا

رمزگشا[۱] توالی خروجی را خودهمبسته تولید می‌کند و در حالی که بر اساس خروجی‌های تولید شده و نمایش‌های رمزگذار، یک توکن را در هر زمان پیش‌بینی می‌کند و بر اساس آنها عمل می‌کند. مشابه رمزگذار، رمزگشا نیز از چندین لایه یکسان تشکیل شده است. هر لایه رمزگشا شامل سه زیرلایه است: خودتوجه چندسر پوشاننده، توجه متقابل[۲] رمزگذار-رمزگشا، و یک شبکه پیش‌خور مبتنی بر موقعیت. بخش خودتوجه پوشاننده تضمین می‌کند که نشانه‌ها در طول آموزش قابل دسترسی باقی نمانند و در نتیجه ماهیت خودهمبسته تولید توالی را حفظ یکند. مکانیسم توجه متقابل، رمزگشا را قادر می‌سازد تا به طور انتخابی به نمایش‌های زمینه‌ای تولید شده توسط رمزگذار توجه کند و امکان هم‌ترازی بین توالی‌های ورودی و خروجی، رمزگذاری شده و رمزنگاری شده را فراهم کند. این معماری در کارهای توالی به توالی مانند ترجمه ماشینی، خلاصه‌سازی متن و تولید گفتگو بسیار کارآمد بوده است.

$$
\begin{aligned}
H_1 &= \text{MaskedMHSA}(Y) \\
H_2 &= \text{CrossAttention}(H_1, E, E) \\
Y_{out} &= \text{FFN}(H_2)
\end{aligned}
\tag{۳۱.۵}
$$

که در اینجا E خروجی لایه انکودر است

۶.۵.۵ تطبیق مدل با سری‌های زمانی مالی

ترنسفورمرها در ابتدا برای توالی‌های زبان طبیعی طراحی شده بودند، اما سری‌های زمانی مالی ویژگی‌های متمایزی دارند که نیاز به تطبیق مدل دارند. ترتیب زمانی از طریق کدگذاری‌های موقعیتی حفظ شده، در حالی که توالی‌های ورودی اغلب شامل ویژگی‌های چند متغیره مانند قیمت‌های دارایی‌ها، حجم‌ها و شاخص‌های فنی مرتبط با داده‌های مالی هستند. برای مدیریت خوشه‌بندی غیرایستا و نوسانات، مدل‌ها معمولاً از پنجره‌های غلتان[۳] یا توجه پنهان برای تمرکز بر داده‌های مرتبط اخیر استفاده می‌کنند. علاوه بر این، مشاهدات گمشده یا با فاصله نامنظم در داده‌های با فرکانس بالا را می‌توان از طریق جانهی یا پوشش توجه[۴] تطبیق داد. این تطبیق‌ها تضمین می‌کنند که ترنسفورمرها

[1] Decoder Stack
[2] Cross-Attention
[3] Sliding Window
[4] Attetion masking

می‌توانند به طور موثر شوک‌های کوتاه‌مدت و وابستگی‌های بلندمدت را همزمان در مجموعه داده‌های مالی ثبت کنند.

۷.۵.۵ کاربرد ترنسفورمرها در تحلیل بازارهای مالی

مدل‌های ترنسفورمر با موفقیت در طیف وسیعی از وظایف مالی به کار گرفته شده‌اند. آن‌ها برای پیش‌بینی بازده دارایی‌ها، ثبت وابستگی‌های پیچیده، پیش‌بینی نوسانات که در آن مکانیسم‌های توجه به مدل‌سازی الگوهای ناهمسانی واریانس کمک می‌کنند. همچنین در زمینه‌ی مدیریت ریسک، با تجزیه و تحلیل همبستگی‌ها و وابستگی‌های غیرخطی، استفاده می‌شوند. توانایی آن‌ها در پردازش توالی‌های بزرگ و چند متغیره به صورت موازی آن‌ها را برای معاملات الگوریتمی و تجزیه و تحلیل ریزساختار بازار[۱]، که در آن‌ها داده‌های با ابعاد بالا رایج هستند نیز مناسب می‌کند.

۸.۵.۵ ملاحظات آموزش و بهینه‌سازی

آموزش ترنسفورمرها بر روی داده‌های بازارهای مالی چالش‌های متعددی را ایجاد می‌کند. توابع زیان[۲] اصولا بر اساس وظیفه پیش‌بینی انتخاب می‌شوند. به طور مثال، میانگین مربعات خطا برای بازده‌ها یا لگاریتم درستنمایی منفی برای نوسانات، تکنیک‌های مرتبط با منظم‌سازی مانند $dropout$ و $decay\ weight$، برای جلوگیری از بیش‌برازش داده‌ها به دلیل داده‌های محدود بسیار مهم هستند. سری‌های زمانی مالی اغلب غیر ایستا هستند، بنابراین نرمال‌سازی دقیق داده‌ها، پنجره‌بندی داده‌ها یا آموزش آگاه از رژیم می‌تواند پایداری را بهبود بخشد. هزینه محاسباتی یکی دیگر از ملاحظات است، زیرا ترنسفورمرها حافظه محور هستند. استراتژی‌هایی مانند توجه پراکنده[۳]، برش توالی[۴] یا کاهش ابعاد[۵] معمولاً برای امکان‌پذیر کردن آموزش به کار گرفته می‌شوند.

۹.۵.۵ مزایا و محدودیت‌ها

ترنسفورمرها مزایای متعددی در مدل‌سازی مالی ارائه می‌دهند: این مدل‌ها می‌توانند وابستگی‌های بلندمدت را بدون بازگشت ثبت کنند، توالی‌های چند متغیره را به طور مؤثر مدیریت کرده و از طریق وزن‌های توجه، قابلیت تفسیر را فراهم کنند. با این حال، آن‌ها محدودیت‌هایی نیز در تفسیرپذیر داده‌ها دارند. ترنسفورمرها برای آموزش موثر به داده‌های قابل توجه و در حجم بالایی نیاز دارند که می‌تواند برای دارایی‌های

[1] Market micro-structures
[2] Loss Functions
[3] Sparse Attention
[4] Sequence Truncation or Sequence Cropping
[5] Dimensionality Reduction

با فرکانس پایین چالش برانگیز باشد. دلیل این است که از نظر محاسباتی گران و حساس به انتخاب‌های فراپارامتری هستند و بهینه‌سازی را نسبت به مدل‌های سنتی بسیار سخت‌تر می‌کنند. علاوه بر این، وزن‌های توجه[۱] ممکن است همیشه با روابط علی معنادار مطابقت نداشته باشند و هنگام استفاده برای تصمیم‌گیری در زمینه‌های مالی حساس به ریسک، نیاز به ارزیابی دقیق دارند.

۱۰.۵.۵ مهندسی ویژگی

مهندسی ویژگی[۲] فرآیند تبدیل داده‌های خام مالی به ورودی‌های آموزنده[۳] است که عملکرد پیشبینی مدل‌های یادگیری ماشین را افزایش می‌دهد. در سری‌های زمانی مالی، قیمت‌ها و بازده‌های خام اغلب حاوی نویز و وابستگی‌های زمانی پیچیده هستند، بنابراین ویژگی‌های مهندسی شده می‌توانند الگوها، روندها یا ساختارهای نوسان اساسی را آشکار کنند. تکنیک‌های رایج شامل میانگین‌های متحرک، شاخص‌های مومنتوم[۴]، معیارهای نوسان و گشتاورهای آماری[۵] است. مهندسی ویژگی به ویژه برای مدل‌های یادگیری عمیق مهم است، زیرا می‌تواند پیچیدگی آموزش را به نسبت کاهش داده و تعمیم را بهبود بخشد و به مدل اجازه دهد تا به جای نوسانات، بر پویایی‌ها و روابط معناداری که به کمک فرآیند مهندسی ویژگی‌ها استخراج شده‌اند تمرکز کند.

۶.۵ مدل TCN

شبکه عصبی پیچشی زمانی[۶] یک معماری یادگیری عمیق است که برای داده‌های ترتیبی و سری‌های زمانی مالی طراحی شده است و محاسبات بازگشتی را با عملیات پیچشی یک بعدی جایگزین می‌کند. برخلاف شبکه‌های عصبی بازگشتی، این مدل توالی‌ها را به صورت موازی پردازش می‌کند و در عین حال نظم زمانی را از طریق پیچش‌های سببی[۷] حفظ می‌کنند و تضمین می‌کنند که پیش‌بینی‌ها در زمان t فقط به ورودی‌های فعلی و گذشته بستگی دارند. برای ثبت کارآمد وابستگی‌های زمانی بلندمدت، این مدل‌ها از پیچش‌های متسع استفاده می‌کنند که به صورت نمایی میدان پذیرا را بدون افزایش تعداد پارامترها گسترش می‌دهند. همچنین اتصالات باقیمانده جریان گرادیان را بهبود بخشیده و آموزش شبکه‌های عمیق‌تر را تسهیل می‌کند. این مدل‌ها به دلیل محاسبات موازی، بهینه‌سازی پایدار و توانایی مدل‌سازی روابط بلندمدت، عملکرد بهتری را در مقایسه با معماری‌های بازگشتی داشته‌اند. [۹۰-۹۴]

[1] Attention Weights
[2] Feature Engineering
[3] Learnable Inputs
[4] Momentum Indicators
[5] Statistical moments
[6] Temporal Convolutional Network (TCN)
[7] Causal Convlutions

۱.۶.۵ فرمول بندی ریاضی

۲.۶.۵ causal convolution

برای یک دنباله ورودی

$$x = \{x_1, x_2, ..., x_T\}, \tag{۳۲.۵}$$

خروجی در زمان t برابر است با

$$y_t = \sum_{i=0}^{k-1} w_i x_{t-i}, \tag{۳۳.۵}$$

که در آن k اندازه هسته و w_i وزن‌های کانولوشن قابل یادگیری هستند. کانولوشن علی است، به این معنی که

$$y_t = f(x_1, ..., x_t), \tag{۳۴.۵}$$

و مشاهدات آینده هرگز استفاده نمی‌شوند.

۳.۶.۵ dilated convolution

این مدل‌ها از طریق پیچش‌های متسع[1]، میدان گیرنده را گسترش می‌دهند:

$$y_t = \sum_{i=0}^{k-1} w_i x_{t-di}, \tag{۳۵.۵}$$

که در آن d ضریب انبساط است. $d = 2^l$، که در آن l شاخص لایه است. بنابراین، اتساع به صورت $1, 2, 4, 8, 16, ...$ رشد می‌کند و امکان افزایش نمایی پوشش زمانی را فراهم می‌کند.

[1] Dialated Convolution

۴.۶.۵ میدان پذیرا

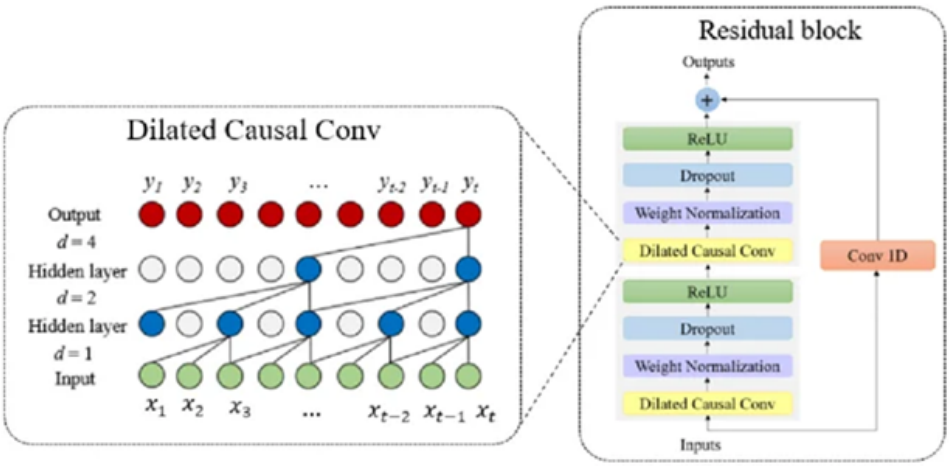
میدان گیرنده لایه L به صورت زیر است:

$$R = 1 + (1 - k) \sum_{l=0}^{L-1} d_l \tag{۳۶.۵}$$

وقتی $d_l = 2^l$ باشد، این به صورت زیر ساده می‌شود: $R = 1 + (k - 1)(2L - 1)$. از این رو، برای مدل‌سازی وابستگی‌های زمانی بسیار طولانی، تنها به تعداد کمی لایه نیاز است.

۵.۶.۵ بلوک باقیمانده

یک بلوک باقیمانده، $y = F(x) + x$ را محاسبه می‌کند، که در آن $F(x)$ نشان دهنده دو لایه کانولوشنی متسع شده روی هم انباشته شده که به دنبال آن فعال‌سازی و نرمال‌سازی غیرخطی انجام می‌شود.



شکل ۶.۵: مکانیزم کارکرد مدل پیچشی زمانی

از مزایای این مدل‌ها می‌توان به این مورد اشاره کرد که چون از خانواده‌ی مدل‌های شبکه‌های عصبی هستند، اطلاعات محلی را متوجه می‌شوند و وابستگی‌های زمانی کوتاه‌برد را بهتر از مدل‌های دیگر متوجه می‌شوند. همچنین می‌توان گفت که یادگیری باقی‌مانده، مشکل گرادیان ناپدید شونده را کاهش داده و معماری‌های عمیق‌تری را امکان‌پذیر می‌سازد.

فصل ۶

شبیه‌سازی‌ها و نتایج

در این فصل به شبیه‌سازی‌های این پژوهش می‌پردازیم. در اینجا به طور کلی به سه آزمایش برای بررسی رفتار مدل‌های خطی، مدل‌های ماشینی و مدل‌های مناسب مدل‌سازی توالی‌ها می‌پردازیم. آزمایش اول به جهت بررسی رفتار مقیاسی در داده‌های مالی و قدرت مدل‌های متفاوت در پیش‌بینی پذیری این بازارها طراحی شده‌اند. آزمایش دوم نیز به جهت مطالعه‌ی رفتار ماشین‌ها در سری‌های زمانی‌ای طراحی شده که در آن، ساختارها و طرح‌هایی وجود دارد که مدل با کمک بررسی آنها می‌تواند اطلاعات بیشتری را بررسی کند. در آزمایش آخر هم سعی داریم به کمک مدلی الهام گرفته شده از مدل بولتزمن و معیارهای برآمده از بازارهای مالی مانند معیار شاخص قدرت نسبی مبتنی بر شمارش، داده‌هایی تولید کرده و قدرت مدل‌های یادشده را در بررسی این سری‌های زمانی جدید که وابسته به پارامتر دما و رفتار جمعی هستند، بررسی و تحلیل کنیم. همچنین لازم به ذکر است که بر اساس مرور ادبیات مرتبط به بخش شبیه‌سازی‌ها و بررسی ضعف‌ها و نقاط قوت مورد مطالعه، بر اساس منابع اخیر [۵۶، ۱۱۸]، سری‌های زمانی تصنعی برای هر آزمایش تولید شده و به کمک معیارهای بررسی اطلاعات، مشاهدات سنجیده شده‌اند. [۱۱۹]

۱.۶ انتخاب مدل‌ها

مدل‌های انتخاب شده برای آزمایش اول و دوم، مدل $ARIMA$ از خانواده مدل‌های خطی، مدل $XGBOOST$ از خانواده مدل‌های مبتنی بر درخت تصمیم‌گیری به عنوان نماینده‌ای از مدل‌های یادگیری ماشین که معمولا برای تشخیص روابط غیرخطی مناسب هستند، انتخاب شده است. همچنین از خانواده‌ی مدل‌های یادگیری عمیق مناسب برای تحلیل داده‌های توالی، مدل‌های GRU، $LSTM$و TCN انتخاب شدند تا در کنار مدل‌هایی از خانواده مدل‌های ترنسفورمرها مورد بررسی و مطالعه قرار گیرند. مدل‌های انتخاب شده از خانواده‌ی ترنسفورمرها در زیربخش‌های زیر معرفی می‌شوند. لازم به ذکر است که در تمامی مراحل آزمایش‌های اول و دوم، پیکربندی مدل‌های ماشینی ثابت بوده و تغییر نکرده‌اند.

۱.۱.۶ مدل Causal Encoder Transformer

با انتخاب یک مدل ترنفسورمر مبدل ساده، مکانیسم خودتوجهی معماری مبدل را با اعمال یک پوشانندگی علی[1]، یا پیش‌بین بر روی ماتریس توجه، برای نوعی از پیش‌بینی ترتیبی که متناسب با امور مالی باشد و اطلاعاتی از آینده را به مدل ندهد، تطبیق می‌دهد. برای دنباله $X = (x_1, , x_T)$، نمایش در زمان t فقط مجاز به توجه به مشاهدات قبل از زمان بررسی $x_1, ..., x_t$ است و در نتیجه از نشت اطلاعات از مراحل زمانی آینده به منطق پیش‌بینی کننده‌ی مدل جلوگیری می‌کند. توجه ضرب نقطه‌ای مقیاس‌بندی شده پوشاننده را می‌توان به صورت $Attention(Q, K, V) = softmax(QK/d_k + M)V$ بیان کرد، که در آن $M_{ij} = -\infty$ وقتی $j > i$ باشد. این ساختار، مبدل‌های علّی را برای مدل‌سازی سری‌های زمانی خودهمبسته مناسب می‌کند، چرا که ماتریس مشاهدات را بالامثلثی کرده و اطلاعاتی از آینده را بروز نمیدهد. به عبارتی دیگر این مدل یک رمزگذار علی برآمده از یک معماری مبدل فقط رمزگذار است که در عین حال که مکانیسم خود-توجهی خود را با یک پوشاننده‌ی سببی اصلاح می‌کند، برخلاف یک رمزگذار مبدل معمولی، که هر موقعیت می‌تواند به صورت دو طرفه به تمام موقعیت‌های دیگر توجه کند، رمزگذار سببی نمایش در زمان t را به مشاهدات فعلی و قبلی محدود می‌کند. هر لایه رمزگذار عموماً شامل خود-توجهی چند سر به همراه پوشاننده در هر لایه، تبدیل‌های پیش‌خور مبتنی بر موقعیت مکانی داده‌ها، اتصالات باقیمانده برای هر لایه و نرمال‌سازی در انتهای رمزگذار است. این طراحی کمک می‌کند که مدل، قابلیت نمایش و موازی‌سازی محاسباتی مبدل‌های رمزگذار را حفظ کرده و در همان زمان به مجموعه اطلاعات زمانی مورد نیاز برای پیش‌بینی نیز توجه قادل شود. از آنجا که هیچ رمزگشای[2] جداگانه یا مکانیسم توجه متقابل رمزگذار-رمزگشای جداگانه‌ای مورد نیاز نبوده، همچنین می‌توان به کمک این مدل یک چارچوب فشرده برای پیش‌بینی توالی

[1] Causal Masking

[2] Decoder Stack

ارائه داد. برای سری‌های زمانی مالی، رمزگذار سببی می‌تواند روابط غیرخطی را در چندین افق زمانی بدون ایجاد سوگیری‌های پیش‌بین یاد بگیرد که آن را برای یادگیری بازده سهام، نوسانات و سایر مسائل پیش‌بینی توالی‌ها مناسب می‌کند. به این دلیل ترنسفورمر می‌تواند وابستگی‌ها را در افق‌های زمانی بسیار طولانی‌تری نسبت به معماری‌های شبکه‌های بازگشتی مرسوم ثبت کنند و در عین حال با انجام محاسبات به صورت موازی در طول آموزش، اطلاعات را سریع‌تر حفظ کنند. در امور مالی، این محدودیت علّی مهم است چرا که تضمین می‌کند که پیش‌بینی‌ها منحصراً از اطلاعاتی تولید می‌شوند که در زمان پیش‌بینی در دسترس بوده‌اند. [۱۰۵]

۲.۱.۶ مدل Residual Causal Transformer

مدل رمزگذار علی باقیمانده، پیش‌بینی مدل را با توجه صریح روی اتصالات باقیمانده یا پرش‌ها حول تبدیل‌های توجه، گسترش می‌دهد.بدون نیاز به اینکه در هر لایه یک ساخت نمایش جدید داشته باشیم، یک بلوک باقیمانده $H(l+1) = H(l) + F(H(l))$ تولید می‌کند، که در آن $F(.)$ نشان دهنده تبدیل انجام شده توسط توجه علی و لایه‌های غیرخطی است. پوشاننده علی ترتیب زمانی مسئله پیش‌بینی را حفظ کرده و این در حالی است که اتصالات باقیمانده مسیر مستقیمی برای اطلاعات و گرادیان‌ها را از طریق شبکه فراهم می‌کنند. بدین صورت مدل می‌تواند ویژگی‌های سطح پایین متناسب با ویژگی‌های سری‌های زمانی اصلی را حفظ کرده و در عین حال به تدریج و رفته رفته، به یادگیری نمایش‌های زمانی سطح بالاتر بپردازد. یادگیری باقیمانده برای معماری‌های عمیق‌تر مفید است چون مشکلاتی از قبیل بهینه‌سازی و تخریب‌های مرتبط با افزایش عمق شبکه را کاهش می‌دهد. بنابراین می‌توان ادعا کرد که برای سری‌های زمانی مالی، این معماری می‌تواند نسبت مفیدی را بین حفظ سیگنال اصلی و وابستگی‌های زمانی غیرخطی بلندمدت برقرار سازد. [۱۰۶]

۳.۱.۶ مدل PatchTST

این مدل یک معماری مبتنی بر رمزگذار است که برای پیش‌بینی سری‌های زمانی چند متغیره توسعه داده شده و یک سری زمانی را به عنوان دنباله‌ای از تکه‌های زمانی به جای مشاهدات تکی بررسی می‌کند. در اینجا یک دنباله ورودی به طول L، زیردنباله‌های توالی یا به همراه همپوشانی به طول P به توکن‌های سطح اولیه‌ی وصله تبدیل می‌شوند و توسط یک لایه‌ی رمزگذار پردازش می‌شوند. این استراتژی وصله‌بندی برای هر تکه، تعداد توکن‌های ارائه شده به مکانیسم توجه را کاهش داده و به این توکن‌ها این اجازه را می‌دهد تا الگوی زمانی محلی را به طور خلاصه‌تری یاد گرفته و مدل‌سازی داده‌های تاریخی طولانی‌تر را راحت‌تر انجام دهد.

یکی دیگر از ویژگی‌های مهم این مدل این است که استقلال کانالی را رعایت می‌کند. در اینجا که هر متغیر از یک سری زمانی چند متغیره به شکل یک دنباله جداگانه در نظر گرفته می‌شوند و پارامترهای یکسانی را در کانال‌ها به اشتراک می‌گذارند. این طراحی، کارایی محاسباتی

را بشدت بهبود بخشیده و خطر بیش‌برازش داده‌ها را با نسبت خوبی کاهش می‌دهد و مدل را قادر می‌کند تا هم الگوهای محلی درون تکه‌ها و هم وابستگی‌های دامنه‌های طولانی‌تر بین این تکه‌ها را ثبت کند. در نتیجه این مدل با ثبت اطلاعات محلی، نسبت به یک مدل ساده‌ی علی رمزگذار بهبود داده شده و به یک مبنای مهم برای پیش‌بینی سری‌های زمانی بلندمدت تبدیل شده و معماری مفیدی را در زمانی که دنباله‌های ورودی طولانی باید به طور موثر مدل شوند، ارائه می‌دهد. [۱۰۷]

۲.۶ انتخاب روش‌ها و معیارها

۱.۲.۶ آنتروپی اطلاعات شنون

آنتروپی اطلاعات، که در ابتدا توسط شانون[1] معرفی شد، عدم قطعیت یا غیرقابل پیش‌بینی بودن یک متغیر تصادفی یا سری زمانی را اندازه‌گیری می‌کند. در زمینه‌های مالی، این مفهوم میزان اطلاعات و میزان عدم قطعیت موجود در حرکات قیمت، بازده یا سایر سیگنال‌های بازار را کمی می‌کند. به طور رسمی، برای یک متغیر تصادفی گسسته X با نتایج ممکن $\{x_1, x_2, ..., x_n\}$ و احتمالات $p(x_i)$، آنتروپی شانون به صورت زیر تعریف می‌شود:

$$H(X) = -\sum_{i=1}^{n} p(x_i) \log(x_i). \tag{۱.۶}$$

آنتروپی بالاتر نشان‌دهنده تصادفی بودن بیشتر، عدم قطعیت بیشتر و در نتیجه قابلیت پیش‌بینی کمتر است، در حالی که آنتروپی پایین‌تر با نظم و ساختار بیشتر مطابقت داشته و بی‌نظمی و تصادفی بودن کمتری را نشان میدهد. آنتروپی اطلاعات می‌تواند به عنوان یک ویژگی مهم در مفهوم یادگیری و تئوری یادگیری در بررسی مدل‌های یادگیری ماشین و یادگیری عمیق عمل کند و برای ثبت سطح عدم قطعیت یا بی‌نظمی در سری‌های زمانی مالی مورد استفاده قرار گیرد. همچنین می‌تواند با ارائه یک دیدگاه احتمالی در مورد پیچیدگی بازار و عدم قطعیت منوبط به هر سری زمانی مالی، معیارهایی مانند آنتروپی جایگشت[2] را تکمیل کند.

[1] Shannon Entropy

[2] Permutation Entropy

۲.۲.۶ آنتروپی جایگشت

آنتروپی جایگشت یک معیار برای پیچیدگی اطلاعات است که با تحلیل الگوهای ترتیبی مشاهدات توالی‌ها، میزان بی‌نظمی یا غیرقابل‌پیش‌بینی بودن در یک سری زمانی ارتباط دارد. برخلاف معیارهای رایج برای آنتروپی اطلاعات، آنتروپی جایگشت در برابر نویزهای کوچک و بزرگ به نسبت مقاوم بوده و تحت تبدیل‌های یکنواخت، پویایی ثابتی دارد. به همین دلیل است که آن را به ویژه معیاری مناسب برای مهندسی ویژگی‌ها یا تحلیل داده‌های مالی مناسب می‌کند. این معیار با بررسی یک نگاشت توالی مقادیر به جایگشت‌هایی در یک پنجره‌ی مشخص زمانی که نشان‌دهنده ترتیب نسبی آنها هستند، محاسبه شده و پس از آن آنتروپی توزیع این جایگشت‌ها را محاسبه می‌کند.

آنتروپی جایگشت بالا می‌تواند نشان از پیچیدگی بیشتر در سری زمانی و نشان‌دهنده رفتار نامنظم و غیرقابل‌پیش‌بینی باشد و همچنین در مقابل، مقادیر پایین مربوط به آن، به الگوهای قطعی‌تر سری زمانی متناسب می‌شود. استفاده از آنتروپی جایگشت به عنوان یک ویژگی به مدل یادگیری ماشین این اجازه را می‌دهد تا پیچیدگی زمانی و تغییرات رژیم‌ها را بهتر ثبت کند و نمایش فشرده‌ای از پویایی بازار برای پیش‌بینی این سری‌های زمانی مالی ارائه دهد.

۳.۲.۶ آنتروپی بلوک

آنتروپی شنون میزان عدم قطعیت یک متغیر کاتورهای اندازه‌گیری می‌کند. اما اگر ما یک توالی نمادین داشته باشیم، چه باید کرد؟ در اینجا بحث آنتروپی بلوک طرح می‌شود. اگر یک توالی نمادین $S_1, S_2, ..., S_N$ داشته باشیم، که در آن مشاهدات به یک الفبای محدود A تعلق دارد، آنتروپی یک نماد به فرم زیر خواهد بود:

$$H(1) = -\sum_{s \in A} p(s) \log_2 p(s). \tag{۲.۶}$$

اگر چه نماد $H(1)$ عدم قطعیت یک تک مشاهده را نشان میدهد اما در نمایش ترتیب زمانی آن ضعف دارد. به عبارت دیگر دو توالی می‌توانند ساختار زمانی متفاوت ولی آنتروپی تک نماد یکسانی داشته باشند. همچنین می‌توان گفت که آنتروپی بلوک، آنتروپی شنون را به برای کلمات متوالی به طول L می‌تواند گسترش دهد. یعنی برای یک کلمه شروع شونده در زمان t خواهیم داشت:

$$W_t^{(L)} = (S_t, S_{t+1}, ..., S_{t+L-1}). \tag{۳.۶}$$

در اینجا اگر $p_L(w)$ را احتمال مشاهده‌ی کلمه‌ی w فرض کنیم آنتروپی بلاک آن کلمه به شکل زیر خواهد بود:

$$H(L) = -\sum_{w \in A^L} p_L(w) \log_2 p_L(w). \tag{۴.۶}$$

پس برای یک الفبا شامل M نماد می‌توان M^L کلمه‌ی احتمالی را متصور شد. و در این صورت بیشینه آنتروپی بلوک به شکل زیر خواهد شد:

$$H_{\max}(L) = L \log_2 M. \tag{۵.۶}$$

پس برای یک توالی دوتایی که در آن $M = 2$ است بیشینه آنتروپی بلوک برابر با $H_{\max}(L) = L$ خواهد بود. زمانی به این مقدار بیشینه خواهیم رسید که تمام کلمات با احتمال برابر داخل توالی وجود داشته باشند. پس برای حالتی که فقط بعضی از این کلمات مجاز به حضور هستند، یا برای حالتی که احتمال‌ها نابرابرند، $[H(L) < L]$ خواهد شد. این خود نشان‌دهنده‌ی افزونگی زمانی است.[۱] همچنین آنتروپی بلوک بر حسب هر سایت به کمک معادله‌ی زیر محاسبه می‌شود:

$$\frac{H(L)}{L}. \tag{۶.۶}$$

این نماد از آنتروپی میانگین عدم قطعیت بر حسب مشاهدات داخل یک کلمه به طول L نشان میدهد. همچنین افزایش آنتروپی شرطی با کمک فرمول زیر محاسبه می‌شود:

$$h(L) = H(L) - H(L-1), \tag{۷.۶}$$

که این نماد عدم قطعیت وارد شده به ازای هر نماد در حالی که $L-1$ نماد شناخته شده‌اند، نمایش میدهد. همچنین می‌توان گفت که برای یک فرآیند پایا، هر دوی این نمادها به یکدیگر تبدیل می‌شوند. به عبارتی دیگر داریم:

$$h_\infty = \lim_{L \to \infty} \frac{H(L)}{L} = \lim_{L \to \infty} [H(L) - H(L-1)]. \tag{۸.۶}$$

[1] Temporal Redundancy

در اینجا مشخصه‌ی آنتروپی نرخ [1] نمایانگر اطلاعات جدید تولید شده برای هر مشاهده است. برای مثال برای یک توالی دوتایی مستقل متعادل، آنتروپی نرخ معادل یک بیت به ازای هر نماد است. حال اگر مشاهده‌ی قبلی شامل اطلاعات قابل پیش‌بینی باشد، آنروپی نرخ کمتر از یک خواهد بود. همچنین افزایش نسبی [2] به صورت زیر محاسبه می‌شود:

$$R = 1 - \frac{h_\infty}{H(1)}. \tag{۹.۶}$$

اگر این مقدار زیاد باشد، به این معنا است که بسیاری از عدم قطعیت مرزی حال حاضر از طریق اطلاعات منوط به مشاهدات گذشته، قابل درک است. به تجربه می‌توان گفت که احتمال کلمات از فرکانس‌های مشاهده شده قابل تخمین خواهد بود. به این صورت که:

$$\hat{p}_L(w) = \frac{n_L(w)}{N - L + 1}. \tag{۱۰.۶}$$

که در اینجا صورت کسر تعداد مشاهدات کلمه‌ی w است. حال در اینجا آنتروپی بلوک تجربی به فرم زیر است:

$$\hat{H}(L) = -\sum_{w:n_L(w)>0} \hat{p}_L(w)\log_2\hat{p}_L(w). \tag{۱۱.۶}$$

همچنین لازم به ذکر است که برای L های بزرگ، تخمینگر بالا به سمت پایین متمایل می‌شود. این به این دلیل است که تعداد کلمات احتمالی به سرعت رشد کرده، در حالی که اندازه‌ی نمونه محدود باقی می‌ماند. به عبارتی دیگر خیلی از کلمات طولانی در مشاهدهات تجربی تحقق نیافته و احتمال تجربی آن برابر با صفر می‌شود. در نتیجه نتایج تجربی برای کلماتی با طول‌های بزرگ باید با احتیاط محاسبه شوند. [۱۱۷]

[1] Entropy Rate

[2] Relative Redundancy

۳.۶ آزمایش اول

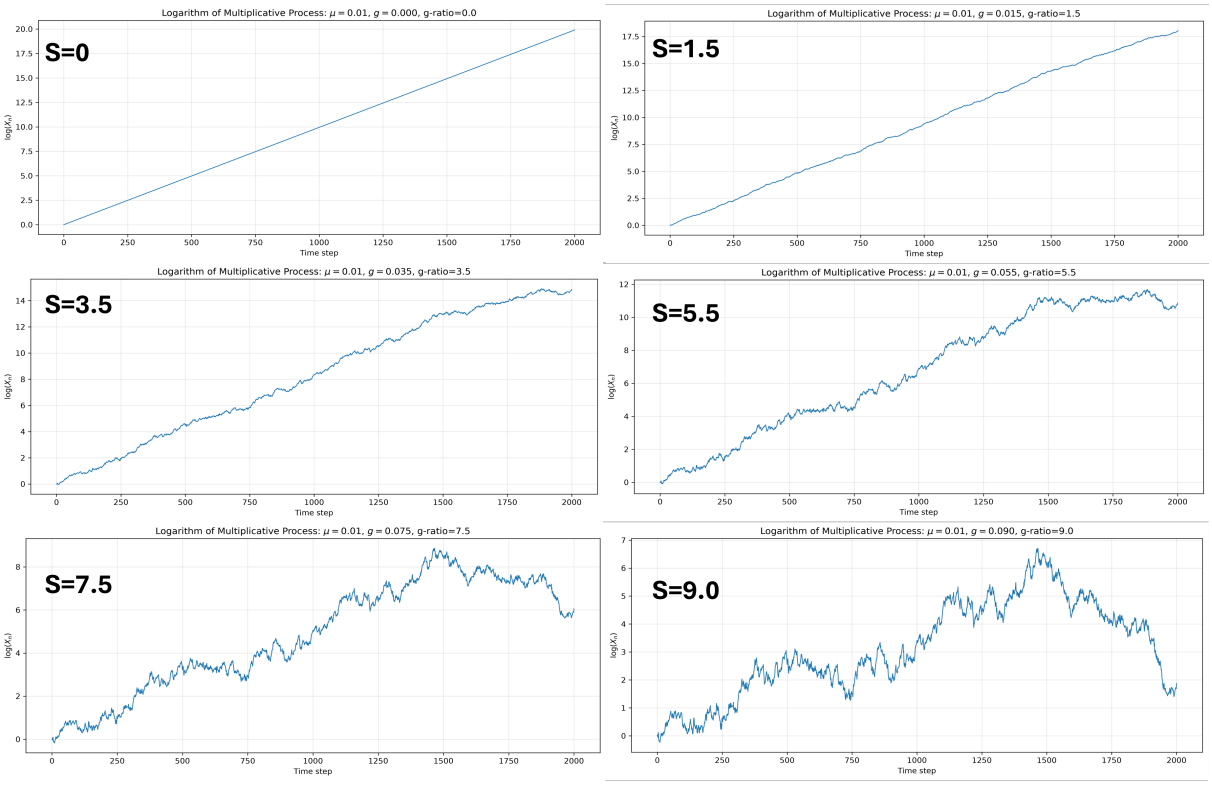
در این آزمایش به کمک معادله‌ی اویلر-ماریوما، [۱۱۶] 19 فرآیند تصادفی برای نسبت $s = \frac{g}{\mu}$ با گام‌های نیم قدمی تولید شدند. فرمول محاسبه‌ی این فرآیندهای تصادفی به شکل زیر است:

$$dx = \mu x_t dt + g x_t dw$$

$$\frac{dx}{x} = \mu dt + g dw \tag{۱۲.۶}$$

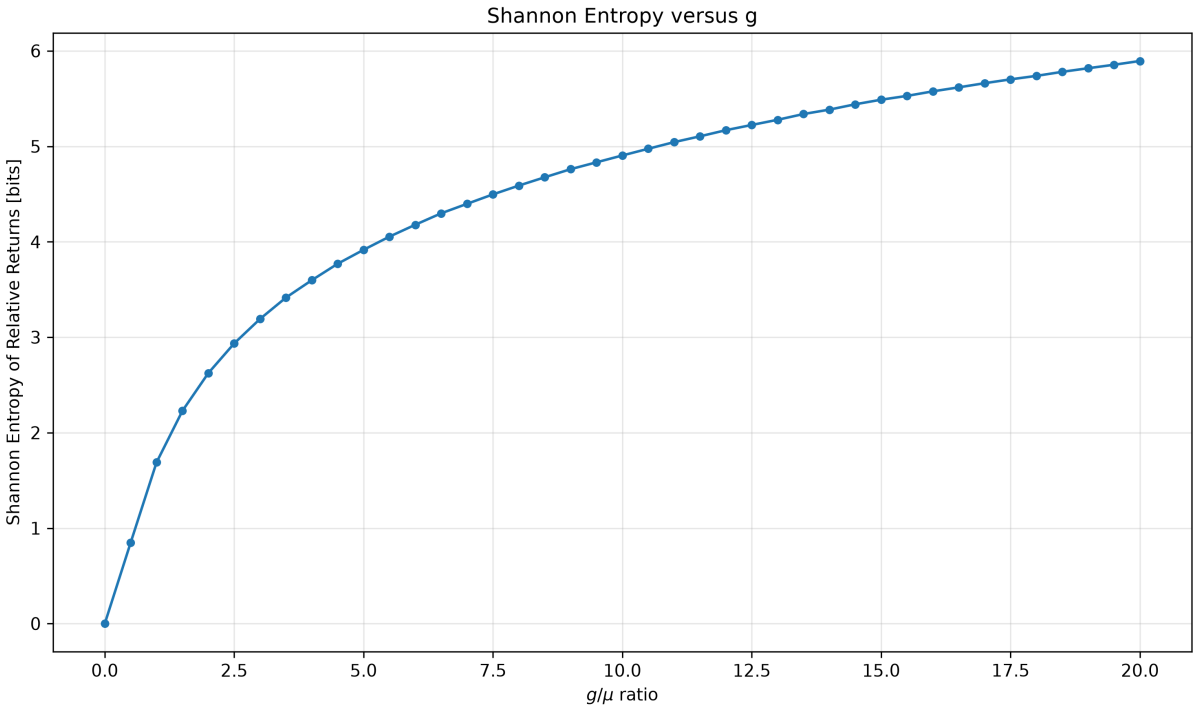
$$r_n = \frac{x_{n+1} - x_n}{x_n} = \mu dt + g dw$$

در شکل زیر می‌توانید نمونه‌هایی از این سری‌های زمانی تولید شده را مشاهده کنید.



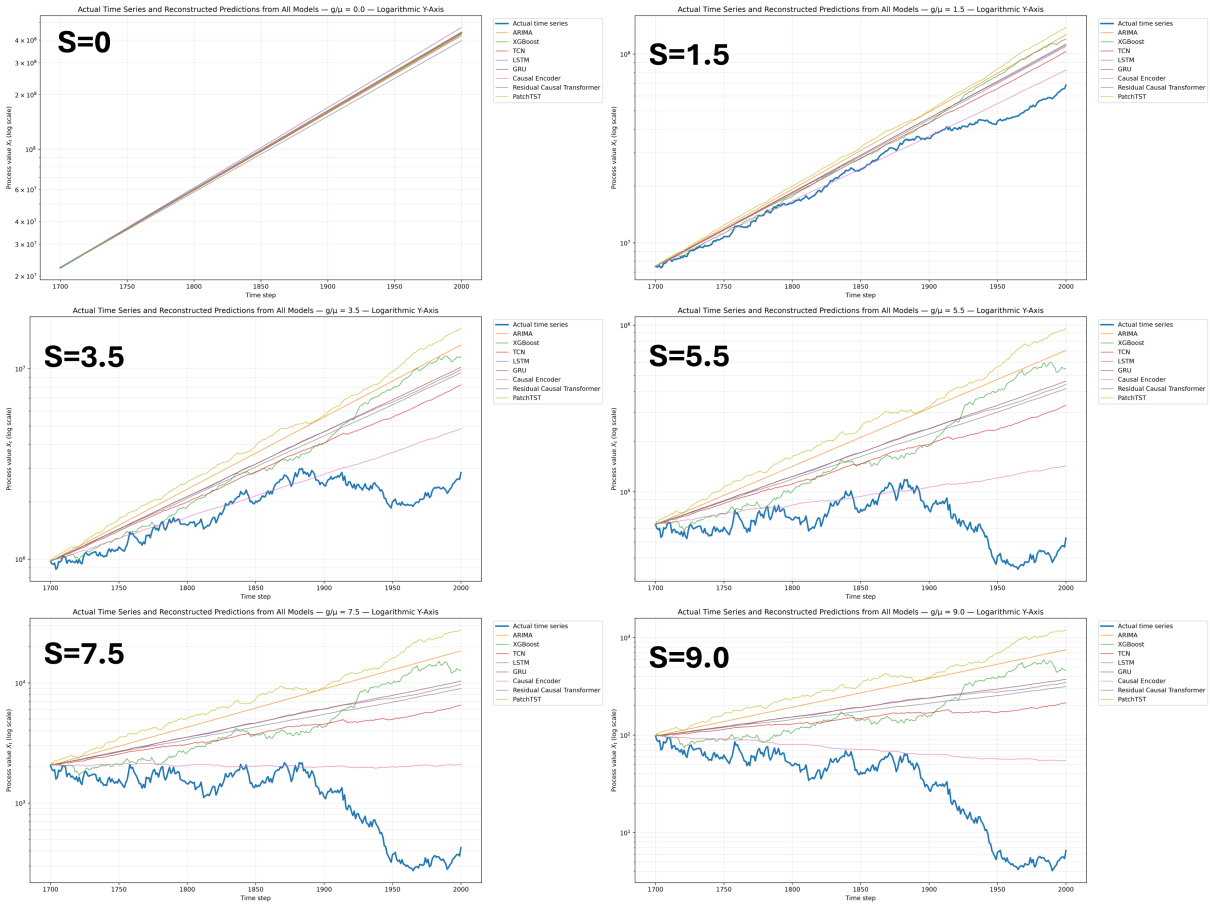
شکل ۱.۶: نمونه‌هایی از سری‌های زمانی تولید شده به کمک معادله‌ی اویلر

هدف در اینجا بررسی لگاریتم بازده سهام است. در اینجا با افزایش نسبت مذکور، نسبت نویز به روند افزایش یافته و عدم قطعیت وارد فرآیندهای تصادفی شده و مقدار آن افزایش می‌یابد. در نمودار زیر می‌توانید روند افزایش نسبت نویز به روند را در سری‌های زمانی تولید شده بررسی کنید. معادله‌ها تا نسبت نویز به روند ۹ برای بررسی ماشینی انتخاب شده‌اند.



شکل ۲.۶: بررسی نسبت نویز به روند به کمک آنتروپی اطلاعات (شنون) در سری‌های زمانی تولید شده

سپس مدل‌های یاد شده در بالا روی این سری‌های زمانی به طور جداگانه آموزش داده شده و پیش‌بینی‌های آنها مورد مطالعه قرار گرفته است. در شکل زیر می‌توانید تاثیر افزایش عدم قطعیت را در کاهش پیش‌بینی پذیری بازار در بررسی ماشینی را مطالعه کنید.

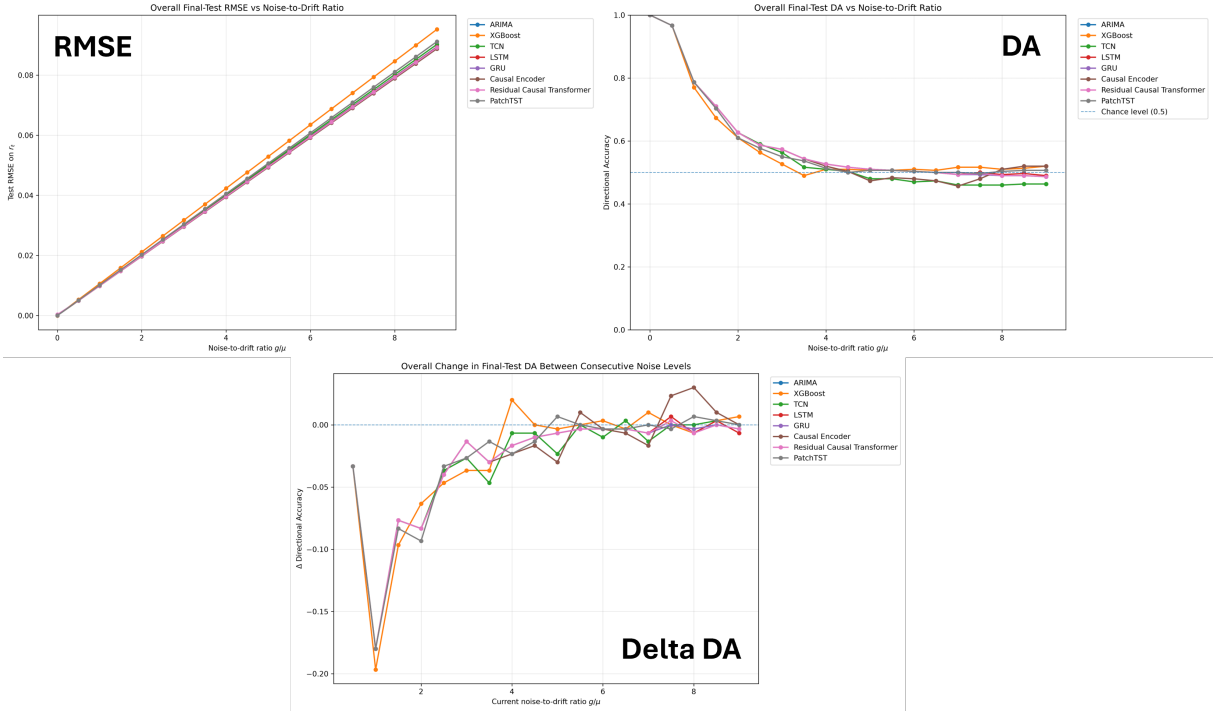


شکل ۳.۶: کاهش پیش‌بینی پذیری مدل‌ها با افزایش نویز در سری‌های زمانی تولید شده

دو معیار $RMSE$ و $DirectionalAccuracy$ اولی به دلیل بررسی رفتار مدل‌ها نسبت بهم و دومی به دلیل کاربرد رایج در پیش‌بینی جهت بازار در تحلیل بازارهای مالی انتخاب شده‌اند.

$$\begin{aligned} \mathrm{RMSE} &= \sqrt{\frac{1}{N}\sum_{t=1}^{N}(\hat{r}_t - r_t)^2} \\ \mathrm{DA} &= \frac{1}{N}\sum_{t=1}^{N} 1[\mathrm{sign}(\hat{r}_t) = \mathrm{sign}(r_t)] \end{aligned} \tag{۱۳.۶}$$

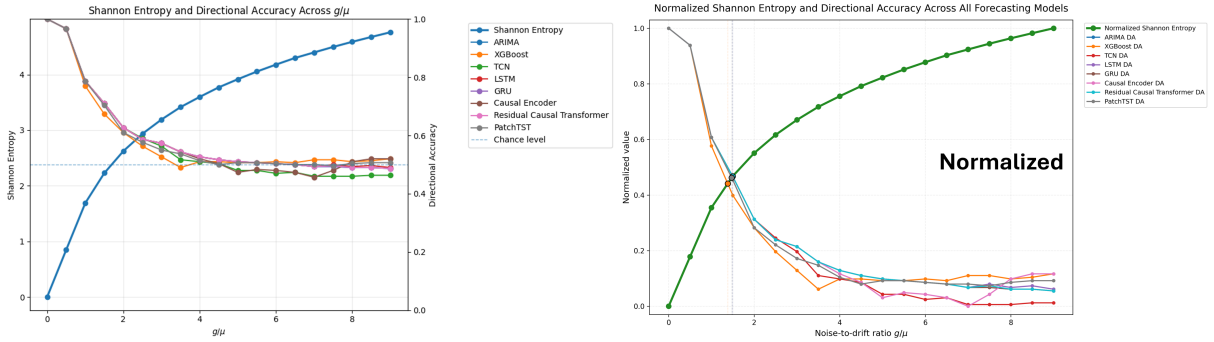
در شکل زیر می‌توانید تاثیر افزایش نویز بر کاهش پیش‌بینی پذیری همه‌ی مدل‌ها به کمک بررسی معیارها بالا را تا مرحله‌ای که نتایج آنها چیزی جز شانس نیست مشاهده کنید.



شکل ۴.۶: بررسی معیارهای پیش‌بینی پذیری مدل‌ها با افزایش نویز در سری‌های زمانی تولید شده

همچنین در این بررسی می‌توان به کمک آنتروپی اطلاعات بهنجارشده، به طور دقیق‌تری نقطه‌ای را که در آن مدل‌ها برتری پیش‌بینی پذیری خود را از دست می‌دهند پیدا کرد. در اینجا معیارهای $Directional Accuracy$ و آنتروپی اطلاعات شنون به کمک معادلات زیر بهنجار شده‌اند.

$$H^* = \frac{H - H_{\min}}{H_{\max} - H_{\min}}$$
$$DA^* = \frac{DA - DA_{\min}}{DA_{\max} - DA_{\min}} \quad (۱۴.۶)$$



شکل ۵.۶: بررسی افزایش آنتروپی اطلاعات و پیش‌بینی پذیری جهت بازار بهنجار شده با افزایش نویز در سری‌های زمانی تولید شده

به طور کلی می‌توان گفت که این آزمایش نشان دهنده‌ی تخریب واضح پیش‌بینی‌پذیری ناشی از نویز است. هنگامی که سهم تصادفی نسبت به رانش قطعی[1] ناچیز باشد، فرآیند تولید شده عدم قطعیت اطلاعات کمی دارد و می‌توان آن را با دقت جهت‌گیری تقریبا کامل پیش‌بینی کرد. افزایش نسبت نویز به رانش g/μ آنتروپی شانون را افزایش می‌دهد و همزمان باعث کاهش سریع عملکرد پیش‌بینی جهت‌گیری در تمام مدل‌های مورد بررسی می‌شود. قوی‌ترین تخریب در رژیم نویز کم تا متوسط رخ می‌دهد، پس از آن دقت جهت‌گیری به سمت معیار حدس تصادفی $DA = 0.5$ همگرا می‌شود و تغییرات متوالی در DA کوچک می‌شوند، که نشان دهنده اشباع تخریب پیش‌بینی است. در عین حال، $RMSE$ تقریبا متناسب با شدت نویز افزایش می‌یابد زیرا مقیاس نوسانات بازگشتی خود با g رشد می‌کند.

مسیرهای سری زمانی بازسازی شده شواهد مکملی را نیز ارائه می‌دهند. مسیرهای مدل در نویز کم از فرآیند قطعی پیروی می‌کنند اما با افزایش تصادفی بودن، به طور فزاینده‌ای از مسیر تحقق یافته فاصله می‌گیرند، و ترکیب بازگشتی خطاهای کوچک پیش‌بینی بازگشت را تقویت می‌کند. علیرغم تفاوت‌های اساسی در معماری از $ARIMA$ و $XGBoost$ گرفته تا مدل‌های بازگشتی، کانولوشنی و مبتنی بر ترانسفورمرها، مدل‌ها الگوهای تخریب کاملا مشابهی را نشان می‌دهند، که نشان می‌دهد محدودیت غالب در رژیم نویز بالا ناشی از کاهش محتوای اطلاعاتی فرآیند تصادفی زیربنایی است و نه صرفا از ظرفیت مدل.

در مجموع نتایج آنتروپی، $RMSE$، دقت جهت‌داری و بازسازی مسیر، از وجود گذار از یک رژیم با آنتروپی کم و بسیار قابل پیش‌بینی به یک رژیم با آنتروپی بالا و نویز غالب پشتیبانی می‌کنند که در آن پیش‌بینی جهت‌دار به عملکرد سطح شانس نزدیک می‌شود.

۴.۶ آزمایش دوم

برای تولید سری زمانی تصنعی، ۸ حالت ۸ گانه برای تولید طرح شکل دوتایی برای ایجاد ساختارهایی داخل سری زمانی تعریف شدند. بنا به آنچه از آنتروپی بلوک میدانیم، به کمک این هشت گانگی، می‌توان ۲۵۶ طرح تولید کرد. طرح‌های مدنظر سازنده‌ی سری زمانی مدنظر

[1] Deterministic Trend

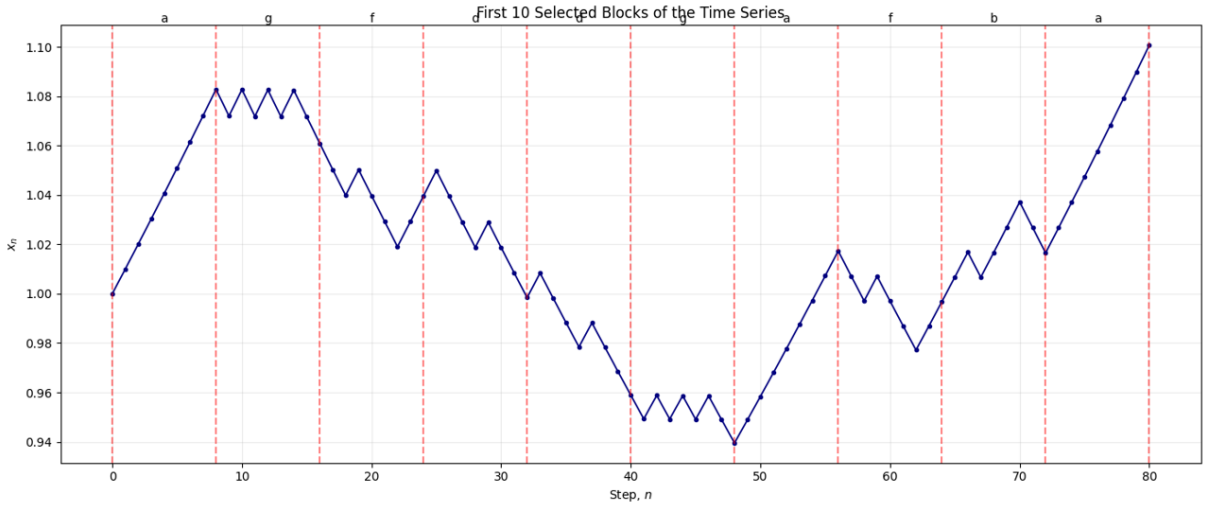
ما به شکل زیر هستند:

$$
\begin{aligned}
a &= [+1, +1, +1, +1, +1, +1, +1, +1], \\
b &= [+1, +1, -1, +1, +1, +1, -1, -1], \\
c &= [+1, -1, +1, -1, +1, -1, +1, +1], \\
d &= [+1, -1, -1, -1, +1, -1, -1, -1], \\
e &= [-1, -1, -1, -1, -1, -1, -1, -1], \\
f &= [-1, -1, +1, -1, -1, -1, +1, +1], \\
g &= [-1, +1, -1, +1, -1, +1, -1, -1], \\
h &= [-1, +1, +1, +1, -1, +1, +1, +1].
\end{aligned}
\tag{۱۵.۶}
$$

به عبارت دیگر و به فرم خلاصه‌تر، تمام ۸ حالت بالا را می‌توان به صورت زیر تصویر کرد:

$$
B_k = [U_k, V_k, W_k, V_k, U_k, V_k, W_k, W_k], \tag{۱۶.۶}
$$

که در اینجا $U_k, V_k, W_k \in \{-1, +1\}$ متغیرهای دودویی مستقل هستند. پس بدین صورت در ساختار سازنده‌ی سری زمانی وابسته به نماد ما، فقط سه بیت کاتوره‌ای جدید در هر بلوک هشت علامته معرفی می‌شوند. این بدان معناست که پنج علامت دیگر اطلاعات تکراری هستند که در هر هشت بلوک مشاهده می‌شوند. در شکل زیر می‌توانید به بخشی نمونه برداری شده از داده‌های تصنعی تولیدی توجه کنید:



شکل ۶.۶: نمونه‌ی تولید شده از ده بلوک اول سری زمانی تولید شده

در اینجا برای ساخت تمام سری زمانی، ۱۰۰۰ بلوک به طور مستقل و با احتمال برابر انتخاب شدند که در نتیجه ۸۰۰۰ علامت را تولید می‌کند. سری زمانی تصنعی ما به فرمت زیر تولید می‌شود:

$$x_{n+1} = x_n(1 + \mu s_n), \tag{۱۷.۶}$$

در اینجا داریم:

$$\mu = 0.01, \quad x_0 = 1, \quad s_n \in \{-1, +1\}. \tag{۱۸.۶}$$

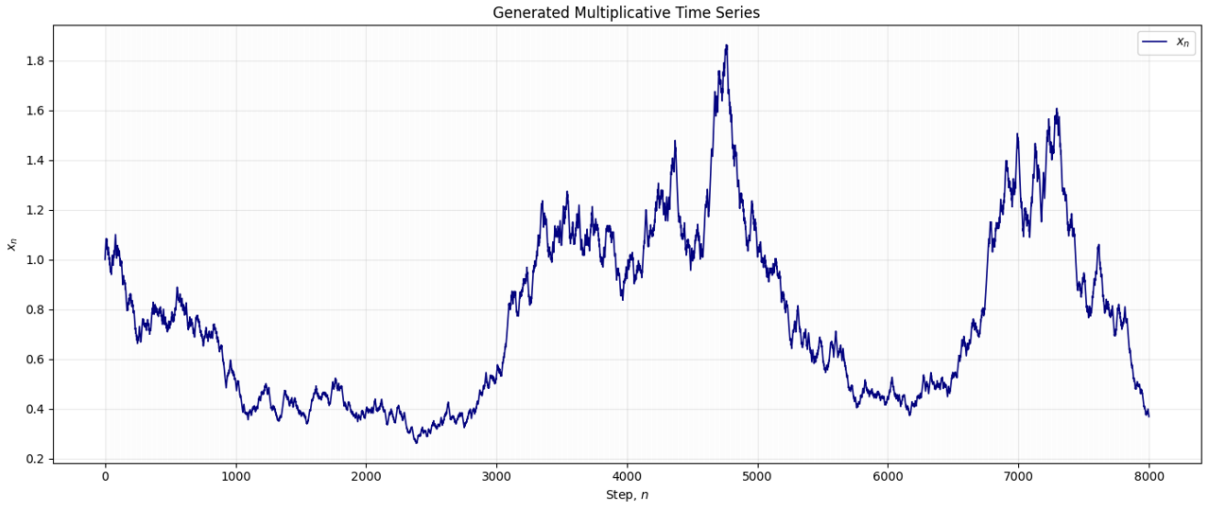
پس در اینجا بازده نسبی به شکل زیر است:

$$r_{n+1} = \frac{x_{n+1} - x_n}{x_n} = \mu s_n. \tag{۱۹.۶}$$

در اینجا داریم:

$$r_{n+1} \in \{-0.01, +0.01\}. \tag{۲۰.۶}$$

در اینجا ۸۰۰۱ مقدار برای سری زمانی و ۸۰۰۰ بازده سهام تعریف شده است. همچنین دیتا به سه بازه‌ی ۷۰-۱۵-۱۵ برای داده‌های آموزش، اعتبار و تست جهت آموزش ماشینی جدا سازی شده است. همچنین لازم به ذکر است که تنها داده‌ی بازده سهام نسبی به مدل‌های پیش بینی داده شده است و از دادن مهندسی ویژگی‌هایی مانند نام بلوک، جایگاه حروف داخل هر بلوک و علامت بلوک جلوگیری شده است. به همین جهت هیچ گونه نشت اطلاعاتی متوجه آزمایش ما، داده‌ی تولیدی و مشخصات ماشینی مورد استفاده نبوده و خروجی مدل‌ها کاملا آمادگی پیاده‌سازی در شرایط تجربی و با داده‌های واقعی را دارا هستند.



شکل ۷.۶: سری زمانی تولید شده به کمک ساختار الفبایی مدنظر

۱.۴.۶ مشخصه‌ی آنتروپیک داده‌ی سری زمانی تولید شده با ساختار الفبایی

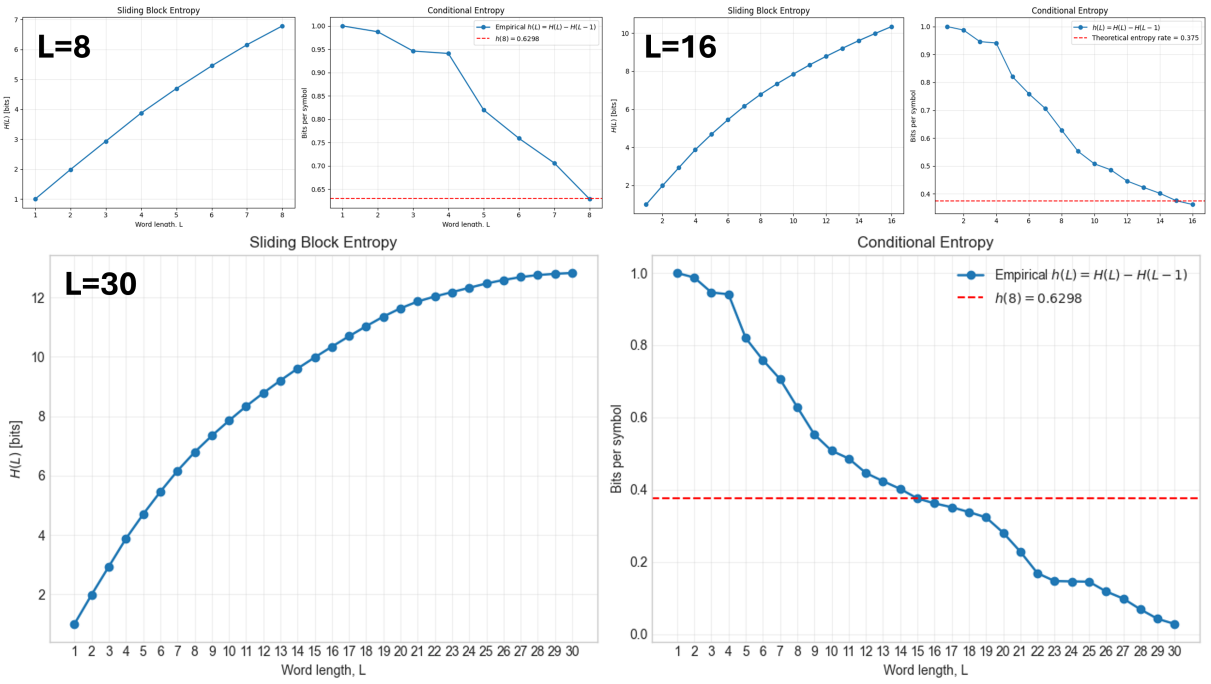
از آنجا که بلوک‌ها به توزیع یکسان انتخاب شده‌اند، آنتروپی تئوری برای این داده‌ها به صورت زیر است:

$$H_{\text{aligned}}(8) = \log_2 8 = 3\,\text{bits}. \tag{۲۱.۶}$$

در حالی که آنتروپی بلوک تجربی به صورت تقریبی برابر با $\hat{H}_{\text{aligned}}(8) = 2.9984\,\text{bits}.$ است. بدین ترتیب می‌توان آنتروپی نرخ را به صورت زیر نوشت:

$$\hat{h} = \frac{2.9984}{8} = 0.3748\,\text{bits per observation}, \tag{۲۲.۶}$$

که به شدت به مقدار تئوری مدنظر نزدیک است. مقدار تئوری برابر با: $h_\infty = \frac{3}{8} = 0.375$ است. آنتروپی مرزی برای یک علامت تقریبا برابر یک بیت است چرا که مثبت‌ها و منفی‌ها تقریبا با اوزان یکسان توزیع شده‌اند. همچنین افزونگی نسبی به صورت تقریبی به اندازه‌ی $R = 1 - \frac{0.375}{1} = 0.625$ است.



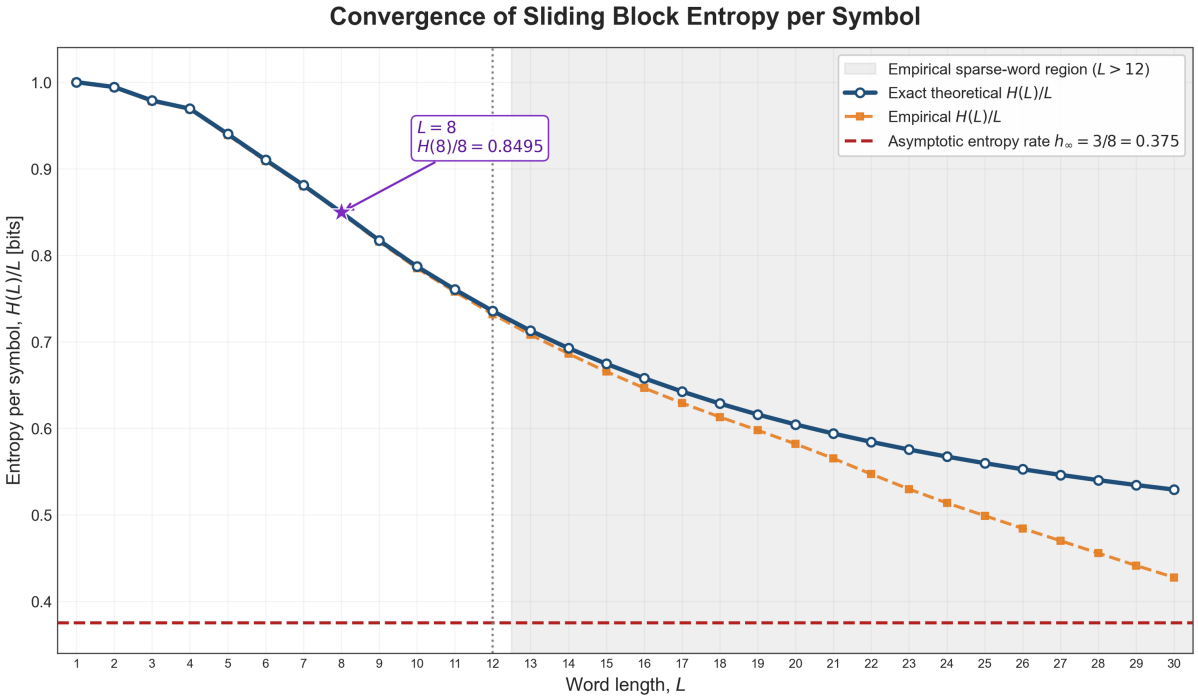
شکل ۸.۶: آنتروپی بلوک و آنتروپی شرطی برای طول کلمات ۸ و ۱۶ و ۳۰

پس می‌توان ادعا کرد که تقریبا 62.5 درصد عدم قطعیت یک تک نماد موقتا زائد بوده‌اند. میدانیم که در اینجا ما ۲۵۶ حالت دودویی از طول بلوک ۸ داریم در حالی که تابع تولیدی ما فقط از ۸ حالت از آنها استفاده می‌کند. پس تقریبا نزدیک به 3.125 درصد از تمام طرح سطح را شامل می‌شود. همچنین می‌توان گفت که در گذر از هر بلوک پنجره‌ای، طرح‌های مرزی‌ای اضافه بر طرح‌های ساخته شده‌ی ما تولید می‌شوند که این طرح‌ها، حاوی اطلاعات هستند. پنجره‌ی رونده‌ی آنتروپی بلوک در $L = 8$ تقریبا $H_{\text{sliding}}(8) = 6.7880$ bits است در حالی که در قیاس با مقدار تئوری داریم: $H_{\text{sliding}}(8) = 6.7960$ bits. پس آنتروپی شرطی برای این طول از کلمات به صورت زیر خواهد شد:

$$h(8) = H(8) - H(7) \approx 0.6298 \text{ bits.} \tag{۲۳.۶}$$

این مقدار از مقدار آنتروپی نرخ مجانبی به اندازه‌ی 0.375 انحراف دارد و همان که اندازه‌ی کلمات افزایش می‌یابد، آنتروپی شرطی به مقدار نرخ مجانبی متمایل می‌شود.

البته نکته‌ی مهم لازم به ذکر این است که به طور تقریبی و برای نتایج تجربی، به ازای افزایش طول اندازه‌ی کلمات از $L = 12$ نتایج تجربی به سوی پایین بایاس می‌شود.



شکل ۹.۶: آنتروپی بلوک بایاس شده به علت طول کلمات بزرگ

۲.۴.۶ بخش اول، مطالعه‌ی رگرسیونی

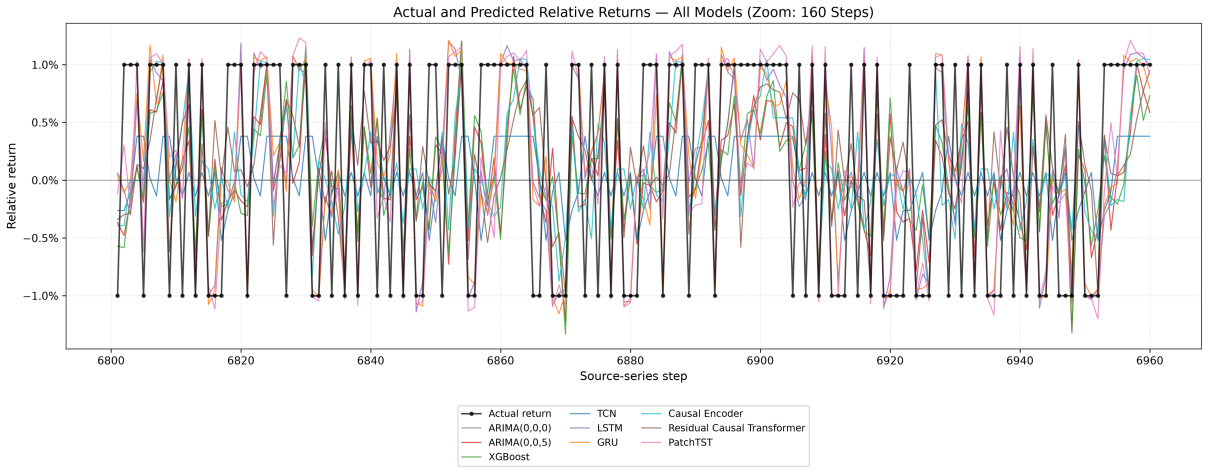
اولین فرمولاسیون پیش بینی برای پیش بینی‌های پیوسته‌ی بازده سهام نسبی به شکل زیر است:

$$\hat{r}_{t+1} = f_\theta(r_{t-L+1}, \ldots, r_t). \tag{۲۴.۶}$$

اگرچه بازده‌ی واقعی قرار است که همیشه $+0.01$ یا -0.01 باشد، مدل‌های رگرسیونی می‌توانند هر مقدار پیوسته‌ای را تولید کنند. مدل‌های ماشینی یاد شده به همراه هایپرپارامترهای فریز شده از آزمایش قبلی در اینجا نیز مورد استفاده قرار گرفته‌اند. تنها تغییر جزئی در پارامتر میانگیری گیری مدل پایه‌ی $ARIMA$ جهت دقیق‌تر شدن این مدل پایه با ساختار داده‌ی تولیدی است که از مقدار صفر به پنج تغییر کرده است. همچنین در اینجا معیار $Directional Accuracy$ تفاوت کوچکی کرده است و برای مقادیر غیرصفر، و مطابق معادله‌ی زیر استفاده می‌شود:

$$\mathrm{DA} = \frac{1}{N_{valid}} \sum_{t \in \nu} \mathrm{I}[\mathrm{sign}(r_t) = \mathrm{sign}(\hat{r}_t)], \tag{۲۵.۶}$$

در شکل زیر می‌توانید نمایی از پیش بینی‌های رگرسیونی ماشین‌های مورد مطالعه را بررسی کنید.



شکل ۱۰.۶: پیش بینی رگرسیونی مدل‌های مورد مطالعه از جهت بازار برای بازده سهام نسبی

همچنین از بازده‌های پیش بینی شده در بالا، مسیرهای فرآیند تصادفی و مسیرهای تولیدی از پیش بینی‌های ماشینی برای تنها یک قدم جلوتر بازیابی شده و مقدار بعدی با فرمولاسیون ریاضی زیر تولید می‌شود:

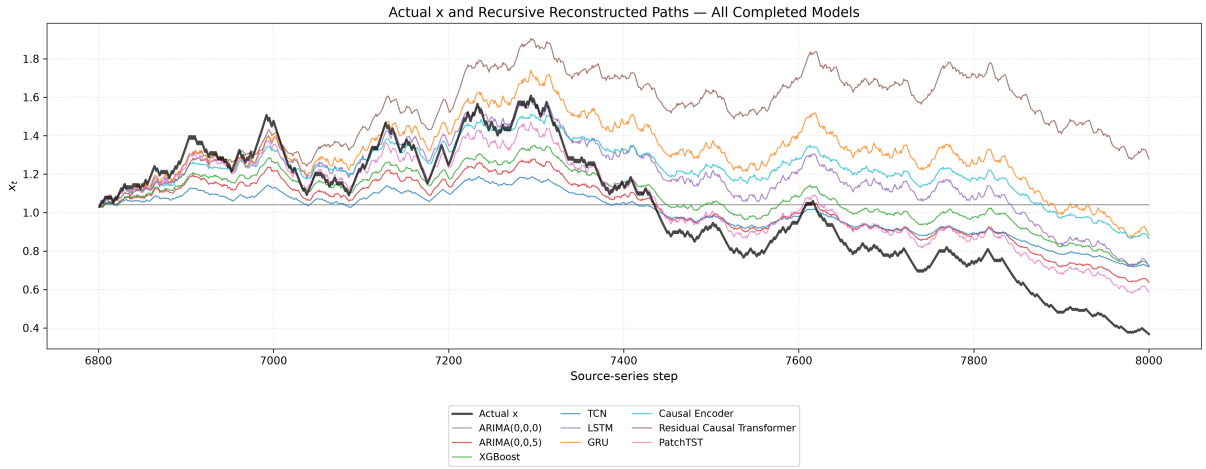
$$\hat{x}_{t+1}^{(1)} = x_t(1 + \hat{r}_{t+1}), \tag{۲۶.۶}$$

که در اینجا می‌توان همین رابطه را برای بازتولید بازگشتی[1] نیز به شکل زیر تعریف کرد:

$$\hat{x}_{t+1}^{(rec)} = \hat{x}_t^{(rec)}(1 + \hat{r}_{t+1}). \tag{۲۷.۶}$$

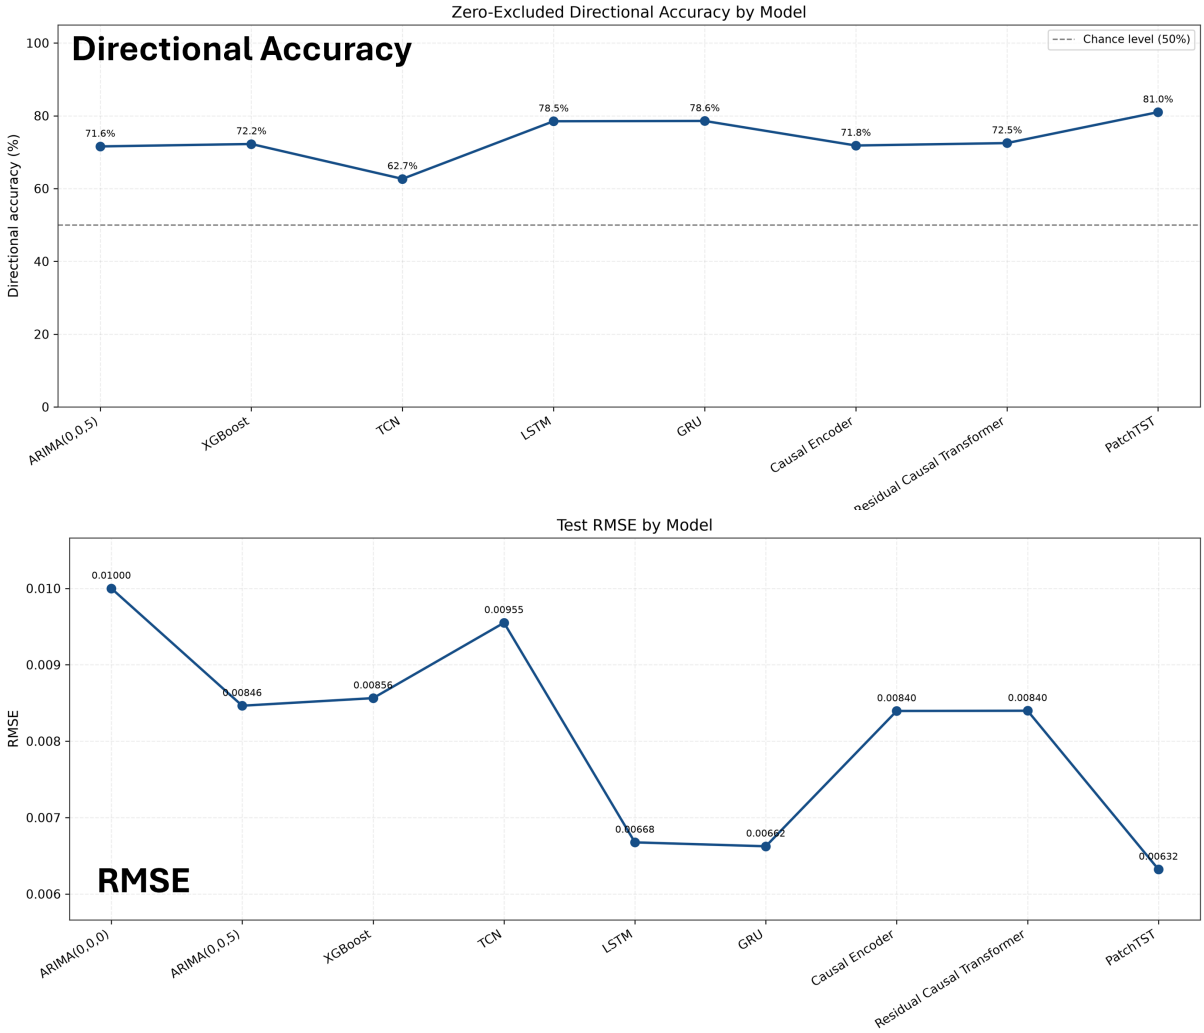
در نتیجه، خطاها در بازسازی یک مرحله‌ای منتشر نشدند، بلکه به صورت ضربی در مسیر بازگشتی انباشته شدند. در شکل زیر این نتایج به نمایش گذاشته شده‌اند.

[1] Recursive Reconstruction



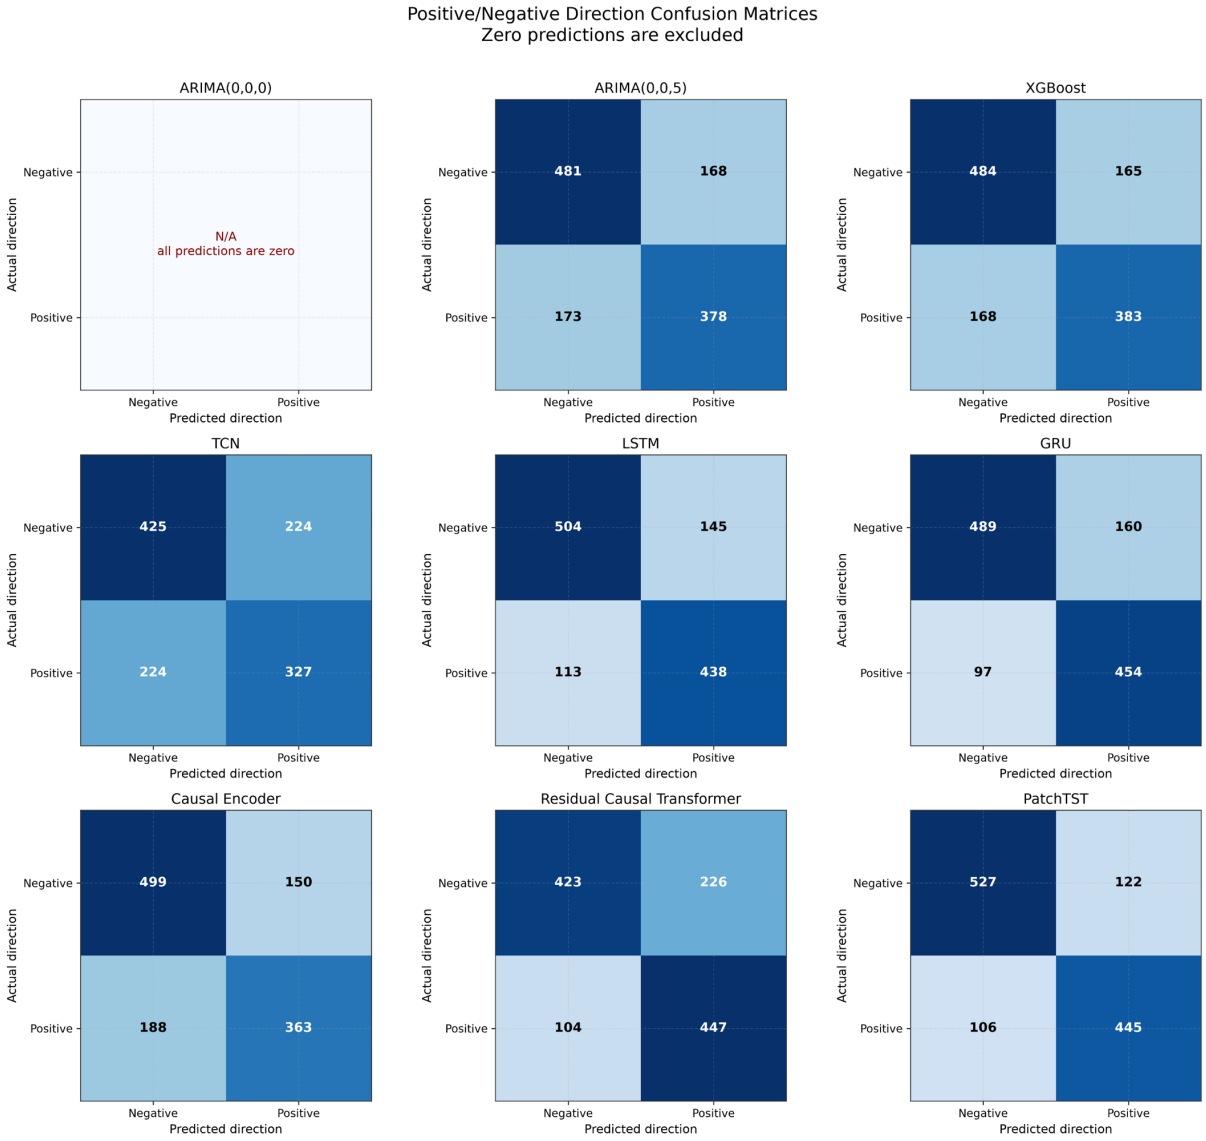
شکل ۱۱.۶: سری‌های زمانی بازیابی شده و نتایج پیش بینی‌های بازیابی شده مدل‌های ماشینی

در شکل زیر می‌توانید رفتار مدل‌های ماشینی پیاده‌سازی شده در این سری زمانی تصنعی را برای دو معیار DA و $RMSE$ مطالعه کنید. بر اساس این شکل، بهترین مدل، از مدل‌های خانواده‌ی ترنسفورمرها، مدل $PatchTST$ بوده که هم در خانواده‌ی ترنسفورمرها و هم نسبت به همه‌ی مدل‌های مورد مطالعه در این پژوهش رفتار بهتری داشته است. سپس مدل‌های یادگیری عمیق $LSTM$ و GRU رفتار بهتری در تشخیص جهت بازار داشته و بعد از آنها نیز مدل‌ها دیگر خانواده‌ی ترنسفورمرها قرار دارند. همچنین مشخص است که مدل‌های ماشینی و پایه عملکرد به نسبت بهتری نسبت به مدل TCN در این آزمایش داشته‌اند. نتایج بدست آمده از نمودار معیار $RMSE$ نیز بر مشاهدات معیار قبلی صحه میگذارند.



شکل ۱۲.۶: مقایسه‌ی مدل‌های ماشینی با کمک معیارهای DA و $RMSE$

همچنین در شکل زیر، نیز نتایج ماتریس درهمریختگی مدل‌ها برای پیش بینی جهت بازار مورد مطالعه قرار گرفته است.



شکل ۱۳.۶: ماتریس درهم‌ریختگی مدل‌های ماشینی

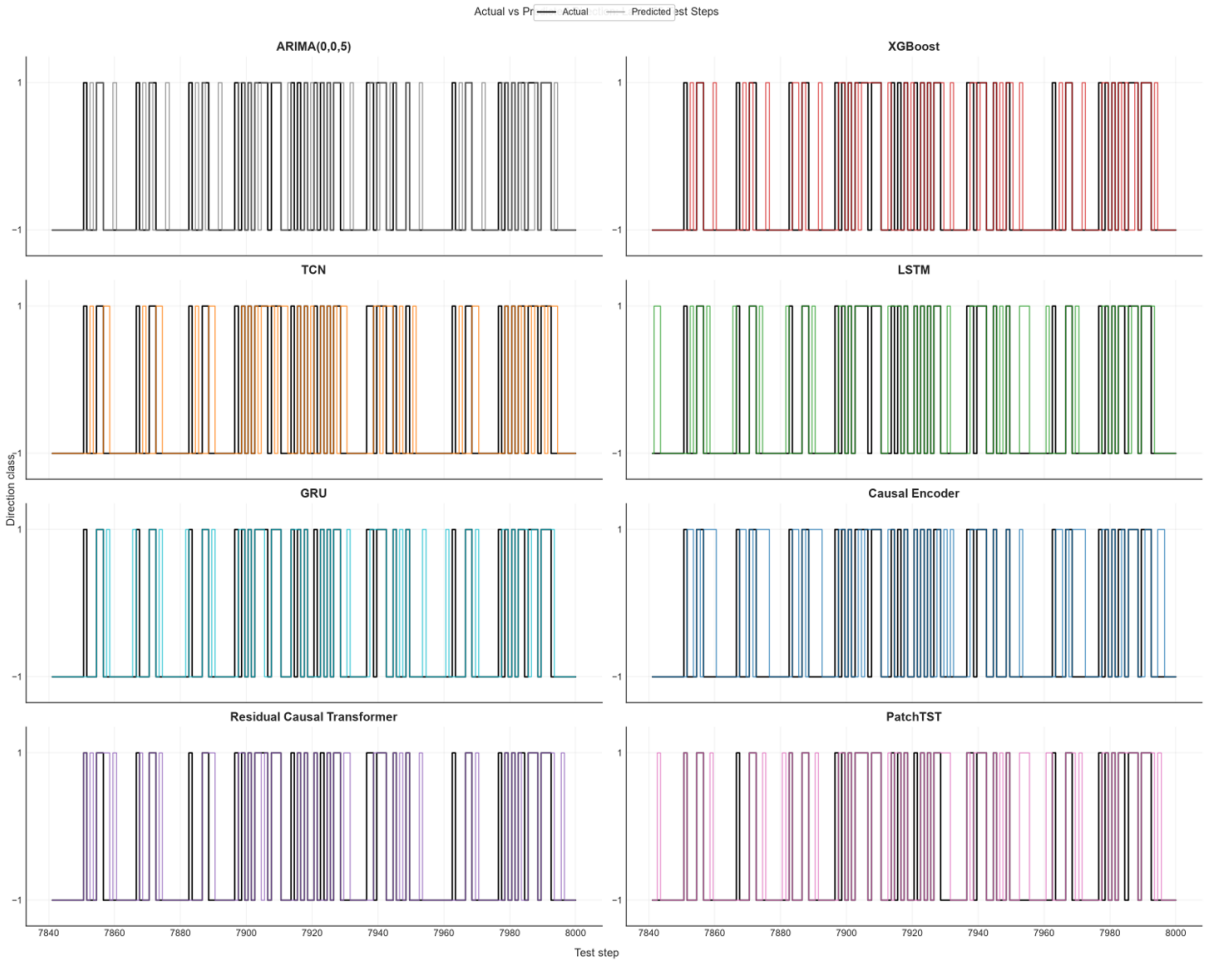
بر اساس شکل بالا مدل $PatchTST$ تقریبا 81.0 دقت بدست آورد که بسیار نزدیک به دقت بهینهی این آزمایش است و قوی‌ترین دقت رگرسیونی این آزمایش نام گرفت. همچنین مدل‌های GRU و $LSTM$ به ترتیب تقریباً 78.6 درصد و 78.5 درصد را به دست آوردند. مدل‌های دیگر خانواده‌ی ترنسفورمرها به همراه مدل‌های پایه $ARIMA$ و $XGBOOST$ دقت جهت‌دار 71 تا 73 درصد را ثبت کردند. مدل TCN نیز دقت 62.7 درصد را بدست آورد.

۳.۴.۶ بخش دوم، مطالعه‌ی طبقه‌بندی

از آنجا که بزرگی هر بازده ثابت شده است، مسئله‌ی پیش بینی بازار را می‌توان به یک مسئله‌ی طبقه‌بندی دودویی بازنویسی کرد. در اینجا داریم:

$$y_t = \begin{cases} 1, & r_t = +0.01, \\ 0, & r_t = -0.01. \end{cases} \tag{۲۸.۶}$$

در شکل زیر می‌توان نتایج هر مدل را در پیش بینی بازده نسبی روز بعد بررسی کرد:



شکل ۱۴.۶: مقایسه‌ی عملکرد مدل‌ها در پیش بینی بازده نسبی سهام یک روز بعد به کمک مسئله‌ی طبقه بندی

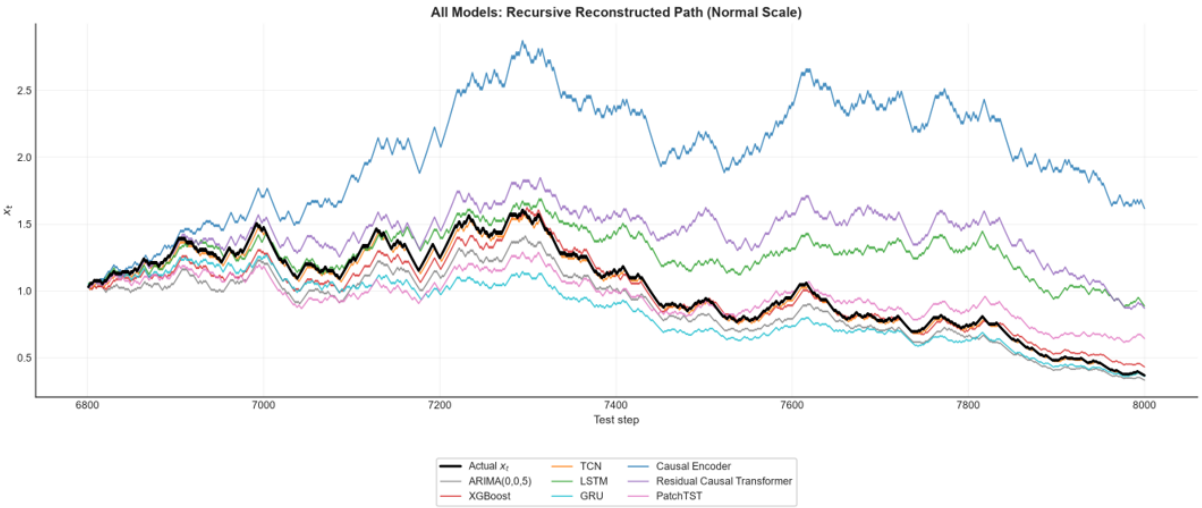
که در اینجا هر طبقه بندی کننده احتمال زیر را تخمین میزند:

$$p_t = P(y_t = 1 | r_{t-L}, ..., r_{t-1}). \tag{۲۹.۶}$$

و جهت نهایی به کمک یک مرز برابر با نیم تعیین می‌شود. بدین صورت که:

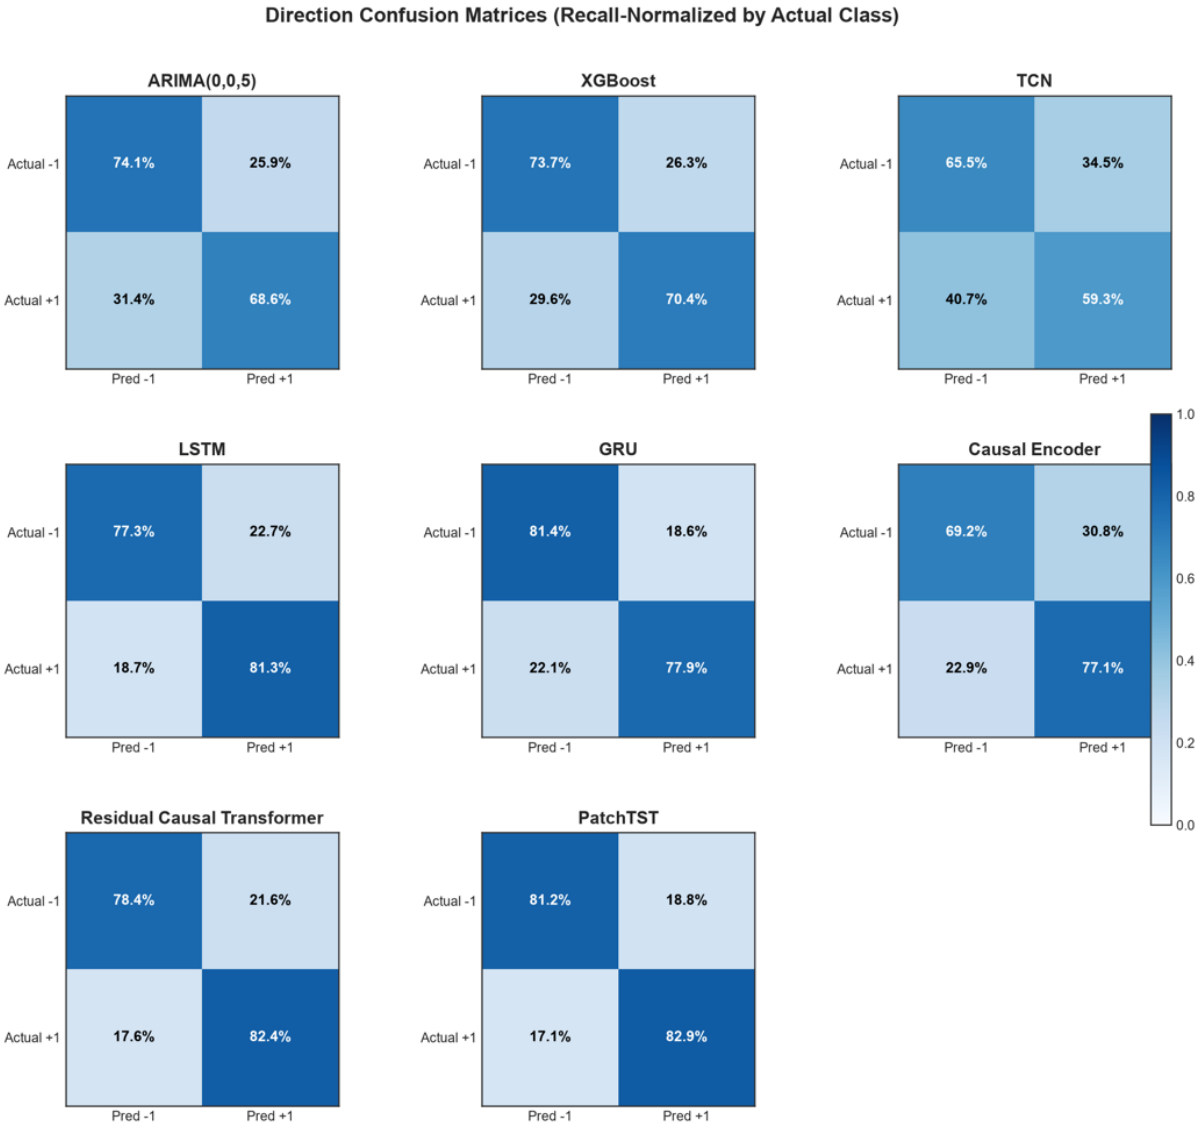
$$\hat{s}_t = \begin{cases} +1, & p_t \geq 0.5, \\ -1, & p_t \leq 0.5. \end{cases} \tag{۳۰.۶}$$

در شکل زیر نیز می‌توان نتایج بازیابی شده‌ی سری زمانی و نتایج پیش بینی بازیابی شده‌ی مدل‌ها را مشاهده کرد. در اینجا فرآیند بازیابی دقیقا به شکل آزمایش رگرسیون صورت گرفته است.



شکل ۱۵.۶: مقایسه‌ی عملکرد مدل‌ها در پیش بینی بازیابی شده‌ی سری زمانی به کمک مسئله‌ی طبقه بندی

همچنین سرهای مدل‌ها از ساختار رگرسیونی به سر طبقه بندی یا سر طبقه بندی کننده‌ی دودویی تغییر پیدا کرد. از آنجا که هر پیش بینی می‌توانست فقط مقدار مثبت یک یا منفی یک بگیرد، معیار DA به همان معیار $Classification Accuracy$ تبدیل شد و خروجی‌های تقریبا یکسانی بدست آمد. در شکل زیر می‌توان درصد دقت مدل‌ها را در این مسئله‌ی طبقه بندی به کمک بررسی ماتریس درهم‌ریختگی مورد مطالعه و بررسی قرار داد.



شکل ۱۶.۶: ماتریس درهم‌ریختگی نتایج مدل‌های ماشینی در مسئله‌ی طبقه بندی

مدل $PatchTST$ با دقت جهت‌گیری تقریبا 82 درصد، قوی‌ترین مدل باقی ماند. میزان بازیابی آن برای بازده‌های منفی تقریبا 81.2 درصد بوده و برای بازده‌های مثبت 82.9 درصد است. همچنین مبدل سببی باقیمانده به طور قابل توجهی از تقریبا 72.5 درصد در رگرسیون به 80.2 درصد در طبقه‌بندی بهبود یافت. این بیشترین رکورد ثبت شده از بهبود نتایج در این آزمایش است.

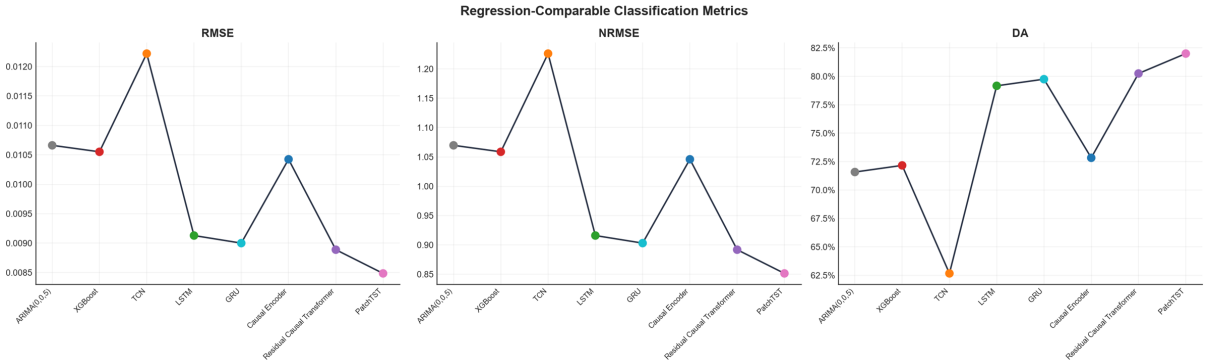
GRU و $LSTM$ به ترتیب تقریبا 79.8 درصد و 79.1 درصد به دست آوردند. همچنین مدل $CausalEncoder$ 72.8 درصد دقت بدست آورد. این در حالی است که $ARIMA(0,0,5)$، $XGBoost$ و TCN تغییر کمی از رگرسیون نشان دادند.

در اینجا به اضافه‌ی معیارهای قبلی، یک معیار بهنجار شده برای معیار $RMSE$ به نام $NRMSE$ معرفی شد که به شکل زیر تعریف

می‌شود:

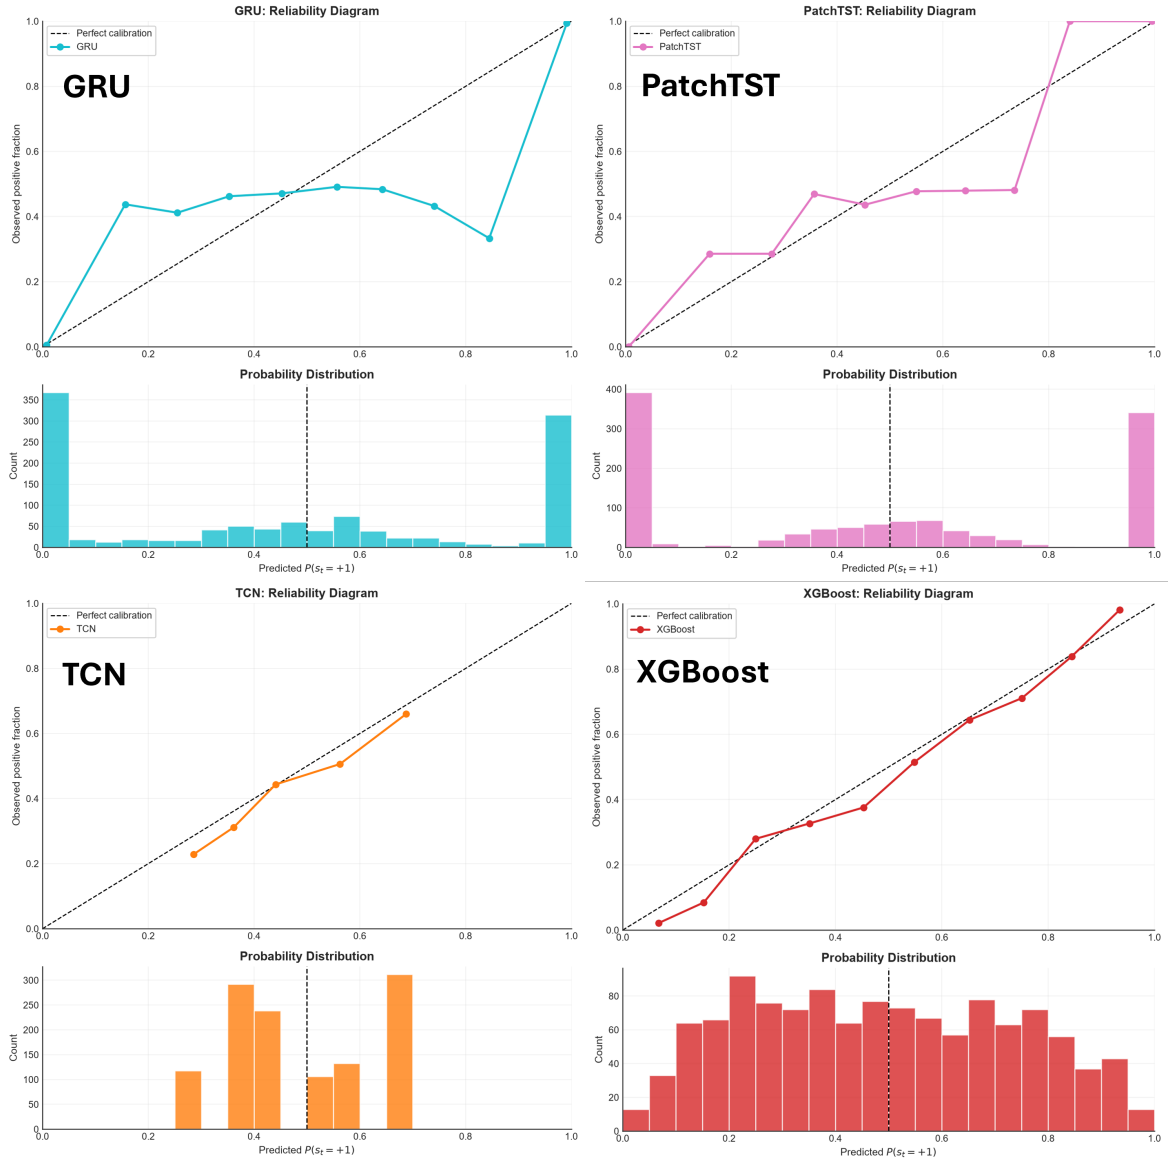
$$\mathrm{NRMSE} = \frac{\mathrm{RMSE}}{std(r_t)}. \tag{۳۱.۶}$$

نتایج هر سه معیار در شکل زیر آمده است. همچنان مانند آزمایش رگرسیونی، نتایج معیارهای دیگر بر یافته‌های معیار DA صحه گذاشته و آن را تایید می‌کنند.



شکل ۱۷.۶: نتایج معیارهای بررسی فرآیند یادگیری مدل‌های ماشینی در مسئله‌ی طبقه بندی

در انتها برای مقایسه‌ی دقت جواب‌های تولید شده به کمک مدل‌ها، شکل زیر را برای توجیه میزان اطمینان به مدل‌ها ارائه میدهیم.



شکل ۱۸.۶: نتایج مقایسه‌ی میزان اعتمادپذیری نتایج مدل‌های ماشینی در مسئله‌ی طبقه بندی

در مجموع، $XGBoost$ بهترین مدل کالیبره شده است زیرا منحنی قابلیت اطمینان آن در یک محدوده احتمال وسیع، نزدیک به قطر کالیبراسیون کامل باقی می‌ماند. TCN به طور معقول کالیبره شده است اما عمدتاً احتمالات متوسطی تولید می‌کند که نشان‌دهنده اطمینان محدود و تمایز ضعیف‌تر است. GRU و $PatchTST$ پیش‌بینی‌های زیادی را نزدیک به صفر و یک متمرکز می‌کنند و بنابراین تصمیمات دقیق‌تری می‌گیرند، اما احتمالات میانی آنها به طور قابل توجهی از قطر منحرف می‌شود که نشان‌دهنده اعتماد بیش از حد و کالیبراسیون احتمال ناسازگار است. بنابراین، $PatchTST$ و GRU ممکن است به طور دقیق طبقه‌بندی کنند، اما $XGBoost$ قابل اعتمادترین تخمین‌های احتمال را ارائه می‌دهد.

۵.۶ آزمایش سوم

در این آزمایش سعی کرده‌ایم که به کمک شاخص مقاومت نسبی، تابع مولدی تولید کنیم که با الهام‌گیری از مدل بولتزمن در فیزیک آماری، وزن‌هایی برای انتخاب بلوک‌های بعدی در این آزمایش تعریف کنیم و آزمایش قبلی را نسبت به اوزان جدید تعریف شده، بنا بگذاریم. در اینجا ما یک سری زمانی جدید برای بلوک‌های دودویی ۸ تایی از قبل تعریف شده مانند زیر داشته باشیم:

$$B = \{B_a, B_b, ..., B_h\}, \tag{۳۲.۶}$$

به مانند قبل هر بلوک متشکل از ۸ علامت است. به طوری که:

$$B_b = (s_{b,1}, s_{b,2}, ..., s_{b,8}), \quad s_{b,j} = \{-1, +1\}. \tag{۳۳.۶}$$

همچنین سری زمانی از معادله‌ی زیر پیروی می‌کند:

$$x_{t+1} = x_t(1 + \mu s_{t+1}), \tag{۳۴.۶}$$

در اینجا $\mu = 0.01$ است و ۱۰۰۰ بلوک ۸ علامته و یک سری زمانی با ۸۰۰۰۱ مشاهده و ۸۰۰۰ بازده تولید شد. در آزمایش قبلی، ۸ بلوک به طور مستقل و با احتمال‌های برابر انتخاب شدند.

$$P(B_b) = \frac{1}{8}. \tag{۳۵.۶}$$

در این آزمایش اما قصد داریم که احتمال انتخاب بلوک بعدی به رفتار جهتی سری زمانی به کمک فرمولاسیون شاخص مقاومت نسبی بر اساس بررسی تعداد مثبت‌ها و منفی‌های مشاهده در ۱۴ قدم قبلی، محاسبه شود.

۱.۵.۶ شاخص قدرت نسبی مبتنی بر شمارش

در هر نقطه‌ی انتخاب بلوک جدید، شاخص قدرت نسبی از رفتار ۱۴ علامت قبلی بررسی شده و داریم:

$$\begin{aligned} n_+(t) &= \sum_{i=t-13}^{t} 1(s_i = +1), \\ n_-(t) &= \sum_{i=t-13}^{t} 1(s_i = -1), \\ n_+(t) + n_-(t) &= 14 \end{aligned} \tag{۳۶.۶}$$

در اینجا نسبت شاخص قدرت نسبی به شکل زیر تعریف می‌شود:

$$RS_t = \frac{n_+(t)}{n_-(t)}, \tag{۳۷.۶}$$

و شاخص قدرت نسبی به شکل زیر خواهد شد:

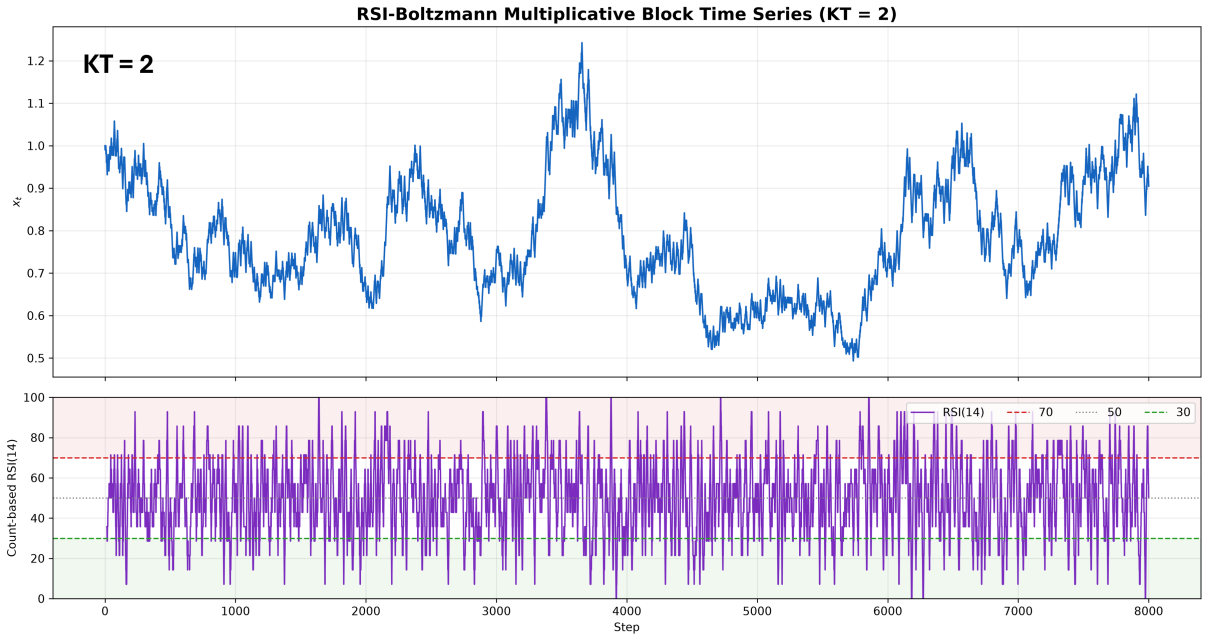
$$RSI_t = 100 - \frac{100}{1 + RS_t}. \tag{۳۸.۶}$$

و از آنجا که پنجره‌ی این شاخص فقط به ۱۴ علامت قبلی نگاه می‌کند، فرمول به شکل زیر ساده می‌شود:

$$RSI_t = 100\frac{n_+(t)}{14}. \tag{۳۹.۶}$$

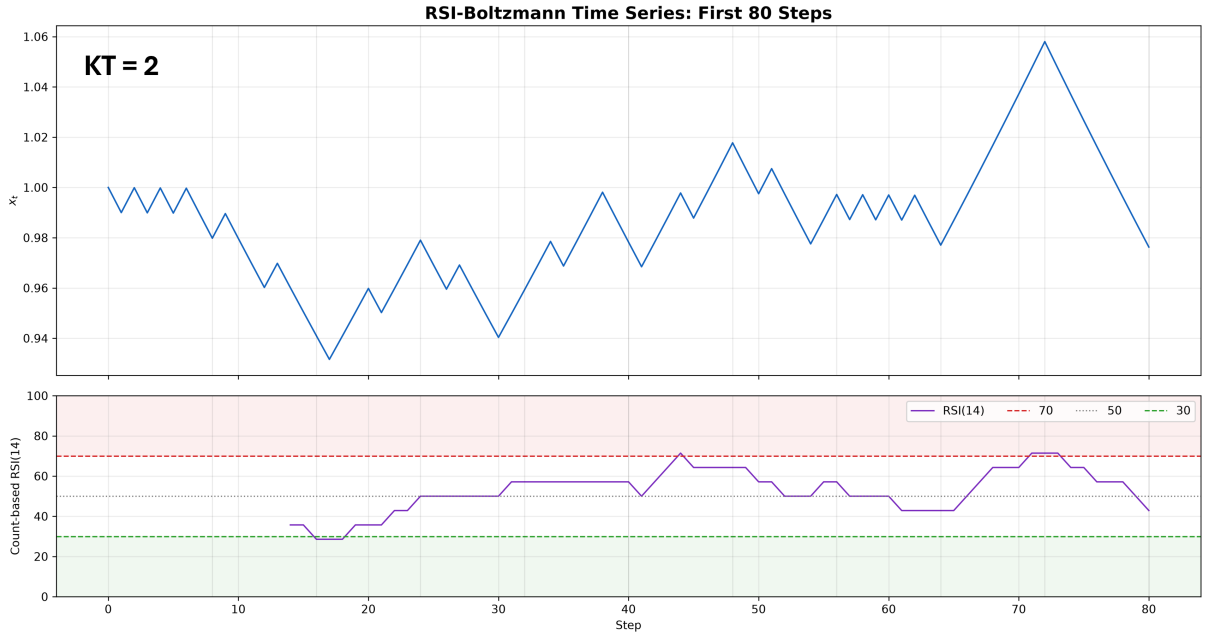
این شاخص همواره بین صفر تا صد است و اگر این شاخص مقدار ۵۰ را نشان دهد، نشان دهنده‌ی این است که در ۱۴ مشاهده‌ی قبلی، تعداد برابری از مثبت‌ها و منفی‌ها ظهور کرده‌اند.

در شکل زیر می‌توانید داده‌ی تولیدی برای این آزمایش را به همراه شاخص قدرت نسبی مشاهده کنید.



شکل ۱۹.۶: داده‌ی تصنعی تولیدی جدید برای پارامتر دمای ۲

همچنین در شکل زیر، نمایی از داده‌ی تولیدی بالا برای ۱۰ بلوک اول آورده شده است.



شکل ۲۰.۶: داده‌ی تصنعی پارامتر دمای ۲ برای ۱۰ بلوک اول

۲.۵.۶ شاخص‌های تعریفی برای هر بلوک

برای هر بلوک، بازده‌ی بلوک به شکل زیر تعریف می‌شود:

$$R_b = \frac{x_{t+8}^{(b)} - x_t}{x_t} = \prod_{j=1}^{8} (1 + \mu s_{b,j}) - 1. \tag{۴۰.۶}$$

حال در کنار این بازده‌ی هر بلوک، می‌توان انرژی هر بلوک را با کمک الهام از مدل بولتزمن در فیزیک آماری تعریف کنیم. انرژی برای هر بلوک از طریق زیر تعریف می‌شود:

$$E_b(t) = (RSI_t - 50)R_b. \tag{۴۱.۶}$$

حال بنا به این تعریف، انرژی هم به جهت حالت‌های اخیر و هم بازده‌ی تولید شده برای هر بلوک مرتبط است. این معیار باید برای هر بلوک قبل از انتخاب بلوک بعدی، مشخص شود.

حال برای اینکه به کمک مدل بولتزمن در انتخاب بلوک‌ها وزن ایجاد کنیم، معیار زیر را تعریف می‌کنیم:

$$w_b(t) = \exp\left[-\frac{E_b(t)}{KT}\right], \tag{۴۲.۶}$$

که در این صورت پارامتر دما مانند $KT = 2$ تنظیم خواهد شد. پس وزن‌های ما به شکل زیر خواهند بود:

$$w_b(t) = \exp\left[-\frac{E_b(t)}{2}\right]. \tag{۴۳.۶}$$

حال برای بدست آوردن احتمالات معتبر، وزن‌ها بهنجار شده و تابع پارش به شکل زیر تعریف می‌شود:

$$Z_t = \sum_{c \in B} \exp\left[-\frac{E_c(t)}{2}\right]. \tag{۴۴.۶}$$

پس در این صورت احتمال انتخاب یک بلوک به شکل زیر خواهد بود:

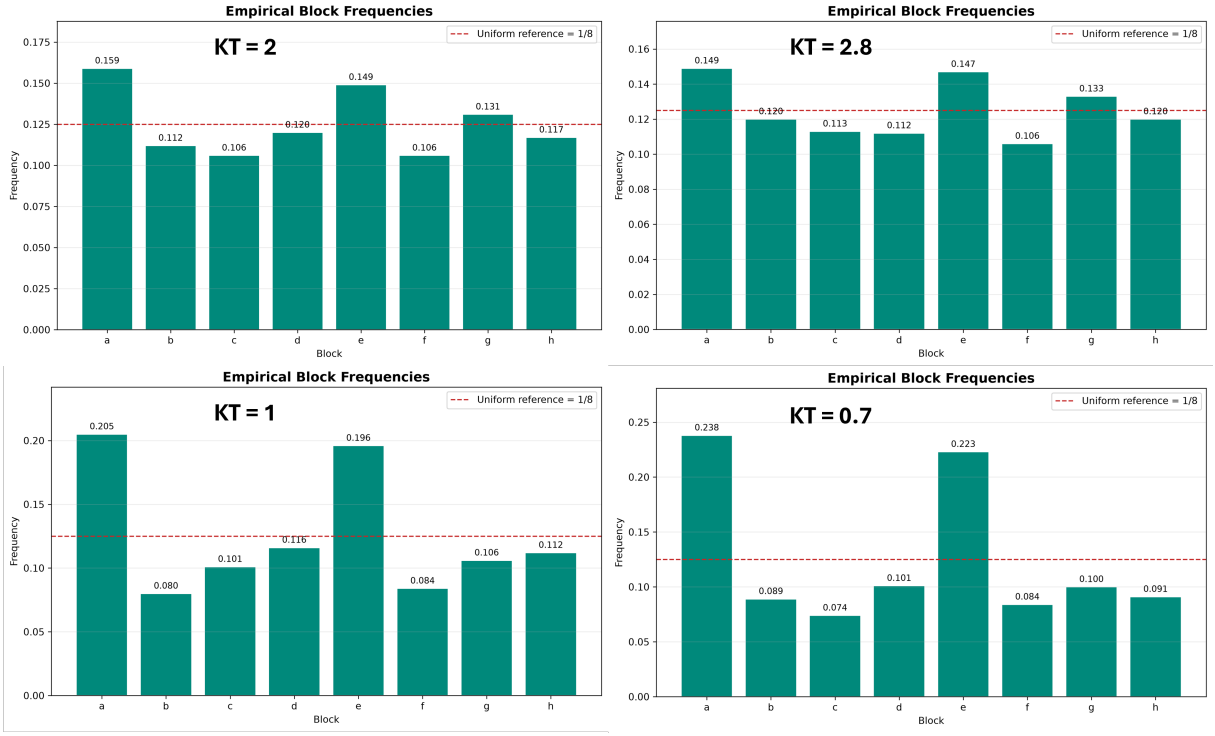
$$P(B_{t+1} = B_b | s_{t-13:t}) = \frac{\exp\left[-\frac{E_b(t)}{2}\right]}{\sum_{c \in B} \exp\left[-\frac{E_c(t)}{2}\right]}. \quad (۴۵.۶)$$

نرمال‌سازی تضمین می‌کند که:

$$\sum_{b \in B} P(B_{t+1} = B_b | s_{t-13:t}) = 1. \quad (۴۶.۶)$$

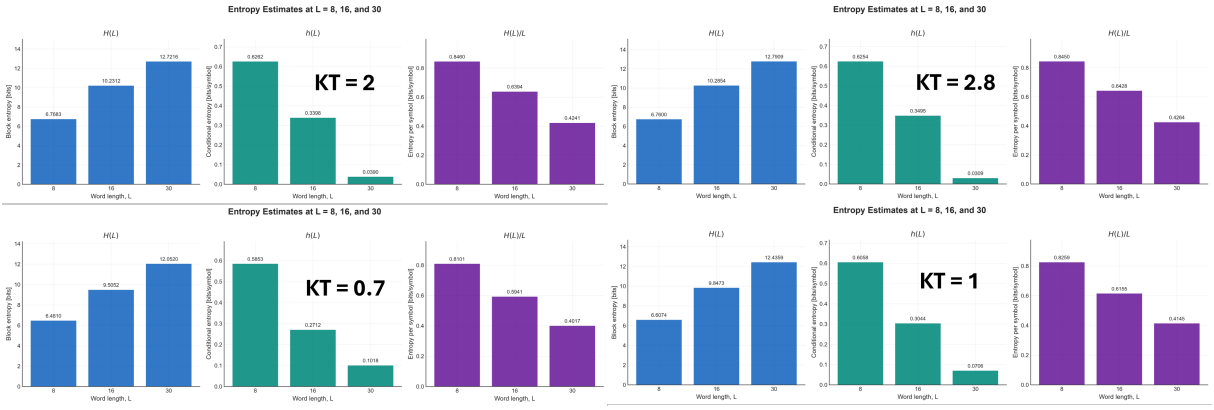
حال فاکتور بولتزمن یک مکانیزم بازگشت به میانگین می‌سازد. برای مثال اگر شاخص قدرت نسبی بالای ۵۰ باشد، بلوک‌هایی با بازده‌ی مثبت، انرژی مثبت داشته و احتمالات کمتری می‌گیرد و اگر بلوک‌هایی با بازده‌ی منفی داشته باشیم، انرژی کمتر و به تبع آن احتمالات بیشتری خواهیم داشت. در این صورت تابع مولد علاقه دارد که بر خلاف حرکت مثبت رو به بالا حرکت کند و حال اگر شاخص قدرت نسبی کمتر از ۵۰ باشد، بلوک‌هایی با بازده‌ی منفی، جریمه شده و بلوک‌هایی با بازده‌ی مثبت ترجیحا انتخاب می‌شوند. حال اگر این شاخص دقیقا برابر با ۵۰ باشد، تمام انرژی برابر با صفر و بلوک‌ها با توزیع یکسان انتخاب می‌شوند.

در اینجا برای پارامترهای دمای مختلف $KT = \{0.7, 1, 2, 2.8\}$ داده‌هایی تولید شده است که بلوک بعدی با توزیع متفاوتی از توزیع آزمایش پیشین انتخاب شدند. در اینجا داده‌ها با کمک اوزان تولیدی از روابط بولتزمن و وابسته به دما تولید شده‌اند. در شکل زیر می‌توانید فرکانس انتخاب بلوک‌ها را برای دماهای مختلف مشاهده کنید. بدیهی است که از آنجا که تابع توزیع‌های دماهای مختلف متفاوتند، سری‌های زمانی تولیدی نیز متفاوت هستند.



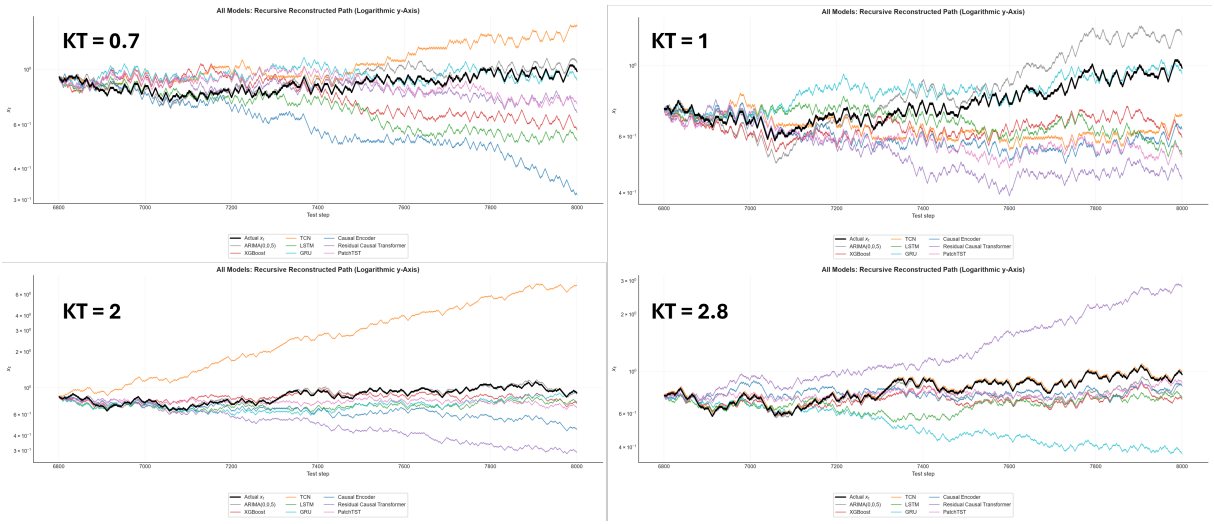
شکل ۲۱.۶: فرکانس انتخاب بلوک‌ها برای داده‌های دماهای مختلف

همچنین در بررسی آنتروپی بلوک برای داده‌های وابسته به دمای جدید می‌توان ادعا کرد که تخمین‌های آنتروپی نشان می‌دهند که پیچیدگی عموماً با KT افزایش می‌یابد، اما بالاتر از $KT = 2$ شروع به اشباع می‌کند. در هر طول کلمه، $KT = 0.7$ کمترین آنتروپی بلوک را دارد که از $H(8) = 6.4810$ به $H(30) = 12.0520$ افزایش می‌یابد و پس از آن $KT = 1$ با $H(8) = 6.6074$ و $H(30) = 12.4359$ قرار دارد. بزرگترین مقادیر برای $KT = 2$ و $KT = 2.8$ رخ می‌دهد که بسیار مشابه هستند: در $L = 30$، آنتروپی بلوک آنها به ترتیب 12.7216 و 12.7909 است. آنتروپی نرمال شده $H(L)/L$ ترتیب یکسانی را ارائه می‌دهد و آنتروپی بیشتر به ازای هر نماد را در KT بالاتر نشان می‌دهد. به عنوان مثال، در $L = 30$، از 0.4017 برای $KT = 0.7$ به 0.4264 برای $KT = 2.8$ افزایش می‌یابد. در تمام موارد، هم آنتروپی شرطی $h(L)$ و هم آنتروپی نرمال‌شده با افزایش L کاهش می‌یابند، که نشان می‌دهد بلوک‌های طولانی‌تر، نظم‌های زمانی را آشکار می‌کنند و میزان اطلاعات جدید ارائه شده توسط هر نماد اضافی را کاهش می‌دهند. با این حال، تخمین‌های آنتروپی شرطی بسیار کوچک در $L = 30$، به ویژه برای $KT = 2$ و $KT = 2.8$، باید با احتیاط تفسیر شوند زیرا اندازه نمونه محدود باعث نمونه‌برداری کمتر از حد و سوگیری رو به پایین برای کلمات طولانی می‌شود. به طور کلی، افزایش KT از 0.7 به 2 افزایش واضحی در پیچیدگی توالی ایجاد می‌کند، در حالی که تفاوت‌های کوچک بین $KT = 2$ و $KT = 2.8$ نشان می‌دهد که آنتروپی تا حد زیادی به ناحیه اشباع رسیده است.



شکل ۲۲.۶: تخمین‌گرهای آنتروپی برای داده‌های با دماهای مختلف

برای بررسی رفتار مدل‌های ماشینی در داده‌های تصنعی جدید، به شکل آزمایش‌های قبل، برای حل مسئله‌ی طبقه‌بندی، آموزش انجام شده و نتایج بازیابی شده از فرآیند آموزش مدل‌های ماشینی روی بازده سهام و همچنین جدول مقایسه‌ی نتایج این مدل‌ها را می‌توان در شکل‌های زیر مشاهده کرد:



شکل ۲۳.۶: نتایج بازیابی شده از فرآیند آموزش مدل‌های ماشینی روی بازده سهام داده‌های تصنعی جدید برای دماهای مختلف

همچنین نتایج دقت تمام مدل‌ها در حدول زیر به طور خلاصه آورده شده است:

Model	Regression-derived	Uniform direct	KT=2.8	KT=2	KT=1	KT=0.7
ARIMA(0,0,5)	71.4	71.4	71.9	71.4	71.0	71.7
XGBoost	72.1	72.1	70.3	72.1	71.8	74.1
TCN	62.4	62.4	64.3	62.4	62.1	61.8
LSTM	78.6	79.3	**81.2**	79.3	85.0	85.7
GRU	78.9	79.7	81.1	79.7	85.0	**86.3**
Causal Encoder	71.4	73.2	70.6	73.2	74.6	77.5
Residual Causal Transformer	73.2	80.4	75.6	80.4	81.4	78.6
PatchTST	**81.0**	**82.1**	80.8	**82.1**	**86.9**	85.9

شکل ۲۴.۶: نتایج دقت مدل‌ها برای همه‌ی آزمایش‌ها

نتایج نشان می‌دهند که اثر پیش‌بینی‌کننده‌ی مکانیسم بولتزمن هدایت‌شده با RSI به شدت به دما و معماری مدل بستگی دارد. در دمای نسبتاً بالا $KT = 2.8$، احتمالات بلوک به یکنواختی نزدیک‌تر باقی می‌مانند و در نتیجه بیشتر نتایج مشابه فرآیند اصلی هستند. با کاهش دما، توزیع انتخاب بلوک تیزتر می‌شود و وابستگی زمانی قوی‌تر و قابل یادگیری‌تری را ایجاد می‌کند. این امر به ویژه برای مدل‌های بازگشتی مفید است: $LSTM$ از 79.3 درصد تحت انتخاب یکنواخت به 85.7 درصد در $KT = 0.7$ بهبود می‌یابد، در حالی که GRU به 86.3 درصد می‌رسد، که نشان می‌دهد پنجره‌های ورودی 16 مرحله‌ای آنها به طور موثر حافظه $RSI - 14$ مرحله‌ای را ثبت می‌کنند. $PatchTST$ به بالاترین دقت متعادل کلی 86.9 درصد در $KT = 1$ دست می‌یابد، احتمالاً به این دلیل که تکه‌های هشت مرحله‌ای آن مستقیماً با طول بلوک مولد مطابقت دارند در حالی که زمینه طولانی‌تر آن، انتقال‌های وابسته به RSI بین بلوک‌ها را ثبت می‌کند. رمزگذار سببی نیز از دمای پایین‌تر بهره‌مند می‌شود، اگرچه نگاه به عقب هشت مرحله‌ای آن مانع از مشاهده پنجره کامل RSI می‌شود. در مقابل، $ARIMA$، $XGBoost$ و به ویژه TCN بهبود محدود یا متناقضی را نشان می‌دهند که نشان‌دهنده ناتوانی آنها در پیکربندی‌های فعلی برای نمایش مکانیسم بازخورد کامل است. به طور کلی، یافته‌ها نشان می‌دهند که دمای پایین‌تر، پیش‌بینی جهت را افزایش می‌دهد، اما دمای بهینه وابسته به معماری است: $KT = 0.7$ برای مدل‌های بازگشتی مناسب‌ترین است، در حالی که مقدار میانی $KT = 1$ برای $PatchTST$ و $ResidualCausalTransformer$ بهینه است.

فصل ۷

نکاتی برای مطالعات بیشتر

در این بخش سعی شده که متناسب با هر فصل این پایان‌نامه، منابع دیگری که پتانسیل مناسبی جهت مطالعه و تحقیقات بیشتر در کارهای آینده دارد را معرفی کرده و مورد یک بررسی کلی قرار دهیم.

۱.۷ بازتولید حقایق سبکمند بازارهای مالی به کمک مدل‌های توسعه‌یافته در فیزیک

یکی از موارد مطالعه‌ی جذاب در کارهای آینده می‌تواند بررسی مدل‌های برآمده از فیزیک و سیستم‌های پیچیده در بازتولید حقایق آماری موجود در بازارهای مالی باشد. برای مثال در مقاله‌ی [۱۰۸] محققان با مدل‌سازی تعامل‌کنندگان در یک بازارمالی به عنوان چرخش‌های در حال تعامل، به کمک مدل آیزینگ میدان عرضی یک چارچوب جدید برای بررسی حقایق سبکمند ارائه دادند. در اینجا کوپلینگ فرومغناطیسی رفتار گله‌ای را نشان می‌دهد و میدان عرضی تصمیم‌گیری مستقل را ارتقا داده و فازهایی از بی‌نظمی و نظم می‌سازند. حال اگر دینامیک مغناطیسی با یک فرآیند بازده تصادفی جفت شود، می‌توان به بازتولید هرچه بهتر خواص بازارهای مالی مانند دم پهن، خودهمبستگی ناچیز بازده‌ها و خوشه‌بندی نوسانات منجر شود.

یا در مثالی دیگر در مقاله‌ی [۱۰۹] معامله‌گران به عنوان اسپین‌های دوتایی خریدار و فروشنده معرفی شدند. در اینجا نیز تعاملات بین عوامل داخل بازار و یک میدان خارجی عرضی سعی در نمایش رفتار جمعی و حساسیت به اطلاعات خارجی را نشان میدهد. این مدل اما یک

چارچوب به جهت بررسی تاثیر رفتار منطقی و غیرمنطقی در پویایی بازار ارائه میدهد. همچنین توانایی مدل در پیاده‌سازی حقایق سبکمند و حتی توان هرست بررسی و ثابت شده است.

در مقاله‌ی اخیرا منتشره شده‌ی [۱۱۰] نیز محققیق به کمک بررسی مدل آیزینگ و مدل‌های اسپین گلسی در چارچوب فیزیک آماری واسبتگی بین دارایی‌ها را مورد بررسی قرار دادند. در اینجا مدل آیزینگ انسجام جمعی بازار را ثبت می‌کند و چارچوب مدل اسپین گلس به تعاملات مثبت و منفی بازارها واکنش داده و ساختگارهای وابسته به پیچیدگی بازارها را آشکار می‌کند. در نتایج آنها نشان داده شده است که در حالی که مدل‌های آیزینگی معیار مناسبی برای رفتار جمعی ارائه میدهند اما دینامیک‌های اسپین گلسی برای نمایش دینامیک‌های غیرخطی بازارها مناسبت‌تر هستند.

۲.۷ بررسی همبستگی متقابل در بازارهای مالی به کمک مدل‌های مقیاسی

بر اساس آنچه از مرور ادبیات یافت می‌شود، امروزه علاقه‌ی بیشتر محققان در حوزه‌ی فیزیک اقتصاد به بررسی همبستگی‌های متقابل دارایی‌ها به کمک مدل‌های توانی، مقیاسی و دیگر مدل‌های مورد بررسی در این گزارش است. در اینجا می‌توان به مقاله‌ی [۱۱۱] اشاره کرد که محققان در این مطالعه به بررسی همبستگی‌های متقاطع چندفرکتالی بین سهام بازارهای نوظهور و دارایی‌های مالی اصلی با کمک بررسی‌هایی از تحلیل همبستگی متقاطع چندفرکتالی بدون روند[1] می‌پردازد. نتایج این مقاله وابستگی‌های پایدار، غیرخطی و وابستگی به خواص مقیاسی را، بین سهام بازارهای نوظهور و سهام کالاها و دارایی‌های انرژی در بازارهای توسعه‌یافته، با روابطی قوی‌تر و در مقیاس‌های زمانی طولانی‌تر به نمایش میگذارد. رمزارزها نیز بررسی شده‌اند و همبستگی‌های متقاطع به نسبت ضعیف‌تری از خود نشان می‌دهند. این رفتار چندفرکتالی مشاهده‌شده، تاییدی بر تفسیر اقتصادفیزیک از بازارهای مالی به عنوان سیستم‌های پیچیده تطبیقی است.

همپنین مقاله‌ی [۱۱۲] که اخیرا در مجله‌ی physica-a منتشر شده است به تحلیل همبستگی‌های متقابل چندفرکتالی روابط چندگانه به کمک بررسی وابستگی همزمان بین چندین سری زمانی غیرایستا میرسند و چارچوب رایج در بررسی‌های دوگانه را به بررسی‌های چندگانه ارتقا میدهند. در این کار، اعتبارسنجی مقاله به کمک شبیه‌سازی‌های آماری و شبیه‌سازی مونت کارلو مورد بررسی قرار گرفته است و است که مرتبه‌های نوسان مختلف به طور کمی شده به نمایش گذاشته شده است.

[1] Multifractal Detrended Cross-Correlation Analysis (MFDCCA)

۳.۷ مدل‌های هیبرید: ترکیب مدل‌های سنتی تحلیل بازارهای مالی با مدل‌های ماشینی

رویکردهای مدل‌سازی ترکیبی، نقاط قوت مدل‌های سری زمانی سنتی را با تکنیک‌های مدرن یادگیری ماشین یا یادگیری عمیق ترکیب می‌کنند تا عملکرد پیش‌بینی و استحکام را بهبود بخشند. یک رویکرد رایج، مدل‌سازی دینامیک‌های اصلی یک سری زمانی مالی با استفاده از یک مدل کلاسیک، مانند ARIMA یا ،GARCH و سپس اعمال یک مدل یادگیری ماشین یا یادگیری عمیق بر روی باقیمانده‌ها است. مدل سنتی، روندهای خطی، فصلی بودن و یا خوشه‌بندی نوسانات را ثبت می‌کند، در حالی که مدل ML/DL[1] الگوهای غیرخطی و وابستگی‌های پیچیده‌ای را که در باقیمانده‌ها باقی می‌مانند، یاد می‌گیرد.

به عنوان مثال، یک هیبرید ARIMA+ML ابتدا یک مدل ARIMA را برای پیش‌بینی سری اصلی برازش می‌دهد، سپس یک شبکه عصبی، جنگل تصادفی[2] یا مدل تقویت گرادیان[3] را روی باقیمانده‌ها آموزش می‌دهد تا اثرات غیرخطی را ثبت کند. به طور مشابه، DeepAR و سایر مدل‌های یادگیری عمیق احتمالی را می‌توان با استفاده از خروجی‌های مدل‌های کلاسیک به عنوان متغیرهای کمکی یا مقداردهی اولیه پیش‌بینی‌ها بر اساس پیش‌بینی‌های سنتی، با آنها ادغام کرد. این رویکردهای ترکیبی اغلب از هر دو دسته از مدل‌ها به تنهایی، به ویژه در بازارهای مالی که سری‌های زمانی هم ساختارهای خطی قوی و هم رفتارهای غیرخطی پیچیده را نشان می‌دهند، بهتر عمل می‌کنند.

برای مثال در مقاله‌ی [۵۲] یک چارچوب جدید پیش بینی مبتنی بر احتمال معرفی شده است که در آن داخل یک شبکه عصبی بازگشتی، ساختار خودبازگشتی عاریه گرفته شده از مدل‌های سنتی تحلیل بازارهای مالی استفاده شده است. در اینجا، این مدل به کمک یادگیری شرطی روی مشاهدات قبلی، می‌تواند دینامیک سری‌های زمانی پیچیده و غیرخطی را ثبت کرده و به بررسی احتمالات شرطی بپردازد. نتایج تجربی این مدل نشان داده‌اند که این مدل هیبرید، از مدل‌های سنتی بهتر عمل کرده و این در حالی رخ میدهد که این مدل دسترسی‌های به نسبت محدودتری به مهندسی ویژگی داده‌ها داشته است.

در مقاله‌ی [۱۱۳] نیز مدل‌های سنتی چند متغیره‌ی اندازه‌گیری نوسانات در بازارهای مالی به کمک یک مدل $LSTM$ تقویت شده است و این مدل سعی می‌کند که به کمک یک مدل یادگیری عمیق، در کنار یادگیری، حفظ و ثبت حقایق سبکمند وابسته به نوسانات بازار مانند خوشه‌بندی نوسانات، وابستگی‌های غیرخطی و همبستگی‌های متغیر با زمان و هم‌حرکتی‌های نامتقارن را نیز به کمک مدل‌های پیشرفته‌تر یادگیری عمیق بررسی کند. نتایج تجربی بررسی و پیاده‌سازی این مدل‌ها در بازارهای مالی نشان داده‌اند که رویکردهای ترکیبی در عین حفظ قابلیت تفسیر ساختارهای اقتصادسنجی می‌توانند به بهبود پیش‌بینی ریسک نیز پرداخته و در آن زمینه نیز موفق عمل کنند.

[1] Short for Machine Learning and Deep Learning (ML, DL) models

[2] Random Forest

[3] Gradient Boosting Model (GBM)

به طور کل می‌توان اشاره کرد که روش‌شناسی ترکیبی همچنین مزایای تفسیرپذیری[1] را ارائه می‌دهد: مدل سنتی اجزای سیستماتیک را توضیح می‌دهد، در حالی که مدل ML/DL بر ثبت پیچیدگی‌های باقیمانده تمرکز دارد و تحلیلگران را قادر می‌سازد تا اجزای قابل پیش‌بینی و غیرقابل پیش‌بینی رفتار بازار را درک کنند. در مجموع، ترکیب مدل‌های سنتی و مدرن، یک استراتژی عملی و انعطاف‌پذیر برای پیش‌بینی مالی و مدیریت ریسک ارائه می‌دهد.

۴.۷ مدل‌های زبانی بزرگ در تحلیل بازارهای مالی

در زمینه‌ی پردازش زبان طبیعی، امروز مدل‌های زبانی بزرگ حرف اول را میزنند. در اینجا به بررسی دو مورد از مهم‌ترین و بروزترین مقالات در این حوزه که به بررسی منابع زبان طبیعی و داده‌های متن‌محور در بررسی بازارهای مالی کمک می‌کنند پرداخته ایم. اولین مدل مورد بررسی، مدل فین‌برت است. طبق مقاله‌ی [۱۱۴] نویسندگان یک مدل زبانی سازگار با امور مالی را ارائه میدهند که در آن برای ثبت معانی خاص منابع متنی، اصطلاحات خاص این حوزه و بررسی متون به جهت طبقه‌بندی احساسات سرمایه‌گذاران به سه طبقه‌ی مثبت، منفی و خنثی استفاده شده است. نتایج تجربی استفاده از مدل در کنار بررسی مدل‌های سنتی و مدل‌های یادگیری ماشین و یادگیری عمیق نشان میدهند که این مدل برتری خاصی در استخراج اطلاعات طبقه‌بندی شده دارد. همچنین این مدل چارچوب جدیدی برای استخراج اطلاعات متنی برای تحلیل متون مالی به نسبت کارهای گذشته ارائه داده است.

در نهایت مقاله‌ی جالب [۱۱۵] را مورد بررسی قرار دادیم که در آن یک مدل بنیادی چندوجهی[2] معرفی شده است که به طور مشترک توانایی درک زبان طبیعی و پردازش آن و سری‌های زمانی عددی را داراست. و هم می‌تواند برای سری‌های زمانی پیش‌بینی ارائه داده و هم متون مربوط به این حوزه را بررسی کند. در اینجا یک معماری یکپارچه‌ی فقط رمزگشا[3] در داخل ترنسفورمر استفاده شده است. برخلاف رویکردهای دیگر که قابلیت‌های زمانی را به مدل‌های زبانی از پیش آموزش‌دیده اضافه می‌کنند، کرونیکل از ابتدا در هر دو حالت آموزش داده می‌شود و امکان بررسی و نمایش مشترک خروجی‌ها را برای ثبت روابط بین بافت متنی و دینامیک زمانی فراهم می‌کند. با وجود دارا بودن معماری فشرده‌ی ۳۲۴ میلیون پارامتری، این مدل عملکرد رقابتی خوبی را در درک زبان طبیعی، طبقه‌بندی سری‌های زمانی و پیش‌بینی به طور همزمان ارائه می‌دهد.

[1] Explainability

[2] Multimodal Foundation model

[3] Encoder only

۱۰ پیوست الف: آزمون‌های آماری رایج در تحلیل بازارهای مالی

آزمون‌های آماری برا تشخیص خصوصیات آماری سهام‌ها در بازار مالی اساسی هستند چرا که ویژگی‌های توزیعی و زمانی بازده دارایی‌ها را قبل از اعمال مدل‌های پیشرفته‌ی اقتصادسنجی یا پیاده‌سازی الگوریتم‌های یادگیری ماشین مشخص می‌کنند. برای مثال "چولگی"، عدم تقارن توزیع بازده را اندازه‌گیری کرده و نشان میدهد که بازده‌های مثبت یا منفی شدید شایع‌تر هستند یا خیر. در حالی که "کشیدگی بیش از حد" سنگینی دنباله‌ی توزیع داده‌ها را نسبت به توزیع گاوسی کمی کرده و اندازه‌گیری می‌کند. این معیارها معمولاً برای شناسایی حقایق سبکمند در حوزه‌ی مالی، مخصوصا برای بررسی عدم تقارن و رفتار دنباله پهن، استفاده می‌شوند.

آزمون جارک-برا نیز رفتار نرمال بودن را با استفاده از هر دو معیار چولگی و کشیدگی ارزیابی کرده و از مهم‌ترین تست‌های آماری به شمار میرود چرا که دقیقا بازده‌های مالی اغلب از فرض گاوسی منحرف می‌شوند.

ایستایی معمولاً با استفاده از آزمون‌های مکمل آزمون‌های ADF و $KPSS$ بررسی می‌شود: ADF وجود ریشه واحد را بررسی می‌کند، در حالی که $KPSS$ ایستایی را فرضیه صفر خود در نظر گرفته و به کمک بررسی این دو آزمون، شواهد مکملی در مورد خواص تصادفی سری می‌توان بدست آورد.

همچنین برای بررسی وابستگی زمانی سری، می‌توان با استفاده از آزمون لیونگ-باکس، ارزیابی به عمل آورد. این آزمون بررسی می‌کند که آیا خودهمبستگی معناداری در مجموعه‌ای مشخص از وقفه‌ها باقی خواهد ماند یا خیر. البته هنگامی که برای بازده‌های مجذور یا مطلق اعمال می‌شود، شواهدی از وابستگی به نوسان و خوشه‌بندی نوسانات نیز ارائه میدهد.

در نهایت، آزمون $ARCH - LM$ ناهمسانی واریانس شرطی را با آزمایش اینکه آیا اختلالات مجذور گذشته، اختلالات مجذور فعلی را توضیح می‌دهند، تشخیص می‌دهد. این آزمون میگوید که آیا یک اثر $ARCH$ معنادار بوده و انگیزه آماری برای استفاده و مدل‌سازی به کمک مدل‌های خانواده‌ی نوسان مانند $ARCH$ و $GARCH$ فراهم می‌کند.

در مجموع، این آزمون‌ها تعیین می‌کنند که آیا فرضیات کلیدی مربوط به نرمال بودن، ایستایی، وابستگی سریالی و واریانس ثابت برآورده می‌شوند یا خیر و یک پایه تجربی مناسب را برای انتخاب مدل‌های آماری به جهت تحلیل بازده مالی و نوسانات مربوطه به آن فراهم می‌کنند.

در شکل زیر، آزمون‌های آماری رایج به همراه کاربردها، استفاده و ریاضیات به کار گرفته شده در آنها آورده شده است.

Test / Metric	Application	Mathematical Representation	Use Case
Skewness	Measures asymmetry	$\gamma_1 = \frac{E[(X-\mu)^3]}{\sigma^3}$	Stylized facts
Excess Kurtosis	Measures fat tails	$\gamma_2 = \frac{E[(X-\mu)^4]}{\sigma^4} - 3$	Stylized facts
Jarque-Bera Test	Normality test	$JB = \frac{n}{6}(S^2 + \frac{(K-3)^2}{4})$	Fat tails / non-normality
ADF Test	Unit-root test	$\Delta y_t = \alpha + \beta y_{t-1} + \sum \gamma_i \Delta y_{t-i} + \varepsilon_t$	Stationarity before modeling
KPSS Test	Stationarity confirmation	$KPSS = \frac{1}{T^2}\sum_{t=1}^{T} S_t^2 / \hat{\sigma}^2$	Stationarity verification
Ljung-Box Test	Residual autocorrelation	$Q = n(n+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{n-k}$	Residual diagnostics; volatility clustering
ARCH-LM Test	Detect ARCH effects	$LM = nR^2$	Volatility clustering before GARCH

شکل ۱: آزمون‌های آماری رایج در تحلیل بازارهای مالی

مراجع

کتاب‌نامه

[1] https://www.youtube.com/watch?v=FBkFu1g5PlE

[2] Anderson, Philip W. ”More is different: broken symmetry and the nature of the hierarchical structure of science.” Science 177, no. 4047 (1972): 393-396.

[3] Anderson, Philip W. ”Physics: the opening to complexity.” Proceedings of the National Academy of Sciences 92, no. 15 (1995): 6653-6654.

[4] Wigner, Eugene P. ”The unreasonable effectiveness of mathematics in the natural sciences.” Mathematics and science 13 (1990): 1-14.

[5] Kutner, Ryszard, Marcel Ausloos, Dariusz Grech, Tiziana Di Matteo, Christophe Schinckus, and H. Eugene Stanley. ”Econophysics and sociophysics: Their milestones, challenges.” Physica A: Statistical Mechanics and its Applications 516 (2019): 240-253.

[6] Buonocore, R. J., N. Musmeci, T. Aste, and T. Di Matteo. ”Two different flavours of complexity in financial data.” The European Physical Journal Special Topics 225, no. 17 (2016): 3105-3113.

[7] Mantegna, Rosario Nunzio. ”Lévy walks and enhanced diffusion in Milan stock exchange.” Physica A: Statistical Mechanics and its Applications 179, no. 2 (1991): 232-242.

[8] H Eugene Stanley and Rosario N Mantegna. An introduction to econophysics. Cambridge University Press, Cambridge, 2000 (cit. on pp. 1, 2).

[9] Chakraborti, Anirban, Ioane Muni Toke, Marco Patriarca, and Frédéric Abergel. ”Econophysics review: I. Empirical facts.” Quantitative Finance 11, no. 7 (2011): 991-1012.

[10] Cont, Rama. ”Empirical properties of asset returns: stylized facts and statistical issues.” Quantitative finance 1, no. 2 (2001): 223.

[11] Bacry, Emmanuel, Jean Delour, and Jean-François Muzy. ”Modelling financial time series using multifractal random walks.” Physica A: statistical mechanics and its applications 299, no. 1-2 (2001): 84-92.

[12] Mandelbrot, Benoit. ”The variation of certain speculative prices.” Journal of business 36, no. 4 (1963): 394.

[13] Banerjee, Anand, Victor M. Yakovenko, and Tiziana Di Matteo. ”A study of the personal income distribution in Australia.” Physica A: statistical mechanics and its applications 370, no. 1 (2006): 54-59.

[14] Aste, Tomaso, and Tiziana Di Matteo. ”Introduction to complex and econophysics systems: A navigation map.” Complex physical, biophysical and econophysical systems (2010): 1-35.

[15] Mandelbrot, Benoit, Adlai Fisher, and Laurent Calvet. ”A multifractal model of asset returns.” (1997).

[16] Gopikrishnan, Parameswaran, Martin Meyer, LA Nunes Amaral, and H. Eugene Stanley. ”Inverse cubic law for the distribution of stock price variations.” The European Physical Journal B-Condensed Matter and Complex Systems 3, no. 2 (1998): 139-140.

[17] Aaron, Clauset. ”Power-law distributions in empirical data.” arXiv, 0706. 1062v1 physics (2007).

[18] Antypas, Antonios, Phoebe Koundouri, and Nikolaos Kourogenis. ”Aggregational Gaussianity and barely infinite variance in financial returns.” Journal of Empirical Finance 20 (2013): 102-108.

[19] Kullmann, L., J. Töyli, J. Kertesz, A. Kanto, and K. Kaski. ”Characteristic times in stock market indices.” Physica A: Statistical Mechanics and its Applications 269, no. 1 (1999): 98-110.

[20] Fisher, Ronald Aylmer. Statistical methods for research workers. No. 5. Oliver and Boyd, 1928.

[21] Kendall, Maurice George. The Advanced Theory Or Statistics. C. Griffin, 1947.

[22] Pagan, Adrian. ”The econometrics of financial markets.” Journal of empirical finance 3, no. 1 (1996): 15-102.

[23] Fama, Eugene F. ”Efficient capital markets: II.” The journal of finance 46, no. 5 (1991): 1575-1617.

[24] Malkiel, Burton G. ”Efficient market hypothesis.” In Finance, pp. 127-134. London: Palgrave Macmillan UK, 1989.

[25] Bouchaud, J. P., and M. Potters. ”Theorie des Risques Financiéres (Alea-Saclay.” BOUCHAUD, J (1997).

[26] Cutler, David M., James M. Poterba, and Lawrence H. Summers. ”What moves stock prices?.” (1988).

[27] Di Matteo, Tiziana. ”Multi-scaling in finance.” Quantitative finance 7, no. 1 (2007): 21-36.

[28] Junior Buonocore, Riccardo, Tomaso Aste, and Tiziana Di Matteo. ”Measuring multiscaling in financial time-series.” arXiv e-prints (2015): arXiv-1509.

[29] Tumminello, Michele, Tiziana Di Matteo, Tomaso Aste, and Rosario N. Mantegna. ”Correlation based networks of equity returns sampled at different time horizons.” The European Physical Journal B 55, no. 2 (2007): 209-217.

[30] Pozzi, Francesco, Tiziana Di Matteo, and Tomaso Aste. ”Exponential smoothing weighted correlations.” The European Physical Journal B 85, no. 6 (2012): 175.

[31] Kadanoff, Leo P. ”Scaling and universality in statistical physics.” Physica A: Statistical Mechanics and its Applications 163, no. 1 (1990): 1-14.

[32] Barenblatt, Grigory Isaakovich. Scaling. Vol. 34. Cambridge University Press, 2003.

[33] Mandelbrott, B. B. ”The fractal geometry of nature.” NY: Freeman (1982).

[34] Qian, Bo, and Khaled Rasheed. ”Hurst exponent and financial market predictability.” In IASTED conference on Financial Engineering and Applications, pp. 203-209. Proceedings of the IASTED International Conference. Chicago Cambridge, MA, 2004.

[35] Hurst, Harold Edwin. ”Long-term storage capacity of reservoirs.” Transactions of the American society of civil engineers 116, no. 1 (1951): 770-799.

[36] Hurst, Harold Edwin. ”Long term storage.” An experimental study (1965).

[37] Brandi, Giuseppe, and Tiziana Di Matteo. ”Multiscaling and rough volatility: An empirical investigation.” International Review of Financial Analysis 84 (2022): 102324.

[38] Frisch, Uriel, and Giorgio Parisi. ”Fully developed turbulence and intermittency.” New York Academy of Sciences, Annals 357 (1980): 359-367.

[39] Mandelbrot, Benoit B. ”Intermittent turbulence in self-similar cascades: divergence of high moments and dimension of the carrier.” Journal of fluid Mechanics 62, no. 2 (1974): 331-358.

[40] Pietronero, L., and A. P. Siebesma. ”Self-similarity of fluctuations in random multiplicative processes.” Physical review letters 57, no. 9 (1986): 1098.

[41] Brandi, Giuseppe, and Tiziana Di Matteo. ”On the statistics of scaling exponents and the multiscaling value at risk.” The European Journal of Finance 28, no. 13-15 (2022): 1361-1382.

[42] Mandelbrot, Benoit B. ”A multifractal walk down Wall Street.” Scientific American 280, no. 2 (1999): 70-73.

[43] Jiang, Zhi-Qiang, Wen-Jie Xie, Wei-Xing Zhou, and Didier Sornette. ”Multifractal analysis of financial markets: A review.” Reports on Progress in Physics 82, no. 12 (2019): 125901.

[44] Bacry, Emmanuel, Jean Delour, and Jean-François Muzy. ”Multifractal random walk.” Physical review E 64, no. 2 (2001): 026103.

[45] Buonocore, Riccardo J., Tomaso Aste, and Tiziana Di Matteo. ”Asymptotic scaling properties and estimation of the generalized Hurst exponents in financial data.” Physical Review E 95, no. 4 (2017): 042311.

[46] Papoulis, Athanasios. Random variables and stochastic processes. McGraw Hill, 1965.

[47] Tsay, Ruey S. Analysis of financial time series. John wiley and sons, 2005.

[48] Engle, Robert F. ”Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation.” Econometrica: Journal of the econometric society (1982): 987-1007.

[49] Nelson, Daniel B. ”Conditional heteroskedasticity in asset returns: A new approach.” Econometrica: Journal of the econometric society (1991): 347-370.

[50] Glosten, Lawrence R., Ravi Jagannathan, and David E. Runkle. ”On the relation between the expected value and the volatility of the nominal excess return on stocks.” The journal of finance 48, no. 5 (1993): 1779-1801.

[51] Baillie, Richard T., Tim Bollerslev, and Hans Ole Mikkelsen. ”Fractionally integrated generalized autoregressive conditional heteroskedasticity.” Journal of econometrics 74, no. 1 (1996): 3-30.

[52] Flunkert, Valentin, David Salinas, and Jan Gasthaus. ”Deepar: Probabilistic forecasting with autoregressive recurrent networks.” arXiv preprint arXiv:1704.04110 23 (2017).

[53] Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. ”Attention is all you need.” Advances in neural information processing systems 30 (2017).

[54] Fama, Eugene F., and Kenneth R. French. ”The capital asset pricing model: Theory and evidence.” Journal of economic perspectives 18, no. 3 (2004): 25-46.

[55] Fama, Eugene F., and Kenneth R. French. ”A five-factor asset pricing model.” Journal of financial economics 116, no. 1 (2015): 1-22.

[56] Bao, Wuzhida, Yuting Cao, Yin Yang, Hangjun Che, Junjian Huang, and Shiping Wen. ”Data-driven stock forecasting models based on neural networks: A review.” Information Fusion 113 (2025): 102616.

[57] Westphal, Rebecca, and Didier Sornette. ”How market intervention can prevent bubbles and crashes.” Swiss Finance Institute Research Paper 20-74 (2020).

[58] Westphal, Rebecca, and Didier Sornette. ”How Market Intervention can Prevent Bubbles and Crashes: An Agent Based Modelling Approach: R. Westphal, D. Sornette.” Computational Economics 64, no. 3 (2024): 1315-1356.

[59] Muzy, Jean-François, Emmanuel Bacry, and Alain Arneodo. ”Wavelets and multifractal formalism for singular signals: Application to turbulence data.” Physical review letters 67, no. 25 (1991): 3515.

[60] Muzy, Jean-François, Emmanuel Bacry, and Alain Arneodo. ”Multifractal formalism for fractal signals: The structure-function approach versus the wavelet-transform modulus-maxima method.” Physical review E 47, no. 2 (1993): 875.

[61] Kolmogorov, Andrey Nikolaevich. ”A refinement of previous hypotheses concerning the local structure of turbulence in a viscous incompressible fluid at high Reynolds number.” Journal of Fluid Mechanics 13, no. 1 (1962): 82-85.

[62] Van Atta, C. W., and W. Y. Chen. ”Structure functions of turbulence in the atmospheric boundary layer over the ocean.” Journal of Fluid Mechanics 44, no. 1 (1970): 145-159.

[63] Kyriazis, Nikolaos A. ”Is Bitcoin similar to gold? An integrated overview of empirical findings.” Journal of Risk and Financial Management 13, no. 5 (2020): 88.

[64] Ciaian, Pavel, Miroslava Rajcaniova, and d’Artis Kancs. ”The economics of BitCoin price formation.” Applied economics 48, no. 19 (2016): 1799-1815.

[65] Bouoiyour, Jamal, and Refk Selmi. ”The Bitcoin price formation: Beyond the fundamental sources.” arXiv preprint arXiv:1707.01284 (2017).

[66] Wu, Di. ”Institutional Adoption and Correlation Dynamics: Bitcoin’s Evolving Role in Financial Markets.” arXiv preprint arXiv:2501.09911 (2025).

[67] Zipf, George Kingsley. The Principle of Least Effort. CH3, 1949.

[68] Newman, Mark EJ. ”Power laws, Pareto distributions and Zipf’s law.” Contemporary physics 46, no. 5 (2005): 323-351.

[69] Clauset, Aaron, Cosma Rohilla Shalizi, and Mark EJ Newman. ”Power-law distributions in empirical data.” SIAM review 51, no. 4 (2009): 661-703.

[70] Klüppelberg, Claudia, and Thomas Mikosch. Modelling extremal events for insurance and finance. Springer, 1997.

[71] McNeil, Alexander J., Rüdiger Frey, and Paul Embrechts. Quantitative risk management: Concepts, techniques and tools. Vol. 2, no. 5. Princeton: Princeton university press, 2015.

[72] Coles, Stuart, Joanna Bawa, Lesley Trenner, and Pat Dorazio. An introduction to statistical modeling of extreme values. Vol. 208. London: Springer, 2001.

[73] Pickands III, James. ”Statistical inference using extreme order statistics.” the Annals of Statistics (1975): 119-131.

[74] Balkema, August A., and Laurens De Haan. ”Residual life time at great age.” The Annals of probability (1974): 792-804.

[75] Fisher, Ronald Aylmer, and Leonard Henry Caleb Tippett. ”Limiting forms of the frequency distribution of the largest or smallest member of a sample.” In Mathematical proceedings of the Cambridge philosophical society, vol. 24, no. 2, pp. 180-190. Cambridge University Press, 1928.

[76] Gnedenko, Boris. ”Sur la distribution limite du terme maximum d’une serie aleatoire.” Annals of mathematics 44, no. 3 (1943): 423-453.

[77] Coles, Stuart, Joanna Bawa, Lesley Trenner, and Pat Dorazio. An introduction to statistical modeling of extreme values. Vol. 208. London: Springer, 2001.

[78] Klüppelberg, Claudia, and Thomas Mikosch. Modelling extremal events for insurance and finance. Springer, 1997.

[79] McNeil, Alexander J., Rüdiger Frey, and Paul Embrechts. Quantitative risk management: Concepts, techniques and tools. Vol. 2, no. 5. Princeton: Princeton university press, 2015.

[80] M Bishop, Christopher. "Pattern recognition and machine learning." (2006).

[81] Murphy, Kevin P. Probabilistic machine learning: an introduction. MIT press, 2022.

[82] Goodfellow, Ian, Yoshua Bengio, Aaron Courville, and Yoshua Bengio. Deep learning. Vol. 1, no. 2. Cambridge: MIT press, 2016.

[83] Rabiner, Lawrence R. "A tutorial on hidden Markov models and selected applications in speech recognition." Proceedings of the IEEE 77, no. 2 (1989): 257-286.

[84] Hamilton, James D. Time series analysis. Vol. 2. Princeton University Press: Princeton, 1994.

[85] Durbin, James, and Siem Jan Koopman. Time series analysis by state space methods. Oxford University Press (UK), 2012.

[86] Murphy, Kevin P. Probabilistic machine learning: Advanced topics. MIT press, 2023.

[87] Kalman, Rudolph Emil. "A new approach to linear filtering and prediction problems." (1960): 35-45.

[88] Hochreiter, Sepp, and Jürgen Schmidhuber. "Long short-term memory." Neural computation 9, no. 8 (1997): 1735-1780.

[89] Cho, Kyunghyun, Bart Van Merriënboer, Çağlar Gulçehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. "Learning phrase representations using RNN encoder–decoder for statistical machine translation." In Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP), pp. 1724-1734. 2014.

[90] Bai, Shaojie, J. Zico Kolter, and Vladlen Koltun. "An empirical evaluation of generic convolutional and recurrent networks for sequence modeling." arXiv preprint arXiv:1803.01271 (2018).

[91] Yu, Fisher, and Vladlen Koltun. "Multi-scale context aggregation by dilated convolutions." arXiv preprint arXiv:1511.07122 (2015).

[92] He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770-778. 2016.

[93] Borovykh, Anastasia, Sander Bohte, and Cornelis W. Oosterlee. ”Conditional time series forecasting with convolutional neural networks.” arXiv preprint arXiv:1703.04691 (2017).

[94] Lim, Bryan, Sercan Ö. Arık, Nicolas Loeff, and Tomas Pfister. ”Temporal fusion transformers for interpretable multi-horizon time series forecasting.” International journal of forecasting 37, no. 4 (2021): 1748-1764.

[95] Harris, Zellig S. ”Distributional structure.” Word 10, no. 2-3 (1954): 146-162.

[96] Sparck Jones, Karen. ”A statistical interpretation of term specificity and its application in retrieval.” Journal of documentation 28, no. 1 (1972): 11-21.

[97] Salton, Gerard, and Christopher Buckley. ”Term-weighting approaches in automatic text retrieval.” Information processing & management 24, no. 5 (1988): 513-523.

[98] Robertson, Stephen E., and Steve Walker. ”Some simple effective approximations to the 2-poisson model for probabilistic weighted retrieval.” In SIGIR’94: Proceedings of the Seventeenth Annual International ACM-SIGIR Conference on Research and Development in Information Retrieval, organised by Dublin City University, pp. 232-241. London: Springer London, 1994.

[99] Mikolov, Tomas, Kai Chen, Greg Corrado, and Jeffrey Dean. ”Efficient estimation of word representations in vector space.” arXiv preprint arXiv:1301.3781 (2013).

[100] Pennington, Jeffrey, Richard Socher, and Christopher D. Manning. ”Glove: Global vectors for word representation.” In Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP), pp. 1532-1543. 2014.

[101] Peters, Matthew, and Mark Neumann. ”Iyyer et al (2018) Deep contextualized word representations.” In Proceedings of the 2018 conference of the North American chapter of the association for computational linguistics: human language technologies, vol. 1, pp. 2227-2237. 2018.

[102] Rogers, Anna, Olga Kovaleva, and Anna Rumshisky. ”A primer in BERTology: What we know about how BERT works.” Transactions of the association for computational linguistics 8 (2020): 842-866.

[103] Alammar, Jay. ”The illustrated transformer.” The illustrated transformer–Jay Alammar–visualizing machine learning one concept at a time 27, no. 1 (2018).

[104] Jurafsky, Dan, and James H. Martin. Speech and language processing. Vol. 3. London: Pearson, 2014.

[105] Radford, Alec, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. ”Improving language understanding by generative pre-training.” (2018).

[106] Li, Shiyang, Xiaoyong Jin, Yao Xuan, Xiyou Zhou, Wenhu Chen, Yu-Xiang Wang, and Xifeng Yan. ”Enhancing the locality and breaking the memory bottleneck of transformer on time series forecasting.” Advances in neural information processing systems 32 (2019).

[107] Nie, Yuqi, Nam H. Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. ”A time series is worth 64 words: Long-term forecasting with transformers.” arXiv preprint arXiv:2211.14730 (2022).

[108] Carvalho, J. Lucas P., and Leonardo Lima. ”Transverse-Field Ising Model as a Framework for Financial Markets.” Available at SSRN 6625481.

[109] dos Santos Lima, Leonardo, and J. L. P. Carvalho. ”Self-organizing quantum frustrated Ising model of financial market.” Available at SSRN 6141453.

[110] Georgescu, Irina, and Jani Kinnunen. ”Comparing Ising and spin glass dynamics in financial markets: A complex systems approach to asset interdependence.” Entropy 28, no. 3 (2026): 344.

[111] Acikgoz, Turker. ”The multifractal nature of cross-correlations between emerging market equities and financial assets: An econophysics perspective: T. acikgoz.” Computational Economics 67, no. 5 (2026): 3607-3634.

[112] da Silva Filho, A. M., A. P. N. de Castro, and E. F. Guedes. ”Multifractal detrended multiple cross-correlation coefficient (qDMC).” Physica A: Statistical Mechanics and Its Applications (2026): 131424.

[113] Wang, Haoyuan, Chen Liu, Minh-Ngoc Tran, and Chao Wang. ”Deep Learning Enhanced Multivariate GARCH.” arXiv preprint arXiv:2506.02796 (2025).

[114] Huang, Allen H., Hui Wang, and Yi Yang. ”FinBERT: A large language model for extracting information from financial text.” Contemporary Accounting Research 40, no. 2 (2023): 806-841.

[115] Quinlan, Paul, Jeremy Levasseur, Qingguo Li, and Xiaodan Zhu. ”Chronicle: A Multimodal Foundation Model for Joint Language and Time Series Understanding.” arXiv preprint arXiv:2605.20268 (2026).

[116] Jacobs, Kurt. Stochastic processes for physicists: understanding noisy systems. Cambridge University Press, 2010.

[117] Cover, Thomas M., Joy A. Thomas, and John Kieffer. Elements of information theory. Vol. 2. New York: wiley, 1991.

[118] Varley, Thomas F. ”Information theory for complex systems scientists: What, why, and how.” Physics Reports 1148 (2025): 1-55.

[119] Osoulian, Hosseini Esfidvajani, Bagheri, and Mobina. ”Analysis of the Total Index Using an Entropy Approach.” *Financial Management Perspective* 8, no. 24 (2019): 159-180.

Abstract:

Financial time series are complex, nonlinear, and non-stationary systems whose dynamics often exhibit scaling, long-range dependence, multifractality, and varying degrees of predictability. This thesis investigates the role of scaling behavior and information-theoretic complexity in the analysis and forecasting of time series, with particular emphasis on financial markets. First, the fundamental characteristics of complex systems and the main stylized facts of financial data are examined using scaling laws, fractal and multifractal methods, and statistical measures. Classical econometric approaches, including ARMA, ARIMA, ARCH, and GARCH, are then reviewed alongside modern sequence-modeling techniques such as TCN, RNN, LSTM, GRU, causal Transformers, residual Transformers, and PatchTST. The empirical investigation uses controlled synthetic stochastic processes with different noise intensities and dependency structures. Shannon entropy and block entropy are employed to quantify the uncertainty and temporal information contained in these processes. The forecasting capabilities of ARIMA, XGBoost, deep neural networks, and Transformer-based architectures are subsequently evaluated through both regression and classification tasks. The findings indicate that increasing noise and entropy progressively reduce the information available for forecasting, resulting in higher prediction errors and directional accuracy approaching chance level. Conversely, structured temporal dependencies provide exploitable information that advanced sequence models, particularly attention-based architectures, can capture effectively. Overall, the results demonstrate that scaling and entropy measures offer a useful framework for identifying changes in time-series complexity and determining the conditions under which reliable prediction remains possible. By creating high-scale relationships, information entropy is reduced, and predictability is increased.

Keywords: Physics, Complex Systems, Financial Time Series, Information Entropy, Sequence Modeling, Monofractal, Multifractal, Attention Mechanism, Deep Learning, Statistical Physics



Shahid Beheshti University

Faculty of Physics

A THESIS SUBMITTED
FOR THE DEGREE OF
MASTER OF SCIENCE

The Role of Scaling Behavior in Time-Series Analysis and Predictability

By

Ali Khabazian Zadehhendouabadi

Supervisor:

Dr. A. Hosseiny

August 2026